

Notas de Clase: Econometría

Regresión Multivariada, Modelos No
Lineales, Sistemas de Ecuaciones,
Datos Panel y otras herramientas del
análisis de datos

Benjamín Oliva ¹

Jésica Tapia ²

Omar Alfaro ³

Draft Diciembre 2026

¹benjov@ciencias.unam.mx y <https://github.com/benjov>

²jesticatapia@gmail.com y <https://github.com/>

³omarxalpha@gmail.com

Documento siempre en proceso de mejora.
Comentarios, siempre serán bienvenidos...

Índice general

1. El concepto de esperanza condicional y su relación con la econometría	3
1.1. Introducción	3
1.2. El concepto de Regresión Lineal	5
1.3. El concepto de regresión entre dos variables	8
1.4. Modelo de regresión lineal	11
1.4.1. Supuestos del modelo de regresión lineal	11
1.4.2. Estimación de los parámetros del modelo lineal bivariado	15
1.5. Estimación de parámetros por mínimos cuadrados	18
1.6. Modelos no lineales	22
1.6.1. Regresión exponencial	22
1.6.2. Regresión logarítmica	23
1.6.3. Funciones logísticas	24
1.7. Esperanza condicional y algunas de sus propiedades	26
1.8. Efectos Marginales	30
1.8.1. Ejercicios	31
1.9. Introducción a Gráficos Acíclicos Dirigidos o <i>Directed Acyclic</i> <i>Graphs</i>	32
1.9.1. Cerrar rutas traseras y el problema del colisionador . .	35
1.10. Ejercicios	36
2. Estimación de modelos lineales de una sola ecuación por el método de Mínimos Cuadrados Ordinarios	41
2.1. El estimador de Mínimos Cuadrados Ordinarios (MCO) y el análisis clásico de regresión	41
2.2. Interpretación geométrica de MCO: la proyección ortogonal . .	47
2.3. Bondad de ajuste	51
2.4. Modelos lineales y algunas de sus propiedades	54

2.5.	Propiedades asintóticas de los estimadores de MCO	56
2.6.	Inferencia asintótica bajo MCO	59
2.7.	Una aplicación clásica: la función de costos de la industria eléctrica	66
2.8.	Ejercicios	67
3.	Estimación de modelos lineales de una sola ecuación por el método de Variables Instrumentales	73
3.1.	Introducción y motivación	73
3.2.	Estimación por Mínimos Cuadrados en Dos Etapas – 2SLS . .	75
3.3.	Método de Variables Instrumentales en casos con múltiples instrumentos	76
3.4.	Propiedades asintóticas del estimador de 2SLS	78
3.4.1.	Condiciones de identificación	78
3.4.2.	Consistencia	79
3.4.3.	Normalidad asintótica y varianza	80
3.5.	El problema de los instrumentos débiles	81
3.6.	Pruebas de especificación	83
3.6.1.	Prueba de endogeneidad de Hausman	83
3.6.2.	Prueba de sobreidentificación	85
3.7.	Interpretación causal: efectos heterogéneos y el LATE	86
3.8.	Aplicación: los orígenes coloniales del desarrollo comparado . .	87
3.9.	Ejercicios	89
4.	Estimación de sistemas de ecuaciones por el método de Mínimos Cuadrados Ordinarios y Mínimos Cuadrados Generalizados	97
4.1.	Introducción a Sistemas de Ecuaciones	97
4.2.	Estimación de Sistemas de Ecuaciones Multivariantes	99
4.3.	Mínimos Cuadrados Generalizados	102
4.4.	Sistemas de Ecuaciones Aparentemente No Relacionadas (SUR)	106
4.4.1.	Motivación	107
4.4.2.	Planteamiento del modelo	107
4.4.3.	El estimador SUR	108
4.4.4.	Estimación factible: SUR en dos etapas	109
4.4.5.	¿Cuándo vale la pena estimar por SUR?	110
4.4.6.	Prueba de diagonalidad de Σ	112
4.4.7.	Aplicación: las funciones de inversión de Grunfeld . . .	113

4.5.	Estimación de Sistemas de Ecuaciones con Variables Instrumentales	113
4.5.1.	Estimación de un sistema por Mínimos Cuadrados en Dos Etapas (2SLS)	117
4.5.2.	Estimación de un sistema por Mínimos Cuadrados en Tres Etapas (3SLS)	118
4.6.	Ejercicios	119
5.	Modelos de Datos Panel	123
5.1.	Introducción y motivación	123
5.2.	Modelos y métodos de estimación	124
5.2.1.	Efectos Fijos	126
5.2.2.	Efectos Aleatorios	130
5.2.3.	Regresión Pool	133
5.3.	Pruebas para seleccionar modelo	134
5.3.1.	La prueba de Hausman: efectos fijos frente a efectos aleatorios	134
5.3.2.	Prueba de Breusch-Pagan: efectos aleatorios frente a regresión pool	137
5.3.3.	Prueba F: efectos fijos frente a regresión pool	138
5.3.4.	Sobre el nombre “prueba de Hausman”	138
5.4.	Consideraciones adicionales	139
5.4.1.	Inferencia en datos panel	139
5.4.2.	Una limitación importante: los paneles dinámicos	139
5.5.	Conclusión	140
5.6.	Ejercicios	141
6.	Métodos de estimación basados en verosimilitud	145
6.1.	Introducción	145
6.2.	Marco general de estimación por máxima verosimilitud	147
6.2.1.	El vector de puntajes y la ecuación de verosimilitud	148
6.2.2.	Dos resultados fundamentales	149
6.2.3.	Condiciones de regularidad	151
6.2.4.	Propiedades asintóticas	152
6.2.5.	Estimación de la matriz de varianzas	153
6.2.6.	Cuasi máxima verosimilitud	154
6.3.	Pruebas de hipótesis	154
6.3.1.	Prueba de Wald	155

6.3.2.	Prueba de razón de verosimilitudes	155
6.3.3.	Prueba del multiplicador de Lagrange	156
6.3.4.	Comparación de las tres pruebas	156
6.4.	Un ejemplo completo: el modelo lineal con errores normales . .	158
6.5.	Ejercicios	159
7.	Estimación de modelos no lineales	163
7.1.	Modelos de respuesta binaria	163
7.1.1.	Planteamiento general	163
7.1.2.	Algunos planteamientos adicionales	164
7.1.3.	Modelos Logit y Probit	166
7.1.4.	Estimación	167
7.2.	Modelos de respuesta multinomial y ordenada	168
7.2.1.	Modelos de respuesta multinomial	169
7.2.2.	Modelos de respuesta ordenada: Logit y Probit Ordinal	171
7.2.3.	Una aplicación: clasificación con datos de videojuegos .	175
7.3.	Modelos de conteo y otras respuestas	175
7.3.1.	Modelos de conteo del tipo Poisson	176
7.3.2.	Robustez del modelo Poisson y la sobredispersión . . .	178
7.3.3.	Interpretación de los coeficientes	179
7.4.	Ejercicios	179
8.	Modelos con datos truncados, censurados, con endogeneidad por selección de muestra y otros casos	185
8.1.	Truncamiento	186
8.1.1.	La razón inversa de Mills	189
8.1.2.	El modelo de regresión truncada	190
8.1.3.	Efectos marginales	192
8.2.	Selección de muestra: el truncamiento incidental	192
8.2.1.	El modelo de Heckman	194
8.2.2.	Estimación en dos etapas	195
8.3.	Datos con censura	197
8.3.1.	Las tres esperanzas del modelo Tobit	199
8.3.2.	Efectos marginales	200
8.3.3.	Por qué MCO es inconsistente	200
8.3.4.	Estimación por máxima verosimilitud	201
8.3.5.	Una limitación importante: el modelo de dos partes . .	203
8.4.	Aplicación y consideraciones prácticas	203

8.4.1.	Implementación en Python	203
8.4.2.	Aplicación: la oferta laboral de mujeres casadas	204
8.5.	Ejercicios	204
9.	Introducción a inferencia causal	209
9.1.	El marco de resultados potenciales	209
9.1.1.	Motivación	209
9.1.2.	Resultados potenciales y el problema fundamental	210
9.1.3.	Los parámetros de interés	211
9.1.4.	Por qué la comparación simple de medias falla	211
9.1.5.	Supuestos de identificación	213
9.1.6.	Estrategias de identificación y el resto del capítulo	214
9.2.	Estimación de modelos para determinar efectos de tratamiento	215
9.2.1.	Motivación del procedimiento Difference - in - Differences (DiD)	215
9.2.2.	Estrategia de estimación	217
9.2.3.	El supuesto de tendencias paralelas	219
9.2.4.	Diferencia en diferencias con múltiples periodos y unidades	223
9.2.5.	Estudios de eventos y tendencias previas	224
9.2.6.	Adopción escalonada y los problemas del estimador TWFE	226
9.2.7.	Inferencia	227
9.2.8.	Pruebas de robustez y diseños relacionados	228
9.3.	Control Sintético	229
9.3.1.	Motivación	229
9.3.2.	Planteamiento del método de estimación	232
9.3.3.	¿Por qué usar el control sintético?	234
9.3.4.	Inferencia mediante pruebas de placebo	235
9.3.5.	Cuándo no debe usarse el control sintético	237
9.4.	Ejercicios	238
10.	Estimación de modelos de duración	245
10.1.	Introducción y motivación	245
10.2.	Conceptos fundamentales: las cuatro representaciones de una duración	247
10.2.1.	Relaciones entre las cuatro funciones	248
10.2.2.	Dependencia de la duración	249

10.3. Distribuciones paramétricas para la duración	251
10.3.1. Distribución exponencial	251
10.3.2. Distribución Weibull	251
10.3.3. Distribución log-logística	252
10.3.4. Otras especificaciones	253
10.4. El problema de la censura y el esquema de muestreo	254
10.4.1. Tipos de censura	254
10.4.2. Muestreo de flujo y muestreo de acervo	254
10.5. Estimación por máxima verosimilitud con datos censurados . .	255
10.5.1. Construcción de la verosimilitud	255
10.5.2. Aplicación al modelo Weibull con covariables	257
10.6. Modelos de riesgos proporcionales	258
10.6.1. Planteamiento	258
10.6.2. Interpretación de los coeficientes	258
10.6.3. El modelo de Cox y la verosimilitud parcial	259
10.6.4. Modelos de tiempo de falla acelerado	261
10.7. Estimación no paramétrica: el estimador de Kaplan-Meier . .	261
10.8. Heterogeneidad no observada	263
10.9. Datos agrupados y modelos en tiempo discreto	265
10.10 Riesgos en competencia	266
10.11 Consideraciones prácticas y aplicación	267
10.11.1. Estrategia de trabajo empírico	267
10.11.2. Implementación en Python	268
10.11.3. Aplicación sugerida: duración hasta la reincidencia de- lictiva	268
10.12 Ejercicios	269
11. Introducción al Aprendizaje Estadístico	273
11.1. Motivación, introducción y Notación en el análisis de regresión	273
11.2. Formas funcionales no lineales: recapitulación	275
11.2.1. Funciones polinomiales	276
11.3. Aprendizaje Estadístico	277
11.3.1. Ajuste y separación del conjunto de datos	280
11.3.2. La disyuntiva entre sesgo y varianza	280
11.3.3. Método de regresiones restringidas (Shrinkage methods).	283
11.4. Aplicación de modelos clasificación mediante clustering.	288
11.4.1. Análisis de Componentes Principales	288
11.4.2. Análisis Factorial	290

11.4.3. Clúster	291
11.4.4. Agrupamiento de datos de series temporales	297
11.5. Aplicación de modelos de regresión de respuesta binaria	304
11.5.1. Modelos de respuesta binaria y ordenada: resumen operativo	304
11.5.2. Regresión logística con información de videojuegos. . .	309
11.6. Modelos de árboles de decisión y bosques aleatorios.	316
11.6.1. Métodos basados en árboles	316
11.6.2. Métodos de conjunto: bagging, bosques aleatorios y boosting	320
11.7. Modelos de redes neuronales.	321
11.7.1. Introducción y Motivación	321
11.7.2. Algunos conceptos relevantes	322
11.7.3. Preprocesamiento de datos	328
11.7.4. Entrenamiento del modelo	328
11.8. Ejercicios	330

Bibliografía	335
---------------------	------------

A. Teoría de convergencia asintótica	341
A.1. Convergencia de sucesiones	341
A.2. Convergencia en probabilidad y acotamientos en probabilidad	342
A.3. Convergencia en distribución	343
A.4. Teoremas límite para muestras aleatorias	344
A.5. Teorema de Slutsky y método delta	345
A.6. Relación entre los modos de convergencia	347
A.7. Estimadores y estadísticas de prueba	347
A.8. Ejercicios	348

Índice de figuras

1.1. Relación entre Latitud y Velocidad del Viento	6
1.2. Relación entre Latitud y Temperatura	6
1.3. Relación entre Latitud y Nubocidad	7
1.4. Relación entre Latitud y Humedad	7
1.5. Supuestos del modelo lineal (Retomado de Larsen (2012, p. 545) [LM12]), donde se muestra una notación con las siguientes equivalencias $f_{Y x}(y) = f(Y x)$ y $y = \mu_{Y x} = \mathbb{E}[Y x]$	12
1.6. Ilustración del error de estimación, retomado de Greene (2012, pp. 40) [Gre12]	19
1.7. Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) [LM12]	23
1.8. Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) [LM12]	24
1.9. Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) [LM12]	25
1.10. Ejemplo 1 de un DAG	33
1.11. Ejemplo 2 de un DAG, confusor	33
1.12. Ejemplo 3 de un DAG, ganancias de la educación	34
1.13. Ejemplo 5 de un DAG, colisionador: condicionar en C induce asociación entre A y B	36
1.14. Ejemplo 4 de un DAG, IV estimator	36
2.1. Ajuste por mínimos cuadrados con dos variables explicativas: el plano ajustado y las distancias verticales que se minimizan, retomado de Hastie, Tibshirani y Friedman (2017, p. 45) [HTF17]	43
2.2. Proyección ortogonal de $\mathbf{Y}$ sobre el espacio generado por las columnas de $\mathbf{X}$, retomado de Hastie, Tibshirani y Friedman (2017, p. 46) [HTF17]	49

2.3.	Descomposición del vector $\mathbf{Y}$ en el valor ajustado $\hat{\mathbf{Y}}$ y el vector de residuales $\mathbf{e}$, retomado de Greene (2012, p. 31) [Gre12] . . .	49
3.1.	Distribución muestral del estimador de 2SLS según la fuerza del instrumento	83
3.2.	Instrumentación de la información de la demanda y la oferta, respectivamente	92
5.1.	Regresión pool frente a efectos fijos cuando el efecto individual está correlacionado con el regresor	129
6.1.	Interpretación geométrica de las pruebas de Wald, razón de verosimilitudes y multiplicador de Lagrange	157
7.1.	Modelo de probabilidad lineal frente a los modelos logit y probit	165
8.1.	¿Talento y la belleza están negativamente correlacionados? . .	187
8.2.	Relación entre belleza y talento, retomado de [Cun21]. . . .	188
8.3.	Efecto del truncamiento y de la censura sobre la distribución de la variable dependiente	190
8.4.	Inconsistencia de MCO ante datos censurados, con datos simulados	201
9.1.	Comparación de los casos de cólera según proveedor de agua en Londres.	217
9.2.	Representación gráfica del estimador de diferencia en diferencias	220
9.3.	Qué estima MCO cuando el supuesto de tendencias paralelas no se cumple	222
9.4.	Gráfico de estudio de eventos: coeficientes de adelantos y rezagos con sus intervalos de confianza	225
9.5.	Control sintético: trayectorias e inferencia mediante placebos en el espacio	236
10.1.	Formas de la función de riesgo bajo las especificaciones Weibull y log-logística	253
10.2.	Estimador de Kaplan-Meier de la función de supervivencia con observaciones censuradas	263
10.3.	Dependencia negativa espuria de la duración generada por heterogeneidad no observada	264

11.1. ¿Qué relación hay entre años de educación y el salario?, retomado de: https://wol.iza.org/articles/using-linear-regression-to-establish-employment/es	274
11.2. Funciones polinomiales, retomado de https://discdown.org/flexregression/smoothreg.html	278
11.3. Disyuntiva entre sesgo y varianza, obtenida por simulación . . .	282
11.4. División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]	282
11.5. Por qué el Lasso produce coeficientes exactamente iguales a cero y la regresión Ridge no	287
11.6. US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) [Cha20]	293
11.7. K-Means algorithm, retomado de Ng (2023, p 146) [Ng23] . . .	295
11.8. Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) [Cha20]	296
11.9. División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]	308
11.10 Probabilidades en un modelo de respuesta ordenada, considerando $J = 4$ (retomado de Greene (2012, 788) [Gre12])	311
11.11 En la tabla de datos ubicamos 417 tags distintas	316
11.12 Ejemplo de regiones. Retomado de Hastie et al (2017, 305) . . .	317
11.13 Ejemplo de árbol. Retomado de Hastie et al (2017, 304) . . .	318
11.14 Ejemplo de redes neuronales. Retomado de Shmueli et al (2019, 285) [Shm+19]	323
11.15 Ejemplo de la función de activación Sigmoide. Retomado de Jurafsky, et al (2024, Cap. 7, p.2) [JM23]	324
11.16 Ejemplo de la función de activación $\tanh$. Retomado de Jurafsky, et al (2024, Cap. 7, p.4) [JM23]	325
11.17 Funciones de activación y sus derivadas	325
11.18 Ilustración de una unidad neuronal. Retomado de Jurafsky, et al (2024, Cap. 7, p.3) [JM23]	327
11.19 Ilustración de una red neuronal con 1 capa oculta. Retomado de Jurafsky, et al (2024, Cap. 7, p.11) [JM23]	327

Índice de cuadros

2.1. Resultados de la regresión de salarios	69
9.1. Tabla XII de Snow (1854)–Casos de cólera en Londres por cada 10,000 habitantes según proveedor de agua, retomado de Cunningham(2021, p. 472) [Cun21]	217
11.1. Formas funcionales y su interpretación	276
11.2. Dos lecturas del mismo modelo	305
11.3. Matriz de Confusión	308

Introducción, motivación y alcance del documento

El propósito de este documento es familiarizar al lector con un amplio rango de temas de econometría moderna, apoyándonos en trabajos empíricos a lo largo de cada una de las secciones de estas notas. Este trabajo se origina en la necesidad de construir un texto accesible para alumnos de nivel de licenciatura.

Queremos discutir los documentos de la bibliografía como: Adams (2020) [Ada20], Cameron y Trivedi (2005) [CT05]; Cunningham (2021) [Cun21]; Greene (2012) [Gre12], Hastie, Tibshirani y Friedman (2017) [HTF17], James, Witten, Hastie y Tibshirani (2013) [Jam+13], Larsen (2012) [LM12], Ng (2023) [Ng23], Verbeek (2017) [Ver17], y Wooldridge (2010) [Woo10]. Asimismo, discutir diversos papers relacionados.

El texto base del curso es Wooldridge (2010) [Woo10], y a lo largo de las notas remitimos a los capítulos correspondientes de esa obra, así como a Greene (2012) [Gre12] y a Hayashi (2000) [Hay00] para los desarrollos matemáticos más detallados. Para la parte de inferencia causal seguimos principalmente a Cunningham (2021) [Cun21], Huntington-Klein (2022) [Hun22] y Angrist y Pischke (2009) [AP09].

Conocimientos previos

Obligatoriamente Estadística II, Introducción a la Econometría o sus equivalentes. Se asume además familiaridad con álgebra lineal (operaciones matriciales, rango, inversas y formas cuadráticas), con cálculo diferencial en varias variables y con los conceptos básicos de probabilidad: variables aleatorias, distribuciones conjuntas y condicionales, esperanza y varianza, y los teoremas de convergencia que se recuerdan en el apéndice sobre teoría de

convergencia asintótica al final de este documento.

Recursos en línea y otros materiales

El material de apoyo del curso está distribuido en los siguientes recursos:

- **Repositorio de código.** Los cuadernos de Python con todas las aplicaciones empíricas que se mencionan a lo largo de estas notas, junto con los conjuntos de datos correspondientes, se encuentran en <https://github.com/benjov/Econometria-I-2026>. Cada capítulo de estas notas remite explícitamente al cuaderno que le corresponde.
- **Videos de las sesiones.** Las clases se graban y se publican en https://www.youtube.com/playlist?list=PLlCKfRj1U6SxFNrR7vLe_xMefqbdM1XTB.
- **Material complementario.** La bibliografía, los artículos discutidos, el temario y las notas se encuentran en la carpeta compartida del curso.
- **Herramientas.** Para el trabajo aplicado utilizamos Python mediante cuadernos de Jupyter. Se recomienda instalar Visual Studio Code o bien trabajar en Google Colab, que no requiere instalación local. Quien no tenga experiencia previa con el lenguaje puede consultar el material introductorio de <https://learnpython.org/> y las lecciones preliminares incluidas en el repositorio del curso.

1

El concepto de esperanza condicional y su relación con la econometría

1.1. Introducción

El objetivo del análisis empírico en las ciencias sociales es determinar cuál es el efecto o cambio que una variable causa en otra. Por ejemplo, cuando pensamos en qué factores o variables determinan el nivel salarial promedio de las personas es posible que relacionemos el efecto que tienen los años de estudio y en particular el efecto que tiene un año adicional de estudio. Otro ejemplo puede presentarse cuando tratamos de entender el efecto que tienen las horas de estudio en las calificaciones finales de un grupo de estudiantes.

Dentro del análisis empírico se suele hacer uso de dos términos o conceptos:

1. *Ceteris paribus*
2. *Causalidad*

El primero se emplea en el análisis empírico para establecer que el efecto de una variable se sostiene siempre que asumamos que el resto de variables que pueden afectar a dicha variable que queremos explicar permanecen constantes. El segundo sirve para entender que en el análisis empírico la existencia de correlaciones no significa la presencia de causalidad. La causalidad, en la primera parte del curso, será la condición observada entre dos variables y

deriva de la construcción teórica, modelación o racionalización que hagamos de los fenómenos que queremos analizar. Más adelante modificaremos esta condición.

Tanto *ceteris paribus* como causalidad son conceptos contenidos en lo que en estadística se conoce como **esperanza condicional**. Supongamos dos variables, y y x , que tienen una distribución conjunta y para las cuales queremos estimar el efecto que tiene la segunda en la primera. Así, es posible que utilicemos una expresión de la esperanza condicional de y en x , misma que solemos representar como:

$$\mathbb{E}[y|x, \mathbf{C}] \tag{1.1}$$

Donde $\mathbf{C}$ representa un conjunto o vector de variables de control, en el sentido de que también explican la variabilidad de y por lo que no podemos omitirlas en un proceso de estimación de la esperanza condicional.

Dicho lo anterior, el análisis empírico que proponemos en este curso está basado en identificar correlaciones que pueden ser interpretadas como causalidad y que consiste en estimar a la ecuación (1.1) y determinar el efecto marginal o efecto parcial que tiene x en y , condicional en que todas las demás variables permanecen constantes, es decir, *ceteris paribus*.

En la ecuación (1.1) hemos asumido que $\mathbf{C}$ contiene la información disponible que sirve de control, por lo que es un vector que contiene sólo información que es observable. Sin embargo, no siempre es posible observar toda la información que sirve de control. Por ejemplo, al responder qué factores determinan el salario de las personas podríamos pensar en múltiples factores cuantificables y observables como: edad, sexo, años de educación, etc. No obstante, también consideraríamos factores como las habilidades propias de cada individuo, las cuales no son necesariamente observables.

Adicionalmente, en el proceso de estimación de la ecuación (1.1) asumiremos que las muestras de datos que utilizaremos son muestras aleatorias de la población. En concreto asumiremos que la información es una muestra aleatoria independiente e idénticamente distribuida (iid) que proviene de una población dada.

Para finalizar esta sección introductoria plantearemos los tres casos que ejemplifican los tipos de datos que son comúnmente analizados en el análisis de regresión o econometría. El primero es un análisis de datos de sección cruzada en el que las ecuaciones representativas de la ecuación (1.1) son

como la siguiente:

$$\ln(\text{Salario}_i) = \beta_0 + \beta_1 \text{Educacion}_i + \beta_2 \text{Experiencia}_i$$

Donde las variables de Salario_i , Educacion_i y Experiencia_i son observadas para cada uno de los individuos en la muestra es indexado por $i = 1, 2, 3, \dots, N$.

El segundo ejemplo es respecto de datos de series de tiempo como la siguiente expresión:

$$\ln(\text{PIB}_t) = \beta_0 + \beta_1 \text{Empleo}_t + \beta_2 \text{Salarios}_t$$

Donde las variables PIB_t , Empleo_t y Salarios_t son observadas para un individuo o entidad a lo largo de una muestra del tiempo indexada por $t = 1, 2, 3, \dots, T$.

El tercer ejemplo resulta de la combinación de los dos anteriores. De esta forma podríamos observar a una muestra de un conjunto de individuos a lo largo del tiempo y analizar el comportamiento de una variable a través de una ecuación como la siguiente:

$$\ln(\text{Salario}_{it}) = \beta_0 + \beta_1 \text{Educacion}_{it} + \beta_2 \text{Experiencia}_{it}$$

Donde las variables Salario_{it} , Educacion_{it} y Experiencia_{it} se observan para los mismos individuos a lo largo del tiempo que se indexan con los pares (i, t) , $i = 1, 2, 3, \dots, N$ y $t = 1, 2, 3, \dots, T$.

1.2. El concepto de Regresión Lineal

En esta sección analizaremos el concepto de regresión lineal. El cual está basado en la observación cotidiana de cómo es la relación entre dos o más variables, una dependiente, y , y otras independientes (o dadas), x , dado que hemos obtenido una muestra aleatoria, y es la base del análisis de esperanza condicional planteado anteriormente. Por ejemplo, ¿qué determina el cáncer pulmonar en las personas? Algunas respuestas son: fumar, dieta, contaminación, condiciones genéticas, etc.

De forma similar, otros ejemplos son, si la latitud explica algunas condiciones climáticas. Las figuras 1.1, 1.2, 1.3, 1.4 muestran la relación geométrica entre la latitud y diversas variables del clima para una muestra de 500 ciudades en la fecha que se señala.




Figura 1.1: Relación entre Latitud y Velocidad del Viento




Figura 1.2: Relación entre Latitud y Temperatura




Figura 1.3: Relación entre Latitud y Nubocidad




Figura 1.4: Relación entre Latitud y Humedad

1.3. El concepto de regresión entre dos variables

Definición 1.1 Sea $f(Y|x)$ la función de densidad de probabilidad de una variable aleatoria Y dado un valor de $X = x$, y sea $\mathbb{E}[Y|x]$ el valor esperado asociado con la función $f(Y|x)$. La función:

$$\mu_{Y|x} = \mathbb{E}[Y|x]$$

se denomina como la curva de regresión de Y en $X = x$. De forma similar podemos definir la curva de regresión de X en $Y = y$.

Ejemplo. Supongamos una función dada por:

$$f(Y|x) = \begin{cases} \frac{x+y}{x+\frac{1}{2}} & \text{para } 0 \leq y \leq 1, 0 \leq x \leq 1 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la función de regresión de Y en $X = x$. Para ello primero determinemos si $f(Y|x)$ es una función de densidad de probabilidad condicional:

$$\begin{aligned} \int_D f(Y|x) dy &= \int_0^1 \frac{x+y}{x+\frac{1}{2}} dy = \int_0^1 \frac{x}{x+\frac{1}{2}} dy + \int_0^1 \frac{y}{x+\frac{1}{2}} dy \\ &= \frac{xy}{x+\frac{1}{2}} \Big|_0^1 + \frac{y^2/2}{x+\frac{1}{2}} \Big|_0^1 = \frac{x}{x+\frac{1}{2}} + \frac{\frac{1}{2}}{x+\frac{1}{2}} \\ &= \frac{x+\frac{1}{2}}{x+\frac{1}{2}} = 1 \end{aligned}$$

Por lo tanto, observamos que $f(Y|x)$ es una función de densidad de probabilidad. Ahora determinemos $\mu_{Y|x}$:

$$\begin{aligned} \mu_{Y|x} &= \mathbb{E}[Y|x] = \int_0^1 y \frac{x+y}{x+\frac{1}{2}} dy = \int_0^1 \frac{xy + y^2}{x+\frac{1}{2}} dy = \frac{\frac{xy^2}{2} + \frac{y^3}{3}}{x+\frac{1}{2}} \Big|_0^1 \\ &= \frac{\frac{x}{2} + \frac{1}{3}}{x+\frac{1}{2}} = \frac{\frac{3x}{2} + 1}{3x + \frac{3}{2}} = \frac{3x+2}{6x+3} \end{aligned}$$

Podemos plantear una definición más amplia:

Definición 1.2 Sea $f(x, y)$ una función de densidad conjunta de las variables aleatorias X y Y , la función de regresión consiste en determinar la densidad condicional de Y dado $X = x$, la cual resulta de evaluar la integral:

$$\mu_{Y|x} = \mathbb{E}[Y|x] = \int_D y \cdot f(Y|x) dy$$

El resultado de la integral es denominado como ecuación de regresión de Y en X . De forma similar, la regresión de X en Y estará dada por:

$$\mu_{X|y} = \mathbb{E}[X|y] = \int_D x \cdot f(X|y) dx$$

Donde las funciones de densidad condicional resultan de:

$$\begin{aligned} f(Y|x) &= \frac{f(x, y)}{g(x)} \\ f(X|y) &= \frac{f(x, y)}{g(y)} \end{aligned}$$

Y las funciones marginales son resultado de:

$$\begin{aligned} g(x) &= \int_{D_y} f(x, y) dy \\ g(y) &= \int_{D_x} f(x, y) dx \end{aligned}$$

Ejemplo. Dadas dos variables aleatorias X y Y con función de densidad conjunta dada por:

$$f(x, y) = \begin{cases} x \cdot e^{-x(1+y)} & \text{para } x > 0, y > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la ecuación de regresión de Y en X . Para ello requerimos de:

$$\begin{aligned} g(x) &= \int_{D_y} f(x, y) dy = \int_{D_y} x \cdot e^{-x(1+y)} dy = -e^{-x(1+y)} \Big|_0^\infty \\ &= \begin{cases} e^{-x} & \text{para } x > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

De esta forma podemos determinar la función de densidad condicional como:

$$f(Y|x) = \frac{f(x, y)}{g(x)} = \frac{x \cdot e^{-x(1+y)}}{e^{-x}} = \begin{cases} x \cdot e^{-xy} & \text{para } y > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Podemos observar que es una función de densidad ya que:

$$\int_{D_y} f(Y|x) dy = \int_0^\infty x \cdot e^{-xy} dy = -e^{-xy} \Big|_0^\infty = 1$$

Finalmente, la ecuación de regresión de Y en X estará dada por:

$$\begin{aligned} \mu_{Y|x} &= \mathbb{E}[Y|x] = \int_{D_y} y \cdot f(Y|x) dy = \int_0^\infty y \cdot x \cdot e^{-xy} dy \\ &= -y \cdot e^{-xy} \Big|_0^\infty + \int_0^\infty e^{-xy} dy = -y \cdot e^{-xy} \Big|_0^\infty - \frac{1}{x} e^{-xy} \Big|_0^\infty \\ &= \begin{cases} \frac{1}{x} & \text{para } x > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

Ejemplo. Supongamos una función de densidad conjunta de X_1, X_2, X_3 variables aleatorias dada por:

$$f(x_1, x_2, x_3) = \begin{cases} (x_1 + x_2)e^{-x_3} & \text{para } 1 > x_1 > 0, 1 > x_2 > 0, x_3 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases}$$

Determinemos la ecuación de regresión de X_2 en X_1 y X_3 . Para ello requerimos de la función de densidad marginal dada por:

$$\begin{aligned} g(x_1, x_3) &= \int_{D_{x_2}} f(x_1, x_2, x_3) dx_2 = \int_0^1 (x_1 + x_2)e^{-x_3} dx_2 \\ &= \left(x_1 x_2 + \frac{x_2^2}{2} \right) e^{-x_3} \Big|_0^1 \\ &= \begin{cases} \left(x_1 + \frac{1}{2} \right) e^{-x_3} & \text{para } 1 > x_1 > 0, x_3 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

Determinemos entonces la función de densidad condicional, la cual estará dada por:

$$\begin{aligned} f(X_2|x_1, X_3) &= \frac{f(x_1, x_2, x_3)}{g(x_1, x_3)} = \frac{(x_1 + x_2)e^{-x_3}}{(x_1 + \frac{1}{2})e^{-x_3}} \\ &= \begin{cases} \frac{x_1+x_2}{x_1+\frac{1}{2}} & \text{para } 1 > x_1 > 0, 1 > x_2 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

Entonces, la ecuación de regresión estará dada por:

$$\begin{aligned} \mu_{X_2|x_1, x_3} &= \int_{D_{x_2}} x_2 \cdot f(X_2|x_1, X_3) dx_2 = \int_0^1 x_2 \frac{x_1 + x_2}{x_1 + \frac{1}{2}} dx_2 = \left. \frac{\frac{x_1 x_2^2}{2} + \frac{x_2^3}{3}}{x_1 + \frac{1}{2}} \right|_0^1 \\ &= \frac{\frac{x_1}{2} + \frac{1}{3}}{x_1 + \frac{1}{2}} = \begin{cases} \frac{x_1 + \frac{2}{3}}{2x_1 + 1} & \text{para } 1 > x_1 > 0 \\ 0 & \text{en cualquier otro caso} \end{cases} \end{aligned}$$

1.4. Modelo de regresión lineal

1.4.1. Supuestos del modelo de regresión lineal

Un caso especial es el de la regresión lineal. Lo que hasta ahora hemos visto es el caso general en el que $\mu_{Y|x} = \mathbb{E}[Y|x]$, el cual modificaremos bajo los siguientes supuestos – **Supuestos del Modelo Lineal**:

1. **Normalidad.** $f(Y|x)$ es una función de densidad de probabilidad normal $\forall x$
2. **Homocedasticidad.** La desviación estándar, σ , asociada con $f(Y|x)$ es la misma $\forall x$
3. **Linealidad.** Las medias de todas las distribuciones condicionales son una combinación lineal dada por:

$$\mu_{Y|x} = \mathbb{E}[Y|x] = \beta_0 + \beta_1 x$$

Donde β_0 y β_1 son parámetros por determinar, como veremos más adelante




Figura 1.5: Supuestos del modelo lineal (Retomado de Larsen (2012, p 545)[LM12]), donde se muestra una notación con las siguientes equivalencias $f_{Y|x}(y) = f(Y|x)$ y $y = \mu_{Y|x} = \mathbb{E}[Y|x]$

4. Todas las distribuciones condicionales representan variables aleatorias independientes como se ilustra en la Figura 1.5.

Ahora enunciaremos un teorema relevante para el caso del modelo lineal.

Teorema 1.1 Sean Y y X dos variables aleatorias que cumplen con los supuestos del modelo lineal. Si la regresión de Y en X es lineal, entonces:

$$\mu_{Y|x} = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)$$

Si la regresión de X en Y es lineal, entonces:

$$\mu_{X|y} = \mu_X + \rho \frac{\sigma_X}{\sigma_Y} (y - \mu_Y)$$

Para demostrar el teorema anterior partamos de recordar que la media condicional estará dada por:

$$\mu_{Y|x} = \int_{D_y} y \cdot f(Y|x) dy = \beta_0 + \beta_1 x \quad (1.2)$$

Multiplicando cada uno de los lados de la última parte de la ecuación (1.2) por $g(x)$, la función de densidad de probabilidad marginal, e integrando ambos lados tenemos lo siguiente:

$$\begin{aligned}
\int_{D_x} \int_{D_y} y \cdot f(Y|x)g(x)dydx &= \beta_0 \int_{D_x} g(x)dx + \beta_1 \int_{D_x} x \cdot g(x)dx \\
\iff \int_{D_x} \int_{D_y} y \cdot f(x,y)dydx &= \beta_0 + \beta_1 \mu_X \\
\iff \int_{D_y} \int_{D_x} y \cdot f(x,y)dxdy &= \beta_0 + \beta_1 \mu_X \\
&\iff \int_{D_y} y \cdot g(y)dy = \beta_0 + \beta_1 \mu_X \\
&\iff \mu_Y = \beta_0 + \beta_1 \mu_X
\end{aligned} \tag{1.3}$$

Retomando la ecuación (1.2) y multiplicando por un factor dado por $x \cdot g(x)$ e integrando, tenemos:

$$\begin{aligned}
\int_{D_x} \int_{D_y} y \cdot f(Y|x) \cdot x \cdot g(x)dydx &= \beta_0 \int_{D_x} x \cdot g(x)dx + \beta_1 \int_{D_x} x^2 \cdot g(x)dx \\
\iff \int_{D_x} \int_{D_y} x \cdot y \cdot f(x,y)dydx &= \beta_0 \mu_X + \beta_1 \mathbb{E}[X^2] \\
&\iff \mathbb{E}[X \cdot Y] = \beta_0 \mu_X + \beta_1 \mathbb{E}[X^2]
\end{aligned} \tag{1.4}$$

Aquí recordamos un par de resultados que conocemos:

$$Cov(X, Y) = \mathbb{E}[X \cdot Y] - \mathbb{E}[X]\mathbb{E}[Y] = \sigma_{XY} = \mathbb{E}[X \cdot Y] - \mu_X \mu_Y$$

$$\mathbb{E}[X \cdot Y] = \sigma_{XY} + \mu_X \mu_Y$$

$$Var(X) = \mathbb{E}[X^2] - \mu_X^2 = \sigma_X^2$$

$$\mathbb{E}[X^2] = \sigma_X^2 + \mu_X^2$$

Retomando las ecuaciones (1.3) y (1.4) y los resultados mostrados tenemos que resolver el siguiente sistema de ecuaciones:

$$\begin{aligned}
\mu_Y &= \beta_0 + \beta_1 \mu_X \\
\sigma_{XY} + \mu_X \mu_Y &= \beta_0 \mu_X + \beta_1 (\sigma_X^2 + \mu_X^2)
\end{aligned}$$

De la primera despejamos:

$$\beta_0 = \mu_Y - \beta_1 \mu_X$$

Sustituimos en la segunda para encontrar:

$$\begin{aligned}\sigma_{XY} + \mu_X \mu_Y &= (\mu_Y - \beta_1 \mu_X) \mu_X + \beta_1 (\sigma_X^2 + \mu_X^2) \\ &= \mu_X \mu_Y - \beta_1 \mu_X^2 + \beta_1 \sigma_X^2 + \beta_1 \mu_X^2 \\ \sigma_{XY} &= \beta_1 \sigma_X^2\end{aligned}$$

De donde:

$$\beta_1 = \frac{\sigma_{XY}}{\sigma_X^2} = \frac{\sigma_X \sigma_Y}{\sigma_X \sigma_Y} \frac{\sigma_{XY}}{\sigma_X^2} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y} \frac{\sigma_X \sigma_Y}{\sigma_X^2} = \rho \frac{\sigma_Y}{\sigma_X}$$

Y:

$$\beta_0 = \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X$$

Sustituyendo en la ecuación de regresión:

$$\begin{aligned}\mu_{Y|x} &= \beta_0 + \beta_1 x \\ &= \mu_Y - \rho \frac{\sigma_Y}{\sigma_X} \mu_X + \rho \frac{\sigma_Y}{\sigma_X} x \\ &= \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (x - \mu_X)\end{aligned}$$

Con lo cual hemos demostrado la primera parte del teorema. La segunda parte se demuestra de forma similar.

Antes de pasar a la estimación conviene enunciar por separado los supuestos que utilizaremos y el resultado que de ellos se obtiene, porque se confunden con frecuencia: los supuestos se llaman *condiciones de Gauss-Markov* y el resultado es el *Teorema de Gauss-Markov*.

Los **supuestos estándar de Gauss-Markov** son los siguientes:

$$\mathbb{E}[\varepsilon_i] = 0 \quad (1.5)$$

$$\{\varepsilon_1, \varepsilon_2, \dots, \varepsilon_N\} \text{ y } \{x_1, x_2, \dots, x_N\} \text{ son independientes} \quad (1.6)$$

$$Var(\varepsilon_i) = \sigma^2, \forall i = 1, 2, \dots, N \quad (1.7)$$

$$Cov(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j \quad (1.8)$$

Donde la ecuación (1.6) es el supuesto de exogeneidad, la ecuación (1.7) es el de homocedasticidad y la ecuación (1.8) el de ausencia de autocorrelación. Con ellos podemos enunciar el resultado.

Teorema 1.2 Teorema de Gauss-Markov. *Bajo los supuestos (1.5) a (1.8), el estimador de mínimos cuadrados ordinarios es el **mejor estimador lineal insesgado** (MELI, o BLUE por sus siglas en inglés): entre todos los estimadores que son funciones lineales de $\mathbf{Y}$ y que son insesgados, el de MCO es el de mínima varianza.*

Es importante subrayar tres cosas sobre este teorema, que demostraremos formalmente en el capítulo siguiente. La primera es que **no requiere el supuesto de normalidad**: los supuestos (1.5) a (1.8) no dicen nada sobre la forma de la distribución de los errores. La normalidad se necesita para la inferencia en muestras pequeñas, no para la optimalidad de MCO. La segunda es que la optimalidad está restringida a la clase de estimadores *lineales e insesgados*; como veremos en el capítulo de aprendizaje estadístico, existen estimadores sesgados con menor error cuadrático medio. Y la tercera es que el teorema garantiza mínima varianza, no que la varianza sea pequeña: si los regresores tienen poca variación o están muy correlacionados entre sí, MCO seguirá siendo MELI y sin embargo será impreciso.

1.4.2. Estimación de los parámetros del modelo lineal bivariado

Antes de plantear el proceso de estimación respondamos ¿cuáles son los parámetros $\boldsymbol{\theta}' = (\theta_1, \theta_2, \dots, \theta_K)'$ del modelo lineal dado por $\mathbb{E}[Y|x] = \beta_0 + \beta_1 x$? Así, $\boldsymbol{\theta}' = (\beta_0, \beta_1, \sigma^2)'$. Dado que asumimos que Y tienen una distribución de probabilidad, en este caso normal, podemos determinar los parámetros por medio del uso de un procedimiento de máxima verosimilitud.

Sean $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ un conjunto de datos que satisfacen los supuestos del modelo lineal, entonces podemos establecer la siguiente transformación Z y la función de verosimilitud:

$$Z_i = \frac{y_i - \mathbb{E}[Y|x_i]}{\sigma}$$

$$\begin{aligned}
L &= \prod_{i=1}^N f(Y_i|x_i) = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}Z_i^2} = \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \mathbb{E}[Y|x_i]}{\sigma}\right)^2} \\
&= \prod_{i=1}^N \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2} = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N e^{-\frac{1}{2}\sum_{i=1}^N \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2} \\
&= \frac{1}{(2\pi\sigma^2)^{N/2}} e^{-\frac{1}{2}\sum_{i=1}^N \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2} \tag{1.9}
\end{aligned}$$

Tomando el logaritmo de la ecuación (1.9) tenemos:

$$\ln(L) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2} \sum_{i=1}^N \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2 \tag{1.10}$$

$$-2 \ln(L) = N \cdot \ln(2\pi) + N \cdot \ln(\sigma^2) + \sum_{i=1}^N \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2 \tag{1.11}$$

Ambas ecuaciones (1.10) y (1.11) son equivalentes. La ecuación (1.11) expresa el mismo problema como una minimización en lugar de una maximización, y es la forma en que suele reportarse la llamada *desviación*; conviene no confundirla con la distribución log-normal, que es un objeto distinto. Como veremos en el capítulo de métodos de estimación basados en verosimilitud, son las *diferencias* de $-2 \ln(L)$ entre modelos anidados las que tienen una distribución Chi cuadrada asintótica. De la ecuación (1.10) obtendremos el siguiente vector gradiente:

$$\frac{\partial \ln(L)}{\partial \boldsymbol{\theta}} = \begin{bmatrix} \frac{\partial \ln(L)}{\partial \beta_0} \\ \frac{\partial \ln(L)}{\partial \beta_1} \\ \frac{\partial \ln(L)}{\partial \sigma^2} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) \\ \frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) x_i \\ -\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2 \end{bmatrix}$$

Así, podemos obtener las siguientes expresiones para los parámetros:

$$\begin{aligned}
\frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) &= 0 \\
\sum_{i=1}^N y_i - \sum_{i=1}^N \beta_0 - \sum_{i=1}^N \beta_1 x_i &= 0 \\
\sum_{i=1}^N y_i - N\beta_0 - \sum_{i=1}^N \beta_1 x_i &= 0 \\
\beta_0 &= \frac{\sum_{i=1}^N y_i - \beta_1 \sum_{i=1}^N x_i}{N} \quad (1.12)
\end{aligned}$$

Para la segunda ecuación del gradiente y utilizando 1.12 tenemos:

$$\begin{aligned}
\frac{1}{\sigma^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) x_i &= 0 \\
\sum_{i=1}^N y_i x_i - \sum_{i=1}^N \beta_0 x_i - \sum_{i=1}^N \beta_1 x_i^2 &= 0 \\
\sum_{i=1}^N y_i x_i - \beta_0 \sum_{i=1}^N x_i - \beta_1 \sum_{i=1}^N x_i^2 &= 0 \\
\sum_{i=1}^N y_i x_i - \left(\frac{\sum_{i=1}^N y_i - \beta_1 \sum_{i=1}^N x_i}{N} \right) \sum_{i=1}^N x_i - \beta_1 \sum_{i=1}^N x_i^2 &= 0 \\
N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N y_i \sum_{i=1}^N x_i + \beta_1 \sum_{i=1}^N x_i \sum_{i=1}^N x_i - \beta_1 N \sum_{i=1}^N x_i^2 &= 0 \\
- \sum_{i=1}^N y_i \sum_{i=1}^N x_i + N \sum_{i=1}^N y_i x_i + \beta_1 \left(\left(\sum_{i=1}^N x_i \right)^2 - N \sum_{i=1}^N x_i^2 \right) &= 0 \quad (1.13)
\end{aligned}$$

Utilizando las ecuaciones (1.12) y (1.13) llegamos a las siguientes soluciones para los estimadores de los parámetros:

$$\hat{\beta}_1 = \frac{N \sum_{i=1}^N y_i x_i - \sum_{i=1}^N y_i \sum_{i=1}^N x_i}{N \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} \quad (1.14)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \quad (1.15)$$

Finalmente:

$$-\frac{N}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2 = 0$$

De donde obtenemos que:

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{N} \quad (1.16)$$

Estos estimadores de las ecuaciones (1.15), (1.14) y (1.16) requieren de verificar sus propiedades de sesgo, consistencia y eficiencia. No obstante, lo dejaremos para más adelante en el caso de regresión múltiple.

1.5. Estimación de parámetros por mínimos cuadrados

Hasta el momento hemos discutido el problema de regresión, lineal o no lineal, partiendo de que conocemos la función de densidad de probabilidad de las variables aleatorias involucradas. En la realidad no siempre es factible conocerlas, y por lo tanto tampoco es factible conocer la función de densidad conjunta de dichas variables.

Pero nuestro problema sigue siendo el mismo, queremos determinar los parámetros β_0 y β_1 que pueden ayudarnos a ajustar una curva de regresión. En esta sección discutiremos el método de mínimos cuadrados ordinarios, cuya primera publicación se debe a Adrien-Marie Legendre en 1805, aunque Gauss reclamó posteriormente la prioridad del descubrimiento.

Una motivación del método es geométrica. La cual considera la relación entre dos o más variables aleatorias, digamos que observamos puntos en el plano cartesiano: $\{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ y supongamos una constante m que determina el grado del polinomio:

$$\hat{y}_i = p(x_i) = \hat{\beta}_0 + \sum_{j=1}^m \hat{\beta}_j x_i^j$$




Figura 1.6: Ilustración del error de estimación, retomado de Greene (2012, pp. 40) [Gre12]

Para cualquier grado del polinomio podemos definir a los residuales para cualquier punto $i = 1, 2, \dots, N$ en el plano como:

$$\begin{aligned} e_i &= y_i - \hat{y}_i \\ &= y_i - \hat{\beta}_0 - \sum_{j=1}^m \hat{\beta}_j x_i^j \end{aligned}$$

Sin pérdida de generalidad, puesto que el siguiente planteamiento es válido para cualquier grado de polinomio, diremos que:

$$e_i = y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i$$

En la Figura 1.6 ilustramos el concepto de error.

El método de mínimos cuadrados ordinarios consiste en resolver un problema de minimización de una función que depende de los residuales que

hemos definido. En esa función introducimos los residuales **al cuadrado**, de modo que el problema se convierte en minimizar la suma de las distancias verticales entre cada valor observado y_i y el valor ajustado $\hat{y}_i$ que predice la recta, de forma conjunta para todos los elementos de la muestra, $i = 1, 2, \dots, N$.

Conviene precisar dos cosas. La primera es que la distancia que se minimiza es **vertical**, es decir, medida en la dirección de y ; no es la distancia perpendicular a la recta ni una distancia entre las coordenadas x_i y y_i , que no serían comparables por estar en unidades distintas. La segunda es por qué se elevan al cuadrado en lugar de tomar valores absolutos: los cuadrados evitan que los errores positivos y negativos se cancelen entre sí — igual que lo haría el valor absoluto — pero además producen una función diferenciable en todo punto, lo que permite obtener una solución analítica. Minimizar la suma de valores absolutos es un problema perfectamente legítimo, conocido como regresión en desviaciones absolutas mínimas, pero no admite solución cerrada y da lugar a un estimador de la mediana condicional en lugar de la media.

Así, partimos del siguiente planteamiento en el cual desconocemos los parámetros β_0 y β_1 :

$$\begin{aligned} S(\beta_0, \beta_1) &= \sum_{i=1}^N e_i^2 \\ &= \sum_{i=1}^N (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i)^2 \end{aligned}$$

Para minimizar la función anterior requerimos de las condiciones de primer orden dadas como:

$$\begin{aligned} \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_0} &= -2 \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) \\ \frac{\partial S(\beta_0, \beta_1)}{\partial \beta_1} &= -2 \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_i) x_i \end{aligned}$$

A estas expresiones se les suele conocer como ecuaciones normales. Si igualamos a cero y resolvemos para encontrar los valores que minimizan las

distancias tendremos que:

$$\begin{aligned} -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) &= 0 \\ -2 \sum_{i=1}^N (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i &= 0 \end{aligned}$$

De donde podemos encontrar que:

$$\begin{aligned} \sum_{i=1}^N y_i &= N\hat{\beta}_0 + \hat{\beta}_1 \sum_{i=1}^N x_i \\ \sum_{i=1}^N y_i x_i &= \hat{\beta}_0 \sum_{i=1}^N x_i + \hat{\beta}_1 \sum_{i=1}^N x_i^2 \end{aligned}$$

Continuando:

$$\begin{aligned} \hat{\beta}_0 &= \frac{\sum_{i=1}^N y_i - \hat{\beta}_1 \sum_{i=1}^N x_i}{N} \\ &= \frac{\sum_{i=1}^N y_i}{N} - \frac{\hat{\beta}_1 \sum_{i=1}^N x_i}{N} \\ &= \bar{Y} - \hat{\beta}_1 \bar{X} \end{aligned}$$

$$\begin{aligned} \sum_{i=1}^N y_i x_i &= \left(\frac{\sum_{i=1}^N y_i - \hat{\beta}_1 \sum_{i=1}^N x_i}{N} \right) \sum_{i=1}^N x_i + \hat{\beta}_1 \sum_{i=1}^N x_i^2 \\ N \cdot \sum_{i=1}^N y_i x_i &= \sum_{i=1}^N y_i \sum_{i=1}^N x_i - \hat{\beta}_1 \left(\sum_{i=1}^N x_i \right)^2 + \hat{\beta}_1 N \cdot \sum_{i=1}^N x_i^2 \\ \hat{\beta}_1 &= \frac{N \cdot \sum_{i=1}^N y_i x_i - \sum_{i=1}^N y_i \sum_{i=1}^N x_i}{N \cdot \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} \end{aligned}$$

Por lo tanto, las soluciones serían:

$$\begin{aligned} \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X} \\ \hat{\beta}_1 &= \frac{N \cdot \sum_{i=1}^N y_i x_i - \sum_{i=1}^N y_i \sum_{i=1}^N x_i}{N \cdot \sum_{i=1}^N x_i^2 - \left(\sum_{i=1}^N x_i \right)^2} \end{aligned}$$

Estas soluciones son las mismas que obtuvimos por el procedimiento de Máxima Verosimilitud.

1.6. Modelos no lineales

¿Qué pasa cuando la relación observada entre las variables no es lineal? Casi siempre pasa eso. A continuación discutiremos tres casos de ecuaciones que nos ayudaran a describir una relación no lineal mediante una transformación que hace la relaciones lineales. Cada uno responde a condiciones o características que la experiencia del investigador tiene que solventar.

Cada una de las ecuaciones se distingue por la tasa de cambio de la variable y en relación a los cambios de la variable x . Partamos de que la forma más simple de una relación lineal está dada por la ecuación (1.17). Note que hemos eliminado los subíndices para indicar que la ecuación se cumple para cada uno de los elementos en la muestra, $i = 1, 2, \dots, N$. Sin pérdida de generalidad digamos que en lugar de β_0 y β_1 empleamos a y b como constantes, y asumimos $\mu_{Y|x} = y$, como una forma de ilustrar cada uno de los fenómenos que discutimos a continuación.

$$y = a + bx \tag{1.17}$$

Esta ecuación (1.17) tiene la característica de que tiene una tasa de variación constante para y en relación a x , de esta forma:

$$\frac{dy}{dx} = b \iff dy = bdx \iff \int dy = \int bdx \iff y = a + bx$$

Los siguientes modelos no lineales tienen una motivación similar, dependen de la forma en que se asuma la variación de y en función de la variación de x .

1.6.1. Regresión exponencial

Supongamos que y depende de x y que los cambios en y derivados de x son proporcionales a y , es decir:

$$\frac{dy}{dx} = by$$




Figura 1.7: Funciones exponenciales, Retomado de Larsen y Marx (2012, p. 532) [LM12]

Donde b es una constante. De esta forma podemos encontrar que:

$$\frac{dy}{dx} = by \iff \frac{dy}{y} = bdx \iff \int \frac{dy}{y} = \int bdx \iff \ln(y) = a + bx$$

De esta forma, tenemos que:

$$y = e^{bx} e^a \iff y = ke^{bx}$$

Por lo tanto, cuando estimamos una relación: $\ln(y) = a + bx$ estamos asumiendo que existe la siguiente relación: $\frac{dy}{dx} = by$. A este tipo de ecuaciones se les conoce como log-lineales. En la Figura 1.7 se ilustra la relación log-lineal - exponencial.

1.6.2. Regresión logarítmica

En este caso suponemos que los cambios en y por causa de cambios en x son proporcionales a la razón que guardan y y x , es decir:

$$\frac{dy}{dx} = b \frac{y}{x}$$

Por lo que podemos establecer:

$$\frac{dy}{dx} = b \frac{y}{x} \iff \frac{dy}{y} = b \frac{dx}{x} \iff \int \frac{dy}{y} = \int b \frac{dx}{x} \iff \ln(y) = a + \ln(x)$$




Figura 1.8: Funciones logarítmicas, Retomado de Larsen y Marx (2012, p. 536) [LM12]

Así, podemos establecer que la forma funcional de la relación de y y x es como sigue y como se muestra en la Figura 1.8.

$$y = kx^b$$

1.6.3. Funciones logísticas

Este tipo de ecuaciones tienen la característica de que permiten modelar crecimientos poblacionales, aceptación de políticas públicas, aceptación de tecnologías, epidemias, etc. En este caso suponemos que enfrentamos que los cambios en y dados los cambios en x son proporcionales a y y a la distancia que y tiene respecto de un factor de saturación L (límite superior o punto de saturación poblacional, cobertura universal, infecciones en el total de la población, etc.).

En este caso suponemos que la variación estará dada por:

$$\frac{dy}{dx} = ky(L - y)$$

Donde k y L son constantes. Una vez solucionada la ecuación diferencial anterior, encontraremos que, si $L = 1$, entonces la solución será como sigue, la Figura 1.9 ilustra ecuaciones como la siguiente:

$$y = \frac{1}{1 + e^{a+bx}} \quad (1.18)$$




Figura 1.9: Funciones logísticas, Retomado de Larsen y Marx (2012, p. 540) [LM12]

Ahora mostremos como llegar a la solución de la ecuación logística:

$$\frac{dy}{dx} = ky(L - y) \iff \frac{dy}{y(L - y)} = kdx \iff \left(\frac{\frac{1}{L}}{y} + \frac{\frac{1}{L}}{(L - y)} \right) dy = kdx$$

$$\iff \frac{1}{L} \left(\frac{dy}{y} + \frac{dy}{(L - y)} \right) = kdx \iff \int \frac{1}{L} \left(\frac{dy}{y} + \frac{dy}{(L - y)} \right) = \int kdx$$

$$\iff \left(\int \frac{dy}{y} + \int \frac{dy}{(L - y)} \right) = \int Lkdx \iff (\ln(y) - \ln(L - y)) = Lkx + C$$

$$\iff (\ln(L - y) - \ln(y)) = -LC - Lkx \iff \ln \left(\frac{L - y}{y} \right) = -LC - Lkx$$

$$\iff \left(\frac{L - y}{y} \right) = e^{-LC - Lkx} \iff y = \frac{L}{1 + e^{-LC - Lkx}}$$

Por lo tanto, la solución general de la ecuación será:

$$y = \frac{L}{1 + e^{a+bx}}$$

Donde asumimos que la forma lineal de la ecuación logística es:

$$\ln \left(\frac{L - y}{y} \right) = a + bx$$

1.7. Esperanza condicional y algunas de sus propiedades

En primer lugar estableceremos un poco de notación. En análisis de regresión siempre partimos de una representación de una ecuación lineal como:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i \quad (1.19)$$

Donde cada una de las variables y_i , x_{ik} y ε_i , se observan para $i = 1, 2, 3, \dots, N$ y $k = 1, 2, \dots, K$, por lo que podremos utilizar una representación para cada i de la forma:

$$\begin{aligned} y_i &= \begin{pmatrix} x_{i1} & x_{i2} & \dots & x_{iK} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{pmatrix} + \varepsilon_i \\ &= \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \end{aligned} \quad (1.20)$$

Conviene fijar aquí la **convención de notación** que usaremos en todo el documento, porque su consistencia facilita la lectura de los capítulos posteriores:

- $\mathbf{x}_i$ denota, en **minúscula**, el vector **renglón** de dimensión $1 \times K$ que contiene las variables explicativas del individuo i , tal como aparece en la ecuación (1.20). Así, el producto $\mathbf{x}_i \boldsymbol{\beta}$ es un escalar y no requiere transposición.
- $\mathbf{X}$ denota, en **mayúscula**, la matriz de dimensión $N \times K$ que resulta de apilar los N renglones $\mathbf{x}_i$.
- $\boldsymbol{\beta}$ es siempre un vector **columna** de dimensión $K \times 1$.
- El tamaño de la muestra se denota con N y el número de variables explicativas con K .

La única excepción aparece en el capítulo de sistemas de ecuaciones y en el de datos panel, donde $\mathbf{X}_i$ pasa a ser una *matriz* — porque cada individuo aporta varias ecuaciones u observaciones — y en consecuencia sí escribiremos su transpuesta $\mathbf{X}_i'$. Lo advertiremos explícitamente en su momento.

En forma general la ecuación (1.20) se puede generalizar para el total de elementos en la muestra como:

$$\mathbf{Y} = \mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (1.21)$$

Donde:

$$\mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_N \end{pmatrix}$$

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \dots & x_{1K} \\ x_{21} & x_{22} & \dots & x_{2K} \\ x_{31} & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \dots & \vdots \\ x_{N1} & x_{N2} & \dots & x_{NK} \end{bmatrix}$$

$$\boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{pmatrix}$$

$$\boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \varepsilon_3 \\ \vdots \\ \varepsilon_N \end{pmatrix}$$

En la mayoría de los casos analizados vamos a asumir que la ecuación (1.19) tiene un término constante, por lo que $x_{i1} = 1$ para todo $i = 1, 2, \dots, N$. Bajo este escenario, representaremos la matriz $\mathbf{X}$ con una columna compuesta del número 1 (uno) en todas sus entradas, tal que, el parámetro β_1 es un término constante en las ecuaciones (1.20) y (1.21). De esta forma la matriz anteriormente mostrada se puede ver como:

$$\mathbf{X} = \begin{bmatrix} 1 & x_{12} & \dots & x_{1K} \\ 1 & x_{22} & \dots & x_{2K} \\ 1 & x_{32} & \dots & x_{3K} \\ \vdots & \vdots & \dots & \vdots \\ 1 & x_{N2} & \dots & x_{NK} \end{bmatrix}$$

De forma similar al caso de una regresión lineal que incluye un término constante, podemos construir matrices $\mathbf{X}$ para casos en que alguna de las variables explicativas es dicotómica –que toma valores de 0 y 1– y casos en los que las variables explicativas han sido interactuadas –multiplicada entre sí– o transformadas mediante potencias o logaritmos.

Retomando las ecuaciones (1.19) y (1.21) y para facilitar la exposición no utilizaremos el índice i , plantearemos la siguiente definición de esperanza condicional.

Definición 1.3 *Sea y una variable aleatoria, a la cual nos referiremos como la variable explicada o variable dependiente. Asimismo, sea $(x_1, x_2, \dots, x_K)$ un vector aleatorio de K variables explicativas. Finalmente, asumamos que $\mathbb{E}[|y|] < \infty$. Entonces, existe una función $\mu : \mathbb{R}^K \rightarrow \mathbb{R}$ tal que:*

$$\mathbb{E}[y|x_1, x_2, \dots, x_K] = \mu(x_1, x_2, \dots, x_K)$$

La función $\mu(x_1, x_2, \dots, x_k)$ determinará o describirá como el valor promedio de y cambia cuando observamos un cambio de alguno de los valores del conjunto $(x_1, x_2, \dots, x_k)$. Por ejemplo, cuando analizamos el efecto de la educación, la experiencia o el coeficiente IQ en el salario podríamos establecer:

$$\mathbb{E}[\text{Salario} | \text{Educacion}, \text{Experiencia}, \text{IQ}]$$

Esta expresión describe el salario promedio dadas las variables aleatorias mencionadas. Ahora bien, tomemos una definición del concepto de ecuación de regresión y veamos como se relaciona con el concepto de esperanza condicional.

Definición 1.4 *Sea $f(x_1, x_2, \dots, x_K, y)$ una función de densidad de probabilidad conjunta de $K + 1$ variables aleatorias, la regresión multivariada consiste en determinar la función de densidad condicional de y dado $X_1 = x_1, X_2 = x_2, \dots, X_K = x_K$ y entonces evaluar la integral (o la suma en el caso discreto) dada por:*

$$\begin{aligned} \mu_{y|x_1, x_2, \dots, x_K} &= \mathbb{E}[y|x_1, x_2, \dots, x_K] \\ &= \int_{-\infty}^{\infty} y \cdot w(y|x_1, x_2, \dots, x_k) dy \end{aligned}$$

Donde:

$$\begin{aligned} w(y|x_1, x_2, \dots, x_k) &= \frac{f(x_1, x_2, \dots, x_k, y)}{g(x_1, x_2, \dots, x_k)} \\ g(x_1, x_2, \dots, x_k) &= \int_D f(x_1, x_2, \dots, x_k, y) dy \end{aligned}$$

Visto de esta manera es claro que la Definición 1.3 es equivalente a la Definición 1.4. En nuestro caso particular para propósito de este curso asumiremos la siguiente equivalencia de la esperanza condicional:

$$\mu_{y|x_1, x_2, \dots, x_K} = \mu(x_1, x_2, \dots, x_K) = \mathbb{E}[y|x_1, x_2, \dots, x_K]$$

Note que la expresión anterior implica, como mostraremos más adelante, que $\mathbb{E}[\varepsilon|x_1, x_2, \dots, x_K] = \mathbb{E}[\varepsilon] = 0$. Veamos algunos ejemplos de las formas funcionales de la esperanza condicional $\mu(x_1, x_2, \dots, x_K)$:

1. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K$
2. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K + x_K^2\beta_{K+1}$, es decir, un caso con un término cuadrático
3. $\mathbb{E}[y|x_1, x_2, \dots, x_K] = e^{\beta_1 + \ln(x_2)\beta_2 + \dots + \ln(x_K)\beta_K}$, con $y > 0$ y $x_k > 0$, para todo $k = 2, 3, \dots, K$

Nótese que en el segundo y el tercer caso la esperanza condicional **no** es lineal en las variables explicativas, pero sí sigue siendo lineal en los parámetros — en el tercer caso, tras aplicar logaritmos —. Esta distinción es fundamental: lo que el modelo lineal exige es linealidad en los *parámetros*, no en las variables, y es la razón por la que puede acomodar términos cuadráticos, interacciones y transformaciones logarítmicas sin salir del marco de MCO.

1.8. Efectos Marginales

Una vez definida la esperanza condicional podemos, a su vez, definir el concepto de Efecto Parcial o Efecto Marginal de y —variable dependiente— cuando existe algún cambio de sólo una de las variables explicativas en el vector $(x_1, x_2, \dots, x_K)$, manteniendo el resto de las variables constantes.

Definición 1.5 *Definimos el Efecto Marginal de una variable x_k como la derivada parcial dada por:*

$$\begin{aligned} EMg_k &= \frac{\partial \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\partial x_k} \\ &\approx \frac{\Delta \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\Delta x_k} \end{aligned}$$

Cuando la variable x_k es discreta o, más concretamente, dicotómica, por ejemplo, tomando valores de 0 o 1, el Efecto Marginal estará definido como sigue:

Definición 1.6 *Definimos el Efecto Marginal de una variable dicotómica $x_1 = \{0, 1\}$ — caso extendible a cualquiera de las variables explicativas — como la diferencia dada por:*

$$EM_{g_1} = \mathbb{E}[y|x_1 = 1, x_2, \dots, x_K] - \mathbb{E}[y|x_1 = 0, x_2, \dots, x_K]$$

Las Definiciones 1.5 y 1.6 pueden particularizarse y extenderse en casos como el siguiente. Asumamos que el valor esperado tiene la forma funcional siguiente:

$$\mathbb{E}[y|x_1, x_2, \dots, x_K] = e^{\beta_1 + \beta_2 \ln(x_2) + \dots + \beta_K \ln(x_K)}$$

En este caso podríamos hacer la siguiente transformación:

$$\ln(\mathbb{E}[y|x_1, x_2, \dots, x_K]) = \beta_1 + \beta_2 \ln(x_2) + \dots + \beta_K \ln(x_K)$$

De esta manera podríamos aproximar el Efecto Marginal de $\ln(x_2)$ como:

$$\begin{aligned} \frac{\partial \ln(\mathbb{E}[y|x_1, x_2, \dots, x_K])}{\partial \ln(x_2)} &= \beta_2 \\ &= \frac{\frac{\partial \mathbb{E}[y|x_1, x_2, \dots, x_K]}{\mathbb{E}[y|x_1, x_2, \dots, x_K]}}{\frac{\partial x_2}{x_2}} \end{aligned} \quad (1.22)$$

Así resulta evidente que la ecuación (1.22) se puede interpretar como una elasticidad.

1.8.1. Ejercicios

Para finalizar establezcamos una serie de ejercicios para continuar con la discusión del Efecto Marginal.

1. Sean y , x_1 y x_2 variables aleatorias y una forma funcional de la esperanza condicional de la forma:

$$\mathbb{E}[y|x_1, x_2] = \beta_1 + \beta_2 x_1 + \beta_3 x_2^2 + \beta_4 x_1 x_2$$

Al respecto, determine el Efecto Marginal de x_1 y x_2 .

- Sean y , x_1 y $D = \{0, 1\}$ variables aleatorias y una forma funcional de la esperanza condicional de la forma:

$$\mathbb{E}[y|x_1, D] = e^{\beta_1 + \beta_2 x_1 + \gamma D}$$

Al respecto, determine el Efecto Marginal de x_1 y $D = \{0, 1\}$.

1.9. Introducción a Gráficos Acíclicos Dirigidos o *Directed Acyclic Graphs*

La notación de los Gráficos Acíclicos Dirigidos (DAG) representa que la causalidad va en una dirección, así para mostrar causalidad en reversa es necesario crear múltiples nodos. La simultaneidad, tal como en el caso de las curvas de oferta y demanda, no tiene una representación directa o inmediata con los DAG.

Otra forma de plantear a los DAG es que se trata de una explicación de un fenómeno en términos de contrafactuales. El tratamiento más completo y accesible de esta herramienta se encuentra en Pearl, Glymour y Jewell (2016) [PGJ16], y una excelente exposición orientada al diseño de investigación empírica en Huntington-Klein (2022) [Hun22].

Definición 1.7 *Un DAG es una representación gráfica de una cadena de efectos causales. Los efectos causales están en sí mismos basados en algún proceso subyacente no observable.*

Los efectos causales pueden observarse en dos vías:

1. Directa: $D \longrightarrow Y$
2. Indirecta, a través de una tercera variable: $D \longrightarrow X \longrightarrow Y$

En este sentido, la ausencia de una flecha $\longrightarrow$ entre dos variables indica que **no existe un efecto causal directo** entre ellas. Es importante no leer esto como que las variables sean independientes: como veremos enseguida, dos variables sin flecha entre sí pueden estar perfectamente correlacionadas si existe una tercera variable que las conecte. Distinguir la ausencia de efecto causal directo de la ausencia de asociación estadística es precisamente lo que los DAG permiten hacer con claridad.

Un ejemplo sencillo de DAG es el siguiente:




Figura 1.10: Ejemplo 1 de un DAG




Figura 1.11: Ejemplo 2 de un DAG, confusor

El DAG mostrado en la Figura (1.10) ilustra que hay una ruta directa de D a Y , lo cual representa un efecto causal. Por su parte la ruta a D tiene una ruta trasera (backdoor path) a través de la ruta $D \leftarrow X \rightarrow Y$. En este caso consideremos que la ruta directa es un efecto causal, pero la backdoor path es no causal. En su caso este proceso crea una correlación espuria entre D y Y .

Pensemos el proceso de ruta trasera como una situación en la que a veces cuando D toma diferentes valores, Y toma diferentes valores debido a que X toma diferentes valores. De esta forma, decimos que existe una correlación espuria entre D y Y .

Un segundo ejemplo de DAG nos permite ilustrar el concepto de confusor, que describe a una variable que no es observable, U , y que representamos su relación en el DAG con líneas punteadas de la forma que se muestra en la Figura (1.11).

De forma similar al caso anterior, existen dos formas para ir de D a Y . Existe la ruta directa de D a Y , lo cual representa un efecto causal. Por su parte la ruta a D tiene una ruta trasera a través de la ruta $D \leftarrow U \rightarrow Y$, pero con la diferencia de que la variable U es no observable.

Veamos otro ejemplo. Una pregunta clásica en economía laboral es si la educación, en general, tiene el potencial de incrementar los ingresos laborales de las personas. La teoría económica indica que la educación incrementa el producto marginal del trabajo, de esta forma los trabajadores serán me-




Figura 1.12: Ejemplo 3 de un DAG, ganancias de la educación

jor pagados, ya que sus salarios son establecidos en función de su producto marginal en mercados competitivos. Así, la teoría afirma que la educación incrementa los ingresos.

Particularicemos el ejemplo a un caso en el cual analizamos el efecto que tiene la educación secundaria en los ingresos. Partamos del hecho de que educarse a un nivel secundario no es un fenómeno aleatorio, puesto que existen múltiples factores que lo pueden explicar. Partamos del siguiente DAG en el cual D será la variable de tratamiento o la variable que indica si una persona tiene formación de educación secundaria; Y es nuestra variable de interés o los ingresos; PE es la variable que indica el nivel educativo de los padres; I es una variable de ingreso familiar, y B son el *background* no observable de la persona (factores como la genética, habilidades individuales, ambiente familiar, etc.).

El DAG de la Figura 1.12 es en sí mismo una historia. Cada persona tiene un cierto *background* que normalmente no se reporta en los conjuntos de datos. Medidas como el grado de inteligencia, la personalidad, la estabilidad emocional, capacidad de resiliencia, dinámica familiar y cualquier otro relacionado con factores ambientales o del entorno no se encuentran en los datos comúnmente. Por lo que se les denomina factores no observables.

Estos factores ambientales (B) están correlacionados o expresados en variables de padres e hijos. Este *background* causa que los padres elijan un nivel educativo o ruta de educación para los hijos y también afecta las decisiones individuales de los niños respecto de la ruta educativa que quieren seguir.

En este caso, también es posible notar que los DAG cuentan 2 historias. Nos dicen lo que está pasando, pero también nos dicen lo que no está pasando. Así, B no tiene un efecto directo en los ingresos laborales, excepto a través de su efecto en la elección educativa. Sin embargo, en muchas ocasiones se suele criticar este tipo de planteamientos por parecer más un supuesto que un hecho real. En estos casos, la decisión es del investigador.

1.9.1. Cerrar rutas traseras y el problema del colisionador

De la discusión anterior se desprende la estrategia general: para identificar el efecto causal de D sobre Y necesitamos **cerrar todas las rutas traseras**. Una ruta trasera se cierra condicionando en — es decir, controlando por — alguna de las variables que la componen. En el DAG de la Figura 1.10, controlar por X cierra la ruta $D \leftarrow X \rightarrow Y$ y deja identificado el efecto directo. Esta es la justificación formal de la práctica de incluir variables de control en una regresión, y también la razón por la que el DAG de la Figura 1.11 plantea un problema: no podemos condicionar en U porque no la observamos.

Existe, sin embargo, un caso en el que controlar por una variable **empeora** las cosas en lugar de mejorarlas, y es uno de los aportes más valiosos de esta forma de representación.

Definición 1.8 *Un **colisionador** (collider) es una variable sobre la que inciden dos flechas dentro de una ruta, es decir, una variable que es consecuencia común de dos otras: $A \rightarrow C \leftarrow B$.*

La regla es la siguiente y conviene memorizarla porque es contraintuitiva: una ruta que pasa por un colisionador está **cerrada de manera natural**, y **condicionar en el colisionador la abre**. Es decir, controlar por un colisionador *introduce* una asociación espuria donde no había ninguna.

La intuición se aprecia con un ejemplo. Supongamos que el talento (A) y la belleza (B) son características completamente independientes entre sí en la población, y que ambas contribuyen a que una persona llegue a ser estrella de cine (C). Dentro del conjunto de las estrellas de cine — es decir, condicionando en C — talento y belleza aparecerán **negativamente** correlacionados, simplemente porque quien llegó a ser estrella sin ser especialmente atractivo tuvo que compensarlo con talento, y viceversa. La correlación es real en esa submuestra y es enteramente un artefacto de la selección. Retomaremos este ejemplo con detalle, y con la simulación correspondiente, en el capítulo de datos truncados y censurados.

La lección práctica es de la mayor importancia y contradice la intuición de que «controlar por más variables siempre es mejor»: las variables por las que se controla deben elegirse con base en la estructura causal supuesta y no por conveniencia estadística. Controlar por un confusor elimina sesgo;




Figura 1.13: Ejemplo 5 de un DAG, colisionador: condicionar en C induce asociación entre A y B




Figura 1.14: Ejemplo 4 de un DAG, IV estimator

controlar por un colisionador — o por una variable que sea consecuencia del tratamiento — lo *crea*.

Veamos un ejemplo más, el caso de las variables instrumentales. La Figura 1.14 ilustra que U es un conjunto de factores no observables que impiden identificar la causalidad entre D y Y . De esta forma, buscamos una variable Z que no esté correlacionada con U pero sí con D , con el objeto de hacer una estimación auxiliar. Nótese que en ese DAG no hay flecha de Z a Y : esa ausencia *es* la restricción de exclusión que discutiremos en el capítulo de variables instrumentales.

1.10. Ejercicios

Además de los ejercicios sobre efectos marginales que planteamos antes, proponemos los siguientes:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) El modelo lineal exige que la esperanza condicional sea una función lineal de las variables explicativas.

- b) El Teorema de Gauss-Markov requiere que los errores se distribuyan normalmente.
 - c) El método de mínimos cuadrados minimiza la distancia perpendicular de cada observación a la recta de regresión.
 - d) El estimador de máxima verosimilitud de σ^2 en el modelo lineal bivariado es insesgado.
 - e) En un DAG, la ausencia de una flecha entre dos variables implica que esas variables son estadísticamente independientes.
 - f) Controlar por más variables en una regresión siempre reduce el sesgo.
 - g) Si $\rho = 0$, entonces la recta de regresión de Y en X es horizontal.
2. Sea $f(x, y) = 2$ para $0 < y < x < 1$ y cero en cualquier otro caso. Se le solicita:
- a) Verificar que se trata de una función de densidad conjunta válida.
 - b) Obtener las densidades marginales $g(x)$ y $g(y)$.
 - c) Obtener la ecuación de regresión de Y en X , es decir $\mathbb{E}[Y \mid x]$, y verificar que resulta lineal en x .
 - d) Obtener la ecuación de regresión de X en Y y verificar que **también** es lineal. Comparar las dos rectas y explicar por qué no son la misma: ¿qué está minimizando cada una?
3. Demuestre la segunda parte del teorema de la sección de supuestos, es decir, que si la regresión de X en Y es lineal entonces $\mu_{X|y} = \mu_X + \rho \frac{\sigma_X}{\sigma_Y}(y - \mu_Y)$, siguiendo los mismos pasos que se emplearon para la primera parte.
4. A partir del teorema anterior, se le solicita:
- a) Mostrar que el producto de las dos pendientes de regresión, la de Y en X y la de X en Y , es exactamente ρ^2 .
 - b) Interpretar el resultado: ¿qué significa que ese producto sea cercano a uno, y qué significa que sea cercano a cero?
 - c) Explicar por qué de aquí se sigue que las dos rectas coinciden únicamente cuando $|\rho| = 1$.

5. Considere la log-verosimilitud del modelo lineal bivariado de la ecuación (1.10). Se le solicita:
- a) Obtener las tres componentes del vector gradiente y verificar el factor $1/2$ en la derivada respecto de σ^2 .
 - b) Resolver el sistema y verificar que se obtienen las ecuaciones (1.15), (1.14) y (1.16).
 - c) Verificar que $\hat{\beta}_0$ y $\hat{\beta}_1$ coinciden con los que se obtienen por mínimos cuadrados, y explicar por qué ocurre esa coincidencia. ¿Seguiría ocurriendo si los errores no fueran normales?
 - d) Demostrar que $\hat{\sigma}^2$ de la ecuación (1.16) es sesgado y proponer la corrección correspondiente.
6. Muestre que el estimador de la ecuación (1.14) puede reescribirse en la forma más habitual:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^N (x_i - \bar{X})(y_i - \bar{Y})}{\sum_{i=1}^N (x_i - \bar{X})^2}$$

Y explique qué relación guarda esta expresión con el resultado poblacional $\beta_1 = \sigma_{XY}/\sigma_X^2$ obtenido en la demostración del teorema.

7. **Sobre los DAG.** Para cada una de las siguientes situaciones, dibuje el DAG correspondiente, identifique si la tercera variable es un confusor, un mediador o un colisionador, y determine si debe o no controlarse por ella para estimar el efecto de D sobre Y :
- a) D : años de escolaridad; Y : salario; tercera variable: habilidad innata.
 - b) D : participación en un programa de capacitación; Y : salario; tercera variable: haber conseguido empleo tras el programa.
 - c) D : consumo de tabaco; Y : cáncer de pulmón; tercera variable: presencia de alquitrán en los pulmones.
 - d) D : recibir una beca; Y : calificaciones; tercera variable: ingreso del hogar, que determina la elegibilidad para la beca.
8. **Simulación del sesgo del colisionador.** Genere en Python dos variables independientes A y B , ambas normales estándar, con $n = 5,000$ observaciones. Se le solicita:

- a)* Verificar que la correlación muestral entre A y B es cercana a cero.
- b)* Construir $C = A + B + u$, con u normal, y conservar únicamente las observaciones con C en el percentil 85 superior.
- c)* Calcular la correlación entre A y B en esa submuestra y graficar el diagrama de dispersión de ambas muestras.
- d)* Explicar el resultado con base en la Figura 1.13 y relacionarlo con el ejemplo de las estrellas de cine.

2

Estimación de modelos lineales de una sola ecuación por el método de Mínimos Cuadrados Ordinarios

2.1. El estimador de Mínimos Cuadrados Ordinarios (MCO) y el análisis clásico de regresión

Si partimos de las ecuaciones (1.20) u (1.21), podemos establecer que el término de error estará dado por:

$$\varepsilon_i = y_i - \mathbf{x}_i\boldsymbol{\beta} \quad (2.1)$$

Donde $i = 1, 2, \dots, N$. De forma similar podremos decir que un estimador de este término de error será aquel que resulte de:

$$e_i = y_i - \mathbf{x}_i\hat{\boldsymbol{\beta}} \quad (2.2)$$

Donde $\hat{\boldsymbol{\beta}}$ es un vector de estimadores de los parámetros $\boldsymbol{\beta}$. De lo dicho hasta ahora es fácil ver que la siguiente ecuación es cierta $\forall i$:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i = \mathbf{x}_i\hat{\boldsymbol{\beta}} + e_i \quad (2.3)$$

Intuitivamente, la ecuación (2.3) significa que siempre que poseamos una muestra de los elementos de la población, podremos explicar una parte de la variable dependiente, no su totalidad. En este sentido, el análisis de regresión consiste en un proceso de ajuste a la variable dependiente. Está es la idea que da origen al R^2 y otras medidas de bondad de ajuste, mismas que se analizan en textos convencionales de análisis de regresión.

El método de MCO, en consecuencia, resulta en encontrar la combinación de valores de los estimadores de los parámetros $\hat{\beta}$ que permita minimizar la suma de los residuales (estimadores de los términos de error ε) al cuadrado dada por:

$$\sum_{i=1}^N e_i^2 = \sum_{i=1}^N (y_i - \mathbf{x}_i' \hat{\beta})^2 \quad (2.4)$$

Donde $\hat{\beta}$ denota el vector de estimadores $\hat{\beta}_1, \dots, \hat{\beta}_K$. En términos matriciales, dado que $(e_1, e_2, \dots, e_n)'(e_1, e_2, \dots, e_n) = \mathbf{e}'\mathbf{e}$, el problema del método de MCO consiste en resolver el problema de optimización:

$$\begin{aligned} \text{Minimizar}_{\hat{\beta}} S(\hat{\beta}) &= \text{Minimizar}_{\hat{\beta}} \mathbf{e}'\mathbf{e} \\ &= \text{Minimizar}_{\hat{\beta}} (\mathbf{Y} - \mathbf{X}\hat{\beta})'(\mathbf{Y} - \mathbf{X}\hat{\beta}) \end{aligned}$$

La figura 2.1 ilustra el problema (2.4) en el caso de dos variables explicativas. Es la extensión directa de la figura 1.6 del capítulo anterior: lo que en el modelo bivariado era una recta ajustada sobre un plano, aquí es un plano ajustado en el espacio, y con K regresores sería un hiperplano de dimensión K que ya no admite dibujo. Cada punto de la nube es una observación i de la muestra, los dos ejes horizontales son las variables explicativas y el eje vertical es la variable dependiente. Los segmentos que unen cada punto con el plano son los residuales e_i , y conviene notar que se trazan **verticales**: se miden en la dirección de y , no perpendicularmente al plano ajustado, por la misma razón que discutimos en el caso de dos variables. Lo que hace el método de MCO es elegir la altura y la inclinación del plano de forma que la suma de los cuadrados de esos segmentos sea la menor posible.

Expandiendo la expresión $\mathbf{e}'\mathbf{e}$ obtenemos:

$$\mathbf{e}'\mathbf{e} = \mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\hat{\beta} + \hat{\beta}'\mathbf{X}'\mathbf{X}\hat{\beta} \quad (2.5)$$

De esta forma obtenemos que las condiciones necesarias de un mínimo son:

$$\frac{\partial S(\hat{\beta})}{\partial \hat{\beta}} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{0} \quad (2.6)$$




Figura 2.1: Ajuste por mínimos cuadrados con dos variables explicativas: el plano ajustado y las distancias verticales que se minimizan, retomado de Hastie, Tibshirani y Friedman (2017, p. 45) [HTF17]

De ecuación anterior obtenemos para la solución del problema del mínimo a las ecuaciones siguientes conocidas como *ecuaciones normales* dadas por:

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y} \quad (2.7)$$

Notemos que dichas ecuaciones normales son en realidad un sistema de ecuaciones de K variables o incógnitas. Por un lado, recordemos que $\mathbf{X}$ es una matriz de dimensión $N \times K$, con lo cual $\mathbf{X}'$ es de dimensión $K \times N$. Así, el producto $\mathbf{X}'\mathbf{X}$ dará como resultado una matriz cuadrada de dimensión $K \times K$. Por otro lado, sabemos que $\mathbf{Y}$ es un vector de tamaño $N \times 1$, con lo cual el producto $\mathbf{X}'\mathbf{Y}$ da como resultado un vector de dimensión $K \times 1$. En conclusión, el sistema de ecuaciones normales consiste en K ecuaciones con K incógnitas $(\hat{\beta}_1, \dots, \hat{\beta}_K)$. Ante este hecho, existen múltiples formas mediante las cuales se puede solucionar dicho sistema, sin embargo en nuestro caso seguiremos el siguiente procedimiento de operaciones matriciales.

Si la matriz $\mathbf{X}$ es de rango completo por columnas, entonces la inversa de la matriz $\mathbf{X}'\mathbf{X}$ existe. De esta forma, la solución está dada por la siguiente expresión:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} \quad (2.8)$$

Esta expresión, a pesar de ser en apariencia compleja se puede ver como un conjunto de sumas. En general hemos supuesto que nuestra regresión a estimar esta descrita por la ecuación: $y_i = x_{i1}\beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K + \varepsilon_i$, de esta forma tenemos K variables independientes en nuestra regresión.

Ahora bien, si denotamos a $\mathbf{X}_k$ como el vector columna formado por todas las observaciones de la muestra ($i = 1, 2, \dots, N$) para la variable k , podemos decir que la matriz $\mathbf{X}$ que contiene todas las variables independientes se forma por la concatenación de cada uno de los K vectores columna. Dicho esto, podemos ver que las matrices $\mathbf{X}$ y $\mathbf{X}'$ se pueden expresar como:

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & x_{13} & \dots & x_{1K} \\ x_{21} & x_{22} & x_{23} & \dots & x_{2K} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{N1} & x_{N2} & x_{N3} & \dots & x_{NK} \end{bmatrix} = [\mathbf{X}_1 \quad \mathbf{X}_2 \quad \mathbf{X}_3 \quad \dots \quad \mathbf{X}_K]$$

$$\mathbf{X}' = \begin{bmatrix} x_{11} & x_{21} & x_{31} & \dots & x_{N1} \\ x_{12} & x_{22} & x_{32} & \dots & x_{N2} \\ x_{13} & x_{23} & x_{33} & \dots & x_{N3} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{1K} & x_{2K} & x_{3K} & \dots & x_{NK} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix}$$

Si suponemos que nuestra regresión tiene una constante, la especificación sería: $y_i = \beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K + \varepsilon_i$, con unas matrices $\mathbf{X}$ y $\mathbf{X}'$ dadas:

$$\mathbf{X} = \begin{bmatrix} 1 & x_{12} & x_{13} & \dots & x_{1K} \\ 1 & x_{22} & x_{23} & \dots & x_{2K} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{N2} & x_{N3} & \dots & x_{NK} \end{bmatrix} = \begin{bmatrix} \mathbf{1}_N & \mathbf{X}_2 & \mathbf{X}_3 & \dots & \mathbf{X}_K \end{bmatrix}$$

$$\mathbf{X}' = \begin{bmatrix} 1 & 1 & 1 & \dots & 1 \\ x_{12} & x_{22} & x_{32} & \dots & x_{N2} \\ x_{13} & x_{23} & x_{33} & \dots & x_{N3} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ x_{1K} & x_{2K} & x_{3K} & \dots & x_{NK} \end{bmatrix} = \begin{bmatrix} \mathbf{1}'_N \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix}$$

Donde $\mathbf{1}_N$ es un vector columna compuesto de 1's (unos). Retomando la ecuación (2.8), desarrollemos cada uno de los casos anteriores, así obtenemos lo siguiente para el caso general:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \mathbf{X}'_1 \\ \mathbf{X}'_2 \\ \mathbf{X}'_3 \\ \vdots \\ \mathbf{X}'_K \end{bmatrix} \begin{bmatrix} \mathbf{X}_1 & \mathbf{X}_2 & \mathbf{X}_3 & \dots & \mathbf{X}_K \end{bmatrix}$$

$$\begin{bmatrix} \mathbf{X}'_1\mathbf{X}_1 & \mathbf{X}'_1\mathbf{X}_2 & \mathbf{X}'_1\mathbf{X}_3 & \dots & \mathbf{X}'_1\mathbf{X}_K \\ \mathbf{X}'_2\mathbf{X}_1 & \mathbf{X}'_2\mathbf{X}_2 & \mathbf{X}'_2\mathbf{X}_3 & \dots & \mathbf{X}'_2\mathbf{X}_K \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{X}'_K\mathbf{X}_1 & \mathbf{X}'_K\mathbf{X}_2 & \mathbf{X}'_K\mathbf{X}_3 & \dots & \mathbf{X}'_K\mathbf{X}_K \end{bmatrix}$$

Por lo tanto, obtenemos que:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} \sum_{i=1}^N x_{i1}^2 & \sum_{i=1}^N x_{i1}x_{i2} & \sum_{i=1}^N x_{i1}x_{i3} & \dots & \sum_{i=1}^N x_{i1}x_{iK} \\ \sum_{i=1}^N x_{i2}x_{i1} & \sum_{i=1}^N x_{i2}^2 & \sum_{i=1}^N x_{i2}x_{i3} & \dots & \sum_{i=1}^N x_{i2}x_{iK} \\ \sum_{i=1}^N x_{i3}x_{i1} & \sum_{i=1}^N x_{i3}x_{i2} & \sum_{i=1}^N x_{i3}^2 & \dots & \sum_{i=1}^N x_{i3}x_{iK} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \sum_{i=1}^N x_{iK}x_{i1} & \sum_{i=1}^N x_{iK}x_{i2} & \sum_{i=1}^N x_{iK}x_{i3} & \dots & \sum_{i=1}^N x_{iK}^2 \end{bmatrix}$$

Por otro lado, cuando supongamos que existe un término constante:

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} N & \sum_{i=1}^N x_{i2} & \sum_{i=1}^N x_{i3} & \cdots & \sum_{i=1}^N x_{iK} \\ \sum_{i=1}^N x_{i2} & \sum_{i=1}^N x_{i2}^2 & \sum_{i=1}^N x_{i2}x_{i3} & \cdots & \sum_{i=1}^N x_{i2}x_{iK} \\ \sum_{i=1}^N x_{i3} & \sum_{i=1}^N x_{i3}x_{i2} & \sum_{i=1}^N x_{i3}^2 & \cdots & \sum_{i=1}^N x_{i3}x_{iK} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum_{i=1}^N x_{iK} & \sum_{i=1}^N x_{iK}x_{i2} & \sum_{i=1}^N x_{iK}x_{i3} & \cdots & \sum_{i=1}^N x_{iK}^2 \end{bmatrix}$$

Adicionalmente, el producto $\mathbf{X}'\mathbf{Y}$, en el caso general, se puede expresar como:

$$\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \mathbf{X}'_1 \mathbf{Y} \\ \mathbf{X}'_2 \mathbf{Y} \\ \mathbf{X}'_3 \mathbf{Y} \\ \vdots \\ \mathbf{X}'_K \mathbf{Y} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N x_{i1}y_i \\ \sum_{i=1}^N x_{i2}y_i \\ \sum_{i=1}^N x_{i3}y_i \\ \vdots \\ \sum_{i=1}^N x_{iK}y_i \end{bmatrix} \quad (2.9)$$

Si en el modelo suponemos la existencia de un término constante, dicho producto se expresa como:

$$\mathbf{X}'\mathbf{Y} = \begin{bmatrix} \mathbf{1}'_N \mathbf{Y} \\ \mathbf{X}'_2 \mathbf{Y} \\ \mathbf{X}'_3 \mathbf{Y} \\ \vdots \\ \mathbf{X}'_K \mathbf{Y} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N y_i \\ \sum_{i=1}^N x_{i2}y_i \\ \sum_{i=1}^N x_{i3}y_i \\ \vdots \\ \sum_{i=1}^N x_{iK}y_i \end{bmatrix}$$

Finalmente, para que esta solución dada para el procedimiento de MCO y mostrada en la ecuación (2.8) sea un mínimo, debemos buscar las condiciones de segundo orden:

$$\frac{\partial^2 S(\hat{\beta})}{\partial \hat{\beta} \partial \hat{\beta}'} = 2\mathbf{X}'\mathbf{X} \quad (2.10)$$

Donde la matriz $\mathbf{X}'\mathbf{X}$ debe ser positiva definida para que la solución de MCO sea un mínimo. Sea $q = \mathbf{c}'\mathbf{X}'\mathbf{X}\mathbf{c}$ para algún vector $\mathbf{c}$ distinto de cero. Entonces:

$$q = \mathbf{v}'\mathbf{v} = \sum_{i=1}^N v_i^2, \text{ donde } \mathbf{v} = \mathbf{X}\mathbf{c}$$

Así, q es positivo. Si $\mathbf{v}$ fuera cero, entonces existe una combinación lineal de las columnas de $\mathbf{X}$ que da como resultado cero, lo cual contradice el

supuesto de que $\mathbf{X}$ es de rango completo. En todos los casos, si $\mathbf{X}$ es de rango completo, entonces la solución del método de MCO, $\hat{\beta}$, es la única que minimiza la suma de los residuales al cuadrado.

2.2. Interpretación geométrica de MCO: la proyección ortogonal

Las ecuaciones normales (2.7) admiten una lectura geométrica que conviene tener presente, porque vuelve evidentes propiedades que de otro modo aparecen como resultados algebraicos sueltos, y porque es la misma idea que reaparecerá en la descomposición del R^2 de la siguiente sección, en el método de variables instrumentales y en la transformación intragrupos de los modelos de datos panel.

Antes de entrar en materia hay que advertir un cambio de espacio, que es la fuente más común de confusión en este punto. La figura 2.1 está dibujada en el **espacio de las variables**: hay un eje por cada variable, cada punto de la nube es una de las N observaciones y el ajuste es un hiperplano de dimensión K . La representación que sigue está dibujada en el **espacio de las observaciones**: hay un eje por cada una de las N observaciones y cada *variable* — es decir, cada columna de $\mathbf{X}$, y también $\mathbf{Y}$ — es un único vector de $\mathbb{R}^N$. Son dos dibujos del mismo problema, no dos problemas distintos, pero los papeles del punto y del eje están intercambiados.

En el espacio de las observaciones, las K columnas de $\mathbf{X}$ generan un subespacio de $\mathbb{R}^N$:

$$\mathcal{C}(\mathbf{X}) = \{\mathbf{X}\mathbf{b} : \mathbf{b} \in \mathbb{R}^K\}$$

Al conjunto $\mathcal{C}(\mathbf{X})$ lo llamaremos el **espacio columna** de $\mathbf{X}$. Su dimensión es exactamente K gracias al supuesto de rango completo por columnas que utilizamos para invertir $\mathbf{X}'\mathbf{X}$: si alguna columna fuera combinación lineal de las demás, el subespacio tendría dimensión menor y un mismo punto de $\mathcal{C}(\mathbf{X})$ podría escribirse con distintos vectores $\mathbf{b}$, que es la lectura geométrica del problema de multicolinealidad perfecta. Como en las aplicaciones $N > K$, este subespacio es una porción muy pequeña de $\mathbb{R}^N$ y no hay razón alguna para que $\mathbf{Y}$ caiga dentro de él; si cayera, existiría un $\hat{\beta}$ que ajustaría la muestra sin error y todos los residuales serían cero.

Elegir $\hat{\beta}$ equivale entonces a elegir un punto $\hat{\mathbf{Y}} = \mathbf{X}\hat{\beta}$ dentro de $\mathcal{C}(\mathbf{X})$, y minimizar $\mathbf{e}'\mathbf{e} = (\mathbf{Y} - \hat{\mathbf{Y}})'(\mathbf{Y} - \hat{\mathbf{Y}})$ equivale a elegir el punto de ese subespacio

que queda **más cerca** de $\mathbf{Y}$ en distancia euclidiana. La solución de ese problema es única y es la que da la geometría elemental: el pie de la perpendicular, es decir, la proyección ortogonal de $\mathbf{Y}$ sobre $\mathcal{C}(\mathbf{X})$. Las ecuaciones normales dicen exactamente eso; basta reescribirlas sustituyendo $\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{e}$:

$$\mathbf{X}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Y} \quad \Longleftrightarrow \quad \mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0} \quad \Longleftrightarrow \quad \mathbf{X}'\mathbf{e} = \mathbf{0} \quad (2.11)$$

La condición (2.11) es un sistema de K ecuaciones, una por cada columna de $\mathbf{X}$, y cada una de ellas dice $\mathbf{X}'_k \mathbf{e} = \sum_{i=1}^N x_{ik} e_i = 0$. El vector de residuales es ortogonal a cada variable explicativa y, en consecuencia, a todo el subespacio que las variables generan. Este es el contenido geométrico del método: MCO descompone a $\mathbf{Y}$ en dos piezas ortogonales entre sí, una que vive dentro del espacio columna y otra que es perpendicular a él.

Las figuras 2.2 y 2.3 muestran esta construcción para el caso $K = 2$, que es el último que puede dibujarse. En ambas, los dos vectores que salen del origen son las columnas de $\mathbf{X}$ vistas como puntos de $\mathbb{R}^N$ y la región sombreada es el plano que generan; el vector de la variable dependiente apunta fuera de ese plano y el valor ajustado es su sombra sobre él. Conviene advertir que las figuras conservan la notación de sus textos originales: lo que ahí se escribe $\mathbf{x}_1$ y $\mathbf{x}_2$ es lo que nosotros hemos llamado $\mathbf{X}_1$ y $\mathbf{X}_2$, y lo que ahí se escribe $\mathbf{y}$ y $\hat{\mathbf{y}}$ es nuestro $\mathbf{Y}$ y $\hat{\mathbf{Y}}$; en nuestra notación la minúscula queda reservada para el renglón de un individuo, como se advirtió en el primer capítulo. La primera hace explícito el ángulo recto en el que la perpendicular toca al plano, que es la condición (2.11); la segunda etiqueta además el vector de residuales $\mathbf{e}$, con lo que se lee de un golpe la descomposición $\mathbf{Y} = \hat{\mathbf{Y}} + \mathbf{e}$ como la suma de dos catetos.

Comparando estas figuras con la figura 2.1 se resuelve una aparente contradicción. Allá dijimos que los residuales se miden en la dirección *vertical* y no perpendicularmente al plano ajustado; aquí decimos que el vector de residuales es *perpendicular* al plano. Ambas afirmaciones son correctas y no se refieren a lo mismo: la primera describe la distancia $y_i - \hat{y}_i$ de cada observación en el espacio de las variables; la segunda describe la posición del vector $\mathbf{e}$, que reúne a las N distancias anteriores, respecto del espacio columna en $\mathbb{R}^N$. Precisamente porque cada residual se mide en la dirección de y , el vector que los reúne resulta ortogonal a las $\mathbf{X}$.

Conviene expresar la proyección con una matriz. Sustituyendo la solución (2.8) en $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$ obtenemos:

$$\hat{\mathbf{Y}} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \mathbf{P}\mathbf{Y} \quad (2.12)$$




Figura 2.2: Proyección ortogonal de $\mathbf{Y}$ sobre el espacio generado por las columnas de $\mathbf{X}$, retomado de Hastie, Tibshirani y Friedman (2017, p. 46) [HTF17]




Figura 2.3: Descomposición del vector $\mathbf{Y}$ en el valor ajustado $\hat{\mathbf{Y}}$ y el vector de residuales $\mathbf{e}$, retomado de Greene (2012, p. 31) [Gre12]

A la matriz $\mathbf{P} = \mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'$, de dimensión $N \times N$, se le conoce como **matriz de proyección**. Su complemento genera los residuales:

$$\mathbf{e} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I}_N - \mathbf{P})\mathbf{Y} = \mathbf{M}\mathbf{Y} \quad (2.13)$$

Ambas matrices son simétricas e idempotentes ($\mathbf{P}' = \mathbf{P}$ y $\mathbf{P}\mathbf{P} = \mathbf{P}$, y lo mismo para $\mathbf{M}$), lo cual tiene una lectura directa: proyectar dos veces sobre el mismo subespacio es igual que proyectar una sola vez, porque el resultado de la primera proyección ya está dentro del subespacio. De la definición se siguen además $\mathbf{P}\mathbf{X} = \mathbf{X}$, $\mathbf{M}\mathbf{X} = \mathbf{0}$ y $\mathbf{P}\mathbf{M} = \mathbf{0}$: el espacio columna queda fijo bajo $\mathbf{P}$ y es aniquilado por $\mathbf{M}$, y las dos piezas de la descomposición son ortogonales entre sí. Por último, la traza de una matriz idempotente es igual a su rango, de modo que $\text{tr}(\mathbf{P}) = K$ y $\text{tr}(\mathbf{M}) = N - K$; esta última cifra es el número de grados de libertad que aparecerá en el estimador de la varianza de los residuales y en el R^2 ajustado, y su interpretación geométrica es la dimensión del subespacio en el que $\mathbf{e}$ tiene permitido moverse una vez impuestas las K restricciones de ortogonalidad.

La ortogonalidad tiene una consecuencia inmediata. Como $\hat{\mathbf{Y}}'\mathbf{e} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{e} = \mathbf{0}$ por (2.11), al desarrollar $\mathbf{Y}'\mathbf{Y} = (\hat{\mathbf{Y}} + \mathbf{e})'(\hat{\mathbf{Y}} + \mathbf{e})$ los términos cruzados desaparecen y queda:

$$\mathbf{Y}'\mathbf{Y} = \hat{\mathbf{Y}}'\hat{\mathbf{Y}} + \mathbf{e}'\mathbf{e} \quad (2.14)$$

Que no es otra cosa que el teorema de Pitágoras aplicado al triángulo rectángulo de las figuras 2.2 y 2.3. La suma de cuadrados de la variable dependiente se parte en la que explica la regresión más la que queda sin explicar, y la partición es limpia — sin término de traslape — únicamente porque los dos componentes son ortogonales.

Falta una precisión que enlaza con la siguiente sección. La descomposición (2.14) está escrita respecto del origen, mientras que el R^2 se define respecto de la media. Si el modelo incluye un término constante, el vector $\mathbf{1}_N$ es una de las columnas de $\mathbf{X}$ y, por lo tanto, pertenece a $\mathcal{C}(\mathbf{X})$; entonces la ortogonalidad (2.11) incluye la fila $\mathbf{1}_N'\mathbf{e} = \sum_{i=1}^N e_i = 0$. Es decir, la suma de los residuales es cero *porque* la constante está en el modelo, que es justamente la condición de la que parte el desarrollo del R^2 . Sin constante, $\mathbf{1}_N$ no pertenece al espacio columna, nada obliga a que los residuales sumen cero y la descomposición respecto de la media deja de ser válida. Por lo demás, la matriz $\mathbf{M}^0$ que aparecerá en la ecuación (2.15) es exactamente la matriz $\mathbf{M}$ de (2.13) correspondiente a una regresión que sólo tiene constante, $\mathbf{M}^0 = \mathbf{I}_N - \mathbf{1}_N(\mathbf{1}_N'\mathbf{1}_N)^{-1}\mathbf{1}_N'$, y por eso restar la media y calcular residuales

son la misma operación. Con ello, la versión centrada de (2.14) es la ecuación (2.18), y el R^2 resulta ser el cuadrado del coseno del ángulo que forman $\mathbf{M}^0\mathbf{Y}$ y $\mathbf{M}^0\hat{\mathbf{Y}}$: vale uno cuando $\mathbf{Y}$ ya está en el espacio columna y cero cuando es ortogonal a él.

Esta forma de ver el problema reaparecerá varias veces. En el capítulo de variables instrumentales, el estimador de 2SLS se escribe con la matriz de proyección $\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$, y su primera etapa consiste en sustituir a $\mathbf{X}$ por su proyección sobre el espacio generado por los instrumentos, es decir, por la parte de $\mathbf{X}$ que es ortogonal al error. En el capítulo de datos panel, la transformación intragrupos se aplica con una matriz $\mathbf{Q}$ que también es simétrica e idempotente y que aniquila el espacio generado por las variables dicotómicas de grupo; que el estimador resultante coincida con el de mínimos cuadrados con variables dicotómicas — el teorema de Frisch-Waugh-Lovell — es un enunciado sobre proyecciones sucesivas.

2.3. Bondad de ajuste

Una vez planteada la solución de MCO plantearemos una medida para determinar en qué grado los datos estimados, definidos como $\hat{\mathbf{Y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$, se ajustan al valor real de $\mathbf{Y}$. La medida o métrica es el R^2 , la cual contrasta el análisis de regresión respecto de hacer una simple estimación de una media para dar un pronóstico de $\mathbf{Y}$. El coeficiente R^2 está montado en el supuesto de que el modelo incluye un término constante. Si el modelo no incluye una constante, no es posible hacer una interpretación del R^2 , en los siguientes párrafos abundaremos al respecto.

Antes de iniciar el desarrollo del R^2 , partamos de que la suma de residuales es igual a cero ($\sum_{i=1}^N e_i = 0$), si y sólo si, el modelo tiene un término constante. Un corolario de este hecho es que el valor promedio de los residuales es cero, si y sólo si, el modelo tiene un término constante, esto es, la única forma en

que se cumpla la siguiente expresión es que la suma de residuales sea cero:

$$\begin{aligned}\bar{e} &= \frac{\sum_{i=1}^N e_i}{N} \\ &= \frac{1}{N} \cdot [1, 1, 1, \dots, 1] \begin{bmatrix} e_1 \\ e_2 \\ e_3 \\ \vdots \\ e_N \end{bmatrix} \\ &= 0\end{aligned}$$

Condición que resulta de las ecuaciones normales de MCO, recordemos que ellas se derivan de que $\mathbf{X}'\mathbf{e} = \mathbf{0}$, y que el primer producto punto de vectores implica a la columna de la constante en la matriz $\mathbf{X}$ y que está definido por $[1, 1, 1, \dots, 1]$.

El R^2 descompone la variación total en dos tramos: la variación originada por la regresión y la variación originada por el término de error. Como primer paso definamos la variación total observada respecto de la media ($\bar{Y}$) como:

$$\sum_{i=1}^N (y_i - \bar{Y})^2 = [y_1 - \bar{Y}, y_2 - \bar{Y}, y_3 - \bar{Y}, \dots, y_N - \bar{Y}] \begin{bmatrix} y_1 - \bar{Y} \\ y_2 - \bar{Y} \\ y_3 - \bar{Y} \\ \vdots \\ y_N - \bar{Y} \end{bmatrix}$$

$$\begin{aligned}
&= (\mathbf{Y} - \bar{\mathbf{Y}})'(\mathbf{Y} - \bar{\mathbf{Y}}) \\
&= \left[\mathbf{Y} - \frac{1}{N} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \mathbf{Y} \right]' \left[\mathbf{Y} - \frac{1}{N} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \mathbf{Y} \right] \\
&= \mathbf{Y}' \left[\mathbb{I}_N - \frac{1}{N} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \right]' \left[\mathbb{I}_N - \frac{1}{N} \begin{bmatrix} 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ 1 & 1 & \dots & 1 \\ \vdots & \vdots & \dots & \vdots \\ 1 & 1 & \dots & 1 \end{bmatrix} \right] \mathbf{Y} \\
&= \mathbf{Y}' \mathbf{M}^0 \mathbf{Y} \tag{2.15}
\end{aligned}$$

En la expresión (2.15) a $\mathbf{M}^0$ se puede interpretar como una matriz que resta a una matriz o vector su promedio, notemos que como resultado dará las desviaciones respecto de la media. Asimismo, $\mathbf{M}^0$ tiene un par de propiedades que son fácilmente demostrables: idempotencia y simetría, es decir, i) $\mathbf{M}^0 = \mathbf{M}^{0'}$ y ii) $\mathbf{M}^0 \mathbf{M}^0 = \mathbf{M}^0$. Dicho lo anterior, retomemos a (2.15) para mostrar que:

$$\begin{aligned}
\mathbf{Y}' \mathbf{M}^0 \mathbf{Y} &= \mathbf{Y}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{Y} \\
&= (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e})' \mathbf{M}^{0'} \mathbf{M}^0 (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}) \\
&= (\hat{\boldsymbol{\beta}}' \mathbf{X}' + \mathbf{e}') \mathbf{M}^{0'} \mathbf{M}^0 (\mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}) \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{e} + \mathbf{e}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{e} + \mathbf{e}' \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^{0'} \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \\
&= \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{M}^0 \mathbf{X} \hat{\boldsymbol{\beta}} + \mathbf{e}' \mathbf{e} \tag{2.16}
\end{aligned}$$

No debe pasar desapercibido que el desarrollo algebraico para llegar a la ecuación (2.16) sólo es posible si el promedio de los residuales es cero, es

decir:

$$\mathbf{M}^0 \mathbf{e} = \mathbf{e} - \begin{bmatrix} \bar{e} \\ \bar{e} \\ \bar{e} \\ \vdots \\ \bar{e} \end{bmatrix} = \mathbf{e} - \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \mathbf{e} \quad (2.17)$$

De otra forma, no se puede concluir la expresión (2.16). Finalmente, (2.16) la expresaremos así:

$$\mathbf{Y}'\mathbf{M}^0\mathbf{Y} = \hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}} + \mathbf{e}'\mathbf{e} \quad (2.18)$$

Así, como mencionamos anteriormente, (2.18) se puede interpretar como que la variación total respecto de la media se puede descomponer en dos variaciones, una que se origina de la regresión, $\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}}$, y otra de los residuales, $\mathbf{e}'\mathbf{e}$. De esta forma planteamos que R^2 es una metrica que cuantifica cuánto de la variación total es explicada por la regresión y cuánto es explicada por los residuales (es decir, por la información no observable):

$$\begin{aligned} R^2 &= \frac{Var.Regresion}{Var.Total} \\ &= \frac{\hat{\boldsymbol{\beta}}'\mathbf{X}'\mathbf{M}^0\mathbf{X}\hat{\boldsymbol{\beta}}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \\ &= \frac{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \\ &= 1 - \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \end{aligned} \quad (2.19)$$

Existe una expresión más que se le denomina como un R^2 ajustado o $R^2 Adj.$, el cual castiga por un uso excesivo de variables independientes:

$$R^2 Adj. = 1 - \frac{N-1}{N-K} \frac{\mathbf{e}'\mathbf{e}}{\mathbf{Y}'\mathbf{M}^0\mathbf{Y}} \quad (2.20)$$

Así, es obvio que la siguiente relación siempre es cierta: $R^2 \geq R^2 Adj.$.

2.4. Modelos lineales y algunas de sus propiedades

Determinado una estimado de MCO dado por la ecuación (2.8), establezcamos el modelo poblacional que es lineal en sus parámetros y que está

dado por (notése que eliminamos los subíndices i para facilitar la exposición—digamos, por economía de pizarrón):

$$y = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K + \varepsilon \quad (2.21)$$

Donde y y $x_1, x_2, \dots, x_K$ son variables aleatorias observables, ε es un término de error o perturbación no observable, y $\beta_1, \beta_2, \dots, \beta_K$ son los parámetros (constantes) que deseamos estimar.

La ecuación (2.21) es un modelo estructural estimable, el cual en ocasiones se obtiene directamente de una modelación teórica y otras veces deriva de un procedimiento algebraico para obtenerlo.

El término de error ε puede ser causa de una serie de fuentes relacionadas con: (1) información no observable, (2) variables relevantes omitidas y (3) errores de medición (que en el fondo implica la omisión de información).

Asumimos que para estimar consistentemente a β a través de una muestra aleatoria de la población, el término de error ε tiene una **media cero** que no está correlacionada con el resto de los regresores, es decir:

$$\begin{aligned} \mathbb{E}[\varepsilon_i] &= 0 \\ \text{Cov}(x_k, \varepsilon_i) &= 0 \end{aligned} \quad (2.22)$$

Donde $k = 1, 2, \dots, K$, e $i = 1, 2, \dots, N$. Dada la ecuación de regresión y el supuesto anterior en la ecuación (2.22), entonces podemos ver este caso como una proyección lineal de y en el vector formado por $(x_1, x_2, \dots, x_K)$ y descrito como: $x_1\beta_1 + x_2\beta_2 + \dots + x_K\beta_K$.

Partiendo de que en la ecuación (2.22) establecimos que el análisis de regresión deberá cumplir con $\mathbb{E}[\varepsilon_i] = 0$, entonces podemos establecer que:

$$\mathbb{E}[\varepsilon|x_1, x_2, \dots, x_K] = \mathbb{E}[\varepsilon|\mathbf{x}] = 0 \quad (2.23)$$

De esta forma podemos decir, utilizando la definición de función de regresión discutida en el capítulo previo tenemos que:

$$\mathbb{E}[y|\mathbf{x}] = \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_K x_K \quad (2.24)$$

Dicho esto, podemos hacer algunas observaciones respecto del efecto de las variables utilizadas. Decimos que una variable explicativa x_k es endógena en la ecuación de regresión si esta no cumple con la ecuación (2.22), es decir, está correlacionada con el término de error, ε . Por el contrario, si x_k no está

correlacionado con ε , entonces se dice que x_k es una variable exógena. De esta forma, la ecuación (2.23) se conoce como el supuesto de exogeneidad.

El supuesto de exogeneidad o el de endogeneidad (depende de cómo lo queramos ver) tiene algunas aristas que debemos analizar.

1. La primera es el problema de variables omitidas. Supongamos que la ecuación de regresión está dada por una expresión como $\mathbb{E}[y|\mathbf{x}, q]$. No obstante, asumamos que q es una variable que no es posible observarse, de forma que nos vemos obligados a estimar una ecuación de regresión del tipo $\mathbb{E}[y|\mathbf{x}]$. En este caso q formará parte del término de error ε . Si q y x_k son variables que están correlacionadas, entonces, tendremos el problema de que x_k será endógena.

Este tipo de situaciones, en las que existe correlación entre variables no observables y variables explicativas son conocidas como problemas de autoselección. En el capítulo de modelos de selección detallaremos más al respecto de este tipo de problemas.

2. La segunda es el problema de simultaneidad. que es un problema que aparece cuando una o más variables explicativas están determinadas simultáneamente con y . Así, si x_k esta parcialmente determinada por y , entonces, x_k y ε estarán correlacionados. En otro capítulo más adelante retomaremos este caso.

2.5. Propiedades asintóticas de los estimadores de MCO

Partamos de una forma funcional general de la ecuación de regresión dada por:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Así para algún individuo y sin hacer uso del subíndice i , tendríamos:

$$y = \mathbf{x}\boldsymbol{\beta} + \varepsilon \tag{2.25}$$

Donde $\mathbf{x}$ es un vector de regresores de dimensión $1 \times K$ y los parámetros $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_K)'$ es un vector de dimensión $K \times 1$. Dado que la mayoría de las veces asumiremos que el modelo considera un término constantes, diremos que $x_1 = 1$.

Asumamos que podemos obtener una muestra aleatoria de tamaño N de la población con el objeto de estimar β a partir de una familia de vectores $\{(\mathbf{x}, y_i) : i = 1, 2, \dots, N\}$, que es una muestra aleatoria independiente e idénticamente distribuida.

Podemos decir que para cada observación $i = 1, 2, \dots, N$ tenemos que:

$$y_i = \mathbf{x}_i\beta + \varepsilon_i \quad (2.26)$$

De esta ecuación ahora discutamos algunas propiedades deseables que deberán cumplir los estimadores β .

La primera es **consistencia**, la cual es una condición de ortogonalidad de la población, la cual implica:

$$\mathbb{E}[\mathbf{x}_i\varepsilon_i] = 0 \quad (2.27)$$

Donde $i = 1, 2, \dots, N$. Si asumimos que el modelo tiene un término constante, entonces, esto implicaría que $\mathbb{E}[\varepsilon_i] = 0$. La segunda es una condición de **no multicolinealidad**:

$$\text{Rank}[\mathbb{E}[\mathbf{X}'\mathbf{X}]] = K \quad (2.28)$$

Así, buscamos que no exista dependencia lineal entre los elementos de $\mathbf{x}'_i\mathbf{x}_i$. Esto debería ponernos a pensar en qué pasa con casos en que incluimos una variable y su cuadrado, o cuando en un modelo que incluye constante decidimos agregar variables dicotómicas con poca variabilidad (e.g. casi todos los individuos son de un tipo), entre otros casos.

Bajo este par de supuestos de las ecuaciones (2.27) y (2.28) se cumplirán los siguientes casos. Diremos que β está identificada, en términos de que se trata de parámetros lineales estimados a partir de una muestra aleatoria tales que β puede ser escrita en términos de los momentos poblacionales, es decir, partiendo de la estimación de estos dada por MCO tendríamos:

$$\hat{\beta} = \mathbb{E}[\mathbf{x}'_i\mathbf{x}_i]^{-1}\mathbb{E}[\mathbf{x}'_iy_i] \quad (2.29)$$

Dado que esta expresión es válida para cada elemento de la muestra y que ilustra la dependencia de que β sea identificable, podemos extender el

análisis para obtener:

$$\begin{aligned}
\mathbb{E}[\hat{\beta} \mid \mathbf{X}] &= \mathbb{E}[\mathbf{X}'\mathbf{X}]^{-1}\mathbb{E}[\mathbf{X}'\mathbf{Y}] \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbb{E}[\mathbf{X}'\mathbf{Y}] \\
&= \beta + \mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\varepsilon}] \\
&= \beta + \left(\frac{\sum_{i=1}^N \mathbf{x}_i'\mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}_i'\boldsymbol{\varepsilon}}{N} \right) \\
&= \beta
\end{aligned}$$

El último paso es válido Si tomamos el límite en probabilidad p $\lim \hat{\beta} = \beta + A^{-1} \times 0 = \beta$. Lo anterior implica que hemos demostrado el siguiente teorema:

O dicho de otra forma, el estimador de MCO es insesgado. Esto también prueba que $\mathbf{X}$ y $\boldsymbol{\varepsilon}$ son independientes.

Teorema 2.1 *Bajo los supuestos de las ecuaciones (2.27) y (2.28) el estimador $\hat{\beta}$ obtenido por MCO a partir de una muestra aleatoria es consistente para β .*

Este teorema implica que $\mathbf{X}\beta$ es una proyección ponderada de $\mathbf{X}$ sobre $\mathbf{Y}$. Más aún, implica que:

$$\mathbb{E}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}] = \beta \quad (2.30)$$

Ahora, analicemos que pasa con la varianza. Derivado del teorema de Gauss - Markov, sabemos que si $\mathbf{Y} = \mathbf{X}\beta + \boldsymbol{\varepsilon}$ y que $Var(\varepsilon_i) = \sigma^2, \forall i$, entonces:

$$\begin{aligned}
Var(\beta \mid \mathbf{X}) &= Var((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}) \\
&= Var((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \boldsymbol{\varepsilon})) \\
&= Var(\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\varepsilon}) \\
&= Var((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\boldsymbol{\varepsilon}) \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'Var(\boldsymbol{\varepsilon})\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\sigma^2\mathbf{I}_N\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\
&= \sigma^2(\mathbf{X}'\mathbf{X})^{-1}
\end{aligned}$$

2.6. Inferencia asintótica bajo MCO

Partamos de que:

$$\begin{aligned}\hat{\beta} &= \beta + \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \varepsilon}{N} \right) \\ \hat{\beta} - \beta &= \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i}{N} \right)^{-1} \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \varepsilon}{N^{1/2} N^{1/2}} \right) \\ \sqrt{N}(\hat{\beta} - \beta) &= \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i}{N} \right)^{-1} \left(\sqrt{N} \sum_{i=1}^N \mathbf{x}'_i \varepsilon \right)\end{aligned}$$

Entonces por el Teorema del Límite Central, tenemos que:

$$\sqrt{N} \sum_{i=1}^N \mathbf{x}'_i \varepsilon \xrightarrow{d} \text{Normal}(\mathbf{0}, \Sigma) \quad (2.31)$$

Donde Σ es una matriz de dimensión $K \times K$ que resulta de:

$$\Sigma = \mathbb{E}[\mathbf{X}' \varepsilon \varepsilon' \mathbf{X}]$$

En este momento introduciremos uno de los supuestos más importantes que es el de **homocedasticidad**, por lo que:

$$\Sigma = \mathbb{E}[\mathbf{X}' \varepsilon \varepsilon' \mathbf{X}] = \sigma^2 \mathbb{E}[\mathbf{X}' \mathbf{X}] \quad (2.32)$$

Donde $\sigma^2 = \mathbb{E}[\varepsilon_i]$ para todo $i = 1, 2, \dots, N$. En general vamos a decir que $\mathbb{E}[\varepsilon_i | \mathbf{X}] = \text{Var}[\varepsilon_i | \mathbf{X}] = \sigma^2$. Dicho lo anterior vamos a enunciar un teorema:

Teorema 2.2 Normalidad asintótica de MCO. *Considerando los supuestos descritos en las ecuaciones (2.27) y (2.32), entonces:*

$$\sqrt{N}(\hat{\beta} - \beta) \sim \text{Normal}(\mathbf{0}, \sigma^2 (\mathbb{E}[\mathbf{X}' \mathbf{X}])^{-1}) \quad (2.33)$$

El teorema anterior se puede interpretar como:

$$\begin{aligned}
\sqrt{N}(\hat{\beta} - \beta) &\sim \text{Normal} \left(\mathbf{0}, \sigma^2 \left(\frac{\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i}{N} \right)^{-1} \right) \\
(\hat{\beta} - \beta) &\sim \text{Normal} \left(\mathbf{0}, \sigma^2 \left(\sum_{i=1}^N \mathbf{x}'_i \mathbf{x}_i \right)^{-1} \right) \\
(\hat{\beta} - \beta) &\sim \text{Normal} (\mathbf{0}, \sigma^2 [\mathbf{X}'\mathbf{X}]^{-1}) \\
\hat{\beta} &\sim \text{Normal} (\beta, \sigma^2 [\mathbf{X}'\mathbf{X}]^{-1})
\end{aligned} \tag{2.34}$$

A partir de la expresión (2.34) construiremos algunas pruebas. En estadística es común que porpongamos como estimador de σ^2 a:

$$\hat{\sigma}^2 = \frac{\mathbf{e}'\mathbf{e}}{N - K} \tag{2.35}$$

El cual es un estimador insesgado de la varianza. Además, queda pendiente en esta sección es demostrar que el estimador de MCO ($\hat{\beta}$) alcanza la cota inferior Cramér-Rao. De esta forma podríamos afirmar que el estimador es de mínima varianza o, equivalentemente, es el más eficiente.

Dicho lo anterior podemos construir las dos pruebas: t y F. Previo a dicha construcción debemos recordar que una prueba t se construye por la relación de una función normal con media cero y varianza 1 (uno), y la raíz cuadrada de una función chi-cuadrado. Supongamos que una variable Z se distribuye de forma normal con media cero y varianza 1 (uno), y que la variable χ_m^2 se distribuye de forma chi-cuadrado con m grados de libertad, entonces:

$$t = \frac{Z}{\sqrt{\frac{\chi_m^2}{m}}} \sim t_m \tag{2.36}$$

Donde t_m tal y como se describe en (2.36) es una distribución t de Student con m grados de libertad. Por otro lado, cuando se tiene una variable Z con distribución normal con media cero y varianza $\sigma^2 = 1$, entonces lo siguiente es cierto:

$$Z^2 \sim \chi_1^2$$

Así, la suma de variables chi-cuadrado es una chi-cuadrado en los siguientes términos:

$$\sum_{i=1}^m Z^2 \sim \chi_m^2$$

Dada la distribución $\hat{\beta}$, y que la varianza de cada uno de los elementos de $\hat{\beta}$, digamos $\hat{\beta}_k$, es: $\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}$. En este punto denotaremos con $\hat{\beta}_k$ al elemento k -ésimo dentro de $\hat{\beta}$. Adicionalmente, con $(\mathbf{X}'\mathbf{X})_{kk}^{-1}$ al elemento en la fila k y la columna k en la matriz $(\mathbf{X}'\mathbf{X})^{-1}$. Derivado de lo anterior, lo siguiente es cierto:

$$Z = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim \mathcal{N}(0, 1)$$

Considerando la distribución de ε_i y de que e_i es un estimador de ε_i , podemos afirmar que:

$$Z = \frac{e_i - 0}{\sigma} = \frac{e_i}{\sigma} \sim \mathcal{N}(0, 1)$$

De esta forma:

$$\sum_{i=1}^N Z_i^2 = \sum_{i=1}^N \frac{e_i^2}{\sigma^2} \sim \chi_N^2$$

Dada la distribución t de Student en la ecuación (2.36) y los elementos antes mencionados podemos llegar a las siguientes conclusiones:

$$\begin{aligned} t &= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\sum_{i=1}^N \frac{e_i^2}{\sigma^2} / (N - K)}} \\ &= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\sum_{i=1}^N \frac{e_i^2}{(N - K)\sigma^2}}} \\ &= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\sqrt{\frac{\hat{\sigma}^2}{\sigma^2}}} \\ &= \frac{\frac{\hat{\beta}_k - \beta_k}{\sqrt{\sigma^2} \sqrt{(\mathbf{X}'\mathbf{X})_{kk}^{-1}}}}{\frac{\sqrt{\hat{\sigma}^2}}{\sqrt{\sigma^2}}} \\ &= \frac{(\hat{\beta}_k - \beta_k) \sqrt{\sigma^2}}{\sqrt{\hat{\sigma}^2} \sqrt{\sigma^2} \sqrt{(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \\ &= \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \end{aligned}$$

De esta forma:

$$t = \frac{\hat{\beta}_k - \beta_k}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim t_{N-K} \quad (2.37)$$

Construida esta expresión (2.37) podemos establecer el siguiente intervalo de confianza para cada uno de nuestros estimadores $\hat{\beta}_k$:

$$-t_{\alpha/2, N-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}} < \hat{\beta}_k - \beta_k < t_{\alpha/2, N-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}$$

$$\hat{\beta}_k - t_{\alpha/2, N-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}} < \beta_k < \hat{\beta}_k + t_{\alpha/2, N-K} \sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}$$

Donde $t_{\alpha/2, n-K}$ es el valor crítico de tablas t-Student. Así, podemos enunciar que el estimador de MCO de la ecuación (2.8) se sujetará a la siguiente prueba de hipótesis general:

$$\begin{aligned} H_0 : \beta_k &= r \\ H_a : \beta_k &\neq r \end{aligned}$$

Donde $k = 1, 2, \dots, K$ y r es un valor respecto del cual se desea comparar a $\hat{\beta}_k$. Dicha prueba se distribuye como una t_{N-K} y su especificación más común en el análisis de regresión es la siguiente:

$$\begin{aligned} H_0 : \beta_k &= 0 \\ H_a : \beta_k &\neq 0 \end{aligned}$$

Lo que en términos de una prueba t es la siguiente:

$$t = \frac{\hat{\beta}_k - 0}{\sqrt{\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}}} \sim t_{N-K} \quad (2.38)$$

Dicha prueba la podemos interpretar como sí es posible que el estimador $\hat{\beta}_k$ sea igual a 0, o en términos económicos, si existe evidencia estadística de que el efecto de la variable x_k en y es nulo.

Como se mostró anteriormente, sólo se hemos hablado de pruebas de hipótesis cuándo se desea comprobar si alguno de los estimadores $\hat{\beta}_k$ de MCO es estadísticamente igual a algún valor determinado. No obstante, en ciertas

condiciones puede ser interesante cuestionar si en conjunto todos los estimadores cumplen una cierta restricción. A este tipo de situaciones se les suele conocer como pruebas de hipótesis globales. Sin pérdida de generalidad podemos enunciar a una prueba global como:

$$\begin{aligned} H_0 : \mathbf{R}\boldsymbol{\beta} &= \mathbf{r} \\ H_a : \mathbf{R}\boldsymbol{\beta} &\neq \mathbf{r} \end{aligned}$$

Donde, $\boldsymbol{\beta}$ es el vector de parámetros del MCO de la ecuación (2.8), $\mathbf{R}$ y $\mathbf{r}$ son de la siguiente manera:

$$\mathbf{R} = \begin{bmatrix} R_{11} & R_{12} & \dots & R_{1K} \\ R_{21} & R_{22} & \dots & R_{2K} \\ R_{31} & R_{32} & \dots & R_{3K} \\ \vdots & \vdots & \dots & \vdots \\ R_{J1} & R_{J2} & \dots & R_{JK} \end{bmatrix}$$

En $\mathbf{R}$ cada una de las R_{jk} toma el valor de 1 o 0, según sea la estructura de la restricción. Con $j = 1, 2, \dots, J$. En el caso de $\mathbf{r}$:

$$\mathbf{r} = \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ \vdots \\ r_J \end{bmatrix}$$

Donde cada uno de los r_j representa el valor de la restricción que es evaluada. No debe pasar desapercibido que en este caso existen J restricciones ($J \leq K$), mismas que se evalúan de forma conjunta en una sola prueba. Esa es la ventaja de la prueba que se enuncia a continuación.

Definamos a F de Fisher como la razón de dos pruebas t de Student, la primera para los valores de una combinación lineal de $\hat{\boldsymbol{\beta}}$, y la segunda para el estimador de la varianza $\hat{\sigma}^2$:

$$\begin{aligned} \mathbf{F} &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})/J}{\hat{\sigma}^2} \\ &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \\ &= \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}Var(\hat{\boldsymbol{\beta}})\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \end{aligned}$$

Por lo tanto la estadística F de prueba será:

$$F = \frac{(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})'[\mathbf{R}\hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}\mathbf{R}']^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - \mathbf{r})}{J} \sim F_{J,N-K} \quad (2.39)$$

Así, la prueba de hipótesis que es la más común en el análisis de regresión y que se le conoce como prueba global. Dicha prueba asume una forma de la matriz $\mathbf{R}$ definida así:

$$\mathbf{R} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Y un vector $\mathbf{r}$:

$$\mathbf{r} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

De esta forma la hipótesis nula de una prueba global se puede escribir como:

$$H_0 : \quad \beta_1 = \beta_2 = \dots = \beta_K = 0$$

$$H_a : \quad NoH_0$$

Esta prueba se le conoce como prueba global, ya que prueba si en conjunto todas las variables independientes tienen un efecto nulo en $\mathbf{Y}$.

Pero ahora discutamos qué sucede cuando no se cumplen los supuestos. El primer caso es cuando no se cumple la ecuación (2.27). La respuesta es que en ese caso MCO no generará un estimador consistente. La solución a ese problema es la implementación del Método de Variables Instrumentales que discutiremos más adelante.

Por otro lado, en los casos en que existe un término de error heterocedástico, es decir, que no cumple con la ecuación (2.34), podemos corregir el problema mediante la matriz de White, la cual asume que la varianza asintótica de $\hat{\boldsymbol{\beta}}$ estará dada por:

$$\widehat{AVar}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{W}\mathbf{X})(\mathbf{X}'\mathbf{X})^{-1} \quad (2.40)$$

Donde $\mathbf{W}$ es una matriz diagonal de dimensión $N \times N$ y cada uno de los elementos de la diagonal resultan de $w_i = e_i^2$, considerando que: $e_i = y_i - \mathbf{x}_i \hat{\boldsymbol{\beta}}$. Esta matriz por la que se pondera la varianza en la ecuación (2.40) fue introducida en la econometría por White en 1980.

La heterocedasticidad modelada y corregida de esta manera se conoce como errores estándar robustos. Una vez que podemos determinar los errores estándar, tendremos la posibilidad de establecer pruebas como la t . No obstante, cuando el supuesto de la ecuación (2.32) no se cumple diremos que la prueba F usual será errónea y no será válida para probar restricciones múltiples.

En este caso nos referimos a casos como:

$$H_0 : \mathbf{R}\boldsymbol{\beta} = r$$

Donde $\mathbf{R}$ es una matriz de restricciones de dimensión $Q \times K$, con $Q \leq K$, r es un vector de dimensión $Q \times 1$. Así en casos de heterocedasticidad utilizaremos una prueba de Wald dada por:

$$\mathbf{W} = (\mathbf{R}\hat{\boldsymbol{\beta}} - r)'(\mathbf{R}\hat{\mathbf{V}}\mathbf{R}')^{-1}(\mathbf{R}\hat{\boldsymbol{\beta}} - r)$$

Donde $\hat{\mathbf{V}} = \widehat{AVar(\hat{\boldsymbol{\beta}})}$, por lo que la distribución de $\mathbf{W}$ será como:

$$\mathbf{W} \sim \chi_Q^2$$

Lo que implica que la formulación $F_{Q,N-K}$ no es de aplicación.

Otro tipo de pruebas que pueden realizarse son aquellas basadas en Multiplicadores de Lagrange. Supongamos un modelo lineal particionado de la siguiente manera:

$$y_i = \mathbf{x}_{i1}\boldsymbol{\beta}_1 + \mathbf{x}_{i2}\boldsymbol{\beta}_2 + \varepsilon \quad (2.41)$$

Donde se cumplen los supuestos dados en las ecuaciones (2.27), (2.28) y (2.32), y $\mathbf{x}_1$ y $\mathbf{x}_2$ son vectores de dimensión $1 \times K_1$ y $1 \times K_2$, respectivamente.

Supongamos que desemos probar la hipótesis de que:

$$H_0 : \boldsymbol{\beta}_2 = \mathbf{0}$$

Sea $\tilde{\boldsymbol{\beta}}_1$ el estimador de $\boldsymbol{\beta}_1$ bajo la hipótesis nula anterior, digamos que este estimador corresponde al modelo restringido. Definamos los residuales:

$$e_i = y_i - \mathbf{x}_{i1}\tilde{\boldsymbol{\beta}}_1$$

Bajo la hipótesis nula, $\mathbf{x}_{i2}$ debería ser una variable no correlacionada con e_i . En este caso la prueba estadística es obtenida como sigue:

1. Corremos una regresión de e_i en $\mathbf{x}_{i1}$ y $\mathbf{x}_{i2}$
2. Asumiendo que $\mathbf{x}_{i1}$ contiene término constante, digamos que R_E^2 denota al R^2 asociado a la regresión.
3. Entonces proponemos que la estadística de Multiplicadores de Lagrange es:

$$LM = N \cdot R_E^2$$

Para llegar a la expresión anterior se requiere de solucionar un problema de optimización.

4. Bajo la H_0 , tenemos que:

$$LM \sim \chi_{K_2}^2$$

Donde K_2 es el número de restricciones que hemos probado. De esta forma, si $N \cdot R_E^2$ es suficientemente grande, entonces e_i estaba significativamente correlacionado con $\mathbf{x}_{i2}$, por lo que la hipótesis debió ser rechazada.

En este punto debe quedar claro que R^2 requiere que $\sum_{i=1}^N e_i = 0$, lo que implica que el modelo tiene un término constante.

Veamos un ejemplo ilustrativo. Sea la siguiente ecuación:

$$\begin{aligned} \ln(\text{Salario}) = & \beta_1 + \beta_2 \text{Experiencia} + \beta_3 \text{Experiencia}^2 \\ & + \beta_4 \text{Educacion} + \beta_5 \text{Edad} + \beta_6 \text{NumHijos} + \varepsilon \end{aligned}$$

Supongamos que la hipótesis que queremos probar es:

$$H_0 : \beta_4 = \beta_5 = 0$$

2.7. Una aplicación clásica: la función de costos de la industria eléctrica

Antes de pasar a los ejercicios conviene señalar cuál es la aplicación empírica canónica del modelo de regresión múltiple, tanto por su valor histórico como porque reúne varios de los elementos que hemos discutido en este capítulo.

Nerlove (1963) [Ner63] estimó una función de costos para una muestra de empresas generadoras de electricidad en Estados Unidos, con el propósito de determinar si la industria presentaba rendimientos crecientes a escala, pregunta con implicaciones directas de política regulatoria. Partiendo de una función de producción Cobb-Douglas y del problema dual de minimización de costos, se obtiene una función de costos que, en logaritmos, resulta lineal en los parámetros:

$$\ln(Costo_i) = \beta_1 + \beta_2 \ln(Produccion_i) + \beta_3 \ln(P_i^{trabajo}) + \beta_4 \ln(P_i^{capital}) + \beta_5 \ln(P_i^{combustible}) + \varepsilon_i$$

Este ejemplo es valioso por al menos cuatro razones. Primero, la forma funcional no es arbitraria sino que **se deriva de la teoría económica**, lo cual es precisamente lo que distingue a la econometría del ajuste estadístico de curvas. Segundo, el coeficiente β_2 tiene una interpretación estructural directa, ya que $1/\beta_2$ es la medida de rendimientos a escala. Tercero, la teoría impone una restricción contrastable sobre los parámetros: la homogeneidad de grado uno en los precios de los factores exige que $\beta_3 + \beta_4 + \beta_5 = 1$, hipótesis que puede contrastarse con la prueba F de restricciones lineales que desarrollamos en este capítulo. Y cuarto, los residuales de la estimación muestran un patrón sistemático relacionado con el tamaño de la empresa, lo cual sugiere que una especificación con un único coeficiente de escala es inadecuada; esta observación motivó posteriormente el trabajo de Christensen y Greene (1976) [CG76], quienes propusieron una forma funcional translogarítmica más flexible que permite que los rendimientos a escala varíen con el nivel de producción.

Los datos y la implementación de este caso se encuentran en el cuaderno `Regresion.Lineal.ipynb` del repositorio del curso, junto con el artículo original. Se sugiere al lector estimar el modelo, contrastar la restricción de homogeneidad y examinar los residuales por tamaño de empresa antes de continuar con los ejercicios.

2.8. Ejercicios

Ahora proponemos los siguientes ejercicios:

1. Utilice el material hasta ahora expuesto en el curso para analizar y determinar si las siguientes afirmaciones son FALSAS o VERDADERAS.

- a) Cuando se realiza un proceso de estimación por el método de MCO, la suma de los errores resultantes siempre es igual a cero, es decir,

$$\sum_{i=1}^N e_i = 0$$

- b) Suponga que realiza una estimación por el método de mínimos cuadrados de la ecuación dada por $y_i = \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i$, para $i = 1, 2, \dots, N$. Asimismo, suponga que como resultado de su estimación encuentra que la estadística R^2 es muy próxima al valor de 0.5, entonces ¿se puede decir que las variables dadas por $x_{i2}, x_{i3}, \dots, x_{iK}$ explican aproximadamente la mitad de la variabilidad de la variable y_i ?
- c) Suponga que estima una ecuación de salario dada por:

$$\text{salario}_i = \beta_1 + \beta_2 \text{educa}_i + \beta_3 \text{educa}_i^2 + \beta_4 D\text{Sexo}_i + \varepsilon_i$$

Donde todas los estimadores $\hat{\beta}_k$, $k = 1, 2, 3, 4$ son estadísticamente significativos; $i = 1, 2, \dots, N$; salario_i es el ingresos mensual por sueldos y salarios de una persona; educa_i es la educación de una persona en años, y $D\text{Sexo}_i$ es una variable dummy que toma el valor de 1 si el individuo es hombre y 0 en cualquier otro caso. Asuma que los resultados indican que: $\hat{\beta}_2 > 0$ y $\hat{\beta}_3 < 0$. Entonces, ¿podemos afirmar qué existe evidencia estadística de la presencia de rendimientos marginales decrecientes de la educación en los salarios?

- d) Asuma que estima una regresión de los salarios de las personas en una cierta industria y encuentra que sus resultados son:

$$\hat{y}_i = \underset{(2.5)}{5.15} + \underset{(0.3)}{1.17} x_i$$

Donde y_i es el salario mensual en miles de pesos de las personas, y x_i es una variable dummy que toma el valor de 1 cuando el individuo i es hombre y 0 cuando es mujer. Entre paréntesis se indica los errores estándar de los estimadores (conocidos como término respectivo a $\hat{\sigma}^2(\mathbf{X}'\mathbf{X})_{kk}^{-1}$).

Entonces, existe evidencia estadística y significativa para afirmar que la mejor estimación al salario de los hombres es 5.15 mil pesos y para las mujeres es de 6.31 mil pesos.

2. Suponga que ha decidido estimar una regresión del logaritmo natural del salario en función de un conjunto de variables para un conjunto de individuos en una industria; de tal forma que obtiene los resultados mostrados en el Cuadro 2.1.

Cuadro 2.1: Resultados de la regresión de salarios

Variable	Coefficiente	Error Estándar	Estadística t
Constante	4.216	0.078	
Masculino	0.154	0.005	
Primaria	0.224	0.018	
Secundaria	0.833	0.063	
Preparatoria	0.902	0.063	
Universidad	0.550	0.065	8.462
ln(Experiencia)	0.907		22.535
Primaria×Masculino	-0.97		-1.242
Secundaria×Masculino	-0.67		-2.272
Preparatoria×Masculino	-0.72		-2.317
Universidad×Masculino	-0.146	0.076	
ln(Experiencia)×Masculino	0.041		4.891
$R^2 = 0.6032$	$F = 89.69$	$N = 1,000$	$\mathbf{e'e} = 415.37$

En donde las variables son como se describen a continuación:

- a) Masculino: es una variable binaria que toma el valor de 1 (uno) cuando el individuo es del sexo masculino y 0 (cero) en cualquier otro caso.
- b) Primaria, Secundaria, Preparatoria y Universidad: son un conjunto de variables categóricas (Dummy) que indican el nivel máximo de estudios del individuo, es decir, toman el valor de 1 si el individuo cumple con la categoría y cero si su nivel máximo de estudios es algún otro nivel. Por lo tanto hemos dejado fuera la dummy que indica nula educación.
- c) Experiencia: es una variable que indica el número de años de experiencia del individuo.

Se le solicita:

- a) Completar el Cuadro 2.1, así como indicar la hipótesis nula y alternativa asociada. También deberá determinar cuales de las variables incluidas en la regresión resultan estadísticamente significativas.
 - b) Utilizando la información de Cuadro 2.1 determine la hipótesis nula y alternativa para saber si el logaritmo natural de la experiencia es estadísticamente igual a 1. realice la prueba t asociada y concluya si se puede rechazar la hipótesis nula.
 - c) Utilizando la información de Cuadro 2.1 determine y explique cuál es el Efecto Marginal de la variable Universidad.
3. Cómo se modifica el resultado expresado en la ecuación (2.19) cuando el R^2 no es respecto de la media $\bar{y}$, es decir, cuando la variación total es como se muestra en la ecuación (2.42):

$$\sum_{i=1}^N (y_i - \bar{y})^2 = \sum_{i=1}^N (y_i - 0)^2 \quad (2.42)$$

4. Un embotellador de bebidas gaseosas analiza las rutas de servicio de las máquinas expendedoras en su sistema de distribución. Le interesa predecir el tiempo necesario para que el representante de ruta atienda las máquinas expendedoras en una tienda. Esta actividad de servicio consiste en abastecer la máquina con productos embotellados, y algo de mantenimiento o limpieza. El ingeniero industrial responsable del estudio ha sugerido que las dos variables más importantes que afectan el tiempo de entrega, y , son la cantidad de cajas de producto abastecido, x_1 , y la distancia caminada por el representante, x_2 . El ingeniero ha reunido una muestra aleatoria de algunas observaciones de tiempo de entrega.

Suponga que desea estimar la ecuación de regresión asumiendo una media condicional dada por:

$$\mu_{y_i|x_{i1},x_{i2},x_{i3}} = \beta_1 + \beta_2 x_{i2} + \beta_3 x_{i3} \quad (2.43)$$

Derivado de la operación matricial de la muestra suponga que obtiene los siguientes resultados:

$$\begin{aligned}
& \begin{bmatrix} \sum y_i^2 & \sum y_i x_{i1} & \sum y_i x_{i2} & \sum y_i x_{i3} \\ \sum x_{i1} y_i & \sum x_{i1}^2 & \sum x_{i1} x_{i2} & \sum x_{i1} x_{i3} \\ \sum x_{i2} y_i & \sum x_{i2} x_{i1} & \sum x_{i2}^2 & \sum x_{i2} x_{i3} \\ \sum x_{i3} y_i & \sum x_{i3} x_{i1} & \sum x_{i3} x_{i2} & \sum x_{i3}^2 \end{bmatrix} \\
& = \begin{bmatrix} 18310.63 & 559.60 & 7375.44 & 324972.70 \\ 559.60 & 25.00 & 219.00 & 9932.00 \\ 7375.44 & 219.00 & 3055.00 & 129099.00 \\ 324972.69 & 9932.00 & 129099.00 & 6402888.00 \end{bmatrix} \quad (2.44)
\end{aligned}$$

Al respecto:

- a) Determine los coeficientes β de regresión lineal
- b) Determine el valor de la varianza estimada de los errores: $\hat{\sigma}^2$
- c) Pruebe la hipótesis nula de que $\beta_2 = 0$ con un $\alpha = 0.05$
- d) Pruebe la hipótesis nula de que $\beta_3 = 0$ con un $\alpha = 0.05$
- e) Escriba una conclusión de las dos pruebas de hipótesis planteadas
- f) Determine el valor del R^2 asociado al caso, para ello recuerde que el procedimiento empleado para determinar la ecuación (2.19)

3

Estimación de modelos lineales de una sola ecuación por el método de Variables Instrumentales

3.1. Introducción y motivación

El método de Variables Instrumentales (VI o IV, por sus siglas en inglés) es el segundo método después de MCO más utilizado en el análisis de regresión. Principalmente, la implementación de IV bajo un procedimiento conocido como Mínimos Cuadrados Ordinarios en 2 Etapas (en inglés Two-Stage Least Squares (2SLS)). Para iniciar partamos de un modelo lineal:

$$y = \beta_1 x_1 + \dots + \beta_k x_k + \varepsilon \quad (3.1)$$

Donde asumimos que $\mathbb{E}[\varepsilon] = 0$ y $Cov[x_j, \varepsilon] = 0$, para $j = 1, 2, \dots, K - 1$. Así, asumiremos que la variable x_K es la única que está correlacionada con el término de error de forma que $Cov[x_K, \varepsilon] \neq 0$. En otras palabras, diremos que sólo las variables $x_1, x_2, \dots, x_{K-1}$ son exógenas y que potencialmente x_K es una variable endógena en la ecuación (3.1).

El método de IV provee una solución general al problema de endogeneidad de una o múltiples variables explicativas. Para utilizar el procedimiento necesitamos encontrar una variable observable z , que no esté incluida en la ecuación (3.1) y que además cumpla con las siguientes dos condiciones:

1. **Condición de exogeneidad o de exclusión.** La variable z no debe estar correlacionada con ε , es decir:

$$Cov[z, \varepsilon] = 0 \quad (3.2)$$

Es decir, que el siguiente vector de variables explicativas son exógenas: $\{x_1, x_2, \dots, x_{K-1}, z\}$.

2. **Condición de relevancia.** La proyección lineal de x_K en todas las variables exógenas estará dada por:

$$x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K \quad (3.3)$$

Donde $\mathbb{E}[\xi_K] = 0$, y ξ_K no está correlacionado con $\{x_1, x_2, \dots, x_{K-1}, z\}$ y $\theta \neq 0$.

Conviene detenerse en la naturaleza asimétrica de estas dos condiciones, ya que es una de las razones por las que el método de variables instrumentales resulta a la vez tan poderoso y tan discutido en el trabajo aplicado. La condición de relevancia de la ecuación (3.3) es **contrastable**: podemos estimar la forma reducida y probar la hipótesis $H_0 : \theta = 0$ con una prueba t ordinaria. La condición de exogeneidad de la ecuación (3.2), en cambio, **no es contrastable** cuando se dispone de un solo instrumento, precisamente porque ε no es observable. Es un supuesto de identificación que debe defenderse con argumentos teóricos, institucionales o de conocimiento del contexto, no con estadística. Como veremos más adelante, cuando el modelo está sobre-identificado sí es posible contrastar parcialmente la validez del conjunto de instrumentos, pero incluso en ese caso la prueba descansa en suponer que al menos una parte de ellos es válida.

Si $Cov(z, \varepsilon) = 0$ y $x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K$, entonces z es una variable instrumental para x_K . A la proyección $x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta z + \xi_K$ la denominaremos como la forma reducida. Si introducimos la forma reducida en la ecuación (3.1) podríamos plantear una expresión como:

$$y = \alpha_0 + \alpha_1 x_1 + \dots + \alpha_{K-1} x_{K-1} + \lambda z + \nu$$

Donde $\nu = \varepsilon + \beta_K \xi_K$ es la forma reducida del término de error, $\alpha_j = \beta_j + \beta_K \delta_j$, $\alpha_0 = \beta_K \delta_0$ y $\lambda = \beta_K \theta$.

3.2. Estimación por Mínimos Cuadrados en Dos Etapas – 2SLS

Ahora planteamos la situación del problema de estimación. Para verlo, partamos de:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \quad (3.4)$$

Asumamos:

$$\begin{aligned} \mathbf{x}_i &= (1, x_{i2}, \dots, x_{iK}) \\ \mathbf{z}_i &= (1, x_{i2}, \dots, x_{iK-1}, z) \end{aligned}$$

Donde $\mathbf{z}_i$ tiene todas las variables exógenas, por lo que cumple con:

$$\mathbb{E}[\mathbf{z}_i' \varepsilon] = \mathbf{0}$$

De esta forma, podríamos multiplicar la ecuación (3.4) por $\mathbf{z}_i$ y tomamos valor esperado, obtendríamos:

$$\begin{aligned} \mathbf{z}_i' y_i &= \mathbf{z}_i' \mathbf{x}_i \boldsymbol{\beta} + \mathbf{z}_i' \varepsilon_i \\ \mathbb{E}[\mathbf{z}' y] &= \mathbb{E}[\mathbf{z}' \mathbf{x}] \boldsymbol{\beta} + \mathbb{E}[\mathbf{z}' \varepsilon] \end{aligned}$$

Donde $\mathbf{z}' \mathbf{x}$ es de rango $K \times K$ y $\mathbf{z}' y$ es de $K \times 1$. Por lo tanto, la solución poblacional estará dada por:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= (\mathbb{E}[\mathbf{z}' \mathbf{x}])^{-1} \mathbb{E}[\mathbf{z}' y] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{z}_i' \mathbf{x}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{z}_i' y_i \right) \\ &= (\mathbf{Z}' \mathbf{X})^{-1} \mathbf{Z}' \mathbf{Y} \end{aligned}$$

Por lo tanto el estimador de Variables Instrumentales estará dado por:

$$\hat{\boldsymbol{\beta}} = (\mathbf{Z}' \mathbf{X})^{-1} \mathbf{Z}' \mathbf{Y} \quad (3.5)$$

Donde $\mathbf{Z}$ y $\mathbf{X}$, ambas, son dimensión $N \times K$. Ahora veamos un ejemplo para el caso de estimación por VI en el caso de variables omitidas puesto que la variable es no observable.

Supongamos una ecuación del logaritmo de los salarios para una muestra dada, la cual estima de la forma:

$$\ln(\text{Salario}) = \beta_1 + \beta_2 \text{Experiencia} + \beta_3 \text{Experiencia}^2 + \beta_4 \text{Educacion} + \varepsilon$$

Donde ε está correlacionado con la variable de *Educacion*, ya que en la estimación hemos omitido las variables relacionadas con la habilidad, así como otros factores, tales como calidad de la educación y los antecedentes basados en condiciones familiares.

Supongamos que ha sido posible identificar la educación de la madre, la cual no está correlacionada con el término ε , pero si lo está con los factores omitidos.

3.3. Método de Variables Instrumentales en casos con múltiples instrumentos

Consideremos un modelo como el de la ecuación (3.1), donde x_K puede estar correlacionada con el ε . Asumamos que tenemos más de una variable instrumental para x_K , las cuales:

$$\{z_1, z_2, \dots, z_M\}$$

Cada una de las variables cumple con $Cov(z_h, \varepsilon) = 0$, $h = 1, 2, \dots, M$. Así, cada una de las variables z_h es exógena, por lo que cualquier combinación lineal de:

$$\{x_1, x_2, \dots, x_{K-1}, z_1, z_2, \dots, z_M\}$$

será exógena o no estará correlacionada con ε . Digamos que el vector que incluye las variables anteriores será definido como por uno de dimensión $1 \times L$, donde $L = K + M$:

$$\mathbf{z} = (1, x_1, x_2, \dots, x_{K-1}, z_1, z_2, \dots, z_M)$$

Entonces, podemos escribir la forma reducida como:

$$x_K = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + \dots + \theta_M z_M + \xi_K$$

Dado que hemos asumido que ξ_K no está correlacionado con el resto de los regresores, entonces podemos establecer que:

$$x_K^* = \delta_0 + \delta_1 x_1 + \dots + \delta_{K-1} x_{K-1} + \theta_1 z_1 + \dots + \theta_M z_M$$

es la parte de x_K que está correlacionada con ε .

Partiendo de lo anterior podemos escribir una ecuación para $\hat{x}_K$ de la forma:

$$\hat{x}_{iK} = \hat{\delta}_0 + \hat{\delta}_1 x_{i1} + \dots + \hat{\delta}_{iK-1} x_{iK-1} + \hat{\theta}_1 z_{i1} + \dots + \hat{\theta}_M z_{iM}$$

Entonces podemos definir al vector:

$$\hat{\mathbf{x}}_K = (x_{i1}, \dots, x_{iK-1}, \hat{x}_{iK})$$

Usando lo anterior podemos utilizar el estimado de IV para determinar:

$$\begin{aligned} \hat{\beta} &= \left(\sum_{i=1}^N \hat{\mathbf{x}}_K \mathbf{x}_K' \right)^{-1} \left(\sum_{i=1}^N \hat{\mathbf{x}}_K y \right) \\ &= (\hat{\mathbf{X}}' \mathbf{X})^{-1} \hat{\mathbf{X}}' \mathbf{Y} \end{aligned} \quad (3.6)$$

Por otro lado, podemos establecer el siguiente vector:

$$\mathbf{z}_i = (1, x_{i1}, \dots, x_{iK-1}, z_{i1}, \dots, z_{iM})$$

Construyendo de forma similar a otras matrices a $\mathbf{Z}$ apilado la información de cada uno de los individuos. De esta forma podremos construir $\hat{\mathbf{X}}$ mediante el uso de un estimador de MCO:

$$\begin{aligned} \hat{\mathbf{X}} &= \mathbf{Z} \hat{\gamma} \\ &= \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{X} \end{aligned}$$

De lo anterior tendríamos que:

$$\hat{\mathbf{X}}' = \mathbf{X}' \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}'$$

Usando las expresiones anteriores en la ecuación (3.6), obtenemos que:

$$\begin{aligned} \hat{\beta} &= (\mathbf{X}' \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{X})^{-1} \hat{\mathbf{X}}' \mathbf{Y} \\ &= (\mathbf{X}' \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{Z} (\mathbf{Z}' \mathbf{Z})^{-1} \mathbf{Z}' \mathbf{X})^{-1} \hat{\mathbf{X}}' \mathbf{Y} \\ &= (\hat{\mathbf{X}}' \hat{\mathbf{X}})^{-1} \hat{\mathbf{X}}' \mathbf{Y} \end{aligned} \quad (3.7)$$

De forma similar al caso de MCO proponemos el siguiente estimador de la varianza del término de error:

$$\hat{\sigma}^2 = \sum_{i=1}^N \frac{e_i^2}{N - K} \quad (3.8)$$

Utilizando la ecuación (3.7) establecemos que la varianza de $\hat{\boldsymbol{\beta}}$ estará dada por:

$$Var(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\hat{\mathbf{X}}'\hat{\mathbf{X}})^{-1} \quad (3.9)$$

De esta forma todas las pruebas de hipótesis planteadas para MCO son aplicables.

En este punto es indispensable hacer una advertencia sobre la ecuación (3.8) que constituye uno de los errores más frecuentes al programar el procedimiento por cuenta propia. Los residuales que deben utilizarse son:

$$e_i = y_i - \mathbf{x}_i\hat{\boldsymbol{\beta}}$$

Es decir, se calculan con las variables explicativas **originales** $\mathbf{x}_i$, y *no* con los valores ajustados $\hat{\mathbf{x}}_i$ de la primera etapa. Esta es la razón por la que estimar el modelo “a mano” en dos etapas, corriendo dos regresiones sucesivas de MCO, produce coeficientes correctos pero errores estándar equivocados: la segunda regresión de MCO calcula su varianza residual con $\hat{\mathbf{x}}_i$ y por lo tanto subestima $\hat{\sigma}^2$. Por ello siempre debe utilizarse una rutina que implemente 2SLS de manera integrada.

3.4. Propiedades asintóticas del estimador de 2SLS

Hasta aquí hemos construido el estimador, pero no hemos establecido sus propiedades. Procedamos a hacerlo. Recordemos la notación: $\mathbf{x}_i$ es un vector $1 \times K$ que contiene todas las variables explicativas de la ecuación estructural (exógenas y endógenas), y $\mathbf{z}_i$ es un vector $1 \times L$ que contiene todas las variables exógenas (las incluidas en la ecuación y los instrumentos excluidos), con $L \geq K$. Definamos las matrices poblacionales:

$$\begin{aligned} \mathbf{C} &= \mathbb{E}[\mathbf{z}_i'\mathbf{x}_i] , \text{ de dimensión } L \times K \\ \boldsymbol{\Omega} &= \mathbb{E}[\mathbf{z}_i'\mathbf{z}_i] , \text{ de dimensión } L \times L \end{aligned}$$

3.4.1. Condiciones de identificación

Antes de discutir la consistencia debemos precisar bajo qué condiciones el parámetro $\boldsymbol{\beta}$ es siquiera identificable.

Definición 3.1 Condición de orden. Es necesario que el número de variables exógenas disponibles sea al menos igual al número de parámetros a estimar, es decir, $L \geq K$. De forma equivalente, el número de instrumentos excluidos debe ser al menos igual al número de variables endógenas.

Definición 3.2 Condición de rango. Es necesario y suficiente que $\text{rank}(\mathbf{C}) = \text{rank}(\mathbb{E}[\mathbf{z}'_i \mathbf{x}_i]) = K$.

La condición de orden es sólo necesaria y es trivial de verificar: basta contar variables. La condición de rango es la que verdaderamente importa y es la versión formal de la condición de relevancia de la ecuación (3.3). Su contenido sustantivo es que los instrumentos deben tener poder explicativo sobre las variables endógenas *una vez controladas las variables exógenas incluidas*. Un instrumento que estuviera perfectamente explicado por las variables exógenas del modelo no aportaría información nueva y el rango de $\mathbf{C}$ sería deficiente, aun cuando la condición de orden se cumpliera. Cuando $L = K$ decimos que el modelo está **exactamente identificado**, y cuando $L > K$ decimos que está **sobreidentificado**.

3.4.2. Consistencia

Teorema 3.1 Consistencia del estimador de 2SLS. Bajo los supuestos de que $\{(\mathbf{x}_i, \mathbf{z}_i, y_i)\}$ es una muestra aleatoria iid, que $\mathbb{E}[\mathbf{z}'_i \varepsilon_i] = \mathbf{0}$, que $\mathbf{\Omega}$ es definida positiva y que se cumple la condición de rango, entonces $\hat{\boldsymbol{\beta}}_{2SLS} \xrightarrow{p} \boldsymbol{\beta}$.

Demostración. Partamos de la ecuación (3.7), escrita en términos de la matriz de proyección $\mathbf{P}_Z = \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}'$:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}'\mathbf{P}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_Z\mathbf{Y}$$

Sustituyendo $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ y simplificando obtenemos la expresión del error de estimación:

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} = \left[\left(\frac{\mathbf{X}'\mathbf{Z}}{N} \right) \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \left(\frac{\mathbf{Z}'\mathbf{X}}{N} \right) \right]^{-1} \left(\frac{\mathbf{X}'\mathbf{Z}}{N} \right) \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \left(\frac{\mathbf{Z}'\boldsymbol{\varepsilon}}{N} \right) \quad (3.10)$$

Donde hemos dividido numeradores y denominadores por N , lo cual no altera la expresión. Por la Ley de los Grandes Números aplicada a cada uno

de los promedios muestrales:

$$\begin{aligned}\frac{\mathbf{Z}'\mathbf{X}}{N} &= N^{-1} \sum_{i=1}^N \mathbf{z}'_i \mathbf{x}_i \xrightarrow{p} \mathbf{C} \\ \frac{\mathbf{Z}'\mathbf{Z}}{N} &= N^{-1} \sum_{i=1}^N \mathbf{z}'_i \mathbf{z}_i \xrightarrow{p} \mathbf{\Omega} \\ \frac{\mathbf{Z}'\boldsymbol{\varepsilon}}{N} &= N^{-1} \sum_{i=1}^N \mathbf{z}'_i \varepsilon_i \xrightarrow{p} \mathbb{E}[\mathbf{z}'_i \varepsilon_i] = \mathbf{0}\end{aligned}$$

Aplicando el teorema de Slutsky a la ecuación (3.10):

$$\hat{\boldsymbol{\beta}} - \boldsymbol{\beta} \xrightarrow{p} (\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1} \mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{0} = \mathbf{0}$$

Donde la inversa $(\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1}$ existe precisamente por la condición de rango. ■

Notemos que la demostración deja ver con claridad cuál es el papel de cada supuesto: la condición de exogeneidad hace que el último término converja a cero, y la condición de rango garantiza que el primer factor sea una matriz finita y bien definida. Si la condición de rango falla o es apenas satisfecha, el primer factor se vuelve enorme y amplifica cualquier desviación del segundo, que es exactamente el problema de los instrumentos débiles que discutiremos enseguida.

3.4.3. Normalidad asintótica y varianza

Teorema 3.2 Normalidad asintótica del estimador de 2SLS. *Bajo los supuestos anteriores y suponiendo que $\mathbf{\Lambda} = \mathbb{E}[\varepsilon_i^2 \mathbf{z}'_i \mathbf{z}_i]$ es finita y definida positiva:*

$$\sqrt{N}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{V}) \quad (3.11)$$

Donde:

$$\mathbf{V} = (\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1} \mathbf{C}'\mathbf{\Omega}^{-1} \mathbf{\Lambda} \mathbf{\Omega}^{-1} \mathbf{C} (\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1} \quad (3.12)$$

Demostración. Multiplicando la ecuación (3.10) por $\sqrt{N}$ y reagrupando:

$$\sqrt{N}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) = \left[\left(\frac{\mathbf{X}'\mathbf{Z}}{N} \right) \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \left(\frac{\mathbf{Z}'\mathbf{X}}{N} \right) \right]^{-1} \left(\frac{\mathbf{X}'\mathbf{Z}}{N} \right) \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{z}'_i \varepsilon_i \right)$$

Por el Teorema del Límite Central aplicado al último factor, dado que $\mathbb{E}[\mathbf{z}'_i \varepsilon_i] = \mathbf{0}$:

$$N^{-1/2} \sum_{i=1}^N \mathbf{z}'_i \varepsilon_i \xrightarrow{d} Normal(\mathbf{0}, \mathbf{\Lambda})$$

Los factores restantes convergen en probabilidad a $(\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1}\mathbf{C}'\mathbf{\Omega}^{-1}$, por lo que aplicando nuevamente el teorema de Slutsky y la propiedad de que si $\mathbf{A}_N \xrightarrow{p} \mathbf{A}$ y $\mathbf{w}_N \xrightarrow{d} Normal(\mathbf{0}, \mathbf{\Lambda})$ entonces $\mathbf{A}_N \mathbf{w}_N \xrightarrow{d} Normal(\mathbf{0}, \mathbf{A}\mathbf{\Lambda}\mathbf{A}')$, obtenemos el resultado. ■

La ecuación (3.12) tiene la forma de emparedado (*sandwich*) que ya conocemos y es válida bajo heterocedasticidad de forma desconocida. Su versión muestral se obtiene sustituyendo cada matriz poblacional por su contraparte, con $\hat{\mathbf{\Lambda}} = N^{-1} \sum_{i=1}^N e_i^2 \mathbf{z}'_i \mathbf{z}_i$.

Si adicionalmente suponemos **homocedasticidad**, es decir $\mathbb{E}[\varepsilon_i^2 | \mathbf{z}_i] = \sigma^2$, entonces por la ley de esperanzas iteradas $\mathbf{\Lambda} = \sigma^2 \mathbf{\Omega}$ y la ecuación (3.12) se simplifica notablemente:

$$\mathbf{V} = \sigma^2 (\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1}$$

Cuya versión muestral, dividida entre N , es precisamente la ecuación (3.9) que ya habíamos anticipado. Esto justifica formalmente el estimador de la varianza que presentamos antes y precisa el supuesto bajo el cual es válido.

3.5. El problema de los instrumentos débiles

Los resultados anteriores son asintóticos y suponen implícitamente que la correlación entre los instrumentos y las variables endógenas es “suficientemente” distinta de cero. Cuando esa correlación es débil, aun cumpliéndose formalmente la condición de rango, el estimador de 2SLS exhibe un comportamiento en muestras finitas que puede ser catastrófico. Este es el problema de los **instrumentos débiles**, estudiado sistemáticamente por Staiger y Stock (1997) [SS97].

Para entender la intuición, consideremos el caso más simple de una variable endógena y un instrumento. El estimador de variables instrumentales puede escribirse como el cociente de dos covarianzas muestrales:

$$\hat{\beta}_{IV} = \frac{\widehat{Cov}(z, y)}{\widehat{Cov}(z, x)}$$

Si el instrumento es débil, el denominador es cercano a cero y el estimador se vuelve extremadamente sensible: pequeñas perturbaciones muestrales en el denominador producen variaciones enormes en el estimador. Las consecuencias prácticas son tres y todas son graves:

1. **Sesgo hacia MCO.** Puede demostrarse que el sesgo del estimador de 2SLS en muestras finitas es aproximadamente proporcional al sesgo de MCO dividido entre el estadístico F de la primera etapa. Es decir, con instrumentos débiles el estimador de 2SLS converge al estimador de MCO, que es precisamente el que estamos tratando de corregir. El remedio resulta peor que la enfermedad.
2. **Inferencia inválida.** La distribución asintótica normal de la ecuación (3.11) deja de ser una buena aproximación, por lo que los errores estándar convencionales subestiman gravemente la incertidumbre y las pruebas de hipótesis rechazan con mucha mayor frecuencia de la nominal.
3. **Amplificación de violaciones a la exogeneidad.** Una violación pequeña de la condición $Cov(z, \varepsilon) = 0$ produce una inconsistencia proporcional a $Cov(z, \varepsilon)/Cov(z, x)$. Con un denominador pequeño, incluso una correlación mínima del instrumento con el error genera un sesgo enorme.

La Figura 3.1 ilustra estas tres consecuencias mediante un ejercicio de simulación. En ambos paneles el valor verdadero del parámetro es el mismo y el único elemento que cambia es la fuerza del instrumento. Con un instrumento fuerte, la distribución muestral del estimador se concentra alrededor del valor verdadero. Con un instrumento débil, en cambio, la distribución se desplaza hacia el límite en probabilidad del estimador de MCO, se vuelve enormemente dispersa y desarrolla colas tan pesadas que una fracción considerable de las réplicas cae fuera del rango graficado.

El diagnóstico estándar consiste en examinar el estadístico F de la prueba conjunta de significancia de los **instrumentos excluidos** en la regresión de la primera etapa. La regla práctica más difundida, propuesta por Staiger y Stock, es que un valor de F menor a 10 debe considerarse una señal de alarma. Debe subrayarse que se trata del F de los instrumentos excluidos únicamente, no del F global de la primera etapa, que casi siempre será grande por la presencia de las variables exógenas incluidas. Stock y Yogo (2005)




Figura 3.1: Distribución muestral del estimador de 2SLS según la fuerza del instrumento

[SY05] desarrollaron valores críticos más precisos, que dependen del número de instrumentos y de la tolerancia que se esté dispuesto a aceptar respecto del sesgo o del tamaño de la prueba. En años recientes la literatura ha señalado que el umbral de 10 es insuficiente en muchos contextos y ha propuesto tanto umbrales más exigentes como procedimientos de inferencia robustos a instrumentos débiles, como la prueba de Anderson-Rubin, que es válida sin importar la fuerza del instrumento.

Una recomendación práctica adicional es reportar siempre la regresión de la primera etapa. En el trabajo aplicado moderno se considera una mala práctica presentar estimaciones por variables instrumentales sin mostrar explícitamente la fuerza y el signo de la relación entre los instrumentos y la variable endógena.

3.6. Pruebas de especificación

3.6.1. Prueba de endogeneidad de Hausman

La primera pregunta que debemos hacernos es si realmente se requiere instrumentar. Recordemos que, cuando el regresor sospechoso resulta ser exógeno, MCO es consistente y *más eficiente* que 2SLS, por lo que instrumentar innecesariamente tiene un costo en precisión. La prueba de Hausman

(1978) [Hau78] contrasta:

$$\begin{aligned} H_0 &: \mathbb{E}[\mathbf{x}'_i \varepsilon_i] = \mathbf{0}, \text{ el regresor sospechoso es exógeno} \\ H_1 &: \text{No } H_0 \end{aligned}$$

La lógica de la prueba es comparar dos estimadores: uno que es consistente bajo ambas hipótesis (2SLS) y otro que es consistente y eficiente sólo bajo la nula (MCO). Si la nula es cierta, ambos estiman lo mismo y su diferencia debe ser pequeña; si es falsa, deben diferir sistemáticamente. La estadística es:

$$H = (\hat{\boldsymbol{\beta}}_{2SLS} - \hat{\boldsymbol{\beta}}_{MCO})' \left[\widehat{Var}(\hat{\boldsymbol{\beta}}_{2SLS}) - \widehat{Var}(\hat{\boldsymbol{\beta}}_{MCO}) \right]^{-1} (\hat{\boldsymbol{\beta}}_{2SLS} - \hat{\boldsymbol{\beta}}_{MCO}) \xrightarrow{d} \chi^2_Q \quad (3.13)$$

Donde Q es el número de regresores potencialmente endógenos. El resultado clave que permite usar la *diferencia* de varianzas en la ecuación (3.13), en lugar de la varianza de la diferencia, es que bajo la nula el estimador eficiente tiene covarianza nula con la diferencia entre ambos estimadores. En muestras finitas la matriz de la diferencia puede no resultar definida positiva, en cuyo caso debe recurrirse a una inversa generalizada.

En la práctica es preferible una versión equivalente y mucho más sencilla de implementar, conocida como prueba de Durbin-Wu-Hausman basada en regresión auxiliar:

1. Estimar la primera etapa por MCO, x_{iK} contra todas las variables exógenas $\mathbf{z}_i$, y guardar los residuales $\hat{\xi}_i$.
2. Estimar por MCO la ecuación estructural aumentada:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + \rho \hat{\xi}_i + error$$

3. Contrastar $H_0 : \rho = 0$ mediante una prueba t ordinaria. Si se rechaza, hay evidencia de endogeneidad y se justifica el uso de variables instrumentales.

La intuición de esta versión es directa: los residuales de la primera etapa contienen precisamente la parte de x_{iK} que no está explicada por las variables exógenas. Si esa parte resulta significativa al explicar y_i una vez incluida x_{iK} , es porque está correlacionada con el error estructural, que es la definición misma de endogeneidad. Este procedimiento se conoce también como enfoque de función de control y lo retomaremos en el contexto de los modelos no lineales.

3.6.2. Prueba de sobreidentificación

Cuando $L > K$ disponemos de más condiciones de momento que parámetros, y esas restricciones adicionales pueden usarse para contrastar parcialmente la validez del conjunto de instrumentos. Las hipótesis son:

$$\begin{aligned} H_0 & : \mathbb{E}[\mathbf{z}_i' \varepsilon_i] = \mathbf{0} , \text{ todos los instrumentos son válidos} \\ H_1 & : \text{No } H_0 \end{aligned}$$

El procedimiento de Sargan (1958) [Sar58] es el siguiente:

1. Estimar el modelo por 2SLS y obtener los residuales $e_i = y_i - \mathbf{x}_i \hat{\beta}_{2SLS}$.
2. Estimar por MCO la regresión auxiliar de los residuales contra *todas* las variables exógenas:

$$e_i = \delta_0 + \delta_1 x_{i1} + \dots + \delta_{K-1} x_{i,K-1} + \theta_1 z_{i1} + \dots + \theta_M z_{iM} + error$$

3. Calcular la estadística de prueba a partir del coeficiente de determinación de esa regresión auxiliar:

$$S = N \cdot R^2 \xrightarrow{d} \chi^2_{L-K} \quad (3.14)$$

Los grados de libertad son $L - K$, es decir, el número de restricciones de sobreidentificación, y no el número total de instrumentos. La razón es que K de las condiciones de momento se utilizan para estimar los parámetros y se satisfacen por construcción; sólo las $L - K$ restantes constituyen información contrastable. Esto explica por qué la prueba no puede aplicarse en el caso exactamente identificado: en ese caso los residuales de 2SLS son ortogonales a todos los instrumentos por construcción, el R^2 de la regresión auxiliar es exactamente cero y no hay nada que contrastar. Bajo heterocedasticidad debe emplearse la versión de Hansen (1982) [Han82], conocida como estadística J , que utiliza la matriz de ponderadores eficiente y que ya presentamos en el contexto de GMM.

La interpretación de esta prueba exige mucho cuidado y es frecuentemente exagerada en el trabajo aplicado. Es importante entender que:

1. La prueba contrasta si los instrumentos producen estimaciones *mutuamente consistentes*, no si son válidos en términos absolutos. Si todos los instrumentos fueran inválidos exactamente en la misma dirección, la prueba no rechazaría.

2. El rechazo indica que al menos uno de los instrumentos es inválido, pero no permite identificar cuál. Formalmente, la prueba requiere suponer que al menos K de los instrumentos son válidos para poder contrastar los restantes.
3. Con instrumentos débiles la prueba tiene poco poder, por lo que no rechazar puede reflejar simplemente falta de información y no validez.

3.7. Interpretación causal: efectos heterogéneos y el LATE

Toda la discusión anterior ha supuesto implícitamente que el efecto de x_K sobre y es un parámetro constante β_K , común a todos los individuos de la población. Cuando ese supuesto de homogeneidad se relaja, la interpretación de lo que estima el método de variables instrumentales cambia de manera importante. Este es el aporte de Imbens y Angrist (1994) [IA94], que constituye uno de los puentes centrales entre la econometría tradicional y la literatura moderna de inferencia causal que abordaremos más adelante.

Consideremos el caso de un tratamiento binario D_i y un instrumento binario Z_i . Denotemos por $D_i(1)$ y $D_i(0)$ el estado de tratamiento que tendría el individuo i si el instrumento tomara el valor de 1 o de 0, respectivamente. La población puede clasificarse en cuatro grupos:

1. **Cumplidores** (*compliers*): $D_i(1) = 1$ y $D_i(0) = 0$. Reciben el tratamiento si y sólo si el instrumento los induce a ello.
2. **Siempre tomadores** (*always takers*): $D_i(1) = D_i(0) = 1$. Reciben el tratamiento sin importar el instrumento.
3. **Nunca tomadores** (*never takers*): $D_i(1) = D_i(0) = 0$. Nunca reciben el tratamiento.
4. **Desafiantes** (*defiers*): $D_i(1) = 0$ y $D_i(0) = 1$. Hacen exactamente lo contrario de lo que induce el instrumento.

Bajo cuatro supuestos, a saber: (i) independencia del instrumento respecto de los resultados potenciales y del tipo de individuo, (ii) restricción de exclusión, es decir que el instrumento afecta a y únicamente a través de D ,

(iii) relevancia, y (iv) **monotonicidad**, que consiste en suponer que no existen desafiantes, se demuestra que el estimador de variables instrumentales identifica:

$$\beta_{LATE} = \frac{\mathbb{E}[y_i | Z_i = 1] - \mathbb{E}[y_i | Z_i = 0]}{\mathbb{E}[D_i | Z_i = 1] - \mathbb{E}[D_i | Z_i = 0]} = \mathbb{E}[y_i(1) - y_i(0) | \text{cumplidor}] \quad (3.15)$$

Es decir, el **Efecto Promedio Local del Tratamiento** (LATE, por *Local Average Treatment Effect*): el efecto causal promedio, pero únicamente sobre el subgrupo de los cumplidores. La expresión intermedia de la ecuación (3.15) se conoce como estimador de Wald y tiene una lectura muy intuitiva: el numerador es el efecto del instrumento sobre el resultado, llamado efecto de forma reducida o de intención de tratar; el denominador es el efecto del instrumento sobre la probabilidad de recibir el tratamiento; y el cociente escala el primero para expresarlo por unidad de tratamiento efectivamente inducido.

Las implicaciones de este resultado son considerables y conviene tenerlas presentes. Primero, el LATE en general **no coincide** con el efecto promedio del tratamiento sobre toda la población. Segundo, el subgrupo de cumplidores no es observable y su composición depende del instrumento elegido, por lo que dos instrumentos válidos distintos aplicados al mismo problema pueden estimar consistentemente parámetros *diferentes*, sin que ello constituya una contradicción. Tercero, y como consecuencia, la relevancia de política de una estimación por variables instrumentales depende de qué tan cercano sea el grupo de cumplidores a la población sobre la que se pretende intervenir. Esta es la razón por la que en el trabajo aplicado moderno se exige caracterizar el grupo de cumplidores y discutir explícitamente la validez externa de la estimación. Para una discusión accesible y detallada véase Angrist y Pischke (2009) [AP09] y Cunningham (2021) [Cun21].

3.8. Aplicación: los orígenes coloniales del desarrollo comparado

La aplicación más influyente del método de variables instrumentales en la economía del desarrollo es la de Acemoglu, Johnson y Robinson (2001) [AJR01], cuyos datos y réplica se encuentran en el cuaderno de la clase de variables instrumentales del repositorio del curso.

La pregunta de investigación es si la calidad de las instituciones causa el desarrollo económico. La relación de interés es:

$$\log(PIB \text{ per cápita})_i = \beta_0 + \beta_1 Instituciones_i + \mathbf{x}_i\boldsymbol{\gamma} + \varepsilon_i$$

Donde las instituciones se miden mediante un índice de protección contra el riesgo de expropiación. El problema de identificación es evidente y presenta las tres formas de endogeneidad que hemos estudiado: hay **causalidad inversa**, ya que los países más ricos pueden permitirse mejores instituciones; hay **variables omitidas**, como factores culturales, geográficos o históricos que afectan simultáneamente a ambas; y hay **error de medición**, dado que cualquier índice de calidad institucional es una medida imperfecta del concepto que pretende capturar.

La estrategia de identificación de los autores es ingeniosa y descansa en un argumento histórico. Durante la colonización europea, la mortalidad que enfrentaban los colonos por enfermedades como la malaria y la fiebre amarilla determinó el tipo de asentamiento que se estableció. Donde la mortalidad era baja, los europeos se asentaron de forma permanente y replicaron instituciones de tipo inclusivo, con protección a la propiedad privada y límites al poder del gobierno. Donde la mortalidad era alta, no se establecieron de manera permanente y crearon en cambio “estados extractivos” orientados a transferir recursos a la metrópoli, con instituciones que concentraban el poder y ofrecían escasa protección a la propiedad. El argumento central es que esas instituciones coloniales persistieron tras la independencia. La cadena causal propuesta es entonces:

Mortalidad de colonos $\longrightarrow$ Tipo de asentamiento $\longrightarrow$ Instituciones coloniales $\longrightarrow$ Instituciones actuales

De esta forma, la tasa de mortalidad de los colonos en el siglo XIX se utiliza como instrumento de la calidad institucional actual. La condición de relevancia se verifica empíricamente en la primera etapa y resulta fuerte. La condición de exclusión, que como señalamos no es contrastable, requiere suponer que la mortalidad de los colonos de hace dos siglos no afecta al PIB actual por ninguna otra vía distinta de las instituciones. Los autores dedican buena parte del artículo a defender este supuesto, mostrando que el resultado es robusto a controlar por latitud, por variables climáticas, por la identidad del colonizador, por la composición religiosa y por indicadores de salud actual, así como a excluir del análisis a distintos subconjuntos de países.

Se sugiere al lector replicar la estimación y realizar los siguientes ejercicios: comparar las estimaciones por MCO y por 2SLS, observando que el coeficiente de 2SLS es *mayor* que el de MCO y discutiendo qué combinación de sesgo por variables omitidas y de atenuación por error de medición podría explicarlo; evaluar la fuerza del instrumento mediante el estadístico F de la primera etapa; y examinar críticamente la restricción de exclusión, que ha sido objeto de un debate considerable en la literatura posterior, particularmente en torno a la calidad y la comparabilidad de los datos históricos de mortalidad.

3.9. Ejercicios

En esta sección plantearemos un caso típico del método de VI. Para lo cual le pedimos seguir la discusión y realizar las actividades que se le piden. Consideremos un modelo de equilibrio de mercado (la discusión original se encuentra en el trabajo de *Working (1927). What do statistical demand curves show?. Quarterly Journal of Economics, 41 pp. 212 - 235*). Supongamos que tenemos el siguiente modelo de demanda o modelo en su forma estructural:

$$\begin{aligned} q^d &= \alpha_0 + \alpha_1 p_i + u_i \\ q^s &= \beta_0 + \beta_1 p_i + v_i \end{aligned}$$

Donde q^d es la cantidad demandada para el bien en cuestión, q^s es la cantidad ofertada, p_i es el precio de dicho bien. Los términos de error u_i y v_i representan otros factores observables que afectan o desplazan a la cantidad ofertada y a la cantidad demandada. Podemos asumir que dichos elementos u_i y v_i son factores no observables. De esta forma $\mathbb{E}[u_i] = 0$ y que $\mathbb{E}[v_i] = 0$. Adicionalmente, suponga que $Cov[u_i, v_i] = 0$ y que $q^d = q^s = q$, de tal forma que el mercado está en equilibrio, por lo que tenemos:

$$q = \alpha_0 + \alpha_1 p_i + u_i \tag{3.16}$$

$$q = \beta_0 + \beta_1 p_i + v_i \tag{3.17}$$

Ambas ecuaciones tienen problemas de endogeneidad, ya que el precio p_i es endógeno en cada una de las ecuaciones, ya que se determina simultáneamente.

Utilizando las ecuaciones (3.16) y (3.17) obtenga la ecuación de demanda:

$$q_i = \frac{\alpha_1\beta_0 - \alpha_0\beta_1}{\alpha_1 - \beta_1} + \frac{\alpha_1v_i - \beta_1u_i}{\alpha_1 - \beta_1} \quad (3.18)$$

$$p_i = \frac{\beta_0 - \alpha_0}{\alpha_1 - \beta_1} + \frac{v_i - u_i}{\alpha_1 - \beta_1} \quad (3.19)$$

De esta forma hemos obtenido dos expresiones (3.18), ecuación de demanda, y (3.19), ecuación de oferta, que representan la solución para el sistema de ecuaciones. No obstante, se puede apreciar que cada una de las variables tiene influencia del término de error de cada una de las ecuaciones, por lo que NO se pueden separar enteramente y se suele decir que tenemos un problema de endogeneidad.

A partir de la ecuación (3.19), determine la covarianza entre p_i y cada uno de los factores de cambio de la demanda (u_i) y de la oferta (v_i). Muestre que es igual a:

$$Cov(p_i, u_i) = -\frac{Var(u_i)}{\alpha_1 - \beta_1} \quad (3.20)$$

$$Cov(p_i, v_i) = \frac{Var(v_i)}{\alpha_1 - \beta_1} \quad (3.21)$$

De esta forma, el precio está correlacionado positivamente con los factores que modifican la demanda y negativamente con los factores que modifican la oferta, ello en razón de que la pendiente de la demanda es negativa ($\alpha_1 < 0$) y la de la oferta es positiva ($\beta_1 > 0$). En este caso, decimos que el problema de endogeneidad se origina por el proceso de equilibrio en el mercado.

La razón de la endogeneidad referida es que de la curva de demanda o de la curva de oferta no es posible inferir si los cambios en el nivel de precios o en las cantidades en el mercado son por causa de desplazamientos de la curva de oferta o de la curva de demanda. Esto significa que sólo es posible estimar la curva de oferta o de demanda si es posible observar alguno de los factores que determina a la demanda o la oferta.

Supongamos que el efecto del término de error en la cantidad ofertada, v_i , puede ser dividido en: los factores observables que están asociados a la demanda x_i y un factor no observable ζ_i que no está correlacionado con x_i . Es decir, que tenemos una formulación de la ecuación de oferta similar a:

$$q_i = \beta_0 + \beta_1p_i + \beta_2x_i + \zeta_i \quad (3.22)$$

De esta forma podemos decir que existe una posibilidad de que se elimine la endogeneidad, esto es, que se pueda instrumentar mediante el uso de variables asociadas a la demanda (x_i). Lo anterior, para efecto de separar del término de error la información que puede ser endógena al sistema, tal y como se muestra en la ecuación (3.22). La Figura 3.2 ilustra esta discusión para cada uno de los casos: de la demanda y de la oferta.

Esta discusión es una aplicación del Método de Variables Instrumentales (IV). Para el cual requerimos un regresor que es endógeno y que requerimos sea instrumentado. Al instrumento se le denomina variable instrumental. En este caso, es la variable x_i quien será nuestra variable instrumental. Retomemos nuestro sistema de ecuaciones de demanda y oferta. Si realizamos el mismo procedimiento de solución del sistema de ecuaciones pero considerando a la ecuación (3.22).

Dicho lo anterior, muestre que obtendríamos un sistema que quedará como sigue:

$$p_i = \frac{\beta_0 - \alpha_0}{\alpha_1 - \beta_1} + \frac{\beta_2 x_i}{\alpha_1 - \beta_1} + \frac{\zeta_i - u_i}{\alpha_1 - \beta_1} \quad (3.23)$$

$$q_i = \frac{\alpha_1 \beta_0 - \alpha_0 \beta_1}{\alpha_1 - \beta_1} + \frac{\alpha_1 \beta_2 x_i}{\alpha_1 - \beta_1} + \frac{\alpha_1 \zeta_i - \beta_1 u_i}{\alpha_1 - \beta_1} \quad (3.24)$$


En este punto, si fue posible instrumentar correctamente la variable endógena, muestre que deberá pasar que $Cov(x_i, \zeta_i) = 0$. Es decir, es esperado que no exista información endógena. Así aseguraríamos que $Cov(x_i, u_i) = 0$.

Adicionalmente al caso anterior, proponemos los siguientes ejercicios:


1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) Si un instrumento cumple la condición de relevancia, entonces necesariamente cumple la condición de exogeneidad.
 - b) La condición de exogeneidad de la ecuación (3.2) puede contrastarse estadísticamente en un modelo exactamente identificado.
 - c) Si la prueba de sobreidentificación de la ecuación (3.14) no rechaza la hipótesis nula, podemos concluir que todos los instrumentos son válidos.
 - d) Cuando el regresor sospechoso resulta ser exógeno, estimar por 2SLS sigue siendo preferible a estimar por MCO porque 2SLS es consistente en ambos casos.

Figura 3.2: Instrumentación de la información de la demanda y la oferta, respectivamente

(a) No shifts in demand



(b) No shifts in supply



- e) El estadístico F que debe reportarse para evaluar la fuerza de los instrumentos es el F global de la regresión de la primera etapa.
 - f) Dos investigadores que estudian el mismo problema con instrumentos válidos pero distintos deben obtener, asintóticamente, el mismo parámetro.
2. Partiendo de la ecuación (3.10), demuestre formalmente que en el caso exactamente identificado, $L = K$, el estimador de 2SLS de la ecuación (3.7) se reduce al estimador de variables instrumentales simple de la ecuación (3.5). Sugerencia: utilice el hecho de que en ese caso $\mathbf{Z}'\mathbf{X}$ es cuadrada y no singular.
 3. Considere el modelo simple $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$ con un único instrumento z_i . Se le solicita:
 - a) Mostrar que el estimador de variables instrumentales puede escribirse como $\hat{\beta}_1 = \widehat{Cov}(z, y) / \widehat{Cov}(z, x)$.
 - b) Obtener el límite en probabilidad de $\hat{\beta}_1$ cuando la condición de exogeneidad se viola parcialmente, es decir, cuando $Cov(z, \varepsilon) = \tau \neq 0$. Muestre que la inconsistencia es $\tau / Cov(z, x)$.
 - c) Utilizando el resultado anterior, explique formalmente por qué la combinación de un instrumento débil con una violación pequeña de la exogeneidad puede producir un estimador peor que el de MCO. Compare con la inconsistencia de MCO, que es $Cov(x, \varepsilon) / Var(x)$.
 4. Demuestre que bajo homocedasticidad, $\mathbb{E}[\varepsilon_i^2 | \mathbf{z}_i] = \sigma^2$, la matriz de varianzas de la ecuación (3.12) se reduce a $\mathbf{V} = \sigma^2(\mathbf{C}'\mathbf{\Omega}^{-1}\mathbf{C})^{-1}$. Sugerencia: aplique la ley de esperanzas iteradas para mostrar que $\mathbf{\Lambda} = \sigma^2\mathbf{\Omega}$.
 5. Explique con detalle por qué estimar 2SLS “a mano”, mediante dos regresiones sucesivas de MCO, produce coeficientes correctos pero errores estándar incorrectos. Identifique con precisión en qué punto del cálculo de la ecuación (3.8) se introduce el error y determine si los errores estándar resultantes son mayores o menores que los correctos.
 6. Considere el modelo de resultados potenciales con un tratamiento binario D_i y un instrumento binario Z_i de la ecuación (3.15). Se le solicita:

- a) Explicar el papel del supuesto de monotonicidad y construir un ejemplo económico concreto en el que dicho supuesto resulte poco plausible.
- b) Demostrar que si el efecto del tratamiento es homogéneo entre individuos, entonces el LATE coincide con el efecto promedio del tratamiento sobre toda la población.
- c) Discutir por qué la proporción de cumplidores, dada por $\mathbb{E}[D_i | Z_i = 1] - \mathbb{E}[D_i | Z_i = 0]$, es a la vez el denominador del estimador de Wald y una medida de la fuerza del instrumento.

7. **Aplicación empírica en Python.** Replique el análisis de Acemoglu, Johnson y Robinson (2001) [AJR01] con los datos disponibles en el repositorio del curso. Se le solicita:

- a) Estimar por MCO la relación entre el logaritmo del PIB per cápita y el índice de protección contra la expropiación, y reportar el resultado.
- b) Estimar la primera etapa, reportar el coeficiente de la mortalidad de los colonos y calcular el estadístico F de los instrumentos excluidos. Concluir sobre la fuerza del instrumento.
- c) Estimar por 2SLS y comparar con el resultado de MCO. Discutir por qué el coeficiente de 2SLS resulta mayor y qué combinación de sesgo por variables omitidas y de atenuación por error de medición podría explicarlo.
- d) Aplicar la prueba de Durbin-Wu-Hausman mediante la regresión auxiliar descrita en el texto y concluir sobre la presencia de endogeneidad.
- e) Verificar la robustez de los resultados incluyendo controles de latitud y de continente, y discutir cómo cada uno de ellos se relaciona con posibles violaciones de la restricción de exclusión.
- f) Construir el gráfico de la forma reducida, es decir, del logaritmo del PIB per cápita contra la mortalidad de los colonos, y explicar por qué este gráfico es informativo aun antes de estimar el modelo estructural.

8. **Aplicación empírica en Python.** Retome el modelo de salarios de la sección de introducción, en el que la educación es endógena por la

omisión de la habilidad no observada, utilizando los datos de Mroz (1987) [Mro87] disponibles en el repositorio. Se le solicita:

- a)* Estimar por MCO la ecuación de salarios y reportar el rendimiento estimado de la educación.
- b)* Estimar por 2SLS utilizando la educación de la madre y del padre como instrumentos. Verificar primero la condición de orden y evaluar la fuerza de los instrumentos.
- c)* Dado que el modelo está sobreidentificado, aplicar la prueba de Sargan de la ecuación (3.14) e interpretar el resultado con las precauciones señaladas en el texto.
- d)* Discutir críticamente la validez de la restricción de exclusión en este caso. En particular, argumente si es plausible que la educación de los padres afecte al salario de los hijos únicamente a través de su propia educación.

4

Estimación de sistemas de ecuaciones por el método de Mínimos Cuadrados Ordinarios y Mínimos Cuadrados Generalizados

4.1. Introducción a Sistemas de Ecuaciones

En esta sección analizaremos una extensión de la estimación por MCO de una sola ecuación al caso de múltiples ecuaciones para el caso de los Sistemas de Ecuaciones Aparentemente No Relacionadas (SUR). Adicionalmente, si el tiempo nos lo permite, incorporaremos el análisis de Mínimos Cuadrados Generalizados Factibles, en el cual propondremos una solución para el caso en el que existe heterocedasticidad, y para sistemas de ecuaciones con problemas de endogeneidad. Algunas de las características de esta metodología aplican al caso de los modelos de datos panel, en estricto sentido los modelos de datos panel son un caso particular de los sistemas de ecuaciones, como lo veremos más adelante.

Una aplicación clásica de este instrumental en organización industrial es la de Baker y Bresnahan (1985) [BB85], quienes estiman conjuntamente sistemas de demanda para productos diferenciados con el fin de evaluar las ganancias derivadas de una fusión o de un acuerdo colusivo, problema en el

que las ecuaciones de demanda de los distintos productos comparten choques no observados y por lo tanto deben estimarse como sistema.

Supongamos un conjunto de G ecuaciones descritas como:

$$\begin{aligned} y_1 &= \mathbf{x}_1\boldsymbol{\beta}_1 + \varepsilon_1 \\ y_2 &= \mathbf{x}_2\boldsymbol{\beta}_2 + \varepsilon_2 \\ &\vdots \\ y_G &= \mathbf{x}_G\boldsymbol{\beta}_G + \varepsilon_G \end{aligned} \tag{4.1}$$

Donde $\mathbf{x}_g$ es un vector de dimensión $1 \times K_g$, y $\boldsymbol{\beta}_g$ es un vector de dimensión $K_g \times 1$, para $g = 1, 2, \dots, G$.

En muchos casos $\mathbf{x}_g$ podría ser el mismo para cada una de las G ecuaciones y, en consecuencia, $\boldsymbol{\beta}_g$ necesariamente tiene la misma dimensión. No obstante, el modelo debe permitir que los elementos en $\mathbf{x}_g$ cambien a lo largo de las ecuaciones.

Pongamos como ejemplo un caso en el que queremos estimar funciones de demanda de las familias de un país, por ejemplo:

$$\begin{aligned} \text{Vivienda} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \\ \text{Alimentos} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \\ \text{Vestido} &= \beta_{11} + \beta_{12}\text{PrecioCasas} + \beta_{13}\text{PrecioAlimentos} \\ &\quad + \beta_{14}\text{PrecioRopa} + \beta_{15}\text{Ingreso} + \beta_{16}\text{IntHogar} + \varepsilon \end{aligned}$$

En general hemos omitido el subíndice $i = 1, 2, \dots, N$, puesto que la forma adecuada de cada ecuación sería:

$$y_{ig} = \mathbf{x}_{ig} + \varepsilon_{ig}$$

En los casos como el modelo anterior en la ecuación (4.1) asumimos que no existe endogeneidad (por razones como omisión de variables, errores estándar o simultaneidad), en particular hemos asumido que existe exogeneidad estricta:

$$\mathbb{E}[\varepsilon_g | \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_g] = 0 \text{ para } g = 1, 2, \dots, G$$

De forma general podemos decir que:

$$\mathbb{E}[y_g | \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_g] = \mathbb{E}[y_g | \mathbf{x}] = \mathbf{x}_g\boldsymbol{\beta}_g, \text{ para } g = 1, 2, \dots, G$$

4.2. Estimación de Sistemas de Ecuaciones Multivariantes

Ahora generalicemos el problema. Asumamos que tenemos observaciones de corte transversal independientes e idénticamente distribuidas:

$$\{\mathbf{X}_i, \mathbf{Y}_i; i = 1, 2, \dots, N\}$$

Donde $\mathbf{X}_i$ es una matriz $G \times K$ y $\mathbf{Y}_i$ es un vector $G \times 1$. Así, la matriz $\mathbf{X}_i$ contiene todas las variables explicativas que aparecen en el sistema, para cada uno de los individuos indexados i :

$$\mathbf{Y}_i = \mathbf{X}_i \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (4.2)$$

Donde $\boldsymbol{\beta}$ es un vector $K \times 1$ y $\boldsymbol{\varepsilon}_i$ es un vector $G \times 1$. De esta forma en general tendríamos:

$$\mathbf{Y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ \vdots \\ y_{iG} \end{bmatrix}$$

$$\boldsymbol{\varepsilon}_i = \begin{bmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \vdots \\ \varepsilon_{iG} \end{bmatrix}$$

Donde $i = 1, 2, \dots, N$.

$$\boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_G \end{bmatrix}$$

Donde:

$$\boldsymbol{\beta}_g = \begin{bmatrix} \beta_{1g} \\ \beta_{2g} \\ \vdots \\ \beta_{K_g g} \end{bmatrix}$$

Y $g = 1, 2, \dots, G$. por lo que $\boldsymbol{\beta}$ es de dimensión $(K_1 + K_2 + \dots + K_G) \times 1$, considerando que $K = K_1 + K_2 + \dots + K_G$.

Par el caso particular de un modelo de ecuaciones simultáneas aparentemente no relacionadas que no compartan variables explicativas:

$$\mathbf{x}_{ig} = [x_{i1}, x_{i2}, \dots, x_{iK_g}]$$

Así, podemos proponer que la matriz $\mathbf{X}_i$ con dimensión $G \times (K_1 + K_2 + \dots + K_G)$ es de la forma:

$$\mathbf{X}_i = \begin{bmatrix} \mathbf{x}_{i1} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{x}_{i2} & \dots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \dots & \mathbf{x}_{iG} \end{bmatrix}$$

Dado el modelo de la ecuación (4.2) establecemos las condiciones de ortogonalidad para $\boldsymbol{\beta}$ como el supuesto:

$$\mathbb{E}[\mathbf{X}_i' \boldsymbol{\epsilon}_i] = \mathbf{0} \quad (4.3)$$

Dado este supuesto obtenemos que:

$$\begin{aligned} \mathbb{E}[\boldsymbol{\epsilon}_i] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\epsilon}_{ig} | \mathbf{X}_i] &= 0 \text{ para } g = 1, 2, \dots, G \end{aligned}$$

Bajo este supuesto de ortogonalidad entonces:

$$\begin{aligned} \mathbb{E}[\mathbf{X}_i' \boldsymbol{\epsilon}_i] &= \mathbb{E}[\mathbf{X}_i' (\mathbf{Y}_i - \mathbf{X}_i \boldsymbol{\beta})] \\ \mathbb{E}[\mathbf{X}_i' \mathbf{Y}_i] &= \mathbb{E}[\mathbf{X}_i' \mathbf{X}_i] \boldsymbol{\beta} \end{aligned}$$

Donde la expresión anterior implica que $\mathbf{X}_i' \mathbf{Y}_i$ es de dimensión $X \times 1$ y $\mathbf{X}_i' \mathbf{X}_i$ es de dimensión $K \times K$ y no es una matriz singular.

De esta forma, el estimador $\boldsymbol{\beta}$ de sistemas de ecuaciones será:

$$\begin{aligned} \hat{\boldsymbol{\beta}} &= \mathbb{E}[\mathbf{X}_i' \mathbf{X}_i]^{-1} \mathbb{E}[\mathbf{X}_i' \mathbf{Y}_i] \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{X}_i' \mathbf{Y}_i \right) \\ &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{Y} \end{aligned}$$

Donde $\mathbf{X}$ es una matriz $NG \times K$ y $\mathbf{Y}$ es un vector de $NG \times 1$. En este punto podemos enunciar el siguiente teorema:

Teorema 4.1 *Consistencia del Sistema OLS.* Bajo los supuestos anteriores $\hat{\beta} \xrightarrow{p} \beta$

De forma similar al caso de MCO requerimos establecer una distribución para $\hat{\beta}$, partamos de:

$$\begin{aligned}\sqrt{N}(\hat{\beta} - \beta) &= \sqrt{N}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} - \beta) \\ &= \sqrt{N}((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \varepsilon) - \beta) \\ &= \sqrt{N}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon_i \\ &= \left(N^{-1} \sum_{i=1}^N \mathbf{x}_i' \mathbf{x}_i \right)^{-1} \left(N^{-1/2} \sum_{i=1}^N \mathbf{x}_i' \varepsilon_i \right)\end{aligned}$$

De esta forma, por el Teorema del Límite Central:

$$N^{-1/2} \sum_{i=1}^N \mathbf{x}_i' \varepsilon_i \xrightarrow{d} N(0, \Sigma)$$

Donde $\Sigma = \mathbb{E}[\mathbf{X}'\varepsilon\varepsilon'\mathbf{X}] = Var(\mathbf{X}'\varepsilon)$. Así, si el modelo es homocedástico:

$$\Sigma = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (4.4)$$

$$Var(\hat{\beta}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1} \quad (4.5)$$

Donde:

$$\hat{\sigma}^2 = \frac{\mathbf{e}'\mathbf{e}}{N - K}$$

Finalmente, podemos establecer las mismas pruebas de hipótesis que en el caso de MCO.

Si el modelo tiene heterocedasticidad la varianza asintótica de $\hat{\beta}$ estará dada por:

$$\begin{aligned}Var(\hat{\beta} | \mathbf{X}) &= Var(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}) \\ &= Var(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'(\mathbf{X}\beta + \varepsilon)) \\ &= Var(\beta + (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon) \\ &= Var((\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\varepsilon) \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'Var(\varepsilon)\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1} \\ &= (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\Sigma\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\end{aligned}$$

Donde,

$$Var(\boldsymbol{\varepsilon}) = \sigma^2 \boldsymbol{\Omega} = \boldsymbol{\Sigma}$$

Por lo que es posible recuperar el caso sin heterocedasticidad, ya que $\boldsymbol{\Sigma} = \mathbf{I}_N$, de forma que: $Var(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_N$, el caso homocedástico.

4.3. Mínimos Cuadrados Generalizados

Como vimos en la sección anterior, podemos generalizar un modelo de regresión lineal como la ecuación:

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$

Donde el número de elementos o individuos en la muestra es N (segmentada de la forma que sea, en el caso de un sistema de ecuaciones) y el número de variables en $\mathbf{X}$ es K (segmenta de la forma que sea). Asimismo, del cual asumimos que se cumplen:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}|\mathbf{X}] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}'|\mathbf{X}] &= \boldsymbol{\Sigma} = \sigma^2 \boldsymbol{\Omega}\end{aligned}$$

En general, $\boldsymbol{\Sigma}$ puede contener elementos que nos indiquen un problema de heterocedasticidad y autocorrelación. Sin embargo, para nuestro caso utilizaremos como supuesto que el modelo sólo tienen heterocedasticidad, de esta forma enfrentaremos un caso en el que la matriz estará dada por:

$$\begin{aligned}\boldsymbol{\Sigma} &= \sigma^2 \boldsymbol{\Omega} \\ &= \begin{bmatrix} \sigma_1^2 & 0 & \dots & 0 \\ 0 & \sigma_2^2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_N^2 \end{bmatrix} \\ &= \sigma^2 \begin{bmatrix} \omega_1 & 0 & \dots & 0 \\ 0 & \omega_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \omega_N \end{bmatrix}\end{aligned}$$

No debe pasar desapercibido que en el caso de que en el modelo exista autocorrelación es posible que enfrentemos una matriz como:

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho_1 & \dots & \rho_{N-1} \\ \rho_1 & \sigma_2^2 & \dots & \rho_{N-2} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{N-1} & \rho_{N-2} & \dots & \sigma_N^2 \end{bmatrix}$$

En estos casos es cuando necesitamos un procedimiento del tipo de Mínimos Cuadrados Generalizados. El método consiste en un algoritmo que asume que:

$$\Omega^{-1} = \mathbf{P}'\mathbf{P}$$

Donde, $\mathbf{P}$ es una matriz no singular y no necesariamente única. Por ahora no nos preocuparemos como se genera una matriz como $\mathbf{P}$. Digamos Ω es definida positiva.

Dicho lo anterior:

$$\begin{aligned} \Omega &= (\mathbf{P}'\mathbf{P})^{-1} \\ &= \mathbf{P}^{-1}(\mathbf{P}')^{-1} \\ \mathbf{P}\Omega\mathbf{P}' &= \mathbf{P}\mathbf{P}^{-1}(\mathbf{P}')^{-1}\mathbf{P}' \\ &= \mathbf{I}_N \end{aligned}$$

Ahora, si multiplicamos a ε por la matriz $\mathbf{P}$ de forma que:

$$\begin{aligned} \mathbb{E}[\mathbf{P}\varepsilon \mid \mathbf{X}] &= \mathbf{P}\mathbb{E}[\varepsilon \mid \mathbf{X}] \\ &= 0 \\ Var(\mathbf{P}\varepsilon \mid \mathbf{X}) &= \mathbf{P}Var(\varepsilon \mid \mathbf{X})\mathbf{P}' \\ &= \mathbf{P}\Sigma\mathbf{P}' \\ &= \sigma^2\mathbf{P}\Omega\mathbf{P}' \\ &= \sigma^2\mathbf{I}_N \end{aligned}$$

En otras palabras, $\mathbf{P}\varepsilon$ satisface las condiciones del teorema Gauss - Markov. Consecuentemente, podemos establecer un nuevo modelo lineal como:

$$\begin{aligned} \mathbf{P}\mathbf{Y} &= \mathbf{P}\mathbf{X}\boldsymbol{\beta} + \mathbf{P}\varepsilon \\ \mathbf{Y}_* &= \mathbf{X}_*\boldsymbol{\beta} + \varepsilon_* \end{aligned} \tag{4.6}$$

Así, los supuestos necesarios para resolver el problema de regresión en la ecuación (4.6) son:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}_* | \mathbf{X}_*] &= \mathbf{0} \\ \mathbb{E}[\boldsymbol{\varepsilon}_* \boldsymbol{\varepsilon}_*' | \mathbf{X}_*] &= \sigma^2 \mathbb{I}_N\end{aligned}$$

La explicación para este último resultado es que:

$$\begin{aligned}\mathbb{E}[\boldsymbol{\varepsilon}_* \boldsymbol{\varepsilon}_*' | \mathbf{X}_*] &= \mathbb{E}[\mathbf{P} \boldsymbol{\varepsilon} \boldsymbol{\varepsilon}' \mathbf{P}' | \mathbf{X}] \\ &= \mathbf{P} \mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}' | \mathbf{X}] \mathbf{P}' \\ &= \mathbf{P} \boldsymbol{\Sigma} \mathbf{P}' \\ &= \sigma^2 \mathbb{I}_N\end{aligned}$$

Bajo esta condición, veríamos que el estimador de Mínimos Cuadrados estará dado por:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{X}_*' \mathbf{X}_*)^{-1} \mathbf{X}_*' \mathbf{Y}_* \\ &= (\mathbf{X}' \mathbf{P}' \mathbf{P} \mathbf{X})^{-1} \mathbf{X}' \mathbf{P}' \mathbf{P} \mathbf{Y} \\ &= (\mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{Y}\end{aligned}\tag{4.7}$$

Una ventaja de usar este planteamiento de la ecuación (4.7) es que no tenemos que derivar más estimadores y resultados que los conocidos, ya que si $\mathbf{Y}_* = \mathbf{X}_* \boldsymbol{\beta} + \boldsymbol{\varepsilon}_*$, entonces:

$$\begin{aligned}\mathbb{E}[\hat{\boldsymbol{\beta}} | \mathbf{X}] &= \mathbb{E}[(\mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{Y}] \\ &= \mathbb{E}[(\mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{X})^{-1} \mathbf{X}' \boldsymbol{\Sigma}^{-1} (\mathbf{X} \boldsymbol{\beta} + \boldsymbol{\varepsilon})] \\ &= \boldsymbol{\beta}\end{aligned}$$

De forma similar, al caso de MCO, en el caso de MCG bajo el escenario de la ecuación (4.7):

$$\begin{aligned}Var(\hat{\boldsymbol{\beta}} | \mathbf{X}) &= \sigma^2 (\mathbf{X}_*' \mathbf{X}_*)^{-1} \\ &= \sigma^2 (\mathbf{X}' \mathbf{P}' \mathbf{P} \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}' \boldsymbol{\Sigma}^{-1} \mathbf{X})^{-1}\end{aligned}$$

Donde σ^2 puede ser estimado, a su vez, como:

$$\begin{aligned}
\hat{\sigma}^2 &= \frac{\mathbf{e}'_* \mathbf{e}_*}{N - K} \\
&= \frac{1}{N - K} (\mathbf{Y}_* - \mathbf{X}_* \hat{\boldsymbol{\beta}})' (\mathbf{Y}_* - \mathbf{X}_* \hat{\boldsymbol{\beta}}) \\
&= \frac{1}{N - K} (\mathbf{Y}'_* - \hat{\boldsymbol{\beta}}' \mathbf{X}'_*) (\mathbf{Y}_* - \mathbf{X}_* \hat{\boldsymbol{\beta}}) \\
&= \frac{1}{N - K} (\mathbf{Y}' \mathbf{P}' - \hat{\boldsymbol{\beta}}' \mathbf{X}' \mathbf{P}') (\mathbf{P} \mathbf{Y} - \mathbf{P} \mathbf{X} \hat{\boldsymbol{\beta}}) \\
&= \frac{1}{N - K} (\mathbf{Y}' - \hat{\boldsymbol{\beta}}' \mathbf{X}') \mathbf{P}' \mathbf{P} (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}) \\
&= \frac{1}{N - K} (\mathbf{Y}' - \hat{\boldsymbol{\beta}}' \mathbf{X}') \boldsymbol{\Sigma}^{-1} (\mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}) \\
&= \frac{\mathbf{e}' \boldsymbol{\Sigma}^{-1} \mathbf{e}}{N - K}
\end{aligned}$$

Resultado que es invariante a la elección de $\mathbf{P}$ y, en consecuencia, de $\boldsymbol{\Sigma}$. Notemos que, claramente, sólo podemos estimar mediante MCG (o GLS) si la matriz $\boldsymbol{\Sigma}$ es conocida. En la práctica, este no es el caso típico, por lo que debemos estimar primero una versión de $\boldsymbol{\Sigma}$, denominada $\hat{\boldsymbol{\Sigma}}$. Así, definamos al estimador de Mínimos Cuadrados Generalizados Factibles (MCGF) al siguiente:

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}' \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{X})^{-1} \mathbf{X}' \hat{\boldsymbol{\Sigma}}^{-1} \mathbf{Y}$$

Entonces el procedimiento consiste en determinar o estimar a $\hat{\boldsymbol{\Sigma}}$, para lo cual debemos seguir el siguiente algoritmo:

1. Asumamos una forma funcional de σ_i^2 :

$$\sigma_i^2 = \sigma^2 f(\mathbf{z}_i)$$

Donde $\mathbf{z}_i$ es un conjunto de variables que pueden explicar la heterocedasticidad.

2. Estimamos $\hat{\sigma}_i^2$, asumiendo que $\sigma_i^2 = e_i^2$, que provienen de una regresión de mínimos cuadrados ordinarios:

$$\mathbf{e} = \mathbf{Y} - \mathbf{X} \hat{\boldsymbol{\beta}}$$

3. Determinamos cada elemento de la diagonal de la matriz $\hat{\Sigma}$ será como se describe en el inciso 2.

4. Estimamos:

$$\hat{\beta} = (\mathbf{X}'\hat{\Sigma}^{-1}\mathbf{X})^{-1}\mathbf{X}'\hat{\Sigma}^{-1}\mathbf{Y}$$

En este punto la única incógnita es cómo determinar si el modelo tiene heterocedasticidad. Para lo cual planteamos una hipótesis dada por:

$$\begin{aligned} H_0 &: \sigma_i^2 = \sigma^2, \forall i \\ H_1 &: \text{No } H_0 \end{aligned}$$

Para probar la hipótesis anterior vamos a utilizar una prueba de Breusch-Pagan / Godfrey que está basada en una prueba LM. Esta prueba asume que $\sigma_i^2 = \sigma^2 f(\mathbf{z}_i)$ y propone como estadística a:

$$LM = 1/2 \cdot \begin{bmatrix} \frac{e_1^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \\ \frac{e_2^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \\ \vdots \\ \frac{e_N^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \end{bmatrix}' \mathbf{Z}(\mathbf{Z}'\mathbf{Z})^{-1}\mathbf{Z}' \begin{bmatrix} \frac{e_1^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \\ \frac{e_2^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \\ \vdots \\ \frac{e_N^2}{\frac{\mathbf{e}'\mathbf{e}}{N}} - 1 \end{bmatrix} \quad (4.8)$$

Donde la ecuación (4.8) se distribuye como:

$$LM \sim \chi^2_{[\text{Número de variables en } \mathbf{Z}]}$$

Notemos que es una convención utilizar una forma funcional de la varianza a:

$$\sigma_i^2 = \sigma^2 \cdot e^{\mathbf{z}_i\gamma}$$

4.4. Sistemas de Ecuaciones Aparentemente No Relacionadas (SUR)

Con el instrumental de Mínimos Cuadrados Generalizados ya desarrollado podemos regresar al caso que anunciamos al inicio del capítulo: los Sistemas de Ecuaciones Aparentemente No Relacionadas, o SUR por sus siglas en inglés (*Seemingly Unrelated Regressions*), propuestos originalmente por Zellner (1962) [Zel62].

4.4.1. Motivación

Consideremos G ecuaciones que, vistas una por una, parecen no tener relación entre sí: cada una tiene su propia variable dependiente y su propio conjunto de variables explicativas, y ninguna variable dependiente aparece del lado derecho de otra ecuación. Por ejemplo, podríamos estar interesados en las funciones de inversión de G empresas distintas:

$$\begin{aligned} Inversion_{i1} &= \beta_{01} + \beta_{11}Valor_{i1} + \beta_{21}Capital_{i1} + \varepsilon_{i1} \\ Inversion_{i2} &= \beta_{02} + \beta_{12}Valor_{i2} + \beta_{22}Capital_{i2} + \varepsilon_{i2} \\ &\vdots \\ Inversion_{iG} &= \beta_{0G} + \beta_{1G}Valor_{iG} + \beta_{2G}Capital_{iG} + \varepsilon_{iG} \end{aligned}$$

Aparentemente no hay ninguna relación entre las ecuaciones y, por lo tanto, la intuición sugiere estimar cada una por separado mediante MCO. Sin embargo, las empresas comparten un entorno común: un choque macroeconómico, un cambio en la tasa de interés o una recesión afectan simultáneamente las decisiones de inversión de todas ellas. Ese componente común no observado queda recogido en los errores, de modo que:

$$\mathbb{E}[\varepsilon_{ig}\varepsilon_{ih}] = \sigma_{gh} \neq 0, \text{ para } g \neq h$$

A esta situación la llamamos **correlación contemporánea** de los errores, y es precisamente la “relación” que las ecuaciones sí guardan entre sí, aunque no sea evidente a simple vista. De ahí el nombre: las ecuaciones son *aparentemente* no relacionadas. La idea central de Zellner es que esa correlación contiene información que MCO ecuación por ecuación desperdicia, y que puede aprovecharse para obtener estimadores más eficientes.

4.4.2. Planteamiento del modelo

Retomemos la notación de la ecuación (4.2), donde para cada individuo $i = 1, 2, \dots, N$ tenemos $\mathbf{Y}_i = \mathbf{X}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i$, con $\mathbf{X}_i$ una matriz $G \times K$ de la forma diagonal por bloques:

$$\mathbf{X}_i = \begin{bmatrix} \mathbf{x}_{i1} & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{0} & \mathbf{x}_{i2} & \dots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \dots & \mathbf{x}_{iG} \end{bmatrix}$$

Esta estructura diagonal por bloques es lo que formaliza la idea de que cada ecuación tiene su propio conjunto de regresores $\mathbf{x}_{ig}$ de dimensión $1 \times K_g$, y su propio vector de parámetros β_g de dimensión $K_g \times 1$, con $K = K_1 + K_2 + \dots + K_G$.

Los supuestos del modelo SUR son los siguientes:

1. **Exogeneidad.** $\mathbb{E}[\boldsymbol{\varepsilon}_i \mid \mathbf{X}_i] = \mathbf{0}$, lo cual implica la condición de ortogonalidad de la ecuación (4.3).
2. **Estructura de la varianza.** La matriz de varianzas y covarianzas contemporáneas de los errores es constante entre individuos:

$$\mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_i' \mid \mathbf{X}_i] = \boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} & \dots & \sigma_{1G} \\ \sigma_{21} & \sigma_2^2 & \dots & \sigma_{2G} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{G1} & \sigma_{G2} & \dots & \sigma_G^2 \end{bmatrix} \quad (4.9)$$

Donde $\boldsymbol{\Sigma}$ es de dimensión $G \times G$, simétrica y definida positiva.

3. **Independencia entre individuos.** $\mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_j'] = \mathbf{0}$ para $i \neq j$.
4. **Identificación.** La matriz $\mathbb{E}[\mathbf{X}_i' \boldsymbol{\Sigma}^{-1} \mathbf{X}_i]$ es no singular.

Notemos que el supuesto 2 es exactamente el punto donde el modelo SUR se aparta de MCO ecuación por ecuación: se permite que $\boldsymbol{\Sigma}$ tenga elementos fuera de la diagonal distintos de cero. Bajo los supuestos 2 y 3, la matriz de varianzas y covarianzas del vector apilado completo $\boldsymbol{\varepsilon}$, de dimensión $NG \times 1$, es:

$$\mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}'] = \mathbf{I}_N \otimes \boldsymbol{\Sigma} \quad (4.10)$$

Donde $\otimes$ denota el producto de Kronecker. Es decir, se trata de una matriz diagonal por bloques de dimensión $NG \times NG$ en la que cada bloque de la diagonal es $\boldsymbol{\Sigma}$. Esta es precisamente la situación que motiva el uso de Mínimos Cuadrados Generalizados: la matriz de varianzas y covarianzas de los errores no es escalar.

4.4.3. El estimador SUR

Aplicando el resultado de la ecuación (4.7) con $\boldsymbol{\Sigma}$ sustituida por $\mathbf{I}_N \otimes \boldsymbol{\Sigma}$, obtenemos el estimador de Mínimos Cuadrados Generalizados para este

sistema, al que llamamos estimador SUR:

$$\begin{aligned}\hat{\beta}_{SUR} &= (\mathbf{X}'(\mathbf{I}_N \otimes \Sigma)^{-1}\mathbf{X})^{-1} \mathbf{X}'(\mathbf{I}_N \otimes \Sigma)^{-1}\mathbf{Y} \\ &= \left(\sum_{i=1}^N \mathbf{X}_i' \Sigma^{-1} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i' \Sigma^{-1} \mathbf{Y}_i \right)\end{aligned}\quad (4.11)$$

Donde la segunda igualdad se obtiene de notar que $(\mathbf{I}_N \otimes \Sigma)^{-1} = \mathbf{I}_N \otimes \Sigma^{-1}$ y de desarrollar los productos matriciales por bloques. La ecuación (4.11) tiene una lectura intuitiva: cada observación se pondera por la inversa de la matriz de varianzas y covarianzas contemporáneas, de modo que las ecuaciones con errores de menor varianza reciben mayor peso, y la información contenida en las covarianzas cruzadas se incorpora al estimador.

Bajo los supuestos anteriores puede demostrarse que este estimador es consistente y asintóticamente normal:

$$\sqrt{N}(\hat{\beta}_{SUR} - \beta) \xrightarrow{d} Normal\left(\mathbf{0}, (\mathbb{E}[\mathbf{X}_i' \Sigma^{-1} \mathbf{X}_i])^{-1}\right) \quad (4.12)$$

De donde la matriz de varianzas y covarianzas estimada del estimador es:

$$\widehat{Var}(\hat{\beta}_{SUR}) = \left(\sum_{i=1}^N \mathbf{X}_i' \hat{\Sigma}^{-1} \mathbf{X}_i \right)^{-1}$$

4.4.4. Estimación factible: SUR en dos etapas

Como sucede siempre en el contexto de MCG, la matriz Σ es desconocida y debe estimarse. El procedimiento factible (MCGF) consiste en el siguiente algoritmo:

1. Estimar cada una de las G ecuaciones por separado mediante MCO y obtener los residuales $\hat{\varepsilon}_{ig} = y_{ig} - \mathbf{x}_{ig}' \hat{\beta}_g^{MCO}$, para $g = 1, 2, \dots, G$.
2. Construir un estimador consistente de cada elemento de Σ :

$$\hat{\sigma}_{gh} = \frac{1}{N} \sum_{i=1}^N \hat{\varepsilon}_{ig} \hat{\varepsilon}_{ih} \quad (4.13)$$

Con lo que se forma la matriz $\hat{\Sigma} = N^{-1} \sum_{i=1}^N \hat{\varepsilon}_i \hat{\varepsilon}_i'$. Algunos textos y paquetes estadísticos utilizan una corrección por grados de libertad y dividen entre $N - K_g$ o entre $\sqrt{(N - K_g)(N - K_h)}$; la elección no afecta las propiedades asintóticas del estimador.

3. Sustituir $\hat{\Sigma}$ en la ecuación (4.11) para obtener el estimador SUR factible:

$$\hat{\beta}_{SUR} = \left(\sum_{i=1}^N \mathbf{X}_i' \hat{\Sigma}^{-1} \mathbf{X}_i \right)^{-1} \left(\sum_{i=1}^N \mathbf{X}_i' \hat{\Sigma}^{-1} \mathbf{Y}_i \right) \quad (4.14)$$

En principio el procedimiento puede iterarse: con $\hat{\beta}_{SUR}$ se calculan nuevos residuales, se reestima $\hat{\Sigma}$ y se repite hasta la convergencia. Al procedimiento resultante se le conoce como SUR iterado y, cuando converge, coincide con el estimador de máxima verosimilitud bajo el supuesto de normalidad de los errores. En muestras grandes las tres versiones (SUR factible, SUR iterado y máxima verosimilitud) son asintóticamente equivalentes.

4.4.5. ¿Cuándo vale la pena estimar por SUR?

Existen dos casos importantes en los que el estimador SUR coincide exactamente con la estimación por MCO ecuación por ecuación, es decir, en los que no se gana nada al utilizar el procedimiento.

Teorema 4.2 Equivalencia entre SUR y MCO. *El estimador SUR de la ecuación (4.11) es numéricamente idéntico al estimador de MCO aplicado ecuación por ecuación si se cumple cualquiera de las dos condiciones siguientes:*

- (a) *La matriz Σ es diagonal, es decir, $\sigma_{gh} = 0$ para todo $g \neq h$.*
- (b) *Todas las ecuaciones tienen exactamente el mismo conjunto de variables explicativas, es decir, $\mathbf{x}_{i1} = \mathbf{x}_{i2} = \dots = \mathbf{x}_{iG} = \mathbf{x}_i$.*

Demostración del caso (a). Si Σ es diagonal, entonces Σ^{-1} también lo es, con elementos $1/\sigma_g^2$ en la diagonal. Dado que $\mathbf{X}_i$ es diagonal por bloques, el producto $\mathbf{X}_i' \Sigma^{-1} \mathbf{X}_i$ resulta ser diagonal por bloques, con el bloque g -ésimo igual a $\mathbf{x}_{ig}' \mathbf{x}_{ig} / \sigma_g^2$. Análogamente, el bloque g -ésimo de $\mathbf{X}_i' \Sigma^{-1} \mathbf{Y}_i$ es $\mathbf{x}_{ig}' y_{ig} / \sigma_g^2$. Al invertir una matriz diagonal por bloques y multiplicar, el sistema se separa por completo y el bloque g -ésimo del estimador es:

$$\hat{\beta}_{g,SUR} = \left(\sum_{i=1}^N \frac{\mathbf{x}_{ig}' \mathbf{x}_{ig}}{\sigma_g^2} \right)^{-1} \left(\sum_{i=1}^N \frac{\mathbf{x}_{ig}' y_{ig}}{\sigma_g^2} \right) = \left(\sum_{i=1}^N \mathbf{x}_{ig}' \mathbf{x}_{ig} \right)^{-1} \left(\sum_{i=1}^N \mathbf{x}_{ig}' y_{ig} \right) = \hat{\beta}_g^{MCO}$$

Puesto que el escalar $1/\sigma_g^2$ se cancela. ■

Demostración del caso (b). Si todas las ecuaciones comparten los mismos $K_g = M$ regresores, la matriz diagonal por bloques puede escribirse de forma compacta usando el producto de Kronecker como $\mathbf{X}_i = \mathbf{I}_G \otimes \mathbf{x}_i$. Utilizando la regla del producto mixto de Kronecker, $(\mathbf{A} \otimes \mathbf{B})(\mathbf{C} \otimes \mathbf{D}) = \mathbf{AC} \otimes \mathbf{BD}$, tenemos:

$$\mathbf{X}_i' \Sigma^{-1} \mathbf{X}_i = (\mathbf{I}_G \otimes \mathbf{x}_i') (\Sigma^{-1} \otimes \mathbf{1}) (\mathbf{I}_G \otimes \mathbf{x}_i) = \Sigma^{-1} \otimes \mathbf{x}_i' \mathbf{x}_i$$

Sumando sobre i y denotando por $\mathbf{X}$ a la matriz $N \times M$ que apila los $\mathbf{x}_i$, obtenemos $\sum_{i=1}^N \mathbf{X}_i' \Sigma^{-1} \mathbf{X}_i = \Sigma^{-1} \otimes \mathbf{X}' \mathbf{X}$, cuya inversa es $\Sigma \otimes (\mathbf{X}' \mathbf{X})^{-1}$. De forma similar, el segundo término es:

$$\sum_{i=1}^N \mathbf{X}_i' \Sigma^{-1} \mathbf{Y}_i = \sum_{i=1}^N (\Sigma^{-1} \otimes \mathbf{x}_i') \mathbf{Y}_i = (\Sigma^{-1} \otimes \mathbf{I}_M) \sum_{i=1}^N (\mathbf{I}_G \otimes \mathbf{x}_i') \mathbf{Y}_i$$

Sustituyendo ambos resultados en la ecuación (4.11) y aplicando nuevamente la regla del producto mixto:

$$\begin{aligned} \hat{\beta}_{SUR} &= [\Sigma \otimes (\mathbf{X}' \mathbf{X})^{-1}] (\Sigma^{-1} \otimes \mathbf{I}_M) \sum_{i=1}^N (\mathbf{I}_G \otimes \mathbf{x}_i') \mathbf{Y}_i \\ &= [\Sigma \Sigma^{-1} \otimes (\mathbf{X}' \mathbf{X})^{-1} \mathbf{I}_M] \sum_{i=1}^N (\mathbf{I}_G \otimes \mathbf{x}_i') \mathbf{Y}_i \\ &= [\mathbf{I}_G \otimes (\mathbf{X}' \mathbf{X})^{-1}] \sum_{i=1}^N (\mathbf{I}_G \otimes \mathbf{x}_i') \mathbf{Y}_i \end{aligned}$$

Lo cual es exactamente la estimación por MCO ecuación por ecuación, ya que el bloque g -ésimo es $(\mathbf{X}' \mathbf{X})^{-1} \sum_{i=1}^N \mathbf{x}_i' y_{ig}$. Notemos que Σ desaparece por completo del estimador, independientemente de qué tan correlacionados estén los errores. ■

Este segundo resultado es importante en la práctica y con frecuencia se pasa por alto: por muy alta que sea la correlación contemporánea entre los errores, si todas las ecuaciones comparten los mismos regresores no hay ganancia alguna en estimar por SUR. De los dos resultados anteriores se desprende la intuición sobre cuándo el procedimiento resulta más útil. Las ganancias de eficiencia de SUR respecto de MCO son mayores cuando:

1. La correlación entre los errores de las distintas ecuaciones, σ_{gh} , es alta en valor absoluto.

2. Los conjuntos de variables explicativas de las distintas ecuaciones son muy diferentes entre sí, es decir, la correlación entre los regresores de las distintas ecuaciones es baja.

Debemos hacer una advertencia sobre el tamaño de muestra. La matriz $\hat{\Sigma}$ tiene $G(G+1)/2$ elementos distintos que estimar, y para que sea invertible se requiere al menos $N \geq G$. Cuando G es grande en relación con N , el error de estimación de $\hat{\Sigma}$ puede ser tan grande que el estimador SUR factible resulte, en muestras finitas, peor que MCO, a pesar de su superioridad asintótica.

4.4.6. Prueba de diagonalidad de Σ

Dado el resultado del caso (a) del teorema anterior, antes de estimar por SUR conviene contrastar formalmente si la matriz Σ es diagonal. Las hipótesis son:

$$\begin{aligned} H_0 &: \sigma_{gh} = 0, \forall g \neq h \\ H_1 &: \text{No } H_0 \end{aligned}$$

Bajo la hipótesis nula, MCO ecuación por ecuación es eficiente y no hay motivo para recurrir a SUR. Para contrastarla utilizamos la prueba del Multiplicador de Lagrange de Breusch y Pagan, construida a partir de los residuales de las G regresiones estimadas por MCO. Definamos el coeficiente de correlación muestral entre los residuales de las ecuaciones g y h :

$$r_{gh} = \frac{\hat{\sigma}_{gh}}{\sqrt{\hat{\sigma}_{gg}\hat{\sigma}_{hh}}}$$

Donde los $\hat{\sigma}_{gh}$ se obtienen de la ecuación (4.13). La estadística de prueba es:

$$LM = N \sum_{g=2}^G \sum_{h=1}^{g-1} r_{gh}^2 \xrightarrow{d} \chi_{G(G-1)/2}^2 \quad (4.15)$$

Donde los grados de libertad, $G(G-1)/2$, corresponden al número de covarianzas distintas fuera de la diagonal que se están contrastando. Si la estadística de la ecuación (4.15) excede el valor crítico, rechazamos la hipótesis nula de diagonalidad y concluimos que la estimación por SUR es preferible a MCO.

4.4.7. Aplicación: las funciones de inversión de Grunfeld

El ejemplo clásico de aplicación de SUR es el conjunto de datos de inversión de Grunfeld, construido en la tesis doctoral de Yehuda Grunfeld y difundido a partir de Grunfeld y Griliches (1960) [GG60], que utilizamos también en el capítulo de datos panel y que puede consultarse en el cuaderno `Panel.Data.Grunfeld.Investment.ipynb` del repositorio del curso. Los datos contienen información anual, de 1935 a 1954, sobre la inversión bruta, el valor de mercado de la empresa y el acervo de capital instalado para un conjunto de grandes empresas estadounidenses. El modelo para cada empresa g es:

$$Inversion_{tg} = \beta_{0g} + \beta_{1g}Valor_{tg} + \beta_{2g}Capital_{tg} + \varepsilon_{tg}$$

Este caso reúne las condiciones que hacen atractivo el uso de SUR. Por un lado, las empresas operan en la misma economía y en el mismo periodo, por lo que los choques agregados (la Gran Depresión, la Segunda Guerra Mundial, el ciclo de la inversión) generan correlación contemporánea entre los errores. Por otro lado, cada empresa tiene sus propios valores de mercado y acervos de capital, por lo que los regresores no coinciden entre ecuaciones y, en consecuencia, no estamos en el caso (b) del teorema. Se sugiere al lector estimar el sistema por ambos métodos y comparar los errores estándar resultantes, así como aplicar la prueba de la ecuación (4.15) antes de decidir el método de estimación.

Vale la pena señalar una conexión que retomaremos en el siguiente capítulo: el modelo de datos panel puede verse como un caso particular de un sistema de ecuaciones en el que las G ecuaciones corresponden a los T periodos de tiempo (o a los N individuos, según cómo se organice la información) y en el que se imponen restricciones de igualdad sobre los coeficientes. En ese sentido, el instrumental de MCG y SUR que hemos desarrollado aquí es la base de los estimadores de efectos fijos y efectos aleatorios.

4.5. Estimación de Sistemas de Ecuaciones con Variables Instrumentales

El enfoque moderno para la estimación del sistema con variables instrumentales se basa en el principio del método generalizado de momentos

(GMM). Una clase relacionada de estimadores cae bajo el título de variables instrumentales generalizadas (GIV). También veremos que el estimador GIV, debido a su dependencia de una transformación similar a GLS, es inconsistente en algunos casos importantes cuando GMM permanece consistente.

Partamos de un modelo lineal:

$$\mathbf{Y}_i = \mathbf{X}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (4.16)$$

Donde $\mathbf{X}_i$ es una matriz $G \times K$ y $\mathbf{Y}_i$ es un vector $G \times 1$. Así, la matriz $\mathbf{X}_i$ contiene todas las variables explicativas que aparecen en el sistema, para cada uno de los individuos indexados i .

De forma similar al caso de Variables Instrumentales, podemos asumir que:

$$\mathbb{E}[\mathbf{Z}'_i\boldsymbol{\varepsilon}_i] = \mathbf{0}$$

Donde $\mathbf{Z}_i$ es una matriz $G \times L$ de variables instrumentales y $L \geq K$. También asumiremos que la matriz siguiente es de rango completo:

$$\text{rank}\mathbb{E}[\mathbf{Z}'_i\mathbf{X}_i] = K$$

El proceso de estimación que plantearemos aquí es el del Método Generalizado de Momentos (GMM, por sus siglas en inglés). De esta forma proponemos que la condición del momento poblacional que plantearemos es:

$$\mathbb{E}[\mathbf{Z}'_i(\mathbf{Y}_i - \mathbf{X}_i\boldsymbol{\beta})] = \mathbf{0} \quad (4.17)$$

De esta forma nuestra propuesta de solución será aquella dada por elegir el estimador $\hat{\boldsymbol{\beta}}$ que resulta de:

$$N^{-1} \sum_{i=1}^N \mathbf{Z}'_i(\mathbf{Y}_i - \mathbf{X}_i\hat{\boldsymbol{\beta}}) = \mathbf{0} \quad (4.18)$$

La ecuación (4.18) es un conjunto de L ecuaciones con K incógnitas. Para analizar este caso primero consideremos el caso en el que $L = K$, es decir, estamos en un caso de Variables Instrumentales pero para un sistema de ecuaciones. En este caso sabemos que la matriz siguiente que resulta de despejar $\hat{\boldsymbol{\beta}}$ en (4.18) es de dimensión $K \times K$ y es no singular:

$$\hat{\boldsymbol{\beta}} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i\mathbf{X}_i \right)^{-1} \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i\mathbf{Y}_i \right) \quad (4.19)$$

Lo cual podemos reescribir en forma matricial como:

$$\hat{\beta} = (\mathbf{Z}'\mathbf{X})^{-1} \mathbf{Z}'\mathbf{Y} \quad (4.20)$$

Donde, por ser un sistema de ecuaciones, $\mathbf{Z}$ es una matriz de $N \times G \times L$ obtenida por el apilamiento de cada $\mathbf{Z}_i$, para $i = 1, 2, \dots, N$, $\mathbf{X}$ es una matriz de $N \times G \times K$ obtenida por el apilamiento de cada $\mathbf{X}_i$, para $i = 1, 2, \dots, N$ y $\mathbf{Y}$ es un vector de $N \times G \times 1$ obtenido por el apilamiento de cada $\mathbf{Y}_i$, para $i = 1, 2, \dots, N$. De esta forma la ecuación (4.20) es un estimado de Variables Instrumentales para un sistema de ecuaciones.

¿Qué sucede cuando $L > K$? En esos casos tenemos más columnas en la matriz de variables instrumentales $\mathbf{Z}$ que las necesarias para poder identificar el sistema. Es decir, elegir $\hat{\beta}$ es más complicado. En estos casos proponemos obtener un estimador generado mediante la creación de una matriz de pesos ("weighting matrix") en la forma cuadrática siguiente.

Sea $\hat{\mathbf{W}}$ una matriz simétrica definida positiva, definamos el estimador de GMM de $\hat{\beta}$ como aquel que resulta de resolver el problema:

$$\min_{\beta} \left[\sum_{i=1}^N \mathbf{Z}_i'(\mathbf{Y}_i - \mathbf{X}_i\beta) \right]' \hat{\mathbf{W}} \left[\sum_{i=1}^N \mathbf{Z}_i'(\mathbf{Y}_i - \mathbf{X}_i\beta) \right] \quad (4.21)$$

Dado que la ecuación (4.21) es una forma cuadrática función de β , la solución es una solución cerrada. Veamos el procedimiento con detalle.

Definamos la función de momentos muestrales, que es un vector de dimensión $L \times 1$:

$$\mathbf{g}(\beta) = \sum_{i=1}^N \mathbf{Z}_i'(\mathbf{Y}_i - \mathbf{X}_i\beta) = \mathbf{Z}'\mathbf{Y} - \mathbf{Z}'\mathbf{X}\beta \quad (4.22)$$

Donde la segunda igualdad se obtiene del apilamiento de las matrices, puesto que $\sum_{i=1}^N \mathbf{Z}_i'\mathbf{Y}_i = \mathbf{Z}'\mathbf{Y}$ y $\sum_{i=1}^N \mathbf{Z}_i'\mathbf{X}_i = \mathbf{Z}'\mathbf{X}$. Con esta notación, el problema (4.21) se escribe de forma compacta como:

$$\min_{\beta} Q(\beta) = \mathbf{g}(\beta)'\hat{\mathbf{W}}\mathbf{g}(\beta)$$

Sustituyendo la ecuación (4.22) y desarrollando el producto obtenemos:

$$\begin{aligned} Q(\beta) &= (\mathbf{Z}'\mathbf{Y} - \mathbf{Z}'\mathbf{X}\beta)'\hat{\mathbf{W}}(\mathbf{Z}'\mathbf{Y} - \mathbf{Z}'\mathbf{X}\beta) \\ &= \mathbf{Y}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} - \mathbf{Y}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\beta - \beta'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} + \beta'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\beta \\ &= \mathbf{Y}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} - 2\beta'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} + \beta'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\beta \end{aligned} \quad (4.23)$$

La tercera igualdad utiliza dos hechos. Primero, que los dos términos centrales son escalares, por lo que cada uno es igual a su propia transpuesta. Segundo, que $\hat{\mathbf{W}}$ es simétrica, es decir $\hat{\mathbf{W}}' = \hat{\mathbf{W}}$, de donde:

$$(\mathbf{Y}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\boldsymbol{\beta})' = \boldsymbol{\beta}'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}'\mathbf{Z}'\mathbf{Y} = \boldsymbol{\beta}'\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y}$$

Por lo que ambos términos son idénticos y se suman en uno solo multiplicado por 2.

Ahora obtengamos la condición de primer orden. Recordemos dos reglas de derivación matricial: si $\mathbf{a}$ es un vector de constantes, $\frac{\partial(\boldsymbol{\beta}'\mathbf{a})}{\partial\boldsymbol{\beta}} = \mathbf{a}$; y si $\mathbf{A}$ es una matriz simétrica de constantes, $\frac{\partial(\boldsymbol{\beta}'\mathbf{A}\boldsymbol{\beta})}{\partial\boldsymbol{\beta}} = 2\mathbf{A}\boldsymbol{\beta}$. Notemos que en nuestro caso $\mathbf{A} = \mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}$ efectivamente es simétrica, ya que $\mathbf{A}' = \mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}'\mathbf{Z}'\mathbf{X} = \mathbf{A}$. Aplicando estas reglas a la ecuación (4.23):

$$\left. \frac{\partial Q(\boldsymbol{\beta})}{\partial\boldsymbol{\beta}} \right|_{\boldsymbol{\beta}=\hat{\boldsymbol{\beta}}} = -2\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} + 2\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{0} \quad (4.24)$$

Reordenando la ecuación (4.24) llegamos al sistema de K ecuaciones normales:

$$\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} \quad (4.25)$$

Notemos que la matriz $\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}$ es de dimensión $K \times K$ y es no singular. En efecto, dado que $\hat{\mathbf{W}}$ es definida positiva, podemos escribirla como $\hat{\mathbf{W}} = \mathbf{P}'\mathbf{P}$ para alguna matriz $\mathbf{P}$ no singular, de modo que $\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X} = (\mathbf{P}\mathbf{Z}'\mathbf{X})'(\mathbf{P}\mathbf{Z}'\mathbf{X})$, la cual es definida positiva siempre que $\mathbf{P}\mathbf{Z}'\mathbf{X}$ tenga rango columna completo. Esto último se cumple por el supuesto de rango $\text{rank}\mathbb{E}[\mathbf{Z}_i'\mathbf{X}_i] = K$, que es precisamente la condición de identificación del sistema. De esta forma podemos premultiplicar la ecuación (4.25) por la inversa de dicha matriz, con lo que la solución estará dada por:

$$\hat{\boldsymbol{\beta}} = \left(\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} \right) \quad (4.26)$$

Finalmente, verifiquemos la condición de segundo orden. Derivando nuevamente la ecuación (4.24) obtenemos el hessiano:

$$\frac{\partial^2 Q(\boldsymbol{\beta})}{\partial\boldsymbol{\beta}\partial\boldsymbol{\beta}'} = 2\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X}$$

El cual, por el mismo argumento anterior, es una matriz definida positiva. Por lo tanto, $\hat{\boldsymbol{\beta}}$ en la ecuación (4.26) es efectivamente un mínimo global de $Q(\boldsymbol{\beta})$, y es único.

Vale la pena hacer dos observaciones sobre este resultado. La primera es que el caso exactamente identificado que analizamos antes es un caso particular de la ecuación (4.26). Cuando $L = K$, la matriz $\mathbf{Z}'\mathbf{X}$ es cuadrada y no singular, por lo que:

$$\hat{\beta} = \left(\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{X} \right)^{-1} \mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} = (\mathbf{Z}'\mathbf{X})^{-1}\hat{\mathbf{W}}^{-1}(\mathbf{X}'\mathbf{Z})^{-1}\mathbf{X}'\mathbf{Z}\hat{\mathbf{W}}\mathbf{Z}'\mathbf{Y} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{Y}$$

Es decir, recuperamos la ecuación (4.20) y, más importante aún, la elección de $\hat{\mathbf{W}}$ resulta irrelevante: cuando el sistema está exactamente identificado todas las matrices de ponderadores conducen al mismo estimador. La elección de $\hat{\mathbf{W}}$ sólo importa en el caso sobreidentificado, $L > K$.

La segunda observación es que, si bien cualquier $\hat{\mathbf{W}}$ simétrica y definida positiva produce un estimador consistente, no todas producen un estimador igualmente eficiente. Puede demostrarse (véase Wooldridge (2010) [Woo10], capítulo 8, y Hayashi (2000) [Hay00], capítulo 3) que la elección óptima es:

$$\hat{\mathbf{W}}^* = (\mathbb{E}[\mathbf{Z}'_i \boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}'_i \mathbf{Z}_i])^{-1} = \boldsymbol{\Lambda}^{-1} \quad (4.27)$$

Es decir, la inversa de la matriz de varianzas y covarianzas de las condiciones de momento. Con esta elección, la varianza asintótica del estimador alcanza la cota inferior de la clase de estimadores GMM y está dada por:

$$AVar\sqrt{N}(\hat{\beta} - \beta) = (\mathbf{C}'\boldsymbol{\Lambda}^{-1}\mathbf{C})^{-1}, \quad \text{con } \mathbf{C} = \mathbb{E}[\mathbf{Z}'_i \mathbf{X}_i] \quad (4.28)$$

En la práctica $\boldsymbol{\Lambda}$ es desconocida y se estima en dos etapas: primero se obtiene un estimador consistente pero no necesariamente eficiente $\tilde{\beta}$ (por ejemplo, con $\hat{\mathbf{W}} = (\mathbf{Z}'\mathbf{Z}/N)^{-1}$), se calculan los residuales $\hat{\varepsilon}_i = \mathbf{Y}_i - \mathbf{X}_i\tilde{\beta}$ y se construye $\hat{\boldsymbol{\Lambda}} = N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \hat{\varepsilon}_i \hat{\varepsilon}'_i \mathbf{Z}_i$. Este procedimiento se conoce como GMM en dos etapas o GMM eficiente. Como veremos enseguida, los estimadores de 2SLS y 3SLS para sistemas de ecuaciones son casos particulares de la ecuación (4.26) que corresponden a elecciones específicas de $\hat{\mathbf{W}}$, las cuales resultan óptimas sólo bajo supuestos adicionales sobre la estructura de $\boldsymbol{\Lambda}$.

4.5.1. Estimación de un sistema por Mínimos Cuadros en Dos Etapas (2SLS)

Una forma de seleccionar a $\hat{\mathbf{W}}$ es la siguiente:

$$\hat{\mathbf{W}} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \mathbf{Z}_i \right)^{-1} = \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \quad (4.29)$$

Donde la ecuación (4.29) es un estimador consistente de $\mathbb{E}[\mathbf{Z}'_i \mathbf{Z}_i]^{-1}$. Reemplazando la ecuación (4.29) en la ecuación (4.26) podemos obtener:

$$\begin{aligned}
\hat{\beta} &= \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \\
&= \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{Y} \right) \\
&= \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} (\mathbf{Z}'\mathbf{Z}) (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} (\mathbf{Z}'\mathbf{Z})^{-1} \mathbf{Z}'\mathbf{Y} \right) \\
&= \left(\hat{\mathbf{X}}'\hat{\mathbf{X}} \right)^{-1} \hat{\mathbf{X}}'\mathbf{Y} \tag{4.30}
\end{aligned}$$

A la ecuación (4.30) la conocemos como el estimador de 2SLS para un sistema de ecuaciones.

4.5.2. Estimación de un sistema por Mínimos Cuadrados en Tres Etapas (3SLS)

En algunos casos el estimador GMM se usa con una forma particular de ponderadores. Así podemos definir el estimador de Mínimos Cuadrados en Tres Etapas, 3SLS. Sean los residuales de una estimación inicial, usualmente, de un 2SLS:

$$\mathbf{e}_i = \mathbf{Y}_i - \mathbf{X}_i \hat{\beta}$$

Definamos la matriz $G \times G$ como

$$\hat{\Sigma} = N^{-1} \sum_{i=1}^N \mathbf{e}_i \mathbf{e}_i' \tag{4.31}$$

Usando los mismos argumentos de Mínimos Cuadrados Generalizados Factibles, podemos proponer que:

$$\hat{\mathbf{W}} = \left(N^{-1} \sum_{i=1}^N \mathbf{Z}'_i \hat{\Sigma} \mathbf{Z}_i \right)^{-1} = \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\Sigma})\mathbf{Z}}{N} \right)^{-1} \tag{4.32}$$

Donde $\mathbf{I}_N$ es la matriz identidad. Sustituyendo la ecuación (4.32) en la

ecuación (4.26) podemos obtener:

$$\begin{aligned}\hat{\beta} &= \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\Sigma})\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\frac{\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\Sigma})\mathbf{Z}}{N} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \\ &= \left(\mathbf{X}'\mathbf{Z} \left(\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\Sigma})\mathbf{Z} \right)^{-1} \mathbf{Z}'\mathbf{X} \right)^{-1} \left(\mathbf{X}'\mathbf{Z} \left(\mathbf{Z}'(\mathbf{I}_N \otimes \hat{\Sigma})\mathbf{Z} \right)^{-1} \mathbf{Z}'\mathbf{Y} \right) \quad (4.33)\end{aligned}$$

A la ecuación (4.33) la conocemos como el estimador de 3SLS para un sistema de ecuaciones.

Conviene cerrar con una observación sobre la eficiencia de los dos estimadores anteriores. Como señalamos al discutir la ecuación (4.27), la matriz de ponderadores óptima es $\mathbf{\Lambda}^{-1} = (\mathbb{E}[\mathbf{Z}_i'\boldsymbol{\varepsilon}_i\boldsymbol{\varepsilon}_i'\mathbf{Z}_i])^{-1}$. La elección de la ecuación (4.29), que da lugar al 2SLS, es óptima únicamente si $\mathbb{E}[\boldsymbol{\varepsilon}_i\boldsymbol{\varepsilon}_i' | \mathbf{Z}_i] = \sigma^2\mathbf{I}_G$, es decir, bajo homocedasticidad y ausencia de correlación entre las ecuaciones del sistema. La elección de la ecuación (4.32), que da lugar al 3SLS, relaja el segundo requisito y es óptima si $\mathbb{E}[\boldsymbol{\varepsilon}_i\boldsymbol{\varepsilon}_i' | \mathbf{Z}_i] = \Sigma$, esto es, permite correlación contemporánea entre ecuaciones pero exige que la matriz de varianzas y covarianzas no dependa de los instrumentos. Cuando ninguno de los dos supuestos es defendible, el estimador de GMM en dos etapas con $\hat{\mathbf{\Lambda}}^{-1}$ domina a ambos.

Notemos además la simetría con lo que vimos en la sección de SUR: así como el estimador SUR se reduce a MCO ecuación por ecuación cuando Σ es diagonal, el estimador 3SLS se reduce al 2SLS ecuación por ecuación cuando Σ es diagonal. En ambos casos, la ganancia proviene exclusivamente de explotar la correlación contemporánea entre las ecuaciones del sistema. Finalmente, cabe advertir un costo del 3SLS que no tiene el 2SLS: al estimarse el sistema de forma conjunta, un error de especificación en una sola de las ecuaciones contamina los estimadores de *todas* las demás, mientras que el 2SLS ecuación por ecuación mantiene el problema confinado a la ecuación mal especificada. Esta es la razón por la que, en trabajo aplicado, muchos autores reportan ambos conjuntos de resultados.

4.6. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Utilice el material expuesto en este capítulo para analizar y determinar si las siguientes afirmaciones son FALSAS o VERDADERAS. En todos los casos justifique su respuesta.
 - a) Si los errores de las distintas ecuaciones de un sistema están fuertemente correlacionados de forma contemporánea, entonces siempre se obtiene una ganancia de eficiencia al estimar el sistema por SUR en lugar de estimar cada ecuación por MCO.
 - b) El estimador de Mínimos Cuadrados Generalizados Factibles es insesgado en muestras finitas.
 - c) En un sistema de ecuaciones exactamente identificado, $L = K$, la elección de la matriz de ponderadores $\hat{\mathbf{W}}$ modifica el valor numérico del estimador de GMM.
 - d) El estimador de 3SLS siempre es al menos tan eficiente como el de 2SLS, sin importar la estructura de $\mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_i' \mid \mathbf{Z}_i]$.
 - e) Si en la prueba de Breusch-Pagan de la ecuación (4.15) no se rechaza la hipótesis nula, entonces es preferible estimar el sistema ecuación por ecuación mediante MCO.
2. Considere un sistema de $G = 2$ ecuaciones con la estructura SUR de la ecuación (4.2) y asuma que:

$$\boldsymbol{\Sigma} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

Se le solicita:

- a) Obtenga explícitamente $\boldsymbol{\Sigma}^{-1}$ en términos de σ_1^2 , σ_2^2 y σ_{12} , e indique qué condición debe cumplirse para que la inversa exista.
 - b) Escriba el estimador $\hat{\boldsymbol{\beta}}_{SUR}$ de la ecuación (4.11) desarrollando por completo los productos matriciales por bloques.
 - c) Verifique de manera directa, a partir de la expresión obtenida en el inciso anterior, que si $\sigma_{12} = 0$ el estimador se reduce a la estimación por MCO de cada ecuación.
3. Demuestre el resultado de la ecuación (4.10), es decir, que bajo los supuestos 2 y 3 del modelo SUR la matriz de varianzas y covarianzas del vector apilado de errores es $\mathbb{E}[\boldsymbol{\varepsilon} \boldsymbol{\varepsilon}'] = \mathbf{I}_N \otimes \boldsymbol{\Sigma}$. Muestre además

que $(\mathbf{I}_N \otimes \mathbf{\Sigma})^{-1} = \mathbf{I}_N \otimes \mathbf{\Sigma}^{-1}$ y explique por qué este resultado hace computacionalmente viable la estimación por SUR aun cuando la matriz completa sea de dimensión $NG \times NG$.

4. Retome el problema de minimización de la ecuación (4.21) y se le solicita:
 - a) Reproduzca la obtención de la condición de primer orden (4.24) explicando cada paso de derivación matricial que se emplea.
 - b) Demuestre que si $\hat{\mathbf{W}}_1$ y $\hat{\mathbf{W}}_2 = c\hat{\mathbf{W}}_1$, con $c > 0$ un escalar, entonces ambas matrices de ponderadores producen exactamente el mismo estimador. ¿Qué implica este resultado sobre la normalización de $\hat{\mathbf{W}}$?
 - c) Verifique que la elección de la ecuación (4.29) coincide con la matriz óptima de la ecuación (4.27) cuando $\mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_i' | \mathbf{Z}_i] = \sigma^2 \mathbf{I}_G$.
5. **Prueba de sobreidentificación.** Cuando $L > K$ el sistema impone más condiciones de momento que parámetros a estimar, por lo que las $L - K$ condiciones restantes pueden utilizarse para contrastar la validez del conjunto de instrumentos. La estadística de Sargan-Hansen (Sargan (1958) [Sar58] y Hansen (1982) [Han82]) se define como el valor de la función objetivo evaluada en el óptimo con la matriz de ponderadores eficiente:

$$J = N \cdot \left[N^{-1} \sum_{i=1}^N \mathbf{Z}_i' \hat{\boldsymbol{\varepsilon}}_i \right]' \hat{\mathbf{\Lambda}}^{-1} \left[N^{-1} \sum_{i=1}^N \mathbf{Z}_i' \hat{\boldsymbol{\varepsilon}}_i \right] \xrightarrow{d} \chi_{L-K}^2$$

Se le solicita: (i) explicar por qué los grados de libertad son $L - K$ y no L ; (ii) explicar por qué la prueba no puede aplicarse en el caso exactamente identificado; y (iii) discutir, con cuidado, qué se puede y qué no se puede concluir cuando la prueba rechaza la hipótesis nula. En particular, discuta por qué el rechazo no permite identificar *cuál* de los instrumentos es inválido.

6. **Aplicación empírica en Python.** Utilice el conjunto de datos de inversión de Grunfeld disponible en el repositorio del curso y estime el sistema de funciones de inversión descrito en la sección de SUR. Se le solicita:

- a) Estimar cada ecuación por separado mediante MCO y reportar los coeficientes y errores estándar.
- b) Construir la matriz $\hat{\Sigma}$ de acuerdo con la ecuación (4.13) y reportar la matriz de correlaciones de los residuales.
- c) Aplicar la prueba del Multiplicador de Lagrange de la ecuación (4.15) y concluir si se justifica la estimación por SUR.
- d) Estimar el sistema por SUR factible, ecuación (4.14), y comparar los errores estándar con los del inciso (a). ¿En qué ecuaciones la ganancia de eficiencia es mayor? ¿Es consistente el resultado con la discusión sobre cuándo conviene usar SUR?
- e) Repetir el ejercicio agregando artificialmente a todas las ecuaciones el mismo conjunto de regresores y verificar numéricamente el resultado del caso (b) del teorema de equivalencia entre SUR y MCO.

7. **Aplicación empírica en Python.** Retome el modelo de ecuaciones simultáneas de oferta y demanda de trabajo de mujeres casadas basado en Mroz (1987) [Mro87], que se desarrolla en el cuaderno `Estimating Simultaneous Models.ipynb` del repositorio del curso. Se le solicita:

- a) Establecer con claridad cuáles son las variables endógenas, cuáles las exógenas y cuáles los instrumentos disponibles en cada ecuación, y verificar la condición de orden de identificación de cada una.
- b) Estimar el sistema por 2SLS ecuación por ecuación y posteriormente por 3SLS, según las ecuaciones (4.30) y (4.33).
- c) Comparar los coeficientes y errores estándar de ambas estimaciones. Discutir si la ganancia de eficiencia observada justifica el riesgo de contaminación por especificación errónea que señalamos al final de la sección anterior.
- d) Estimar además el sistema por MCO e interpretar la dirección del sesgo de simultaneidad al comparar con las estimaciones por variables instrumentales.

5

Modelos de Datos Panel

5.1. Introducción y motivación

Datos panel es un caso particular del problema de sistemas de ecuaciones, no obstante, le dedicaremos una sección de estas notas. Un conjunto de datos longitudinales o conjunto de datos panel tiene múltiples observaciones para un número dado de unidades de sección cruzada. Como su nombre lo sugiere un panel tiene dos dimensiones:

1. La primera para las observaciones de sección cruzada
2. La segunda para otro tipo de observaciones, por ejemplo, tiempo u otra característica

En adelante utilizaremos 'grupo' para identificar a la unidad de sección cruzada.

La motivación principal para el concepto de datos panel es el componente de error del modelo o **sesgo por omisión de información relevante** contenida en el término de error. Esta información puede ser observable o no observable. Condición que da lugar a dos modelos tradicionales de datos panel.

El primer tipo de error está relacionado con información que no cambia a través de la segunda dimensión (por ejemplo, a través del tiempo) y que está capturada por el término de error. Este tipo de información relevante omitida no se puede solucionar por el método de variables instrumentales, puesto que no existen instrumentos como tal. A este planteamiento se le conoce como **efecto fijo**.

De forma similar existe un **efecto aleatorio** que está contenido en el término de error y no es capturado por ninguno de los regresores empleados. Es decir, es información del término de error que no está correlacionada con los regresores.

Así, la principal diferencia entre ambos planteamientos, como mostraremos más adelante es si la información omitida está correlacionada con los regresores o no.

5.2. Modelos y métodos de estimación

Antes de continuar conviene advertir un cambio de notación respecto del resto del documento, que anunciamos en el capítulo primero. En los demás capítulos N denota el tamaño de la muestra; aquí, en cambio, la muestra tiene dos dimensiones y usaremos:

- n para el número de **grupos** o unidades de sección cruzada, indexados con i .
- M para el número de **observaciones por grupo** a lo largo de la segunda dimensión, indexadas con m .
- En consecuencia, el número total de observaciones es nM , y aparecerá como tal en las correcciones de grados de libertad.

Del mismo modo, y como también advertimos en el capítulo primero, en este capítulo y en el de sistemas de ecuaciones $\mathbf{x}_i$ deja de ser un vector renglón y pasa a ser una **matriz**, porque cada grupo aporta varias observaciones. Por ello aquí sí escribiremos su transpuesta cuando corresponda.

Al igual que en casos anteriores supondremos que la muestra de datos es una muestra aleatoria. De esta forma tendremos que para cada una de las unidades o grupos de individuos $i = 1, 2, \dots, n$ tendremos M observaciones que corresponden con la segunda dimensión de nuestro panel de datos:

$$\mathbf{y}_i = \begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix}$$

$$\mathbf{x}_i = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix}$$

Así, para cada grupo tendremos M ecuaciones expresadas como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \varepsilon_{i1} \\ \varepsilon_{i2} \\ \varepsilon_{i3} \\ \vdots \\ \varepsilon_{iM} \end{bmatrix}$$

$$\mathbf{y}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \quad (5.1)$$

Donde:

$$\mathbb{E}[\boldsymbol{\varepsilon}_i \cdot \mathbf{x}_i] = 0$$

Así, al igual que en el caso del planteamiento del modelo lineal clásico, en datos panel asumiremos una serie de supuestos:

1. Diremos que el modelo será lineal en sus parámetros: $\mathbf{y}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\varepsilon}_i$
2. Asumiremos que la matriz $\mathbf{x}_i$ es de rango completo $M \times K$
3. Esperamos que las variables incluidas como regresores sean exógenas, es decir, $\mathbb{E}[\boldsymbol{\varepsilon}_i | \mathbf{x}_j] = 0$ para $i, j = 1, 2, \dots, n$
4. El término de error es homocedástico y sin autocorrelación

Dicho lo anterior, para la estimación y modelación de datos panel existen tres alternativas que veremos en este curso: estimación considerando efectos fijos, estimación con efectos aleatorios y estimaciones pool ('pooled regression').

5.2.1. Efectos Fijos

En este caso, diremos que $\mathbf{x}_i$ es una matriz de regresores exógenos. Ahora bien, supondremos que la perturbación tiene un componente dado por:

$$\varepsilon_{im} = \alpha_i + \eta_{im}$$

Donde $m = 1, 2, \dots, M$. Al primer componente α_i se le conoce como el componente de los errores que es común a lo largo de la segunda dimensión, a este se le conoce como efecto individual, heterogeneidad individual o efecto fijo.

Así, la ecuación (5.1) se verá modificada para quedar como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \alpha_i \\ \alpha_i \\ \alpha_i \\ \vdots \\ \alpha_i \end{bmatrix} + \begin{bmatrix} \eta_{i1} \\ \eta_{i2} \\ \eta_{i3} \\ \vdots \\ \eta_{iM} \end{bmatrix}$$

$$\mathbf{y}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\alpha}_i + \boldsymbol{\eta}_i \quad (5.2)$$

El supuesto que define a este modelo, y que conviene enunciar con toda claridad porque es el que lo distingue del modelo de efectos aleatorios, es el siguiente:

$$\mathbb{E}[\eta_{im} \mid \mathbf{x}_i, \alpha_i] = 0 \quad (5.3)$$

$$\mathbb{E}[\alpha_i \cdot x_{imk}] \neq 0, \text{ permitido} \quad (5.4)$$

Es decir, el modelo de efectos fijos **sí permite** que el efecto individual no observado esté correlacionado con los regresores. Esta es precisamente su virtud y la razón por la que se utiliza: si α_i recoge la habilidad no observada de un individuo, la calidad de la administración de una empresa o las instituciones de un país, resulta poco creíble suponer que esos factores no guarden relación con las variables explicativas incluidas. Lo que sí se exige, mediante la ecuación (5.3), es que el componente idiosincrático η_{im} sea estrictamente exógeno respecto de los regresores de *todos* los periodos, condición conocida como exogeneidad estricta y que reencontramos, con otro nombre, al discutir el supuesto de tendencias paralelas en el capítulo de inferencia causal.

Debemos anotar además una restricción de identificación: si el efecto individual α_i se estima para cada grupo, entonces la matriz de regresores **no**

puede contener un término constante adicional, pues sería colineal con el conjunto completo de efectos individuales.

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma que al final quedaría una expresión como:

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 & x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ 1 & 0 & \dots & 0 & x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ 1 & 0 & \dots & 0 & x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \dots & 0 & x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ 0 & 1 & \dots & 0 & x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 1 & \dots & 0 & x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 & x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ 0 & 0 & \dots & 1 & x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ 0 & 0 & \dots & 1 & x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \dots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 & x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \\ \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} \\
 + \begin{bmatrix} \eta_{11} \\ \eta_{12} \\ \eta_{13} \\ \vdots \\ \eta_{1M} \\ \vdots \\ \eta_{n1} \\ \eta_{n2} \\ \eta_{n3} \\ \vdots \\ \eta_{nM} \end{bmatrix}$$

El estimador intragrupos

La representación anterior, conocida como **estimador de variables dicotómicas** o LSDV (*Least Squares Dummy Variables*), es conceptualmente transparente pero computacionalmente impracticable: con n grupos requie-

re estimar $n + K$ parámetros, y en paneles con miles de individuos esto es inviable. Existe un procedimiento equivalente y mucho más eficiente.

Partamos de la ecuación (5.2) escrita observación por observación:

$$y_{im} = \mathbf{x}_{im}\boldsymbol{\beta} + \alpha_i + \eta_{im} \quad (5.5)$$

Calculemos ahora el promedio de la ecuación (5.5) *dentro* de cada grupo, es decir, a lo largo de la segunda dimensión:

$$\bar{y}_i = \bar{\mathbf{x}}_i\boldsymbol{\beta} + \alpha_i + \bar{\eta}_i \quad (5.6)$$

Donde $\bar{y}_i = M^{-1} \sum_{m=1}^M y_{im}$ y análogamente para el resto. Nótese que α_i no cambia al promediar, precisamente porque es constante dentro del grupo. Restando la ecuación (5.6) de la ecuación (5.5) obtenemos:

$$(y_{im} - \bar{y}_i) = (\mathbf{x}_{im} - \bar{\mathbf{x}}_i)\boldsymbol{\beta} + (\eta_{im} - \bar{\eta}_i) \quad (5.7)$$

El efecto individual desapareció. Este es el resultado central del modelo de efectos fijos: la transformación de la ecuación (5.7), llamada **transformación intragrupos** o *within*, elimina por completo α_i sin necesidad de estimarlo y, con ello, elimina el sesgo que su correlación con los regresores habría producido.

La Figura 5.1 ilustra por qué esto importa tanto, con un ejemplo construido de manera que la respuesta correcta sea conocida. En el panel (a) se muestran los datos tal como los observaríamos, junto con la recta que ajustaría una regresión pool: la relación aparente es claramente **positiva**. En el panel (b) se muestran los mismos datos, pero ajustando una recta separada dentro de cada grupo: la relación es **negativa** en todos y cada uno de ellos. La discrepancia se debe a que los grupos con valores altos de x tienen también efectos individuales altos, es decir, α_i está correlacionado con los regresores. La regresión pool confunde esa diferencia permanente entre grupos con el efecto de la variable, y en este caso llega incluso a invertir el signo. El estimador intragrupos, al utilizar únicamente la variación dentro de cada grupo, recupera el efecto correcto. Aplicando MCO a la ecuación (5.7) obtenemos el **estimador intragrupos**:

$$\hat{\boldsymbol{\beta}}_{FE} = \left(\sum_{i=1}^n \sum_{m=1}^M (\mathbf{x}_{im} - \bar{\mathbf{x}}_i)' (\mathbf{x}_{im} - \bar{\mathbf{x}}_i) \right)^{-1} \left(\sum_{i=1}^n \sum_{m=1}^M (\mathbf{x}_{im} - \bar{\mathbf{x}}_i)' (y_{im} - \bar{y}_i) \right) \quad (5.8)$$




Figura 5.1: Regresión pool frente a efectos fijos cuando el efecto individual está correlacionado con el regresor

En notación matricial el procedimiento se expresa de forma compacta definiendo la matriz de transformación intragrupos:

$$\mathbf{Q} = \mathbf{I}_M - \frac{1}{M} \boldsymbol{\iota} \boldsymbol{\iota}'$$

Donde $\boldsymbol{\iota}$ es un vector $M \times 1$ de unos. Esta matriz es simétrica e idempotente ($\mathbf{Q}' = \mathbf{Q}$ y $\mathbf{Q}\mathbf{Q} = \mathbf{Q}$), y al premultiplicar un vector le resta su propia media. Con ella:

$$\hat{\boldsymbol{\beta}}_{FE} = \left(\sum_{i=1}^n \mathbf{x}_i' \mathbf{Q} \mathbf{x}_i \right)^{-1} \left(\sum_{i=1}^n \mathbf{x}_i' \mathbf{Q} \mathbf{y}_i \right)$$

Puede demostrarse, mediante el teorema de Frisch-Waugh-Lovell, que el estimador de la ecuación (5.8) es **numéricamente idéntico** al que se obtendría estimando por MCO la representación con variables dicotómicas. Ambos procedimientos entregan el mismo $\hat{\boldsymbol{\beta}}$; la diferencia es puramente computacional.

Dos observaciones prácticas son importantes. La primera es la corrección de grados de libertad: aunque en la regresión sobre datos transformados sólo aparecen K regresores, se están estimando implícitamente n efectos individuales, por lo que la varianza del error debe calcularse como:

$$\hat{\sigma}_\eta^2 = \frac{\sum_i \sum_m \hat{\eta}_{im}^2}{nM - n - K}$$

Los programas estadísticos hacen esta corrección automáticamente, pero quien implemente el procedimiento a mano demorándose los datos y corriendo MCO obtendrá errores estándar subestimados si no la aplica.

La segunda observación es una limitación de fondo: dado que $\mathbf{Q}\boldsymbol{\iota} = \mathbf{0}$, **toda variable que no cambie dentro del grupo es aniquilada por la transformación**. En un panel de individuos observados en el tiempo, esto significa que no es posible estimar el efecto del sexo, del lugar de nacimiento, de la raza o de cualquier característica fija. Si el interés de la investigación recae precisamente sobre una de esas variables, el modelo de efectos fijos sencillamente no puede responder la pregunta, y esa es la razón principal por la que el modelo de efectos aleatorios sigue utilizándose pese a descansar en un supuesto más fuerte.

Primeras diferencias

Existe una segunda forma de eliminar el efecto individual. Restando la ecuación (5.5) evaluada en $m - 1$ de la misma evaluada en m :

$$(y_{im} - y_{i,m-1}) = (\mathbf{x}_{im} - \mathbf{x}_{i,m-1})\boldsymbol{\beta} + (\eta_{im} - \eta_{i,m-1}) \quad (5.9)$$

El efecto individual también desaparece, ya que $\alpha_i - \alpha_i = 0$. Al estimador de MCO aplicado a la ecuación (5.9) se le conoce como estimador de **primeras diferencias**. Ambos estimadores son consistentes bajo exogeneidad estricta, y cuando $M = 2$ son numéricamente idénticos. Para $M > 2$ difieren en eficiencia: si los η_{im} son independientes e idénticamente distribuidos, el estimador intragrupos es más eficiente; si en cambio siguen una caminata aleatoria, el de primeras diferencias lo es. La comparación entre ambos constituye además una verificación informal de especificación: diferencias sustanciales entre ellos sugieren que el supuesto de exogeneidad estricta puede estar fallando.

5.2.2. Efectos Aleatorios

En este caso, igualmente que en el caso anterior, diremos que $\mathbf{x}_i$ es una matriz de regresores exógenos. Ahora bien, supondremos que la perturbación tiene un componente dado por:

$$\varepsilon_{im} = \nu_i + \eta_{im}$$

Donde $m = 1, 2, \dots, M$ y ν_i es una perturbación aleatoria que captura la información estocástica del individuo y que no está correlacionada con los regresores. A este componente ν_i se le conoce como el componente de los errores que es aleatorio a lo largo de la segunda dimensión, a este se le conoce como efecto aleatorio.

Así, la ecuación (5.1) se verá modificada para quedar como:

$$\begin{bmatrix} y_{i1} \\ y_{i2} \\ y_{i3} \\ \vdots \\ y_{iM} \end{bmatrix} = \begin{bmatrix} x_{i11} & x_{i12} & x_{i13} & \dots & x_{i1K} \\ x_{i21} & x_{i22} & x_{i23} & \dots & x_{i2K} \\ x_{i31} & x_{i32} & x_{i33} & \dots & x_{i3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{iM1} & x_{iM2} & x_{iM3} & \dots & x_{iMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \nu_i \\ \nu_i \\ \nu_i \\ \vdots \\ \nu_i \end{bmatrix} + \begin{bmatrix} \eta_{i1} \\ \eta_{i2} \\ \eta_{i3} \\ \vdots \\ \eta_{iM} \end{bmatrix}$$

$$\mathbf{x}_i = \mathbf{x}_i \boldsymbol{\beta} + \boldsymbol{\nu}_i + \boldsymbol{\eta}_i \quad (5.10)$$

Donde

$$\begin{aligned} \mathbb{E}[\boldsymbol{\epsilon}_i \cdot \mathbf{x}_i] &= 0 \\ \mathbb{E}[\nu_i \cdot x_{im}] &= 0 \\ \mathbb{E}[\eta_{im} \cdot x_{im}] &= 0 \end{aligned}$$

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma similar al modelo de efectos fijos para que al final quedaría una expresión como:

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} = \begin{bmatrix} x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \nu_1 + \eta_{11} \\ \nu_1 + \eta_{12} \\ \nu_1 + \eta_{13} \\ \vdots \\ \nu_1 + \eta_{1M} \\ \nu_2 + \eta_{21} \\ \vdots \\ \nu_2 + \eta_{2M} \\ \vdots \\ \nu_n + \eta_{n1} \\ \nu_n + \eta_{n2} \\ \nu_n + \eta_{n3} \\ \vdots \\ \nu_n + \eta_{nM} \end{bmatrix}$$

La estructura de la varianza y el estimador de efectos aleatorios

El supuesto que define a este modelo, y que lo separa del de efectos fijos, es:

$$\mathbb{E}[\nu_i \mid \mathbf{x}_i] = 0 \quad (5.11)$$

Es decir, el efecto individual no observado **no** está correlacionado con los regresores. Bajo este supuesto, ν_i no genera sesgo y por lo tanto no hay necesidad de eliminarlo: basta con tratarlo correctamente como parte del término de error. Y tratarlo correctamente significa reconocer que induce una estructura particular de correlación.

En efecto, dado que el mismo ν_i aparece en las M observaciones del grupo i , los errores de un mismo grupo están correlacionados entre sí. Suponiendo $\mathbb{E}[\nu_i^2] = \sigma_\nu^2$, $\mathbb{E}[\eta_{im}^2] = \sigma_\eta^2$ y que ambos componentes son independientes entre sí y entre grupos, la matriz de varianzas y covarianzas del vector de errores de cada grupo es:

$$\Sigma = \mathbb{E}[\boldsymbol{\varepsilon}_i \boldsymbol{\varepsilon}_i'] = \sigma_\eta^2 \mathbf{I}_M + \sigma_\nu^2 \boldsymbol{\iota} \boldsymbol{\iota}' = \begin{bmatrix} \sigma_\eta^2 + \sigma_\nu^2 & \sigma_\nu^2 & \dots & \sigma_\nu^2 \\ \sigma_\nu^2 & \sigma_\eta^2 + \sigma_\nu^2 & \dots & \sigma_\nu^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_\nu^2 & \sigma_\nu^2 & \dots & \sigma_\eta^2 + \sigma_\nu^2 \end{bmatrix} \quad (5.12)$$

La ecuación (5.12) describe una estructura de **equicorrelación**: todas las parejas de observaciones del mismo grupo tienen la misma correlación, dada por $\rho = \sigma_\nu^2 / (\sigma_\eta^2 + \sigma_\nu^2)$, conocida como coeficiente de correlación intraclase. Este parámetro mide qué proporción de la varianza total del error es atribuible a la heterogeneidad entre grupos.

Aquí es donde se hace visible la conexión que anunciamos en el capítulo de sistemas de ecuaciones: la matriz de la ecuación (5.12) no es escalar, de modo que MCO es ineficiente y el estimador apropiado es el de Mínimos Cuadrados Generalizados que ya desarrollamos ahí. En efecto, el modelo de datos panel con efectos aleatorios es exactamente un sistema de ecuaciones en el que se ha impuesto que el vector $\boldsymbol{\beta}$ sea el mismo en todas las ecuaciones y en el que la matriz de varianzas tiene la forma particular de la ecuación (5.12).

Aplicando MCG y desarrollando la inversa de la ecuación (5.12), se obtiene un resultado notablemente simple: el estimador de efectos aleatorios equivale a aplicar MCO sobre los datos **cuasi-transformados**:

$$(y_{im} - \theta \bar{y}_i) = (\mathbf{x}_{im} - \theta \bar{\mathbf{x}}_i) \boldsymbol{\beta} + w_{im} \quad (5.13)$$

Donde el factor de transformación es:

$$\theta = 1 - \sqrt{\frac{\sigma_\eta^2}{\sigma_\eta^2 + M\sigma_\nu^2}} \quad (5.14)$$

La ecuación (5.14) permite ver con claridad que los tres modelos que estamos estudiando son casos de una misma familia, indexada por θ :

1. Si $\sigma_\nu^2 = 0$, entonces $\theta = 0$ y la ecuación (5.13) se reduce a la **regresión pool**: no hay heterogeneidad individual que tomar en cuenta.
2. Si $\theta = 1$, la ecuación (5.13) coincide exactamente con la transformación intragrupos de la ecuación (5.7), es decir, con **efectos fijos**. Esto ocurre cuando σ_ν^2 es muy grande en relación con σ_η^2 , o cuando $M \rightarrow \infty$.
3. Para valores intermedios, $0 < \theta < 1$, el estimador de **efectos aleatorios** resta sólo una fracción de la media grupal, conservando así parte de la variación entre grupos que efectos fijos descarta por completo.

Esta última observación explica de dónde proviene la ganancia de eficiencia del modelo de efectos aleatorios: mientras que efectos fijos utiliza únicamente la variación *dentro* de los grupos, efectos aleatorios aprovecha además la variación *entre* grupos. Ese aprovechamiento es legítimo sólo si se cumple la ecuación (5.11); si no se cumple, la variación entre grupos está contaminada y el estimador es inconsistente. Esta es exactamente la disyuntiva que la prueba de Hausman resuelve.

En la práctica σ_η^2 y σ_ν^2 son desconocidas y deben estimarse en una primera etapa, típicamente a partir de los residuales de las regresiones intragrupos y entre grupos, con lo que el procedimiento resulta ser de Mínimos Cuadrados Generalizados Factibles, tal como lo describimos en el capítulo correspondiente.

5.2.3. Regresión Pool

La tercera alternativa consiste en ignorar por completo la estructura de panel y estimar por MCO tratando las nM observaciones como si provinieran de una única muestra de sección cruzada. Este procedimiento es consistente únicamente si no existe heterogeneidad individual no observada, es decir, si $\alpha_i = \alpha$ es una constante común a todos los grupos, en cuyo caso queda

absorbida por el término constante de la regresión. En ese escenario el término de error no se descompone y queda simplemente como ε_{im} .

Debe advertirse que, aun cuando la regresión pool fuera consistente, si existe cualquier correlación dentro de los grupos los errores estándar convencionales estarán subestimados, por la misma razón que discutimos al hablar de la inferencia en diseños de diferencia en diferencias. En ese caso deben emplearse errores estándar agrupados al nivel del grupo.

Para estimar este modelo se requiere de acomodar la información para cada uno de los grupos de forma similar al modelo de efectos aleatorios para que al final quedaría una expresión como:

$$\begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ \vdots \\ y_{1M} \\ y_{2M} \\ \vdots \\ y_{2M} \\ \vdots \\ y_{n1} \\ y_{n2} \\ y_{n3} \\ \vdots \\ y_{nM} \end{bmatrix} = \begin{bmatrix} x_{111} & x_{112} & x_{113} & \dots & x_{11K} \\ x_{121} & x_{122} & x_{123} & \dots & x_{12K} \\ x_{131} & x_{132} & x_{133} & \dots & x_{13K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{1M1} & x_{1M2} & x_{1M3} & \dots & x_{1MK} \\ x_{211} & x_{212} & x_{213} & \dots & x_{21K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{2M1} & x_{2M2} & x_{2M3} & \dots & x_{2MK} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{n11} & x_{n12} & x_{n13} & \dots & x_{n1K} \\ x_{n21} & x_{n22} & x_{n23} & \dots & x_{n2K} \\ x_{n31} & x_{n32} & x_{n33} & \dots & x_{n3K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ x_{nM1} & x_{nM2} & x_{nM3} & \dots & x_{nMK} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \beta_3 \\ \vdots \\ \beta_K \end{bmatrix} + \begin{bmatrix} \varepsilon_{11} \\ \varepsilon_{12} \\ \varepsilon_{13} \\ \vdots \\ \varepsilon_{1M} \\ \varepsilon_{21} \\ \vdots \\ \varepsilon_{2M} \\ \vdots \\ \varepsilon_{n1} \\ \varepsilon_{n2} \\ \varepsilon_{n3} \\ \vdots \\ \varepsilon_{nM} \end{bmatrix}$$

5.3. Pruebas para seleccionar modelo

Disponemos de tres modelos alternativos y necesitamos criterios para elegir entre ellos. Existen tres pruebas, cada una de las cuales contrasta una pareja distinta.

5.3.1. La prueba de Hausman: efectos fijos frente a efectos aleatorios

Esta es la prueba central del capítulo y descansa en el principio general que introdujo Hausman (1978) [Hau78], el mismo que ya empleamos en el

capítulo de variables instrumentales. Conviene enunciar el principio antes de aplicarlo, porque es más general que cualquiera de sus dos aplicaciones.

El principio de Hausman. Supongamos que disponemos de dos estimadores del mismo parámetro:

- Un estimador $\hat{\beta}_A$ que es consistente bajo la hipótesis nula *y* bajo la alternativa, pero ineficiente bajo la nula.
- Un estimador $\hat{\beta}_B$ que es consistente y eficiente bajo la nula, pero inconsistente bajo la alternativa.

Si la hipótesis nula es cierta, ambos estiman lo mismo y su diferencia debe ser pequeña; si es falsa, deben separarse sistemáticamente. La prueba consiste entonces en contrastar si esa diferencia es estadísticamente distinta de cero.

En el contexto de datos panel, el papel de $\hat{\beta}_A$ lo desempeña el estimador de efectos fijos — consistente esté o no correlacionado α_i con los regresores, pero ineficiente porque descarta la variación entre grupos — y el de $\hat{\beta}_B$ el de efectos aleatorios — eficiente si se cumple la ecuación (5.11), inconsistente si no —. Las hipótesis son:

$$\begin{aligned} H_0 &: \mathbb{E}[\nu_i \mid \mathbf{x}_i] = 0, \text{ es decir, efectos aleatorios es válido} \\ H_1 &: \mathbb{E}[\nu_i \mid \mathbf{x}_i] \neq 0, \text{ es decir, se requieren efectos fijos} \end{aligned}$$

Que se traducen en un contraste sobre los estimadores:

$$\begin{aligned} H_0 &: \mathbf{q} = \hat{\beta}_{FE} - \hat{\beta}_{RE} = \mathbf{0} \\ H_1 &: \mathbf{q} \neq \mathbf{0} \end{aligned}$$

La estadística de prueba es:

$$H = \mathbf{q}' \left[\widehat{Var}(\mathbf{q}) \right]^{-1} \mathbf{q} = (\hat{\beta}_{FE} - \hat{\beta}_{RE})' \left[\widehat{Var}(\hat{\beta}_{FE}) - \widehat{Var}(\hat{\beta}_{RE}) \right]^{-1} (\hat{\beta}_{FE} - \hat{\beta}_{RE}) \xrightarrow{d} \chi_{K_1}^2 \quad (5.15)$$

Donde K_1 es el número de regresores que **varían dentro del grupo**. Este detalle es importante y suele pasarse por alto: las variables invariantes en el tiempo no pueden formar parte del contraste, simplemente porque efectos fijos no las estima.

El elemento que hace funcionar a la ecuación (5.15) es el uso de la *diferencia* de las varianzas en lugar de la varianza de la diferencia. En general tendríamos:

$$Var(\mathbf{q}) = Var(\hat{\beta}_{FE}) + Var(\hat{\beta}_{RE}) - 2Cov(\hat{\beta}_{FE}, \hat{\beta}_{RE})$$

Y el término de covarianza sería muy engorroso de calcular. Sin embargo, Hausman demostró que cuando uno de los estimadores es **eficiente** bajo la nula, su covarianza con la diferencia es necesariamente nula, es decir $Cov(\hat{\beta}_{RE}, \mathbf{q}) = 0$. El argumento es elegante: si no fuera así, podría construirse una combinación lineal de $\hat{\beta}_{RE}$ y $\mathbf{q}$ con menor varianza que $\hat{\beta}_{RE}$, contradiciendo su eficiencia. De ahí se sigue que $Cov(\hat{\beta}_{FE}, \hat{\beta}_{RE}) = Var(\hat{\beta}_{RE})$ y, sustituyendo, la expresión colapsa a la diferencia de varianzas.

Advertencias prácticas

La prueba de la ecuación (5.15) tiene cuatro limitaciones que conviene conocer:

1. **La matriz de diferencias puede no ser definida positiva** en muestras finitas, en cuyo caso la estadística puede resultar negativa. Cuando esto ocurre, la solución habitual es recurrir a una inversa generalizada, aunque un valor negativo suele interpretarse en la práctica como ausencia de evidencia contra la nula.
2. **La prueba no es válida con errores estándar robustos o agrupados.** La derivación anterior descansa por completo en que el estimador de efectos aleatorios sea eficiente, lo cual deja de ser cierto en presencia de heterocedasticidad o de correlación serial. Utilizar la ecuación (5.15) con varianzas robustas es un error frecuente y produce una prueba sin fundamento.
3. **Rechazar no implica que efectos fijos sea “correcto”**, sólo que efectos aleatorios es inconsistente. Puede ocurrir que ambos modelos estén mal especificados.
4. **No rechazar no es evidencia fuerte a favor de efectos aleatorios.** Con paneles cortos la prueba tiene poco poder, y la práctica de aceptar sin más el modelo de efectos aleatorios cuando la prueba no rechaza es cuestionable. Muchos autores prefieren reportar efectos fijos

por omisión, y justificar el uso de efectos aleatorios sólo cuando existe una razón sustantiva, típicamente la necesidad de estimar el coeficiente de alguna variable invariante en el tiempo.

Una alternativa robusta: el enfoque de Mundlak

Existe una formulación equivalente y más flexible, debida a Mundlak (1978) [Mun78], que evita los problemas anteriores. La idea consiste en modelar explícitamente la correlación entre el efecto individual y los regresores:

$$\nu_i = \bar{\mathbf{x}}_i \boldsymbol{\pi} + c_i \quad (5.16)$$

Donde c_i ya no está correlacionado con los regresores. Sustituyendo la ecuación (5.16) en el modelo, basta con estimar por efectos aleatorios la regresión aumentada que incluye, además de los regresores originales, sus **medias grupales**:

$$y_{im} = \mathbf{x}_{im} \boldsymbol{\beta} + \bar{\mathbf{x}}_i \boldsymbol{\pi} + c_i + \eta_{im}$$

Y contrastar $H_0 : \boldsymbol{\pi} = \mathbf{0}$ mediante una prueba de Wald ordinaria, que sí admite errores estándar agrupados. Este procedimiento tiene tres virtudes: es asintóticamente equivalente a la prueba de Hausman, permite inferencia robusta, y produce estimadores de $\boldsymbol{\beta}$ que coinciden con los de efectos fijos. A este planteamiento se le conoce también como enfoque de **efectos aleatorios correlacionados**, y tiene la ventaja adicional de permitir que en la misma ecuación se incluyan variables invariantes en el tiempo.

5.3.2. Prueba de Breusch-Pagan: efectos aleatorios frente a regresión pool

La segunda prueba determina si existe heterogeneidad individual del tipo aleatorio, es decir, si hay algún componente de varianza asociado a ν_i . Se trata de una prueba basada en Multiplicadores de Lagrange, debida a Breusch y Pagan (1980) [BP80], cuyas hipótesis son:

$$\begin{aligned} H_0 & : \sigma_\nu^2 = 0 \text{ , la regresión pool es adecuada} \\ H_1 & : \sigma_\nu^2 > 0 \text{ , se requieren efectos aleatorios} \end{aligned}$$

La estadística se construye a partir de los residuales e_{im} de la regresión

pool estimada por MCO:

$$LM = \frac{nM}{2(M-1)} \left[\frac{\sum_{i=1}^n \left(\sum_{m=1}^M e_{im} \right)^2}{\sum_{i=1}^n \sum_{m=1}^M e_{im}^2} - 1 \right]^2 \xrightarrow{d} \chi_1^2 \quad (5.17)$$

La intuición de la ecuación (5.17) es directa: si no hubiera efecto individual, los residuales de un mismo grupo no estarían correlacionados y la suma de residuales por grupo, elevada al cuadrado, sería en promedio igual a la suma de sus cuadrados, con lo que el término entre corchetes sería cercano a cero. Si en cambio los residuales de un mismo grupo comparten un componente común, sus sumas serán sistemáticamente grandes en valor absoluto.

5.3.3. Prueba F: efectos fijos frente a regresión pool

Finalmente, para contrastar la tercera pareja basta con una prueba F ordinaria de restricciones lineales sobre la representación con variables dicotómicas:

$$\begin{aligned} H_0 &: \alpha_1 = \alpha_2 = \dots = \alpha_n, \text{ la regresión pool es adecuada} \\ H_1 &: \text{No } H_0 \end{aligned}$$

Con estadística:

$$F = \frac{(R_{FE}^2 - R_{pool}^2)/(n-1)}{(1 - R_{FE}^2)/(nM - n - K)} \sim F_{(n-1, nM-n-K)} \quad (5.18)$$

Que es simplemente la prueba de significancia conjunta del conjunto completo de efectos individuales. La mayoría de los programas la reporta de manera automática al estimar un modelo de efectos fijos.

5.3.4. Sobre el nombre “prueba de Hausman”

Vale la pena hacer una advertencia terminológica que suele causar confusión. Bajo el nombre de “prueba de Hausman” se conocen al menos dos contrastes distintos, que comparten el principio general enunciado al inicio de esta sección pero que responden preguntas diferentes:

1. La **prueba de endogeneidad** del capítulo de variables instrumentales, que compara MCO con 2SLS y contrasta si un regresor está correlacionado con el término de error. Su versión operativa más común es la regresión auxiliar de Durbin-Wu-Hausman, en la que se incluyen los residuales de la primera etapa en la ecuación estructural.
2. La **prueba de efectos fijos contra efectos aleatorios** de esta sección, dada por la ecuación (5.15).

Ambas comparan un estimador consistente pero ineficiente con uno eficiente pero potencialmente inconsistente; en ambas la hipótesis nula es la ausencia de correlación entre un componente no observado y los regresores. Sin embargo, no son la misma prueba ni se aplican al mismo problema, y conviene precisar siempre a cuál se hace referencia.

5.4. Consideraciones adicionales

5.4.1. Inferencia en datos panel

Un punto que suele descuidarse es el cálculo de los errores estándar. Aun después de haber eliminado el efecto individual mediante la transformación intragrupos, el término idiosincrático η_{im} puede presentar correlación serial dentro de cada grupo, lo cual invalida los errores estándar convencionales exactamente por las razones que discutimos en el capítulo de inferencia causal. La práctica estándar consiste en emplear **errores estándar agrupados al nivel del grupo**, que permiten correlación serial y heterocedasticidad arbitrarias dentro de cada unidad. Como también señalamos ahí, la validez de este procedimiento es asintótica en el número de grupos, por lo que con pocos grupos deben emplearse correcciones adicionales.

5.4.2. Una limitación importante: los paneles dinámicos

Todo lo anterior descansa en el supuesto de exogeneidad estricta de la ecuación (5.3). Ese supuesto se viola de manera inevitable cuando se incluye la variable dependiente rezagada como regresor, es decir, en modelos de la forma:

$$y_{im} = \gamma y_{i,m-1} + \mathbf{x}_{im}\boldsymbol{\beta} + \alpha_i + \eta_{im}$$

El problema es que la transformación intragrupos, al restar la media del grupo, introduce una correlación mecánica entre el regresor rezagado transformado y el error transformado, ya que $\bar{y}_i$ contiene a y_{im} y por lo tanto a η_{im} . El resultado es un sesgo del orden de $1/M$, documentado por Nickell (1981) [Nic81] y conocido como **sesgo de Nickell**. En paneles con pocos periodos — que son la mayoría en microeconometría — ese sesgo puede ser considerable y no desaparece al aumentar el número de individuos.

La solución estándar consiste en emplear estimadores basados en el método generalizado de momentos que instrumentan las diferencias con rezagos suficientemente lejanos de la propia variable, siguiendo a Arellano y Bond (1991) [AB91]. El desarrollo de estos estimadores excede el alcance de estas notas, pero es importante saber que estimar un panel dinámico con las herramientas de este capítulo produce resultados sesgados.

5.5. Conclusión

- El modelo de efectos fijos y el de efectos aleatorios suponen que existe información individual no observada que fue omitida.
- La distinción entre efectos fijos y efectos aleatorios es si el efecto no observable individual está correlacionado con los regresores o si no lo está. Así, esto **no** tiene que ver con si dicho efecto es estocástico o no, ni con si los individuos de la muestra fueron elegidos aleatoriamente. Los nombres de ambos modelos son, en este sentido, desafortunados y son fuente permanente de confusión.
- El estimador de efectos fijos elimina el efecto individual mediante la transformación intragrupos de la ecuación (5.7), a costa de descartar toda la variación entre grupos y, con ella, la posibilidad de estimar coeficientes de variables invariantes en el tiempo.
- El estimador de efectos aleatorios es un caso particular de Mínimos Cuadrados Generalizados sobre un sistema de ecuaciones con errores equicorrelacionados. Es más eficiente que efectos fijos, pero sólo es consistente bajo el supuesto más fuerte de la ecuación (5.11).
- Los tres modelos pertenecen a una misma familia indexada por el parámetro θ de la ecuación (5.14): $\theta = 0$ produce la regresión pool,

$\theta = 1$ produce efectos fijos, y los valores intermedios producen efectos aleatorios.

- La elección entre modelos se apoya en la prueba de Hausman, ecuación (5.15), o preferentemente en su versión robusta de Mundlak; pero la elección final debe descansar tanto en la evidencia estadística como en el conocimiento del problema.
- La regresión pool no es “la alternativa cuando todo falla”, sino un modelo con su propio supuesto de identificación, a saber, la ausencia de heterogeneidad individual, que puede contrastarse formalmente con la ecuación (5.17).

5.6. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) La diferencia entre efectos fijos y efectos aleatorios es que en el primero el efecto individual es una constante y en el segundo es una variable aleatoria.
 - b) El modelo de efectos fijos requiere que el efecto individual no esté correlacionado con los regresores.
 - c) Con el estimador intragrupos es posible estimar el efecto del sexo de una persona sobre su salario, usando un panel de individuos observados durante diez años.
 - d) El estimador de efectos aleatorios es siempre preferible al de efectos fijos porque es más eficiente.
 - e) Si la prueba de Hausman no rechaza la hipótesis nula, queda demostrado que el efecto individual no está correlacionado con los regresores.
 - f) La prueba de Hausman de la ecuación (5.15) puede aplicarse utilizando errores estándar agrupados.
 - g) El estimador de efectos fijos y el de primeras diferencias son numéricamente idénticos cuando $M = 2$.

- h) Incluir la variable dependiente rezagada como regresor no plantea ningún problema particular en un modelo de efectos fijos.
2. Partiendo de la ecuación (5.5), se le solicita:
- a) Derivar paso a paso la transformación intragrupos de la ecuación (5.7) e identificar con precisión en qué punto desaparece α_i .
 - b) Verificar que la matriz $\mathbf{Q} = \mathbf{I}_M - M^{-1}\mathbf{1}\mathbf{1}'$ es simétrica e idempotente.
 - c) Demostrar que $\mathbf{Q}\mathbf{1} = \mathbf{0}$ y explicar por qué este resultado implica que las variables invariantes dentro del grupo no pueden estimarse.
 - d) Explicar por qué la varianza del error debe calcularse dividiendo entre $nM - n - K$ y no entre $nM - K$.
3. Considere el modelo de efectos aleatorios y se le solicita:
- a) Verificar la estructura de la matriz de varianzas de la ecuación (5.12) calculando $\mathbb{E}[\varepsilon_{im}\varepsilon_{im'}]$ para $m = m'$ y para $m \neq m'$.
 - b) Obtener el coeficiente de correlación intraclase y explicar qué mide.
 - c) Verificar que la ecuación (5.14) implica $\theta \rightarrow 1$ cuando $M \rightarrow \infty$, e interpretar el resultado: ¿por qué en paneles con muchos periodos efectos aleatorios y efectos fijos se parecen cada vez más?
 - d) Calcular θ para $\sigma_\eta^2 = 4$, $\sigma_\nu^2 = 1$ y $M = 5$, y decir qué fracción de la media grupal se está restando.
4. Demuestre que, si $\hat{\beta}_{RE}$ es eficiente bajo la hipótesis nula, entonces $Cov(\hat{\beta}_{RE}, \mathbf{q}) = \mathbf{0}$, y utilice ese resultado para obtener la forma de la varianza que aparece en la ecuación (5.15). Sugerencia: considere el estimador $\hat{\beta}_{RE} + \mathbf{A}\mathbf{q}$ para una matriz $\mathbf{A}$ arbitraria, calcule su varianza y note que la eficiencia de $\hat{\beta}_{RE}$ exige que esa varianza se minimice en $\mathbf{A} = \mathbf{0}$.
5. Explique por qué el enfoque de Mundlak de la ecuación (5.16) es asintóticamente equivalente a la prueba de Hausman, y discuta sus tres ventajas prácticas. Explique además por qué en la regresión aumentada los coeficientes $\hat{\beta}$ coinciden con los de efectos fijos.

6. **Sobre el sesgo de Nickell.** Considere el modelo dinámico $y_{im} = \gamma y_{i,m-1} + \alpha_i + \eta_{im}$. Se le solicita: (i) escribir la ecuación transformada intragrupos; (ii) mostrar que el regresor transformado $y_{i,m-1} - \bar{y}_{i,-1}$ y el error transformado $\eta_{im} - \bar{\eta}_i$ están correlacionados, identificando el término responsable; y (iii) explicar por qué el sesgo desaparece cuando $M \rightarrow \infty$ pero no cuando $n \rightarrow \infty$.
7. **Aplicación empírica en Python.** Utilizando los datos de inversión de Grunfeld del cuaderno `Panel_Data_Grunfeld_Investment.ipynb` del repositorio del curso, se le solicita:
- Estimar el modelo por regresión pool, por efectos fijos y por efectos aleatorios, y presentar los tres conjuntos de resultados en un solo cuadro comparativo.
 - Verificar numéricamente que el estimador intragrupos coincide con el que se obtiene al incluir variables dicotómicas por empresa, y comprobar que los errores estándar sólo coinciden si se aplica la corrección de grados de libertad.
 - Aplicar la prueba F de la ecuación (5.18) y la de Breusch-Pagan de la ecuación (5.17), y concluir sobre la existencia de heterogeneidad individual.
 - Aplicar la prueba de Hausman de la ecuación (5.15) e interpretar el resultado.
 - Estimar además la regresión aumentada de Mundlak y contrastar $H_0 : \boldsymbol{\pi} = \mathbf{0}$ con errores estándar agrupados. Comparar la conclusión con la del inciso anterior.
 - Estimar el parámetro θ de la ecuación (5.14) implícito en los datos e interpretar su magnitud.
8. **Aplicación empírica en Python.** Con el conjunto de datos de salarios en panel `wage_panel.csv` del repositorio, estime una ecuación de salarios y se le solicita:
- Identificar qué variables del conjunto de datos son invariantes en el tiempo y verificar empíricamente que desaparecen al estimar por efectos fijos.

- b)* Estimar por efectos aleatorios y reportar los coeficientes de esas variables invariantes. Discutir bajo qué supuesto esos coeficientes admiten interpretación causal.
- c)* Estimar el rendimiento de la experiencia por efectos fijos y por regresión pool, y explicar a qué se debe la diferencia en términos de qué fuente de variación utiliza cada estimador.
- d)* Comparar los errores estándar convencionales con los agrupados a nivel de individuo y discutir la magnitud de la diferencia.

6

Métodos de estimación basados en verosimilitud

6.1. Introducción

En esta sección discutiremos el tratamiento general para la estimación por máxima verosimilitud. La diferencia significativa en estos casos es que asumiremos una distribución subyacente. Noten que los métodos utilizados anteriormente no requieren de que asumamos una distribución particular para realizar la estimación.

Este cambio de enfoque tiene un costo y un beneficio que conviene tener presentes desde el inicio. El costo es que ahora debemos comprometernos con un supuesto mucho más fuerte: no basta con especificar correctamente la media condicional, sino que debemos especificar correctamente *toda* la distribución condicional. Si nos equivocamos en ese supuesto, en general obtendremos estimadores inconsistentes. El beneficio es doble. Por un lado, cuando el supuesto es correcto, el estimador de máxima verosimilitud es asintóticamente eficiente, es decir, ningún otro estimador consistente y asintóticamente normal tiene una varianza asintótica menor. Por otro lado, y más importante para nuestros propósitos, el método permite estimar modelos que simplemente no pueden abordarse con mínimos cuadrados: modelos de respuesta binaria, multinomial, ordinal, de conteo, con censura, con truncamiento y de duración. Todos los capítulos que siguen descansan en el instrumental que desarrollamos aquí.

El planteamiento general del método de máxima verosimilitud considera

un conjunto de observaciones independientes e idénticamente distribuidas descritas por la familia: $\{y_i, \mathbf{x}_i : y_i \in \mathbb{R}, \mathbf{x}_i \in \mathbb{R}^K\}$.

En estos casos también supondremos que buscamos estimar la regresión de y_i en $\mathbf{x}_i$ y no el caso contrario. Por lo tanto, el método requiere de la función de densidad condicional de y_i en $\mathbf{x}_i$, es decir:

$$f(y_i|\mathbf{x}_i)$$

Así, al método en realidad se le conoce como método de máxima verosimilitud condicional. Su aplicación es amplia en casos como:

1. Modelos lineales: regresión de una sola ecuación, sistemas de ecuaciones, modelos de datos panel y modelos generalizados con heterocedasticidad y autocorrelación
2. Modelos no lineales: respuesta binaria, respuesta categórica, respuesta multinivel
3. Modelos de conteo y duración

Ejemplo. Sea y_i^* una variable aleatoria latente que se pueda expresar como:

$$y_i^* = \mathbf{x}_i \boldsymbol{\theta} + \varepsilon_i$$

Donde ε_i es independiente de $\mathbf{x}_i$, el cual es un vector de $1 \times K$ que contienen un término constante. $\boldsymbol{\theta}$ es un vector de $K \times 1$ parámetros a estimar. Finalmente, asumiremos que:

$$\varepsilon_i \sim Normal(0, 1)$$

Supongamos que en lugar de y_i^* nosotros sólo podemos observar la variable binaria indicadora:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* \leq 0 \end{cases}$$

En este caso, la pregunta que pretendemos responder sería: ¿cuál es la probabilidad de que $y_i = 1$ condicional en que tenemos el vector $\mathbf{x}_i$?

$$\begin{aligned} P(y_i = 1) &= P(y_i^* > 0 | \mathbf{x}_i) \\ &= P(\mathbf{x}_i \boldsymbol{\theta} + \varepsilon_i > 0 | \mathbf{x}_i) \\ &= P(\varepsilon_i > -\mathbf{x}_i \boldsymbol{\theta} | \mathbf{x}_i) \end{aligned}$$

Dada la distribución ε_i , entonces:

$$P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) = \int_{-\mathbf{x}_i\boldsymbol{\theta}}^{\infty} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i$$

Sabemos que toda función de densidad cumple con:

$$\begin{aligned} 1 &= \int_{-\infty}^{\infty} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i \\ &= \int_{-\infty}^{-\mathbf{x}_i\boldsymbol{\theta}} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i + \int_{-\mathbf{x}_i\boldsymbol{\theta}}^{\infty} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i \\ &= \int_{-\infty}^{-\mathbf{x}_i\boldsymbol{\theta}} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i + \int_{-\infty}^{\mathbf{x}_i\boldsymbol{\theta}} f(\varepsilon_i|\mathbf{x}_i)d\varepsilon_i \\ &= \Phi(-\mathbf{x}_i\boldsymbol{\theta}) + \Phi(\mathbf{x}_i\boldsymbol{\theta}) \\ &= (1 - \Phi(\mathbf{x}_i\boldsymbol{\theta})) + \Phi(\mathbf{x}_i\boldsymbol{\theta}) \\ &= P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) + P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) \end{aligned}$$

De esta forma tenemos dos ecuaciones:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) = \Phi(\mathbf{x}_i\boldsymbol{\theta}) \\ P(y_i = 0|\mathbf{x}_i) &= P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\theta}|\mathbf{x}_i) = 1 - \Phi(\mathbf{x}_i\boldsymbol{\theta}) \end{aligned}$$

Estas dos funciones de probabilidad son independientes. De esta forma, la función de densidad condicional de y_i será:

$$\begin{aligned} f(y_i|\mathbf{x}_i) &= P(y_i = 1|\mathbf{x}_i)^{y_i} \cdot P(y_i = 0|\mathbf{x}_i)^{1-y_i} \\ &= \Phi(\mathbf{x}_i\boldsymbol{\theta})^{y_i} \cdot (1 - \Phi(\mathbf{x}_i\boldsymbol{\theta}))^{1-y_i} \end{aligned}$$

6.2. Marco general de estimación por máxima verosimilitud

Sea $f(y_i|\mathbf{x}_i)$ la función de densidad condicional de y_i dado $\mathbf{x}_i$. Sea $\boldsymbol{\theta}$ un conjunto de parámetros de la función. Entonces la función de densidad conjunta de variables aleatorias independientes $\{y_i : y_i \in \mathbb{R}\}$ dados los valores $\{\mathbf{x}_i : \mathbf{x}_i \in \mathbb{R}^K\}$ estará dada por:

$$\prod_{i=1}^N f(y_i|\mathbf{x}_i; \boldsymbol{\theta}) = f(y_1, y_2, \dots, y_N|\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N; \boldsymbol{\theta}) = L(\boldsymbol{\theta}) \quad (6.1)$$

A la ecuación (6.1) se le conoce como ecuación de verosimilitud. El problema de máxima verosimilitud entonces será:

$$\max_{\boldsymbol{\theta} \in \Theta} \prod_{i=1}^N f(y_i | \mathbf{x}_i; \boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} L(\boldsymbol{\theta}) \quad (6.2)$$

Dado que el logaritmo natural es una transformación monótona, podemos decir que el problema de la ecuación (6.2) es equivalente a:

$$\max_{\boldsymbol{\theta} \in \Theta} \ln L(\boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} \ln \prod_{i=1}^N f(y_i | \mathbf{x}_i; \boldsymbol{\theta}) = \max_{\boldsymbol{\theta} \in \Theta} \sum_{i=1}^N \ln f(y_i | \mathbf{x}_i; \boldsymbol{\theta}) \quad (6.3)$$

6.2.1. El vector de puntajes y la ecuación de verosimilitud

Para resolver el problema debemos determinar las condiciones de primer y segundo orden. Comencemos por introducir la notación que utilizaremos en todo lo que sigue.

Definición 6.1 El *vector de puntajes* (o score) de la observación i es el gradiente del logaritmo de la densidad condicional respecto de los parámetros:

$$\mathbf{s}_i(\boldsymbol{\theta}) = \frac{\partial \ln f(y_i | \mathbf{x}_i; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \quad (6.4)$$

Se trata de un vector de dimensión $K \times 1$.

Definición 6.2 El *hessiano* de la observación i es la matriz de segundas derivadas:

$$\mathbf{H}_i(\boldsymbol{\theta}) = \frac{\partial^2 \ln f(y_i | \mathbf{x}_i; \boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} \quad (6.5)$$

Se trata de una matriz simétrica de dimensión $K \times K$.

Es importante no confundir estos dos objetos. El hessiano de la ecuación (6.5) **no** es igual al producto externo de los puntajes $\mathbf{s}_i \mathbf{s}_i'$; se trata de dos matrices distintas que, como veremos, sólo coinciden en valor esperado y con signo opuesto.

Con esta notación, la condición de primer orden del problema de la ecuación (6.3) es:

$$\left. \frac{\partial \ln L(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}} = \sum_{i=1}^N \mathbf{s}_i(\hat{\boldsymbol{\theta}}) = \mathbf{0} \quad (6.6)$$

A la ecuación (6.6) se le conoce como la **ecuación de verosimilitud** y es un sistema de K ecuaciones con K incógnitas. La condición de segundo orden requiere que el hessiano de la muestra completa sea definido negativo en el óptimo:

$$\left. \frac{\partial^2 \ln L(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}} = \sum_{i=1}^N \mathbf{H}_i(\hat{\boldsymbol{\theta}}) , \text{ definida negativa} \quad (6.7)$$

A diferencia de lo que sucede en MCO, la ecuación (6.6) en general **no tiene solución analítica cerrada** y debe resolverse mediante métodos numéricos iterativos, como el algoritmo de Newton-Raphson, el método del puntaje de Fisher o el algoritmo BHHH. Todos ellos parten de un valor inicial $\boldsymbol{\theta}^{(0)}$ y actualizan mediante iteraciones de la forma:

$$\boldsymbol{\theta}^{(j+1)} = \boldsymbol{\theta}^{(j)} - \left[\sum_{i=1}^N \mathbf{H}_i(\boldsymbol{\theta}^{(j)}) \right]^{-1} \sum_{i=1}^N \mathbf{s}_i(\boldsymbol{\theta}^{(j)})$$

Hasta que el cambio entre iteraciones sea menor a una tolerancia especificada. Este es el motivo por el cual los programas estadísticos reportan el número de iteraciones y, ocasionalmente, advertencias de falta de convergencia al estimar estos modelos.

6.2.2. Dos resultados fundamentales

Las propiedades del estimador de máxima verosimilitud descansan en dos resultados que demostraremos a continuación. Ambos suponen que el modelo está **correctamente especificado**, es decir, que existe un valor verdadero $\boldsymbol{\theta}_0$ tal que $f(y | \mathbf{x}; \boldsymbol{\theta}_0)$ es la verdadera densidad condicional, y que se cumplen ciertas condiciones de regularidad que enunciamos más adelante.

Teorema 6.1 *Esperanza nula del puntaje.* *Evaluado en el valor verdadero de los parámetros, el puntaje tiene esperanza condicional nula:*

$$\mathbb{E}[\mathbf{s}_i(\boldsymbol{\theta}_0) | \mathbf{x}_i] = \mathbf{0} \quad (6.8)$$

Demostración. Partamos del hecho de que toda función de densidad integra a uno, para cualquier valor de los parámetros dentro del espacio paramétrico:

$$\int f(y | \mathbf{x}; \boldsymbol{\theta}) dy = 1 , \forall \boldsymbol{\theta} \in \Theta$$

Dado que el lado derecho es constante, podemos derivar ambos lados respecto de $\boldsymbol{\theta}$ e intercambiar el orden de derivación e integración, lo cual es válido bajo las condiciones de regularidad:

$$\int \frac{\partial f(y | \mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} dy = \mathbf{0}$$

Ahora multipliquemos y dividamos el integrando por $f(y | \mathbf{x}; \boldsymbol{\theta})$, y notemos que $\partial \ln f / \partial \boldsymbol{\theta} = (\partial f / \partial \boldsymbol{\theta}) / f$:

$$\int \frac{\partial f / \partial \boldsymbol{\theta}}{f} f(y | \mathbf{x}; \boldsymbol{\theta}) dy = \int \frac{\partial \ln f(y | \mathbf{x}; \boldsymbol{\theta})}{\partial \boldsymbol{\theta}} f(y | \mathbf{x}; \boldsymbol{\theta}) dy = \mathbb{E}[\mathbf{s}_i(\boldsymbol{\theta}) | \mathbf{x}_i] = \mathbf{0}$$

Evaluando en $\boldsymbol{\theta} = \boldsymbol{\theta}_0$ obtenemos el resultado. ■

Este resultado es importante por dos razones. Primero, muestra que la ecuación de verosimilitud (6.6) es la contraparte muestral de una condición de momento poblacional válida, lo que conecta la máxima verosimilitud con el método generalizado de momentos que estudiamos en el capítulo de sistemas de ecuaciones. Segundo, es el ingrediente que permite aplicar el Teorema del Límite Central al puntaje y obtener la distribución asintótica del estimador.

Teorema 6.2 Igualdad de la matriz de información. *Bajo especificación correcta y las condiciones de regularidad:*

$$\mathbf{A}(\boldsymbol{\theta}_0) \equiv -\mathbb{E}[\mathbf{H}_i(\boldsymbol{\theta}_0)] = \mathbb{E}[\mathbf{s}_i(\boldsymbol{\theta}_0)\mathbf{s}_i(\boldsymbol{\theta}_0)'] \equiv \mathbf{B}(\boldsymbol{\theta}_0) \quad (6.9)$$

A esta matriz común se le denomina **matriz de información de Fisher**.

Demostración. Partamos del resultado intermedio de la demostración anterior, válido para todo $\boldsymbol{\theta}$:

$$\int \frac{\partial \ln f}{\partial \boldsymbol{\theta}} f dy = \mathbf{0}$$

Derivemos nuevamente, ahora respecto de $\boldsymbol{\theta}'$, aplicando la regla del producto dentro de la integral:

$$\int \frac{\partial^2 \ln f}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} f dy + \int \frac{\partial \ln f}{\partial \boldsymbol{\theta}} \frac{\partial f}{\partial \boldsymbol{\theta}'} dy = \mathbf{0}$$

En el segundo término aplicamos nuevamente el truco de multiplicar y dividir por f , con lo que $\partial f / \partial \boldsymbol{\theta}' = (\partial \ln f / \partial \boldsymbol{\theta}') f$:

$$\int \frac{\partial^2 \ln f}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'} f dy + \int \frac{\partial \ln f}{\partial \boldsymbol{\theta}} \frac{\partial \ln f}{\partial \boldsymbol{\theta}'} f dy = \mathbf{0}$$

Reconociendo que la primera integral es $\mathbb{E}[\mathbf{H}_i]$ y la segunda es $\mathbb{E}[\mathbf{s}_i \mathbf{s}_i']$, y evaluando en $\boldsymbol{\theta}_0$:

$$\mathbb{E}[\mathbf{H}_i(\boldsymbol{\theta}_0)] + \mathbb{E}[\mathbf{s}_i(\boldsymbol{\theta}_0) \mathbf{s}_i(\boldsymbol{\theta}_0)'] = \mathbf{0} \blacksquare$$

La igualdad de la ecuación (6.9) es notable: nos dice que la curvatura esperada de la log-verosimilitud, que mide qué tan pronunciado es el máximo, coincide con la variabilidad del puntaje. Ambas cantidades miden la misma cosa, a saber, cuánta información contiene la muestra sobre el parámetro. Y es esta igualdad la que da lugar a la advertencia que hicimos antes: $\mathbf{H}_i \neq \mathbf{s}_i \mathbf{s}_i'$ observación por observación, pero sí se cumple $-\mathbb{E}[\mathbf{H}_i] = \mathbb{E}[\mathbf{s}_i \mathbf{s}_i']$ en valor esperado.

6.2.3. Condiciones de regularidad

Los resultados anteriores y los que siguen requieren un conjunto de supuestos técnicos que enunciamos brevemente:

1. **Identificación.** Si $\boldsymbol{\theta} \neq \boldsymbol{\theta}_0$, entonces $f(y | \mathbf{x}; \boldsymbol{\theta}) \neq f(y | \mathbf{x}; \boldsymbol{\theta}_0)$ con probabilidad positiva. Sin este supuesto, distintos valores de los parámetros producirían la misma distribución y no habría forma de distinguirlos con los datos.
2. **Especificación correcta.** Existe $\boldsymbol{\theta}_0 \in \boldsymbol{\Theta}$ tal que $f(y | \mathbf{x}; \boldsymbol{\theta}_0)$ es la verdadera densidad condicional.
3. **El espacio paramétrico $\boldsymbol{\Theta}$** es compacto y $\boldsymbol{\theta}_0$ pertenece a su interior, de modo que el máximo no se encuentra en la frontera.
4. **Diferenciabilidad.** $\ln f(y | \mathbf{x}; \boldsymbol{\theta})$ es dos veces continuamente diferenciable en $\boldsymbol{\theta}$.
5. **El soporte de la distribución no depende de $\boldsymbol{\theta}$.** Este supuesto es el que permite intercambiar derivación e integración en las demostraciones anteriores, y su violación es la razón por la cual ciertos modelos, como el de una uniforme con límite superior desconocido, no cumplen la teoría estándar.
6. **Condiciones de dominancia** que permiten aplicar la ley de los grandes números uniforme.

6.2.4. Propiedades asintóticas

Teorema 6.3 Consistencia. *Bajo las condiciones de regularidad, $\hat{\boldsymbol{\theta}} \xrightarrow{p} \boldsymbol{\theta}_0$.*

La intuición de la demostración es la siguiente. Puede mostrarse, usando la desigualdad de Jensen, que $\mathbb{E}[\ln f(y \mid \mathbf{x}; \boldsymbol{\theta})]$ alcanza su máximo en $\boldsymbol{\theta}_0$, resultado conocido como desigualdad de la información de Kullback-Leibler. Dado que $N^{-1} \ln L(\boldsymbol{\theta})$ converge uniformemente a esa esperanza, el valor que maximiza la función muestral converge al valor que maximiza la función poblacional.

Teorema 6.4 Normalidad asintótica. *Bajo las condiciones de regularidad:*

$$\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{A}(\boldsymbol{\theta}_0)^{-1}) \quad (6.10)$$

Demostración. Apliquemos una expansión de Taylor de primer orden a la ecuación de verosimilitud (6.6) alrededor de $\boldsymbol{\theta}_0$:

$$\mathbf{0} = N^{-1/2} \sum_{i=1}^N \mathbf{s}_i(\hat{\boldsymbol{\theta}}) = N^{-1/2} \sum_{i=1}^N \mathbf{s}_i(\boldsymbol{\theta}_0) + \left[N^{-1} \sum_{i=1}^N \mathbf{H}_i(\bar{\boldsymbol{\theta}}) \right] \sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0)$$

Donde $\bar{\boldsymbol{\theta}}$ es un valor intermedio entre $\hat{\boldsymbol{\theta}}$ y $\boldsymbol{\theta}_0$. Despejando:

$$\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) = - \left[N^{-1} \sum_{i=1}^N \mathbf{H}_i(\bar{\boldsymbol{\theta}}) \right]^{-1} N^{-1/2} \sum_{i=1}^N \mathbf{s}_i(\boldsymbol{\theta}_0)$$

Por la consistencia de $\hat{\boldsymbol{\theta}}$ y la ley de los grandes números, el primer factor converge en probabilidad a $(-\mathbb{E}[\mathbf{H}_i(\boldsymbol{\theta}_0)])^{-1} = \mathbf{A}(\boldsymbol{\theta}_0)^{-1}$. Por el teorema de la esperanza nula del puntaje (6.8) y el Teorema del Límite Central, el segundo factor converge en distribución a una $\text{Normal}(\mathbf{0}, \mathbf{B}(\boldsymbol{\theta}_0))$. Aplicando el teorema de Slutsky:

$$\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}_0) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{A}^{-1} \mathbf{B} \mathbf{A}^{-1})$$

Y aplicando finalmente la igualdad de la matriz de información (6.9), que establece $\mathbf{A} = \mathbf{B}$, la expresión de emparejado colapsa a $\mathbf{A}^{-1} \mathbf{A} \mathbf{A}^{-1} = \mathbf{A}^{-1}$. ■

Teorema 6.5 Eficiencia asintótica. *El estimador de máxima verosimilitud alcanza la cota inferior de Cramér-Rao asintóticamente. Es decir, cualquier otro estimador consistente y asintóticamente normal tiene una varianza asintótica mayor o igual a $\mathbf{A}(\boldsymbol{\theta}_0)^{-1}$.*

6.2.5. Estimación de la matriz de varianzas

De los resultados anteriores se desprende que la matriz de varianzas y covarianzas estimada del estimador es:

$$\widehat{Var}(\hat{\theta}) = \frac{1}{N} \hat{\mathbf{A}}^{-1} \quad (6.11)$$

Ahora bien, la igualdad de la matriz de información nos ofrece **tres** formas distintas de estimar $\mathbf{A}$, todas asintóticamente equivalentes bajo especificación correcta pero numéricamente distintas en cualquier muestra finita:

1. **Estimador del hessiano.** Es el más directo y el que utilizan por omisión la mayoría de los programas:

$$\hat{\mathbf{A}}_H = -\frac{1}{N} \sum_{i=1}^N \mathbf{H}_i(\hat{\theta}) \quad (6.12)$$

2. **Estimador del producto externo del gradiente** (OPG), también llamado estimador BHHH por Berndt, Hall, Hall y Hausman. Tiene la ventaja de requerir únicamente primeras derivadas:

$$\hat{\mathbf{B}} = \frac{1}{N} \sum_{i=1}^N \mathbf{s}_i(\hat{\theta}) \mathbf{s}_i(\hat{\theta})' \quad (6.13)$$

3. **Estimador de emparedado** o robusto, también llamado de Huber-White:

$$\widehat{Var}_{rob}(\hat{\theta}) = \frac{1}{N} \hat{\mathbf{A}}_H^{-1} \hat{\mathbf{B}} \hat{\mathbf{A}}_H^{-1} \quad (6.14)$$

La existencia de estas tres alternativas tiene una consecuencia práctica de la mayor importancia. Si el modelo está correctamente especificado, las tres estiman lo mismo y la elección es indiferente asintóticamente. Pero si el modelo está mal especificado, la igualdad de la matriz de información *falla*, y entonces $\hat{\mathbf{A}}_H^{-1}$ y $\hat{\mathbf{B}}^{-1}$ estiman cantidades distintas mientras que sólo la ecuación (6.14) sigue siendo válida. Por esta razón, una diferencia grande entre los errores estándar convencionales y los robustos es un **síntoma de especificación errónea** y debe tomarse como una señal de alerta, no simplemente como una elección técnica sin consecuencias.

6.2.6. Cuasi máxima verosimilitud

El punto anterior merece un desarrollo, porque explica una práctica muy extendida. Supongamos que maximizamos una función de verosimilitud construida a partir de una densidad $f(y \mid \mathbf{x}; \boldsymbol{\theta})$ que *no* es la verdadera. Al estimador resultante se le llama estimador de **cuasi máxima verosimilitud** (QMLE). En general, el QMLE converge a un valor $\boldsymbol{\theta}^*$ que minimiza la divergencia de Kullback-Leibler entre la densidad supuesta y la verdadera, y ese valor no tiene por qué coincidir con el parámetro de interés.

Sin embargo, existe una familia notable de excepciones. Si la densidad supuesta pertenece a la familia lineal exponencial y la **media condicional está correctamente especificada**, entonces el QMLE es consistente para los parámetros de la media condicional, aun cuando el resto del supuesto distribucional sea falso. Los casos más relevantes son el modelo Poisson, que resulta consistente para los parámetros de la media aun cuando exista sobredispersión y por lo tanto la distribución no sea Poisson, y el modelo normal, que produce el estimador de MCO. En estos casos los estimadores puntuales son válidos, pero los errores estándar convencionales no lo son y debe emplearse la varianza robusta de la ecuación (6.14). Esta es precisamente la justificación teórica de por qué en el capítulo de modelos de conteo insistiremos en reportar errores estándar robustos para el modelo Poisson.

6.3. Pruebas de hipótesis

Consideremos un conjunto de Q restricciones sobre los parámetros, expresadas como $H_0 : \mathbf{c}(\boldsymbol{\theta}) = \mathbf{0}$, donde $\mathbf{c}(\cdot)$ es una función continuamente diferenciable de $\mathbb{R}^K$ en $\mathbb{R}^Q$. Un caso particular frecuente es el de restricciones lineales, $H_0 : \mathbf{R}\boldsymbol{\theta} = \mathbf{r}$.

El marco de máxima verosimilitud ofrece tres pruebas para contrastar esta hipótesis, conocidas colectivamente como la **trinidad clásica**. Las tres son asintóticamente equivalentes bajo la nula y se distribuyen χ_Q^2 , pero difieren en qué estimaciones requieren, lo que determina cuál resulta más conveniente en cada situación.

6.3.1. Prueba de Wald

Sólo requiere estimar el modelo **no restringido**. La idea es evaluar directamente qué tan lejos de cero se encuentra $\mathbf{c}(\hat{\boldsymbol{\theta}})$, escalando por su variabilidad:

$$W = \mathbf{c}(\hat{\boldsymbol{\theta}})' \left[\widehat{\mathbf{CVar}}(\hat{\boldsymbol{\theta}}) \mathbf{C}' \right]^{-1} \mathbf{c}(\hat{\boldsymbol{\theta}}) \xrightarrow{d} \chi_Q^2 \quad (6.15)$$

Donde $\mathbf{C} = \partial \mathbf{c}(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}'$ evaluado en $\hat{\boldsymbol{\theta}}$ es el jacobiano de las restricciones, de dimensión $Q \times K$, y Q es el número de restricciones. La aplicación del método delta es lo que justifica la forma de la varianza en el término central.

El caso más simple es el de una sola restricción sobre un coeficiente individual, $H_0 : \theta_k = \theta_k^0$. En ese caso la ecuación (6.15) se reduce al cuadrado de la estadística:

$$Z = \frac{\hat{\theta}_k - \theta_k^0}{\sqrt{\widehat{Var}(\hat{\theta}_k)}} \xrightarrow{d} Normal(0, 1) \quad (6.16)$$

Que es la prueba t asintótica que reportan de forma rutinaria los programas estadísticos. Notemos que, al tratarse de una variable *estandarizada*, su distribución límite es una normal estándar y no una normal con varianza $\widehat{Var}(\hat{\theta}_k)$. Recordemos además que en el contexto de máxima verosimilitud la distribución es exacta sólo asintóticamente, por lo que hablamos de una prueba Z y no de una prueba t con grados de libertad finitos.

Una advertencia relevante sobre la prueba de Wald es que **no es invariante** ante reparametrizaciones no lineales de las restricciones. Contrastar $H_0 : \theta_1 \theta_2 = 1$ y contrastar $H_0 : \theta_1 - 1/\theta_2 = 0$ son hipótesis algebraicamente idénticas, pero pueden producir valores distintos de W y, en casos extremos, conclusiones opuestas. Las otras dos pruebas de la trinidad no comparten este defecto.

6.3.2. Prueba de razón de verosimilitudes

Requiere estimar **ambos** modelos, el restringido y el no restringido. La idea es comparar directamente el valor alcanzado por la función objetivo en cada caso:

$$LR = 2 \left[\ln L(\hat{\boldsymbol{\theta}}_U) - \ln L(\hat{\boldsymbol{\theta}}_R) \right] \xrightarrow{d} \chi_Q^2 \quad (6.17)$$

Donde $\hat{\boldsymbol{\theta}}_U$ es el estimador no restringido y $\hat{\boldsymbol{\theta}}_R$ es el estimador que maximiza la verosimilitud sujeto a las restricciones. Dado que el máximo no

restringido nunca puede ser menor que el restringido, la estadística de la ecuación (6.17) es siempre no negativa. Si las restricciones son ciertas, imponerlas debería reducir muy poco el valor de la log-verosimilitud; si son falsas, la caída será considerable.

Es fundamental subrayar una limitación de esta prueba: su validez descansa en que la verosimilitud esté **correctamente especificada**. A diferencia de la prueba de Wald, que puede construirse con errores estándar robustos, la prueba de razón de verosimilitudes en su forma estándar no es válida bajo cuasi máxima verosimilitud y requiere correcciones específicas.

6.3.3. Prueba del multiplicador de Lagrange

Sólo requiere estimar el modelo **restringido**, lo que la hace especialmente atractiva cuando el modelo no restringido es difícil o costoso de estimar. Es también conocida como prueba del puntaje. La idea es evaluar el gradiente de la log-verosimilitud no restringida en el estimador restringido: si las restricciones son ciertas, ese gradiente debería ser cercano a cero, ya que el estimador restringido estaría cerca del óptimo no restringido.

$$LM = \left[\sum_{i=1}^N \mathbf{s}_i(\hat{\boldsymbol{\theta}}_R) \right]' \left[\sum_{i=1}^N \mathbf{s}_i(\hat{\boldsymbol{\theta}}_R) \mathbf{s}_i(\hat{\boldsymbol{\theta}}_R)' \right]^{-1} \left[\sum_{i=1}^N \mathbf{s}_i(\hat{\boldsymbol{\theta}}_R) \right] \xrightarrow{d} \chi_Q^2 \quad (6.18)$$

Una forma muy conveniente de calcular la ecuación (6.18) es mediante la llamada **regresión artificial**: se corre una regresión de MCO de un vector de unos contra los puntajes individuales evaluados en el estimador restringido, y la estadística resulta ser $LM = N \cdot R_u^2$, donde R_u^2 es el coeficiente de determinación no centrado de esa regresión. Muchas de las pruebas de diagnóstico que ya hemos utilizado a lo largo del curso, como la prueba de Breusch-Pagan de heterocedasticidad de la ecuación (4.8) o la prueba de diagonalidad en el modelo SUR de la ecuación (4.15), son casos particulares de esta construcción.

6.3.4. Comparación de las tres pruebas

La Figura 6.1 resume geométricamente en qué se fija cada una de las tres pruebas sobre una misma función de log-verosimilitud. La prueba de Wald mide una distancia *horizontal*, entre el estimador no restringido y el valor que impone la hipótesis nula. La de razón de verosimilitudes mide




Figura 6.1: Interpretación geométrica de las pruebas de Wald, razón de verosimilitudes y multiplicador de Lagrange

una distancia *vertical*, entre las alturas que alcanza la función en uno y otro punto. La del multiplicador de Lagrange mide una *pendiente*, la de la tangente en el estimador restringido. Se aprecia también por qué cada una requiere estimaciones distintas: la primera sólo necesita el punto de la derecha, la tercera sólo el de la izquierda, y la segunda necesita ambos.

Las tres pruebas son asintóticamente equivalentes bajo la hipótesis nula, de modo que con muestras suficientemente grandes conducirán a la misma conclusión. Sin embargo, en muestras finitas pueden diferir, y en el modelo lineal clásico con errores normales puede demostrarse que se cumple la desigualdad:

$$W \geq LR \geq LM$$

Lo cual implica que la prueba de Wald es la más propensa a rechazar la hipótesis nula y la del multiplicador de Lagrange la más conservadora. Cuando las tres pruebas arrojan conclusiones distintas para un mismo contraste, ello suele ser señal de que la muestra no es lo suficientemente grande para que la aproximación asintótica resulte confiable, o de que el modelo está mal especificado. En la práctica, el criterio de elección suele ser computacional: la prueba de Wald cuando ya se estimó el modelo general, la del multiplicador de Lagrange cuando estimar el modelo general es costoso, y la de razón de

verosimilitudes cuando ambos modelos están disponibles y se confía en la especificación distribucional.

6.4. Un ejemplo completo: el modelo lineal con errores normales

Cerramos el capítulo con un ejemplo que permite verificar todos los resultados anteriores en un caso donde conocemos la respuesta de antemano. Consideremos el modelo lineal $y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$ con $\varepsilon_i \mid \mathbf{x}_i \sim \text{Normal}(0, \sigma^2)$. La densidad condicional es:

$$f(y_i \mid \mathbf{x}_i; \boldsymbol{\beta}, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left[-\frac{(y_i - \mathbf{x}_i\boldsymbol{\beta})^2}{2\sigma^2} \right]$$

De donde la log-verosimilitud de la muestra es:

$$\ln L(\boldsymbol{\beta}, \sigma^2) = -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^N (y_i - \mathbf{x}_i\boldsymbol{\beta})^2 \quad (6.19)$$

Derivando la ecuación (6.19) respecto de $\boldsymbol{\beta}$ e igualando a cero:

$$\frac{\partial \ln L}{\partial \boldsymbol{\beta}} = \frac{1}{\sigma^2} \sum_{i=1}^N \mathbf{x}_i' (y_i - \mathbf{x}_i\boldsymbol{\beta}) = \frac{1}{\sigma^2} \mathbf{X}'(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) = \mathbf{0}$$

Dado que $\sigma^2 > 0$, el factor se cancela y obtenemos exactamente las ecuaciones normales de MCO, de donde $\hat{\boldsymbol{\beta}}_{ML} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \hat{\boldsymbol{\beta}}_{MCO}$. Es decir, bajo normalidad el estimador de máxima verosimilitud de los coeficientes coincide numéricamente con el de mínimos cuadrados ordinarios. Notemos que la última expresión es también, salvo el factor de escala, la condición de ortogonalidad que motivó a MCO en su momento.

Derivando ahora respecto de σ^2 :

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{N}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^N (y_i - \mathbf{x}_i\boldsymbol{\beta})^2 = 0 \quad \implies \quad \hat{\sigma}_{ML}^2 = \frac{\mathbf{e}'\mathbf{e}}{N}$$

Aquí aparece una diferencia importante respecto de lo que vimos en el capítulo de MCO, donde el estimador insesgado de la varianza es $s^2 =$

$\mathbf{e}'\mathbf{e}/(N - K)$. El estimador de máxima verosimilitud divide entre N y no entre $N - K$, por lo que es **sesgado** en muestras finitas, aunque consistente. Este ejemplo ilustra una propiedad general del método: la máxima verosimilitud garantiza consistencia y eficiencia asintótica, pero no insesgamiento en muestras finitas. Es también la razón por la que distintos programas estadísticos pueden reportar valores ligeramente distintos de la varianza residual según estimen el modelo lineal por MCO o por máxima verosimilitud.

Se deja como ejercicio verificar que, en este modelo, la matriz de información resulta ser diagonal por bloques entre $\boldsymbol{\beta}$ y σ^2 , lo cual implica que ambos estimadores son asintóticamente independientes, y que el bloque correspondiente a $\boldsymbol{\beta}$ conduce a $\widehat{Var}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}$, que es el resultado ya conocido.

6.5. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) El hessiano de la log-verosimilitud de una observación es igual al producto externo de su vector de puntajes.
 - b) El estimador de máxima verosimilitud es insesgado en muestras finitas.
 - c) Si el modelo está correctamente especificado, los errores estándar basados en el hessiano y los robustos deben ser asintóticamente iguales.
 - d) La prueba de razón de verosimilitudes puede utilizarse sin modificación cuando estimamos por cuasi máxima verosimilitud.
 - e) La prueba del multiplicador de Lagrange requiere estimar el modelo no restringido.
 - f) El estimador de máxima verosimilitud del modelo lineal con errores normales coincide con el de MCO tanto para $\boldsymbol{\beta}$ como para σ^2 .
2. Demuestre el teorema de la esperanza nula del puntaje, ecuación (6.8), detallando en qué paso exacto se utiliza el supuesto de que el soporte

de la distribución no depende de $\boldsymbol{\theta}$. Construya además un ejemplo de una distribución que viole ese supuesto y explique qué ocurre con el resultado.

3. Considere el modelo de respuesta binaria del ejemplo con el que iniciamos el capítulo, en el que $P(y_i = 1 \mid \mathbf{x}_i) = \Phi(\mathbf{x}_i \boldsymbol{\theta})$. Se le solicita:
 - a) Escribir la función de log-verosimilitud de la muestra.
 - b) Obtener el vector de puntajes $\mathbf{s}_i(\boldsymbol{\theta})$ de la ecuación (6.4). Sugerencia: recuerde que $\partial \Phi(u) / \partial u = \phi(u)$.
 - c) Verificar directamente que $\mathbb{E}[\mathbf{s}_i(\boldsymbol{\theta}_0) \mid \mathbf{x}_i] = \mathbf{0}$, utilizando que $\mathbb{E}[y_i \mid \mathbf{x}_i] = \Phi(\mathbf{x}_i \boldsymbol{\theta}_0)$.
 - d) Explicar por qué la ecuación de verosimilitud no admite solución cerrada en este caso.
4. Sea y_i una variable de conteo con distribución Poisson de media $\mu_i = \exp(\mathbf{x}_i \boldsymbol{\beta})$. Se le solicita: (i) escribir la log-verosimilitud; (ii) obtener el vector de puntajes y mostrar que la ecuación de verosimilitud es $\sum_i \mathbf{x}_i'(y_i - \exp(\mathbf{x}_i \boldsymbol{\beta})) = \mathbf{0}$; (iii) obtener el hessiano y verificar que es definido negativo, de donde se concluye que la log-verosimilitud es globalmente cóncava; y (iv) explicar, a partir de la forma de la ecuación de verosimilitud, por qué el estimador sigue siendo consistente aun cuando la distribución verdadera no sea Poisson, siempre que la media condicional esté bien especificada.
5. Para el modelo lineal con errores normales de la ecuación (6.19), se le solicita:
 - a) Obtener el hessiano completo respecto de $(\boldsymbol{\beta}, \sigma^2)$.
 - b) Calcular $\mathbf{A} = -\mathbb{E}[\mathbf{H}_i]$ y verificar que es diagonal por bloques.
 - c) Concluir que $\widehat{Var}(\hat{\boldsymbol{\beta}}) = \hat{\sigma}^2(\mathbf{X}'\mathbf{X})^{-1}$ y que $\widehat{Var}(\hat{\sigma}^2) = 2\sigma^4/N$.
 - d) Explicar qué implica la diagonalidad por bloques sobre la relación entre los estimadores de $\boldsymbol{\beta}$ y de σ^2 .
6. Verifique la igualdad de la matriz de información, ecuación (6.9), para el caso más simple posible: una muestra de N observaciones Bernoulli independientes con parámetro p , sin covariables. Calcule explícitamente $-\mathbb{E}[H_i]$ y $\mathbb{E}[s_i^2]$ y compruebe que ambos son iguales a $1/[p(1-p)]$.

7. Explique por qué la prueba de Wald no es invariante ante reparametrizaciones no lineales de las restricciones, mientras que las pruebas de razón de verosimilitudes y del multiplicador de Lagrange sí lo son. Construya un ejemplo numérico sencillo con $H_0 : \theta_1\theta_2 = 1$ frente a $H_0 : \theta_1 - 1/\theta_2 = 0$ que ilustre el problema.
8. **Aplicación en Python.** Programe por su cuenta la estimación por máxima verosimilitud de un modelo probit, sin utilizar las rutinas ya implementadas. Se le solicita:
- a) Escribir la función de log-verosimilitud y maximizarla con un optimizador numérico, por ejemplo `scipy.optimize.minimize`, sobre el negativo de la función.
 - b) Calcular los errores estándar mediante los tres estimadores de las ecuaciones (6.12), (6.13) y (6.14), y comparar los resultados entre sí.
 - c) Contrastar sus resultados con los que produce la rutina correspondiente de `statsmodels`.
 - d) Contrastar la significancia conjunta de un subconjunto de coeficientes mediante las tres pruebas de la trinidad clásica y verificar empíricamente el ordenamiento $W \geq LR \geq LM$.

7

Estimación de modelos no lineales

7.1. Modelos de respuesta binaria

7.1.1. Planteamiento general

En el caso de modelos de respuesta binaria, asumiremos que y_i es una variable aleatoria que toma sólo valores de 0 y 1. Los ejemplos pueden ser amplios. Decisiones sobre consumir o no, pagar o no, ir a una escuela determinada, viajar por tierra o aire. En general diremos que 1 es éxito y 0 es fracaso.

Como en el caso de modelos lineales diremos que y_i es la variable dependiente y $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{iK})$ un vector de variables independientes o explicativas. Así, en los modelos no lineales de respuesta binaria estaremos interesados en la probabilidades:

$$P(y_i = 1|\mathbf{x}_i) = P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Dicho lo anterior y de forma similar al de la regresión lineal, podemos establecer el efecto marginal para el caso de una variable independiente x_j continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y_i = 1|x_{i1}, x_{i2}, \dots, x_{iK})$$

Cuando la variable independiente es una variable dummy:

$$\begin{aligned} EMg_j &= P(y_i = 1 | x_{i1}, x_{i2}, \dots, x_{ij} = 1, \dots, x_{iK}) - \\ &P(y_i = 1 | x_{i1}, x_{i2}, \dots, x_{ij} = 0, \dots, x_{iK}) \end{aligned}$$

Este tipo de modelos se basan en el modelo de Bernoulli, cuya función de densidad de probabilidad condicional y podemos plantearlo como:

$$\begin{aligned} P(y_i = 1 | \mathbf{x}_i) &= p(x) \\ P(y_i = 0 | \mathbf{x}_i) &= 1 - p(x) \\ Var(y_i | \mathbf{x}_i) &= p(x) \cdot (1 - p(x)) \end{aligned}$$

7.1.2. Algunos planteamientos adicionales

Antes de introducir los modelos que utilizaremos, conviene entender por qué no basta con aplicar el instrumental lineal que ya conocemos. La alternativa más simple sería estimar por MCO la ecuación:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \quad (7.1)$$

Dado que $\mathbb{E}[y_i | \mathbf{x}_i] = P(y_i = 1 | \mathbf{x}_i)$ cuando y_i es binaria, la ecuación (7.1) equivale a suponer que la probabilidad de respuesta es lineal en los regresores:

$$P(y_i = 1 | \mathbf{x}_i) = \mathbf{x}_i \boldsymbol{\beta}$$

A este planteamiento se le conoce como **Modelo de Probabilidad Lineal** (MPL). Es un modelo perfectamente estimable y de hecho se utiliza con frecuencia, pero presenta tres problemas que conviene tener claros:

1. **Probabilidades fuera del intervalo** $[0, 1]$. Nada impide que $\mathbf{x}_i \hat{\boldsymbol{\beta}}$ sea negativo o mayor que uno para algunos valores de los regresores, lo cual carece de sentido como probabilidad. El problema es más severo cuanto más extremos sean los valores de $\mathbf{x}_i$.
2. **Heterocedasticidad inherente**. Dado que y_i es una variable Bernoulli, su varianza condicional es necesariamente:

$$Var(y_i | \mathbf{x}_i) = P(y_i = 1 | \mathbf{x}_i) [1 - P(y_i = 1 | \mathbf{x}_i)] = \mathbf{x}_i \boldsymbol{\beta} (1 - \mathbf{x}_i \boldsymbol{\beta})$$

Que depende de $\mathbf{x}_i$. Esto no compromete la consistencia, pero exige errores estándar robustos.




Figura 7.1: Modelo de probabilidad lineal frente a los modelos logit y probit

3. **Efectos marginales constantes.** En el MPL el efecto marginal es β_j para cualquier valor de los regresores. Esto suele ser poco plausible: es de esperar que un año adicional de educación tenga un efecto distinto sobre la probabilidad de participar en el mercado laboral según se parta de un nivel bajo o alto de escolaridad.

Notemos que sólo el primer y el tercer problema son de fondo; el segundo se resuelve con errores estándar robustos. Los modelos que desarrollamos a continuación atacan los otros dos imponiendo que la probabilidad se obtenga a través de una función acotada entre cero y uno.

La Figura 7.1 contrasta las tres alternativas. En el panel (a) se aprecia el primer problema: la recta del modelo de probabilidad lineal atraviesa las regiones sombreadas, en las que la probabilidad ajustada sería negativa o mayor que uno, mientras que las funciones logística y normal permanecen siempre dentro del intervalo. Nótese además que ambas curvas son casi indistinguibles cuando el argumento del logit se escala por 1.6, lo que ilustra la equivalencia de escala que mencionaremos más adelante. El panel (b) muestra el tercer problema: en el modelo lineal el efecto marginal es una constante, mientras que en el logit y el probit alcanza su máximo cuando la probabilidad está cerca de 0.5 y se desvanece en los extremos. La lectura económica de esto último es intuitiva: un año adicional de escolaridad cambia poco la decisión de quien de todos modos casi con certeza participará en el mercado laboral, o de quien casi con certeza no lo hará, y mucho la de quien está indeciso.

7.1.3. Modelos Logit y Probit

Este tipo de modelos suponen que existe una variable latente que se puede expresar como una ecuación lineal dada por:

$$y_i^* = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Donde ε_i es una variable aleatoria con función de densidad con media cero y distribución simétrica alrededor de cero. Dado lo anterior, para nosotros sólo es visible que:

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{si } y_i^* < 0 \end{cases}$$

De esta forma tenemos una estructura de la probabilidad dada por:

$$\begin{aligned} P(y_i = 1|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i > 0) = P(\varepsilon_i > -\mathbf{x}_i\boldsymbol{\beta}) = G(\mathbf{x}_i\boldsymbol{\beta}) \\ P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i < 0) = P(\varepsilon_i < -\mathbf{x}_i\boldsymbol{\beta}) = 1 - G(\mathbf{x}_i\boldsymbol{\beta}) \end{aligned}$$

Donde $\mathbf{x}_i$ es un vector de dimensión $K \times 1$ que contiene al menos el término constante y $\boldsymbol{\beta}$ es un vector de parámetros a estimar, de forma que asumiremos:

$$\mathbf{x}_i\boldsymbol{\beta} = \beta_1 + x_{i2}\beta_2 + \dots + x_{iK}\beta_K$$

Asumiremos que $G(\cdot)$ es una función de distribución acumulada de forma que:

$$0 < G(\mathbf{x}_i\boldsymbol{\beta}) < 1, \forall \mathbf{x}_i\boldsymbol{\beta} \in \mathbb{R}$$

En este caso utilizaremos dos modelos que dependen de la forma funcional de $G(\cdot)$ que está determinada por la distribución de ε_i . De esta forma tendremos dos modelos: Probit y Logit:

1. **Modelo Probit**, cuando

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Phi(\mathbf{x}_i\boldsymbol{\beta}) = \int_{-\infty}^{\mathbf{x}_i\boldsymbol{\beta}} \phi(\nu) d\nu$$

Donde $\phi(\cdot)$ es la función de densidad de la normal estándar:

$$\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2}$$

2. Modelo Logit, cuando

$$G(\mathbf{x}_i\boldsymbol{\beta}) = \Lambda(\mathbf{x}_i\boldsymbol{\beta}) = \frac{e^{\mathbf{x}_i\boldsymbol{\beta}}}{1 + e^{\mathbf{x}_i\boldsymbol{\beta}}}$$

Donde $\Lambda(\cdot)$ es la función de distribución acumulada logística, cuya densidad asociada es $\lambda(z) = \Lambda(z)[1 - \Lambda(z)]$.

Ambas especificaciones producen en la práctica resultados muy similares, ya que difieren esencialmente en la escala: la distribución logística tiene varianza $\pi^2/3$ frente a la varianza unitaria de la normal estándar, de modo que los coeficientes del logit resultan aproximadamente 1.6 veces los del probit. Los efectos marginales y las probabilidades ajustadas, en cambio, son casi indistinguibles. La elección entre ambos suele responder a la conveniencia: el logit admite la interpretación en términos de razones de momios, mientras que el probit se generaliza con más facilidad a modelos multivariados con errores normales correlacionados.

Sin importar el modelo que estemos ocupando, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_j sea una variable continua:

$$EMg_j = \frac{\partial}{\partial x_j} P(y = 1|\mathbf{x}_i) = \frac{\partial}{\partial x_j} G(\mathbf{x}_i\boldsymbol{\beta}) = g(\mathbf{x}_i\boldsymbol{\beta})\beta_j$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned} EMg_j &= P(y = 1|\mathbf{x}_i, x_j = 1) - P(y = 1|\mathbf{x}_i, x_j = 0) \\ &= G(\mathbf{x}_i\boldsymbol{\beta}|x_j = 1) - G(\mathbf{x}_i\boldsymbol{\beta}|x_j = 0) \\ &= G(\beta_1 + x_2\beta_2 + \dots + \beta_j + \dots + x_K\beta_K) \\ &\quad - G(\beta_1 + x_2\beta_2 + \dots + 0 + \dots + x_K\beta_K) \end{aligned}$$

7.1.4. Estimación

Supongamos n observaciones de una variable aleatoria independientes e idénticamente distribuidas. En estos casos la función de densidad para cada y_i , $i = 1, 2, \dots, N$, estará dada por:

$$f(y_i|\mathbf{x}_i; \boldsymbol{\beta}) = [G(\mathbf{x}_i\boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i\boldsymbol{\beta})]^{1-y_i}, \text{ donde } y_i = 0, 1$$

En estos términos la función de verosimilitud estará dada por:

$$\begin{aligned} L(\boldsymbol{\beta}) &= \prod_{i=1}^N f(y_i|\mathbf{x}_i; \boldsymbol{\beta}) \\ &= \prod_{i=1}^N [G(\mathbf{x}_i\boldsymbol{\beta})]^{y_i} [1 - G(\mathbf{x}_i\boldsymbol{\beta})]^{1-y_i} \end{aligned}$$

En versión logarítmica:

$$\begin{aligned} \ln L(\boldsymbol{\beta}) &= \sum_{i=1}^N \ln(f(y_i|\mathbf{x}_i; \boldsymbol{\beta})) \\ &= \sum_{i=1}^N y_i \ln[G(\mathbf{x}_i\boldsymbol{\beta})] + \sum_{i=1}^N (1 - y_i) \ln[1 - G(\mathbf{x}_i\boldsymbol{\beta})] \end{aligned}$$

Las condiciones de primer orden serán:

$$\frac{\partial}{\partial \boldsymbol{\beta}} \ln L(\boldsymbol{\beta}) = \sum_{i=1}^N y_i \frac{g(\mathbf{x}_i\boldsymbol{\beta})}{G(\mathbf{x}_i\boldsymbol{\beta})} \mathbf{x}'_i - \sum_{i=1}^N (1 - y_i) \frac{g(\mathbf{x}_i\boldsymbol{\beta})}{1 - G(\mathbf{x}_i\boldsymbol{\beta})} \mathbf{x}'_i$$

Finalmente, las condiciones de segundo orden y varianza estará dada por:

$$\begin{aligned} \frac{\partial^2}{\partial \boldsymbol{\beta} \partial \boldsymbol{\beta}'} \ln L(\boldsymbol{\beta}) &= - \sum_{i=1}^N \frac{y_i g(\mathbf{x}_i\boldsymbol{\beta})^2}{G(\mathbf{x}_i\boldsymbol{\beta})[1 - G(\mathbf{x}_i\boldsymbol{\beta})]} \mathbf{x}'_i \mathbf{x}_i \\ &= H(\boldsymbol{\beta}) \end{aligned}$$

Por lo tanto:

$$\begin{aligned} Var(\hat{\boldsymbol{\beta}}) &= [-\mathbb{E}[H(\boldsymbol{\beta})]]^{-1} \\ &= \left[\sum_{i=1}^N \frac{y_i g(\mathbf{x}_i\boldsymbol{\beta})^2}{G(\mathbf{x}_i\boldsymbol{\beta})[1 - G(\mathbf{x}_i\boldsymbol{\beta})]} \mathbf{x}'_i \mathbf{x}_i \right]^{-1} \end{aligned}$$

7.2. Modelos de respuesta multinomial y ordenada

En esta sección analizaremos modelos de respuesta discreta con más de 2 resultados posibles, los cuales se dividen:

1. Modelos de respuesta no ordenada, son modelos conocidos como de respuesta nominal, donde los valores de los distintos resultados son arbitrarios y no tienen un efecto en la estimación. Ejemplos de estos modelos son casos de selección de seguro, lugar de hospedaje, etc.
2. Modelos de respuesta ordenada, en estos modelos se asigna a cada respuesta un valor no arbitrario. Por ejemplo, modelos de calificación de crédito, modelos de preferencia de bienes, etc.

7.2.1. Modelos de respuesta multinomial

Logit multinomial

Este primer modelo aplica en situaciones en las que la unidad de respuesta o elección depende de las características individuales de los elementos de la muestra, pero no de los atributos de la elección. La aplicación que utilizamos en el cuaderno `Logit_Multinomial.ipynb` del repositorio del curso se basa en los datos de decisiones ocupacionales de hombres jóvenes de Keane y Wolpin (1997) [KW97], donde la elección es entre escuela, trabajo manual y trabajo de cuello blanco.

Dado lo anterior, definiremos el modelo en términos de variables aleatorias que representan a la población subyacente. Sea y_i una variable aleatoria que toma valores en un conjunto $\{0, 1, 2, \dots, J\}$. Sea $\mathbf{x}_i$ un conjunto de valores o regresores para $i = 1, 2, \dots, N$.

Como en el modelo de respuesta binaria, estimaremos el efecto de una variable en la probabilidad de ocurrencia de uno de los valores de respuesta. Dichas variables de respuesta estarán dados por:

$$P(y_i = j | \mathbf{x}_i), \text{ para } j = 1, 2, \dots, J$$

Dado que la suma de probabilidades debe ser 1, se suele tomar como práctica estimar $P(y_i = 0 | \mathbf{x}_i)$ como diferencia del resto de los casos $j = \{1, 2, \dots, J\}$. Así, sea $\mathbf{x}_i$ un vector de dimensión $1 \times K$. De esta forma, el modelo Logit tendrá como probabilidad de cada una de las respuestas a:

$$P(y_i = j | \mathbf{x}_i) = \frac{e^{\mathbf{x}_i \boldsymbol{\beta}_j}}{1 + e^{\mathbf{x}_i \boldsymbol{\beta}_1} + e^{\mathbf{x}_i \boldsymbol{\beta}_2} + \dots + e^{\mathbf{x}_i \boldsymbol{\beta}_J}}$$

Donde cada una de las $\boldsymbol{\beta}_j$, $j = 1, \dots, J$ es de dimensión $K \times 1$. Es fácil observar que si la suma de probabilidades es 1, entonces, la probabilidad de

$y = 0|\mathbf{x}_i$ estará dada por:

$$\begin{aligned} P(y_i = 0|\mathbf{x}_i) &= \frac{e^0}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &= \frac{1}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \end{aligned}$$

De esta forma tenemos:

$$\begin{aligned} 1 &= \sum_{j=0}^J P(y_i = j|\mathbf{x}_i) \\ &= \frac{1}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &\quad + \frac{e^{\mathbf{x}_i\beta_1}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \\ &\quad + \dots + \\ &\quad + \frac{e^{\mathbf{x}_i\beta_J}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \end{aligned}$$

Para el proceso de estimación consideraremos la función de verosimilitud dada por:

$$\begin{aligned} L(\beta_1, \beta_2, \dots, \beta_J) &= \prod_{i=1}^N [(P(j = 0|\mathbf{x}_i))^{I(0)} \cdot (P(j = 1|\mathbf{x}_i))^{I(1)} \\ &\quad \dots (P(j = J|\mathbf{x}_i))^{I(J)}] \end{aligned}$$

Donde $I(j)$ es la función indicadora que toma el valor de 1 o 0 dependiendo de cual de las opciones posibles $j = 0, 1, 2, \dots, J$ es cierta para cada individuo $i = 1, 2, \dots, N$. De forma similar al caso de respuesta binaria en los modelos Logit Multinomiales se interpretan en sus efectos marginales y no de forma directa en los coeficientes β_j .

Para una variable x_{ik} continua y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$\begin{aligned} EMg_k &= \frac{\partial P(y_i = j|\mathbf{x}_i)}{\partial x_{ik}} \\ &= P(y_i = j|\mathbf{x}_i) \cdot \left[\beta_{jk} - \frac{\sum_{h=1}^J \beta_{hk} \cdot e^{\mathbf{x}_i\beta_h}}{1 + e^{\mathbf{x}_i\beta_1} + e^{\mathbf{x}_i\beta_2} + \dots + e^{\mathbf{x}_i\beta_J}} \right] \end{aligned}$$

Donde β_{hk} es el k -ésimo elemento del vector β_h . En el caso de que x_{ik} sea una variable dicotómica (o categórica) y para cada opción $j = 0, 1, 2, \dots, J$ el efecto marginal será:

$$EMg_k = P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0)$$

7.2.2. Modelos de respuesta ordenada: Logit y Probit Ordinal

Sea y_i una variable que representa una respuesta ordenada y que toma los valores de $\{0, 1, 2, \dots, J\}$. En estos casos, en que importa el orden de la respuesta existen dos mecanismos de estimación: el Modelo Probit y el Modelo Logit.

Modelo Probit Ordinal. Este modelo se puede derivar de forma similar al modelo probit de dos respuestas 0 y 1, probit binario. Así, partimos de una variable latente y_i^* definida como:

$$y_i^* = \mathbf{x}_i \beta + \varepsilon_i; \quad \varepsilon_i \sim N(0, 1)$$

Donde β es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que mostramos más adelante. Sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad de la siguiente forma:

$$\begin{aligned} y_i = 0 & \quad \text{si} \quad y_i^* \leq \alpha_1 \\ y_i = 1 & \quad \text{si} \quad \alpha_1 < y_i^* \leq \alpha_2 \\ & \quad \vdots \\ y_i = j & \quad \text{si} \quad \alpha_j < y_i^* \leq \alpha_{j+1} \\ & \quad \vdots \\ y_i = J & \quad \text{si} \quad \alpha_J < y_i^* \end{aligned}$$

Dado que ε_i tiene una distribución normal estándar, para cada uno de

los casos anteriores podemos establecer:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(y_i^* \leq \alpha_1|\mathbf{x}_i) = P(\mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_1|\mathbf{x}_i) \\
P(y_i = 1|\mathbf{x}_i) &= P(\alpha_1 < y_i^* \leq \alpha_2|\mathbf{x}_i) = P(\alpha_1 < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_2|\mathbf{x}_i) \\
&\vdots \\
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1}|\mathbf{x}_i) = P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&\vdots \\
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < y_i^*|\mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i|\mathbf{x}_i)
\end{aligned}$$

Desarrollando las ecuaciones anteriores tenemos para el caso de $y_i = 0$:

$$\begin{aligned}
P(y_i = 0|\mathbf{x}_i) &= P(\mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_1|\mathbf{x}_i) \\
&= P(\boldsymbol{\varepsilon}_i \leq \alpha_1 - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_1 - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned}
P(y_i = j|\mathbf{x}_i) &= P(\alpha_j < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i \leq \alpha_{j+1}|\mathbf{x}_i) \\
&= P(\alpha_j - \mathbf{x}_i\boldsymbol{\beta} < \boldsymbol{\varepsilon}_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= P(\boldsymbol{\varepsilon}_i \leq \alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) - P(\boldsymbol{\varepsilon}_i \leq \alpha_j - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= \Phi(\alpha_{j+1} - \mathbf{x}_i\boldsymbol{\beta}) - \Phi(\alpha_j - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned}
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= P(\alpha_J - \mathbf{x}_i\boldsymbol{\beta} < \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= 1 - P(\boldsymbol{\varepsilon}_i < \alpha_J - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= 1 - \Phi(\alpha_J - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

Es sencillo observar y analizar que:

$$1 = \sum_{j=0}^J P(y_i = j|\mathbf{x}_i)$$

Notemos que en este modelo un mismo vector $\boldsymbol{\beta}$ gobierna las probabilidades de *todas* las categorías, y que lo que las separa son los umbrales α_j ,

$j = 1, 2, \dots, J$. Esto tiene una consecuencia importante sobre la interpretación: dado que las probabilidades deben sumar uno, un aumento en un regresor que eleve la probabilidad de algunas categorías tiene que reducir necesariamente la de otras. En particular, si $\beta_k > 0$, un incremento en x_{ik} reduce la probabilidad de la categoría más baja y eleva la de la más alta, pero el signo del efecto sobre las categorías **intermedias** es ambiguo y depende de los valores concretos de los umbrales y de los regresores. Por esta razón los coeficientes no se interpretan de forma directa, y en su lugar se utiliza el efecto marginal, cuyas expresiones son análogas a las del caso binario y que desarrollamos más adelante.

Modelo Logit Ordinal. Este modelo se puede derivar de forma similar al modelo Probit Ordinal con una variable latente y_i^* , también con β es un vector $(K - 1) \times 1$ ya que en este caso asumiremos que no se considera un término constante, por las razones que hemos mostrado anteriormente. Igualmente, sean $\alpha_1, \alpha_2, \dots, \alpha_J$ un conjunto de umbrales que particionan la probabilidad considerando una función logística $\Lambda(\cdot)$ de la siguiente forma:

$$\varepsilon_i \sim \Lambda(\cdot)$$

$$P(y_i = J | \mathbf{x}_i) = P(\alpha_J < y_i^* | \mathbf{x}_i) = P(\alpha_J < \mathbf{x}_i \beta + \varepsilon_i | \mathbf{x}_i)$$

Desarrollando las ecuaciones de probabilidad de forma similar al Probit Ordinal tenemos para el caso de $y_i = 0$:

$$\begin{aligned} P(y_i = 0 | \mathbf{x}_i) &= P(y_i^* \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\mathbf{x}_i \beta + \varepsilon_i \leq \alpha_1 | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_1 - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= \Lambda(\alpha_1 - \mathbf{x}_i \beta) \end{aligned}$$

En el caso de $y_i = j$, $j = 1, 2, \dots, J - 1$:

$$\begin{aligned} P(y_i = j | \mathbf{x}_i) &= P(\alpha_j < y_i^* \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j < \mathbf{x}_i \beta + \varepsilon_i \leq \alpha_{j+1} | \mathbf{x}_i) \\ &= P(\alpha_j - \mathbf{x}_i \beta < \varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= P(\varepsilon_i \leq \alpha_{j+1} - \mathbf{x}_i \beta | \mathbf{x}_i) - P(\varepsilon_i \leq \alpha_j - \mathbf{x}_i \beta | \mathbf{x}_i) \\ &= \Lambda(\alpha_{j+1} - \mathbf{x}_i \beta) - \Lambda(\alpha_j - \mathbf{x}_i \beta) \end{aligned}$$

Finalmente, para el caso $y_i = J$:

$$\begin{aligned}
P(y_i = J|\mathbf{x}_i) &= P(\alpha_J < y_i^*|\mathbf{x}_i) \\
&= P(\alpha_J < \mathbf{x}_i\boldsymbol{\beta} + \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= P(\alpha_J - \mathbf{x}_i\boldsymbol{\beta} < \boldsymbol{\varepsilon}_i|\mathbf{x}_i) \\
&= 1 - P(\boldsymbol{\varepsilon}_i < \alpha_J - \mathbf{x}_i\boldsymbol{\beta}|\mathbf{x}_i) \\
&= 1 - \Lambda(\alpha_J - \mathbf{x}_i\boldsymbol{\beta})
\end{aligned}$$

También, es sencillo observar y analizar que en los Logit Multinomiales:

$$1 = \sum_{j=0}^J P(y_i = j|\mathbf{x}_i)$$

Notemos que en este modelo un mismo vector $\boldsymbol{\beta}$ gobierna las probabilidades de *todas* las categorías, y que lo que las separa son los umbrales α_j , $j = 1, 2, \dots, J$. Esto tiene una consecuencia importante sobre la interpretación: dado que las probabilidades deben sumar uno, un aumento en un regresor que eleve la probabilidad de algunas categorías tiene que reducir necesariamente la de otras. En particular, si $\beta_k > 0$, un incremento en x_{ik} reduce la probabilidad de la categoría más baja y eleva la de la más alta, pero el signo del efecto sobre las categorías **intermedias** es ambiguo y depende de los valores concretos de los umbrales y de los regresores. Por esta razón los coeficientes no se interpretan de forma directa, y en su lugar se utiliza el efecto marginal, cuyas expresiones son análogas a las del caso binario y que desarrollamos más adelante.

Estimación de modelos Probit y Logit Ordinal. Para la estimación implementaremos un proceso de maximización de la siguiente función de verosimilitud:

$$L(\alpha, \boldsymbol{\beta}) = \prod_{i=1}^N P(y_i = 0|\mathbf{x}_i)^{I(0)} \cdot P(y_i = 1|\mathbf{x}_i)^{I(1)} \cdots P(y_i = J|\mathbf{x}_i)^{I(J)}$$

Donde $I(j)$ es la función indicadora que toma el valor de 0 y 1 si el individuo i -ésimo tiene como respuesta alguno de los posibles valores de $j = 0, 1, \dots, J$. La función es válida sin importar la función $\Phi(\cdot)$ o $\Lambda(\cdot)$ que utilicemos para determinar la $P(y_i = j|\mathbf{x}_i)$, para $j = 1, 2, \dots, J$. Por lo cual simbolizaremos indistintamente estas funciones como $G(\cdot)$.

Finalmente, sin importar el modelo que estemos ocupando, Probit o Logit ordinal, la forma de interpretar el modelo es mediante el efecto marginal, cuando x_k sea una variable continua:

$$EMg_k = \frac{\partial}{\partial x_k} P(y_i = j | \mathbf{x}_i) = \frac{\partial}{\partial x_k} G(\alpha_j - \mathbf{x}_i \boldsymbol{\beta}) = -\beta_k \cdot g(\alpha_j - \mathbf{x}_i \boldsymbol{\beta})$$

Por su parte, cuando x_j sea una variable dicotómica:

$$\begin{aligned} EMg_k &= P(y_i = j | \mathbf{x}_i, x_{ik} = 1) - P(y_i = j | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i, x_{ik} = 1) - G(\alpha_j - \mathbf{x}_i \boldsymbol{\beta} | \mathbf{x}_i, x_{ik} = 0) \\ &= G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + \beta_k + \dots + x_K \beta_K)) \\ &\quad - G(\alpha_j - (\beta_1 + x_2 \beta_2 + \dots + 0 + \dots + x_K \beta_K)) \end{aligned}$$

También es posible hacer un efecto marginal intra respuestas, es decir, para cambios entre una respuesta j y una $j + h$, la cual será:

$$EMg_{j-h} = \beta_k \cdot [g(\alpha_h - \mathbf{x}_i \boldsymbol{\beta}) - g(\alpha_j - \mathbf{x}_i \boldsymbol{\beta})], \text{ con } h < j$$

Donde $k = 1, 2, \dots, K - 1$ y $j = 0, 1, \dots, J$.

7.2.3. Una aplicación: clasificación con datos de videojuegos

El modelo de respuesta ordenada que acabamos de desarrollar se aplica a un caso concreto — la clasificación de videojuegos para PC a partir de sus etiquetas de Steam — en el capítulo de Introducción al Aprendizaje Estadístico. Preferimos presentar ahí ese ejemplo porque su interés principal no está en la estimación de los parámetros, sino en la *capacidad predictiva* del modelo, lo que exige el instrumental de separación entre conjunto de entrenamiento y de prueba, y de evaluación mediante matriz de confusión, que desarrollamos en ese capítulo.

7.3. Modelos de conteo y otras respuestas

Una variable de conteo es una variable que toma valores enteros no negativos y que cumple con dos características:

1. No tienen, de forma natural, una cuota superior

2. El valor cero debe ser posible para algunos de los elementos de la muestra

Muchas variables que conocemos cumplen con estas condiciones. Por ejemplo, el número de veces que un individuo es detenido al año, el número de cigarros que una persona fuma al día, el número de patentes que una empresa registra en un año, etc. Por el contrario, el número de hijos de una familia que se gradúa de la universidad no cumple con la condición 1, ya que ese número está topado por el número de hijos que tiene una familia.

7.3.1. Modelos de conteo del tipo Poisson

En esta sección analizaremos sólo uno de los modelos de conteo, el modelo de conteo basado en una función de distribución del tipo Poisson. Así, sea y una variable de conteo y $\mathbf{x}$ un vector de variables explicativas. De esta forma estaremos interesados en la regresión poblacional dada por:

$$\mathbb{E}[y|\mathbf{x}] = \mu(\mathbf{x})$$

El modelo Poisson es el más utilizado por su simplicidad para implementar mediante un procedimiento de máxima verosimilitud. Los supuestos del modelo son los siguientes.

En primer lugar, asumiremos que existe una función de densidad para y , $f(y|\mathbf{x}) = f(y|x_1, x_2, \dots, x_K)$, que tiene la forma de Poisson:

$$f(y|\mathbf{x}) = \frac{e^{-\mu(\mathbf{x})} \cdot \mu(\mathbf{x})^y}{y!} \quad (7.2)$$

Donde $\mu(\mathbf{x}) = \mathbb{E}[y|\mathbf{x}]$ y $y = 0, 1, \dots$. En segundo lugar, asumiremos que:

$$\mu(\mathbf{x}) = e^{\mathbf{x}\beta}$$

donde $\mathbf{x}$ es un vector de $1 \times K$ y β es un vector de $K \times 1$. Asumiremos que dada la muestra $\{(\mathbf{x}_i, y_i); i = 1, 2, \dots, N\}$ es factible estimar los parámetros β mediante un procedimiento de Máxima Verosimilitud.

Un tercer supuesto es que se cumple la propiedad de la distribución Poisson en la que:

$$Var(y|\mathbf{x}) = \mathbb{E}[y|\mathbf{x}] = \mu(\mathbf{x})$$

No obstante, es posible encontrar planteamientos en los que asumimos que:

$$Var(y|\mathbf{x}) = \sigma^2 \mathbb{E}[y|\mathbf{x}]$$

Donde $\sigma^2 > 0$ es la razón entre la varianza y la media, respecto de la cual observamos dos casos:

- Si $\sigma^2 > 1$ entonces la varianza es más grande que la media, por lo que estaremos en el caso en que existe **sobredispersión**.
- Si $\sigma^2 < 1$ entonces la varianza es menor que la media, por lo que estaremos en el caso en que existe **subdispersión**.

De los dos casos, la sobredispersión es con mucho el más frecuente en datos económicos, y la razón es intuitiva: el supuesto de igualdad entre media y varianza es muy restrictivo, y basta con que exista heterogeneidad no observada entre individuos para que la varianza observada exceda la media. Volveremos sobre las consecuencias de esto más adelante.

Ahora plantearemos el proceso de estimación, para lo cual requerimos establecer la función de verosimilitud a partir de la ecuación (7.2):

$$L(\boldsymbol{\beta}) = \prod_{i=1}^N f(y_i|\mathbf{x}_i) = \prod_{i=1}^N \frac{e^{-\mu(\mathbf{x}_i)} \cdot \mu(\mathbf{x}_i)^{y_i}}{y_i!} \quad (7.3)$$

Tomando el logaritmo tenemos:

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^N \ln(f(y_i|\mathbf{x}_i)) = \sum_{i=1}^N [-\mu(\mathbf{x}_i) + y_i \ln(\mu(\mathbf{x}_i)) - \ln(y_i!)] \quad (7.4)$$

Donde $\mu(\mathbf{x}_i) = e^{\mathbf{x}_i\boldsymbol{\beta}}$. Sustituyendo esta forma funcional en la ecuación (7.4), y notando que $\ln(e^{\mathbf{x}_i\boldsymbol{\beta}}) = \mathbf{x}_i\boldsymbol{\beta}$, la log-verosimilitud se simplifica notablemente:

$$\ln L(\boldsymbol{\beta}) = \sum_{i=1}^N [-e^{\mathbf{x}_i\boldsymbol{\beta}} + y_i \mathbf{x}_i\boldsymbol{\beta} - \ln(y_i!)] \quad (7.5)$$

El último término no depende de $\boldsymbol{\beta}$, por lo que es irrelevante para la maximización. La estimación de los parámetros resulta de igualar a cero el gradiente:

$$\frac{\partial \ln L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \sum_{i=1}^N \mathbf{x}_i' (y_i - e^{\mathbf{x}_i\boldsymbol{\beta}}) = \mathbf{0} \quad (7.6)$$

La ecuación (7.6) merece atención porque es la clave de una propiedad muy útil del modelo. Su estructura es exactamente la de una condición de ortogonalidad entre los regresores y el residual $y_i - \mathbb{E}[y_i | \mathbf{x}_i]$, es decir, la misma forma que tienen las ecuaciones normales de MCO. Puede demostrarse además que el hessiano correspondiente es $-\sum_i e^{\mathbf{x}_i \beta} \mathbf{x}_i' \mathbf{x}_i$, el cual es definido negativo, de modo que la log-verosimilitud es **globalmente cóncava** y el óptimo, cuando existe, es único.

La varianza de los estimadores se obtiene con el procedimiento general del capítulo de máxima verosimilitud:

$$\widehat{Var}(\hat{\beta}) = [-\mathbb{E}[\mathbf{H}(\beta)]]^{-1} = \left[-\mathbb{E} \left[\frac{\partial^2 \ln L(\beta)}{\partial \beta \partial \beta'} \right] \right]^{-1} \quad (7.7)$$

7.3.2. Robustez del modelo Poisson y la sobredispersión

Aquí es donde cerramos la discusión que iniciamos en el capítulo de métodos de estimación basados en verosimilitud al hablar de cuasi máxima verosimilitud. La observación central es la siguiente: la ecuación (7.6) sólo involucra la **media condicional** $\mathbb{E}[y_i | \mathbf{x}_i] = e^{\mathbf{x}_i \beta}$. En ningún momento se utiliza el supuesto de igualdad entre media y varianza.

La consecuencia es notable y explica la enorme popularidad de este modelo: el estimador de máxima verosimilitud Poisson es **consistente para β aun cuando la distribución verdadera no sea Poisson**, siempre que la media condicional esté correctamente especificada. Se trata precisamente del resultado de cuasi máxima verosimilitud para la familia lineal exponencial que enunciamos en su momento. En particular, la presencia de sobredispersión *no* invalida los estimadores puntuales.

Lo que sí invalida es la inferencia. Si $Var(y_i | \mathbf{x}_i) \neq \mathbb{E}[y_i | \mathbf{x}_i]$, la igualdad de la matriz de información falla y los errores estándar convencionales están mal calculados; con sobredispersión resultan **subestimados**, de modo que los coeficientes parecen más significativos de lo que son. De aquí se desprende la recomendación práctica que anticipamos: al estimar un modelo Poisson deben reportarse siempre **errores estándar robustos**, del tipo de emparejado que presentamos en la ecuación de varianza robusta del capítulo de máxima verosimilitud. La diferencia entre los errores estándar convencionales y los robustos es además un diagnóstico informal del grado de sobredispersión presente.

Cuando la sobredispersión es severa, la alternativa habitual es el modelo **binomial negativo**, que introduce un parámetro adicional de dispersión al permitir heterogeneidad no observada multiplicativa en la media. Es importante notar que la relación entre ambos modelos es análoga a la que discutimos en el capítulo de duración entre el modelo con y sin heterogeneidad no observada: en ambos casos, un componente individual no observado que se integra analíticamente genera mayor dispersión que la del modelo base.

7.3.3. Interpretación de los coeficientes

Finalmente, de forma similar a los modelos de elección binaria, multinomial y ordenada, los resultados se interpretan mediante efectos marginales. Para una variable continua:

$$EMg_j = \frac{\partial \mathbb{E}[y_i | \mathbf{x}_i]}{\partial x_{ij}} = e^{\mathbf{x}_i \beta} \cdot \beta_j = \mathbb{E}[y_i | \mathbf{x}_i] \cdot \beta_j \quad (7.8)$$

En el caso de variables dicotómicas:

$$EMg_j = \mathbb{E}[y_i | \mathbf{x}_i, x_{ij} = 1] - \mathbb{E}[y_i | \mathbf{x}_i, x_{ij} = 0]$$

La ecuación (7.8) admite además una lectura mucho más cómoda que la de los modelos anteriores. Reordenando:

$$\beta_j = \frac{\partial \mathbb{E}[y_i | \mathbf{x}_i] / \partial x_{ij}}{\mathbb{E}[y_i | \mathbf{x}_i]} = \frac{\partial \ln \mathbb{E}[y_i | \mathbf{x}_i]}{\partial x_{ij}}$$

Es decir, β_j es una **semielasticidad**: un incremento unitario en x_{ij} modifica el valor esperado de y_i en aproximadamente $100 \cdot \beta_j$ por ciento. Esta interpretación es válida en cualquier punto de la distribución de los regresores, a diferencia de lo que ocurre en los modelos de respuesta binaria, y es la forma en que habitualmente se reportan los resultados. Si además x_{ij} entra en logaritmos, β_j es directamente una elasticidad. Nótese el paralelismo con la interpretación del modelo de riesgos proporcionales del capítulo de duración, donde los coeficientes también son semielasticidades por la misma razón: la forma funcional exponencial.

7.4. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) En el modelo de probabilidad lineal de la ecuación (7.1) el efecto marginal de x_{ij} es constante, lo que constituye una ventaja porque simplifica la interpretación.
 - b) Los coeficientes de un modelo Logit y los de un Probit estimados sobre los mismos datos deben ser numéricamente similares.
 - c) En un modelo de respuesta binaria, el signo del efecto marginal de x_{ij} coincide siempre con el signo de β_j .
 - d) En un modelo de respuesta ordenada con tres categorías, si $\beta_j > 0$ entonces la probabilidad de la categoría intermedia necesariamente aumenta cuando x_{ij} crece.
 - e) El estimador de máxima verosimilitud del modelo Poisson es inconsistente si la varianza condicional excede a la media condicional.
 - f) Si en un modelo de conteo se cumple $\mathbb{V}[y_i | \mathbf{x}_i] > \mathbb{E}[y_i | \mathbf{x}_i]$, los errores estándar basados en el hessiano subestiman la incertidumbre.
 - g) El supuesto de independencia de alternativas irrelevantes es contrastable con los datos.
2. Considere el modelo de probabilidad lineal $y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$ con $y_i \in \{0, 1\}$. Se le solicita:
 - a) Demostrar que $\mathbb{E}[\varepsilon_i | \mathbf{x}_i] = 0$ implica $\mathbb{E}[y_i | \mathbf{x}_i] = P(y_i = 1 | \mathbf{x}_i)$.
 - b) Obtener $\mathbb{V}[\varepsilon_i | \mathbf{x}_i]$ y demostrar que la heterocedasticidad es **inherente** al modelo, no un accidente de los datos.
 - c) Explicar por qué el estimador de MCG que corregiría esa heterocedasticidad no es utilizable en la práctica. Sugerencia: examine qué se necesitaría conocer para construir los ponderadores.
 - d) A pesar de los tres problemas señalados en el texto, el modelo de probabilidad lineal se sigue usando con frecuencia en trabajo aplicado. Discuta en qué circunstancias su uso es defendible.
3. Sea el modelo Logit binario con $P(y_i = 1 | \mathbf{x}_i) = \Lambda(\mathbf{x}_i\boldsymbol{\beta})$, donde $\Lambda(u) = e^u/(1 + e^u)$. Se le solicita:

- a) Demostrar que $\Lambda'(u) = \Lambda(u) [1 - \Lambda(u)]$.
 - b) Obtener el efecto marginal $\partial P(y_i = 1 \mid \mathbf{x}_i) / \partial x_{ij}$ y explicar en qué punto de la distribución de $\mathbf{x}_i \boldsymbol{\beta}$ alcanza su valor máximo.
 - c) Demostrar que el logaritmo de la razón de momios, $\ln[P/(1 - P)]$, es lineal en los parámetros. Ésta es la propiedad que da nombre al modelo.
 - d) Verificar que la log-verosimilitud del modelo es globalmente cóncava, de modo que el óptimo es único. Compare este resultado con la advertencia del capítulo de aprendizaje estadístico sobre la log-verosimilitud de una red neuronal.
4. El texto señala que un coeficiente Logit es aproximadamente 1.6 veces el correspondiente coeficiente Probit. Se le solicita justificar esa relación comparando las varianzas de las distribuciones logística estándar y normal estándar, y explicar por qué se trata de una **diferencia de escala** y no de una discrepancia sustantiva entre los dos modelos. ¿Qué objeto sí es comparable directamente entre ambos?
5. Considere el Logit multinomial con J alternativas. Se le solicita:
- a) Explicar por qué es necesario normalizar los coeficientes de una alternativa a cero y qué consecuencia tiene esa normalización sobre la interpretación de los demás coeficientes.
 - b) Demostrar que la razón de probabilidades entre dos alternativas j y k no depende de las características de ninguna tercera alternativa. Ésta es la independencia de alternativas irrelevantes.
 - c) Analizar el ejemplo clásico del autobús rojo y el autobús azul, y explicar en qué situaciones de elección ocupacional el supuesto resultaría inadmisibles.
 - d) Describir cómo se contrastaría el supuesto con una prueba de Hausman, estimando el modelo con y sin una de las alternativas. Relacione el procedimiento con el principio general de la prueba enunciado en el capítulo de datos panel.
6. En el modelo de respuesta ordenada con variable latente $y_i^* = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i$ y umbrales $\alpha_1 < \alpha_2 < \dots < \alpha_{J-1}$, se le solicita:

- a) Obtener $P(y_i = j \mid \mathbf{x}_i)$ para una categoría intermedia y para las dos categorías extremas.
 - b) Demostrar que el efecto marginal sobre la categoría más alta tiene el mismo signo que β_j , y que el de la categoría más baja tiene el signo contrario.
 - c) Demostrar que el signo del efecto sobre una categoría **intermedia** es ambiguo, y construir un ejemplo numérico en el que sea positivo y otro en el que sea negativo con el mismo β_j .
 - d) Explicar por qué no es posible identificar simultáneamente todos los umbrales y una constante en $\mathbf{x}_i\boldsymbol{\beta}$.
7. Considere el modelo Poisson de la ecuación (7.2). Se le solicita:
- a) Derivar la condición de primer orden (7.6) a partir de la log-verosimilitud (7.5).
 - b) Demostrar que dicha condición implica que los residuales $y_i - e^{\mathbf{x}_i\boldsymbol{\beta}}$ son ortogonales a cada regresor, en analogía exacta con las ecuaciones normales de MCO.
 - c) Demostrar que, si el modelo incluye una constante, la suma de los valores ajustados es igual a la suma de los valores observados.
 - d) Obtener el hessiano y demostrar que la log-verosimilitud es globalmente cóncava.
8. El modelo Poisson impone $\mathbb{V}[y_i \mid \mathbf{x}_i] = \mathbb{E}[y_i \mid \mathbf{x}_i]$, restricción que los datos rara vez satisfacen. Se le solicita:
- a) Explicar por qué el estimador sigue siendo consistente bajo sobre-dispersión, apelando al argumento de cuasi máxima verosimilitud del capítulo de verosimilitud.
 - b) Explicar por qué la inferencia basada en el hessiano deja de ser válida, y en qué dirección se equivoca.
 - c) Proponer una prueba de sobredispersión basada en una regresión auxiliar de $(y_i - \hat{\mu}_i)^2 - y_i$ sobre $\hat{\mu}_i^2$, donde $\hat{\mu}_i = e^{\mathbf{x}_i\hat{\boldsymbol{\beta}}}$.
 - d) Discutir el modelo binomial negativo como alternativa, señalando su analogía con la heterogeneidad no observada del capítulo de duración.

9. **Aplicación.** Con los datos de Mroz (1987) del cuaderno `Clase_05.EleccionBinaria` del repositorio del curso, estime la participación laboral femenina por los tres procedimientos: modelo de probabilidad lineal, Logit y Probit. Se le solicita:
- a) Reportar qué proporción de las probabilidades ajustadas del modelo de probabilidad lineal cae fuera del intervalo $(0, 1)$.
 - b) Comparar los **efectos marginales promedio** de los tres modelos y comprobar que son muy parecidos, pese a que los coeficientes no lo son.
 - c) Distinguir el efecto marginal promedio del efecto marginal evaluado en la media, calcular ambos y explicar cuál reportaría y por qué. Advierta que la mujer promedio de esa muestra tiene 0.24 hijos menores de cinco años.
 - d) Verificar que el cociente entre coeficientes Logit y Probit se aproxima al factor de escala del ejercicio 4.
10. **Aplicación.** Con los datos de fecundidad del cuaderno `Clase_08.ModelosDeConteo`, estime un modelo Poisson del número de hijos. Se le solicita:
- a) Interpretar el coeficiente de la escolaridad como semielasticidad y traducirlo a un cambio porcentual.
 - b) Contrastar la restricción de equidispersión con la prueba del ejercicio 8.
 - c) Comparar los errores estándar del hessiano con los robustos y cuantificar la diferencia.
 - d) Reestimar por binomial negativo y comparar coeficientes, errores estándar e inferencia. ¿Cambia alguna conclusión sustantiva?
11. **Programación.** Escriba la log-verosimilitud del modelo Logit binario y maximícela con un optimizador numérico, sin utilizar la rutina de estimación de ninguna biblioteca. Se le solicita comparar sus estimaciones y errores estándar contra los de la rutina establecida, verificar que la diferencia sea del orden del error de convergencia, y comprobar que las probabilidades ajustadas caen todas dentro del intervalo $(0, 1)$. Esta última comprobación es un ejemplo de las identidades verificables que se discuten en el material de la unidad de código asistido del curso.

8

Modelos con datos truncados, censurados, con endogeneidad por selección de muestra y otros casos

En este capítulo discutiremos tres problemas emparentados: el truncamiento, la censura y la selección de muestra. Los tres dan lugar a modelos particulares que son de uso muy extendido en el trabajo aplicado, en especial el modelo Tobit y el modelo de selección de Heckman.

Conviene distinguir con precisión los tres casos desde el inicio, porque se confunden con frecuencia y las consecuencias de tratarlos como si fueran el mismo son serias:

1. Hay **truncamiento** cuando ciertas observaciones *no aparecen en la muestra* porque la variable de interés queda fuera de un rango determinado. Si estudiamos el gasto de los hogares con ingreso superior a cierto umbral, los hogares por debajo de ese umbral simplemente no fueron encuestados: de ellos no sabemos nada, ni siquiera cuántos son.
2. Hay **censura** cuando todas las observaciones *sí están* en la muestra, pero la variable dependiente sólo se observa dentro de un rango; fuera de él se registra un valor de tope. Conocemos las variables explicativas de todos los individuos y sabemos de cada uno si está o no en el tope, pero no conocemos el valor que habría tomado la variable. Este es

exactamente el mismo tipo de pérdida de información que estudiamos, con otro lenguaje, en el capítulo de modelos de duración.

3. Hay **selección de muestra** cuando la variable dependiente se observa únicamente para el subconjunto de individuos que satisface una condición determinada *por otra ecuación*, y esa condición está relacionada con la variable de interés. El caso clásico es el salario de mercado, que sólo observamos para quienes decidieron trabajar.

La diferencia entre truncamiento y censura es entonces la cantidad de información disponible: con censura conservamos las variables explicativas de las observaciones topadas y podemos aprovecharlas; con truncamiento, esas observaciones no existen para nosotros. La selección de muestra puede verse como un truncamiento *incidental*, en el que lo que determina la presencia en la muestra no es el valor de la propia variable dependiente sino el de una variable relacionada.

Lo que los tres casos comparten, y la razón por la que se estudian juntos, es que en todos ellos **la estimación por MCO es inconsistente**, y que la solución pasa en todos los casos por trabajar con distribuciones condicionadas y estimar por máxima verosimilitud con el instrumental del capítulo correspondiente. Analicemos primero el truncamiento, luego la censura y finalmente la selección de muestra.

8.1. Truncamiento

Truncamiento es una condición observada cuando se toma una muestra a partir de una población que ha sido restringida o truncada. Para resolver este tipo de problemas requerimos del uso de funciones de distribución truncadas, las cuales son una parte por encima o por debajo de algún valor específico en el soporte de la función original. Por ejemplo, cuando analizamos la distribución del ingreso de las personas para aquellos individuos que ganan más de una cierta cantidad dada.

Tomemos un ejemplo más retomado de Cunningham (2021) [Cun21]. Una publicación de blog de CNN de 2009 informó que Megan Fox, quien protagonizó la película *Transformers*, fue votada como la peor y más atractiva actriz de 2009 en una encuesta sobre estrellas de cine. La publicación infería que había una implicación de que el talento y la belleza están negativamente correlacionados. ¿Pero lo son? ¿Y por qué podrían serlo? ¿Qué pasa si en




Figura 8.1: ¿Talento y la belleza están negativamente correlacionados?

realidad son independientes entre sí pero están correlacionados negativamente en una muestra de estrellas de cine debido al sesgo del colisionador? ¿Es eso posible? Un diagrama que ilustra la situación anterior es el mostrado en la figura 8.1.


La figura 8.2 muestra una simulación de la situación. El panel inferior izquierdo muestra el diagrama de dispersión entre talento y belleza. Observe que las dos variables son extracciones aleatorias e independientes de la distribución normal estándar, lo que crea una nube de datos alargada. Pero debido a que “estrella de cine” se encuentra en el percentil 85 superior de la distribución de una combinación lineal de talento y belleza, la muestra consta de personas cuya puntuación combinada se encuentra en la parte superior derecha de la distribución conjunta. Esta frontera tiene una pendiente negativa y se encuentra en la parte superior derecha de la nube de datos, lo que crea una correlación negativa entre las observaciones en la muestra de estrellas de cine. Sin embargo, sabemos que, de hecho, no hay relación entre las dos variables. Este tipo de selección de muestras crea correlaciones espurias. Una muestra aleatoria de la población completa sería suficiente para mostrar que no existe relación entre las dos variables, pero al dividir la muestra en estrellas de cine únicamente, introducimos correlaciones espurias entre las dos variables de interés.

Demos un poco de formalidad al problema. Sea x una variable aleatoria continua con función de densidad $f(x)$ y sea a una constante. La función de densidad truncada por la izquierda en a se define como:

$$f(x | x > a) = \frac{f(x)}{P(x > a)}, \text{ para } x > a \quad (8.1)$$

La lógica de la ecuación (8.1) es simplemente la de una probabilidad condicional: nos quedamos con la parte de la densidad que está por encima de a y la reescalamos dividiendo entre la masa de probabilidad que sobrevive, de modo que la nueva función vuelva a integrar a uno.

Figura 8.2: Relación entre belleza y talento, retomado de [Cun21].



En estos casos, la condición más común es emplear una función de densidad normal truncada. Así, si x tiene una distribución normal con media μ y desviación estándar σ , definamos la constante estandarizada $\alpha = (a - \mu)/\sigma$. Entonces:

$$P(x > a) = \int_a^{\infty} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx = 1 - \Phi\left(\frac{a-\mu}{\sigma}\right) = 1 - \Phi(\alpha)$$

Donde $\Phi(\cdot)$ es la función de distribución acumulada de la normal estándar. De esta forma, podemos construir la función de densidad truncada como:

$$\begin{aligned} f(x \mid x > a) &= \frac{f(x)}{1 - \Phi(\alpha)} \\ &= \frac{\frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}}{1 - \Phi(\alpha)} \\ &= \frac{\frac{1}{\sigma} \cdot \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}}{1 - \Phi(\alpha)} \\ &= \frac{\frac{1}{\sigma} \phi\left(\frac{x-\mu}{\sigma}\right)}{1 - \Phi(\alpha)} \end{aligned} \tag{8.2}$$

Donde $\phi(\cdot)$ es la función de densidad de una normal estándar. Nótese que el paso de la segunda a la tercera línea consiste únicamente en separar el factor $1/\sigma$, y el de la tercera a la cuarta en reconocer que lo que queda es, por definición, la densidad normal estándar evaluada en el valor estandarizado. El factor $1/\sigma$ es el jacobiano del cambio de variable y no debe omitirse.

8.1.1. La razón inversa de Mills

De la distribución truncada nos interesa sobre todo su media, ya que es la que aparecerá en todas las ecuaciones de regresión de este capítulo. Puede demostrarse que, para la normal truncada por la izquierda:

$$\mathbb{E}[x \mid x > a] = \mu + \sigma \lambda(\alpha) , \text{ donde } \lambda(\alpha) = \frac{\phi(\alpha)}{1 - \Phi(\alpha)} \quad (8.3)$$

A la función $\lambda(\cdot)$ definida en la ecuación (8.3) se le conoce como **razón inversa de Mills**, y es el objeto central de todo este capítulo. Su interpretación es directa: mide en cuántas desviaciones estándar se desplaza la media cuando descartamos la cola inferior de la distribución. Sus propiedades relevantes son las siguientes:

1. $\lambda(\alpha) > 0$ siempre, y es creciente en α . Truncar por la izquierda *siempre* eleva la media, y el desplazamiento es mayor mientras más severo sea el truncamiento.
2. Cuando $\alpha \rightarrow -\infty$, es decir cuando el punto de truncamiento se aleja hacia la izquierda y prácticamente no se pierde ninguna observación, $\lambda(\alpha) \rightarrow 0$ y recuperamos la media original.
3. Su derivada es $\lambda'(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$. Definiendo $\delta(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$, se demuestra que $0 < \delta(\alpha) < 1$ para todo α , resultado que utilizaremos repetidamente.

Con esta notación, la varianza de la distribución truncada es:

$$\text{Var}(x \mid x > a) = \sigma^2 [1 - \delta(\alpha)] \quad (8.4)$$

De donde, por la propiedad 3, la varianza de una distribución truncada es siempre **menor** que la de la distribución original. Esto tiene sentido intuitivo: al descartar una cola completa se reduce la dispersión.




Figura 8.3: Efecto del truncamiento y de la censura sobre la distribución de la variable dependiente

La Figura 8.3 contrasta gráficamente los dos problemas que nos ocupan. En el panel (a) se aprecia el truncamiento: la parte de la densidad por debajo del punto de corte desaparece y lo que queda se reescala hacia arriba para volver a integrar a uno; la media se desplaza a la derecha exactamente en la cantidad $\sigma\lambda(\alpha)$ que acabamos de derivar. En el panel (b) se aprecia la censura: la masa de probabilidad que estaba por debajo del corte no desaparece, sino que se acumula en un único punto, de modo que la distribución de lo observado es **mixta**, con una parte discreta en el punto de censura y una parte continua por encima de él. Esta última observación es la razón por la que la verosimilitud del modelo Tobit tendrá dos componentes.

8.1.2. El modelo de regresión truncada

Dado lo anterior podemos plantear el concepto de regresión truncada. Para ello asumiremos que tenemos una ecuación de regresión del tipo:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Donde, de forma convencional, $\mathbf{x}_i$ es un vector de variables explicativas de $1 \times K$ y $\boldsymbol{\beta}$ es un vector de parámetros de $K \times 1$, y

$$\varepsilon_i \mid \mathbf{x}_i \sim \text{Normal}(0, \sigma^2)$$

Así:

$$y_i \mid \mathbf{x}_i \sim \text{Normal}(\mathbf{x}_i\boldsymbol{\beta}, \sigma^2)$$

En este caso estamos interesados en la distribución de y_i dado que y_i es mayor que el punto de truncamiento a . Aplicando el resultado de la ecuación (8.3) con $\mu = \mathbf{x}_i\boldsymbol{\beta}$, la recta de regresión sobre la muestra truncada estará dada por:

$$\mathbb{E}[y_i \mid y_i > a] = \mathbf{x}_i\boldsymbol{\beta} + \sigma \frac{\phi\left(\frac{a - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{a - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \quad (8.5)$$

De esta forma la media condicional es una función no lineal de a , σ , $\mathbf{x}_i$ y $\boldsymbol{\beta}$. De manera compacta:

$$\mathbb{E}[y_i \mid y_i > a] = \mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda(\alpha_i) \quad (8.6)$$

Donde ahora el argumento depende del individuo, $\alpha_i = (a - \mathbf{x}_i\boldsymbol{\beta})/\sigma$. Por simplicidad utilizaremos la notación $\lambda_i = \lambda(\alpha_i)$ y $\delta_i = \delta(\alpha_i)$. De esta forma la ecuación a estimar será:

$$\begin{aligned} y_i \mid y_i > a &= \mathbb{E}[y_i \mid y_i > a] + v_i \\ &= \mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda_i + v_i \end{aligned}$$

Donde el nuevo término de error v_i tiene esperanza cero por construcción, pero varianza:

$$\text{Var}(v_i \mid \mathbf{x}_i) = \text{Var}(y_i \mid y_i > a) = \sigma^2(1 - \delta_i)$$

Aquí aparecen ya las dos razones por las que MCO falla en una muestra truncada. La primera es que, al ignorar el término $\sigma\lambda_i$, incurrimos en un problema de **variable omitida**: como λ_i depende de $\mathbf{x}_i$, la variable omitida está correlacionada con los regresores y el estimador es inconsistente. La segunda es que, aun conociendo λ_i , la varianza del error **depende de i** a través de δ_i , es decir, la regresión truncada es intrínsecamente heterocedástica. Por estas razones la estimación de este tipo de modelos se realiza por máxima verosimilitud, maximizando la log-verosimilitud construida a partir de la densidad truncada de la ecuación (8.2):

$$\ell(\boldsymbol{\beta}, \sigma) = \sum_{i=1}^N \left\{ -\ln \sigma + \ln \phi\left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) - \ln \left[1 - \Phi\left(\frac{a - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) \right] \right\} \quad (8.7)$$

Donde el tercer término es precisamente la corrección por truncamiento: sin él, la ecuación (8.7) sería la log-verosimilitud del modelo lineal normal que obtuvimos en el capítulo de máxima verosimilitud y cuyo máximo coincide con MCO.

8.1.3. Efectos marginales

Un punto que debe subrayarse es que, en la muestra truncada, β **no** es el efecto marginal. Derivando la ecuación (8.6) respecto de $\mathbf{x}_i$ y aplicando la regla de la cadena:

$$\begin{aligned}
 \frac{\partial \mathbb{E}[y_i \mid y_i > a]}{\partial \mathbf{x}_i} &= \beta + \sigma \frac{\partial \lambda_i}{\partial \alpha_i} \cdot \frac{\partial \alpha_i}{\partial \mathbf{x}_i} \\
 &= \beta + \sigma (\lambda_i^2 - \alpha_i \lambda_i) \cdot \left(-\frac{\beta}{\sigma} \right) \\
 &= \beta (1 - \lambda_i^2 + \alpha_i \lambda_i) \\
 &= \beta (1 - \delta_i)
 \end{aligned} \tag{8.8}$$

Donde en la segunda línea usamos $\lambda'(\alpha) = \lambda(\lambda - \alpha) = \lambda^2 - \alpha\lambda$ y $\partial \alpha_i / \partial \mathbf{x}_i = -\beta/\sigma$, y en la última la definición $\delta_i = \lambda_i(\lambda_i - \alpha_i)$.

La ecuación (8.8) tiene una lectura importante. Dado que $0 < \delta_i < 1$, el efecto marginal en la muestra truncada es siempre **menor en valor absoluto** que β , aunque conserva su signo. Es decir, estimar por MCO sobre una muestra truncada produce una **atenuación**: los efectos parecen más pequeños de lo que realmente son en la población. Esta es la razón por la que, por ejemplo, un estudio de los determinantes del gasto realizado únicamente sobre hogares de ingreso alto subestimarán sistemáticamente la sensibilidad del gasto a sus determinantes.

8.2. Selección de muestra: el truncamiento incidental

Ahora veamos un caso particular y de enorme relevancia aplicada: el **truncamiento incidental**. Supongamos que tenemos dos variables aleatorias y y z con distribución conjunta bivariada y coeficiente de correlación ρ . En estos casos estamos interesados en la distribución de y dado que *otra* variable, z , excede un valor determinado. El adjetivo “incidental” se refiere justamente a eso: lo que trunca la muestra no es el valor de la variable de interés, sino el de una variable relacionada con ella.

La intuición sugiere que si y y z están correlacionadas positivamente, entonces el truncamiento de z debería desplazar la distribución de y hacia la

derecha. Formalicemos. La densidad conjunta truncada es:

$$f(y, z \mid z > a) = \frac{f(y, z)}{P(z > a)}$$

Si y y z tienen una distribución normal bivariada con medias μ_y y μ_z , desviaciones estándar σ_y y σ_z , y coeficiente de correlación ρ , entonces la media de la distribución truncada incidentalmente es:

$$\mathbb{E}[y \mid z > a] = \mu_y + \rho \sigma_y \lambda(\alpha_z) \quad (8.9)$$

Donde, con $\alpha_z = (a - \mu_z)/\sigma_z$:

$$\lambda(\alpha_z) = \frac{\phi(\alpha_z)}{1 - \Phi(\alpha_z)}$$

Por su parte la varianza será:

$$\text{Var}(y \mid z > a) = \sigma_y^2 [1 - \rho^2 \delta(\alpha_z)] \quad (8.10)$$

Donde, como antes, $\delta(\alpha_z) = \lambda(\alpha_z) [\lambda(\alpha_z) - \alpha_z]$.

La ecuación (8.9) es el resultado clave y conviene detenerse en él. El desplazamiento de la media es proporcional a ρ , el coeficiente de correlación entre ambas variables. De aquí se desprenden tres observaciones:

1. Si $\rho > 0$, la media de y en la submuestra seleccionada es **mayor** que en la población; si $\rho < 0$, es menor.
2. Si $\rho = 0$, el término desaparece por completo y **no hay problema alguno**. Este es un punto fundamental: seleccionar la muestra con base en una variable no relacionada con la de interés no genera sesgo. El sesgo de selección no proviene de que la muestra sea no aleatoria, sino de que la regla de selección esté relacionada con la variable dependiente.
3. Análogamente, en la ecuación (8.10) la varianza se reduce sólo en la medida en que $\rho \neq 0$.

Adicionalmente, supongamos un modelo lineal subyacente:

$$z_i^* = \mathbf{w}_i \boldsymbol{\gamma} + u_i$$

y un proceso lineal dado por:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

Dado lo anterior, podemos establecer la regla de selección de muestra como y_i es observada siempre que z_i^* es más grande que cero. De esta forma planteamos la ecuación de regresión como:

$$\begin{aligned}\mathbb{E}[y_i|y_i \text{ es observada}] &= \mathbb{E}[y_i|z_i^* > 0] \\ &= \mathbb{E}[y_i|\mathbf{w}_i\boldsymbol{\gamma} + u_i > 0] \\ &= \mathbb{E}[y_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbb{E}[\mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbf{x}_i\boldsymbol{\beta} + \mathbb{E}[\varepsilon_i|u_i > -\mathbf{w}_i\boldsymbol{\gamma}] \\ &= \mathbf{x}_i\boldsymbol{\beta} + \rho\sigma_\varepsilon\lambda_i \\ &= \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i\end{aligned}$$

Donde:

$$\lambda_i = \frac{\phi\left(\frac{\mathbf{w}_i\boldsymbol{\gamma}}{\sigma_u}\right)}{\Phi\left(\frac{\mathbf{w}_i\boldsymbol{\gamma}}{\sigma_u}\right)}$$

Así, podemos plantear el modelo como:

$$\begin{aligned}y_i|z_i^* > 0 &= \mathbb{E}[y_i|\mathbf{w}_i\boldsymbol{\gamma} + u_i > 0] + v_i \\ &= \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i + v_i\end{aligned}$$

8.2.1. El modelo de Heckman

Dicho lo anterior podemos representar el problema de forma completa. El modelo consta de dos ecuaciones. La primera es la **ecuación de selección**, que determina qué observaciones aparecen en la muestra y descansa en una variable latente:

$$z_i^* = \mathbf{w}_i\boldsymbol{\gamma} + u_i \tag{8.11}$$

De la cual sólo observamos el indicador binario:

$$\begin{aligned}z_i &= 1 \text{ si } z_i^* > 0 \\ z_i &= 0 \text{ si } z_i^* \leq 0\end{aligned}$$

Lo cual, normalizando $Var(u_i) = 1$, es exactamente el modelo probit del capítulo de modelos no lineales:

$$\begin{aligned} P(z_i = 1 \mid \mathbf{w}_i) &= \Phi(\mathbf{w}_i\boldsymbol{\gamma}) \\ P(z_i = 0 \mid \mathbf{w}_i) &= 1 - \Phi(\mathbf{w}_i\boldsymbol{\gamma}) \end{aligned}$$

La segunda es la **ecuación de resultado**, que es la que verdaderamente nos interesa:

$$y_i = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i, \text{ observada sólo si } z_i = 1 \quad (8.12)$$

Donde el supuesto distribucional que liga ambas ecuaciones es:

$$\begin{pmatrix} u_i \\ \varepsilon_i \end{pmatrix} \sim Normal \text{ Bivariada } (0, 0, 1, \sigma_\varepsilon, \rho)$$

Aquí $\rho = Corr(u_i, \varepsilon_i)$ es el parámetro que gobierna todo el problema: mide la correlación entre los factores no observados que determinan la *participación* y los que determinan el *resultado*. Aplicando la ecuación (8.9) llegamos a:

$$\mathbb{E}[y_i \mid z_i = 1, \mathbf{x}_i, \mathbf{w}_i] = \mathbf{x}_i\boldsymbol{\beta} + \rho\sigma_\varepsilon\lambda_i = \mathbf{x}_i\boldsymbol{\beta} + \beta_\lambda\lambda_i \quad (8.13)$$

Donde:

$$\lambda_i = \frac{\phi(\mathbf{w}_i\boldsymbol{\gamma})}{\Phi(\mathbf{w}_i\boldsymbol{\gamma})}$$

A este modelo se le conoce como modelo de selección de Heckman (1979) [Hec79]. La ecuación (8.13) permite ver con claridad cuál es la naturaleza del problema: si estimáramos la ecuación (8.12) por MCO sobre la submuestra observada, estaríamos **omitiendo la variable** λ_i . Como λ_i depende de $\mathbf{w}_i$, y las variables de $\mathbf{w}_i$ típicamente se traslapan con las de $\mathbf{x}_i$, la variable omitida está correlacionada con los regresores incluidos y el estimador de MCO es inconsistente. Dicho de otro modo, **el sesgo de selección es un caso particular del sesgo por variable omitida**, y esa observación es la que sugiere de inmediato la solución: si pudiéramos construir λ_i , bastaría con incluirla como regresor adicional.

8.2.2. Estimación en dos etapas

El procedimiento propuesto por Heckman, conocido como *heckit*, hace exactamente eso:

1. Estimar por máxima verosimilitud el probit de la ecuación de selección sobre la muestra **completa** — incluyendo las observaciones para las que y_i no se observa, que es precisamente la información que la censura nos conserva — y obtener $\hat{\gamma}$. Con él se construye para cada observación seleccionada la razón inversa de Mills estimada:

$$\hat{\lambda}_i = \frac{\phi(\mathbf{w}_i \hat{\gamma})}{\Phi(\mathbf{w}_i \hat{\gamma})}$$

2. Estimar por MCO, sobre la submuestra de observaciones con $z_i = 1$, la regresión aumentada:

$$y_i = \mathbf{x}_i \boldsymbol{\beta} + \beta_\lambda \hat{\lambda}_i + \text{error} \quad (8.14)$$

De donde se obtienen $\hat{\boldsymbol{\beta}}$ y $\hat{\beta}_\lambda$, este último un estimador de $\rho \sigma_\varepsilon$.

Deben hacerse cuatro advertencias sobre este procedimiento, todas ellas relevantes en el trabajo aplicado.

Primera: los errores estándar de la segunda etapa no son los que reporta MCO. Dado que $\hat{\lambda}_i$ es un regresor *estimado* en una etapa previa, la incertidumbre de la primera etapa se transmite a la segunda. Además, el error de la ecuación (8.14) es heterocedástico por la ecuación (8.10). Los errores estándar deben corregirse por ambos motivos, o bien obtenerse por remuestreo. Este es el mismo fenómeno de “regresor generado” que ya encontramos al discutir el 2SLS en el capítulo de variables instrumentales.

Segunda: la prueba de selección es inmediata. Dado que $\beta_\lambda = \rho \sigma_\varepsilon$ y que $\sigma_\varepsilon > 0$, contrastar

$$H_0 : \beta_\lambda = 0 \quad \Longleftrightarrow \quad H_0 : \rho = 0$$

mediante una prueba t ordinaria sobre el coeficiente de $\hat{\lambda}_i$ equivale a contrastar la ausencia de sesgo de selección. Si no se rechaza, MCO sobre la submuestra es consistente y preferible por ser más eficiente. El signo de $\hat{\beta}_\lambda$ informa además sobre la dirección del sesgo.

Tercera, y la más importante: la restricción de exclusión. En principio el modelo está identificado aunque $\mathbf{w}_i = \mathbf{x}_i$, porque λ_i es una función *no lineal* de $\mathbf{w}_i \boldsymbol{\gamma}$. Sin embargo, esa identificación descansa exclusivamente en la forma funcional supuesta y es muy frágil: en el rango de valores que suelen presentarse, la razón inversa de Mills es prácticamente lineal, lo que genera

una colinealidad casi perfecta entre $\hat{\lambda}_i$ y las variables de $\mathbf{x}_i$. El resultado son errores estándar enormes y estimaciones inestables. Por ello, un buen diseño requiere que $\mathbf{w}_i$ contenga al menos una variable que **no** esté en $\mathbf{x}_i$: una variable que afecte la probabilidad de participar pero que no afecte directamente el resultado. El paralelismo con la lógica de las variables instrumentales es exacto, y también lo es la dificultad de encontrar una variable defendible.

Cuarta: es un modelo fuertemente paramétrico. Todo el procedimiento descansa en el supuesto de normalidad bivariada. Si esa distribución no es la correcta, la corrección puede empeorar las cosas en lugar de mejorarlas. Existen alternativas semiparamétricas que relajan este supuesto, aunque a costa de una mayor complejidad.

Como alternativa al procedimiento en dos etapas, el modelo puede estimarse conjuntamente por **máxima verosimilitud completa**, maximizando de forma simultánea sobre $(\beta, \gamma, \sigma_\varepsilon, \rho)$ la log-verosimilitud que combina la contribución de las observaciones no seleccionadas, $\ln[1 - \Phi(\mathbf{w}_i\gamma)]$, con la de las seleccionadas, que involucra la normal bivariada. Este procedimiento es asintóticamente más eficiente que el de dos etapas y entrega directamente errores estándar correctos, pero es más sensible a la especificación y puede presentar problemas de convergencia. En la práctica es recomendable estimar por ambos métodos y verificar que los resultados coincidan.

8.3. Datos con censura

La censura es una condición más común que el truncamiento, ya que este último ocurre muchas veces por decisión del investigador. La censura es un problema observado en la distribución de la variable dependiente. Por ejemplo, es común encontrar variables que tienen un número considerable de valores cero: gasto en ciertos bienes que no son de la preferencia de todos los consumidores, horas trabajadas, monto de donativos, etc. No obstante, puede existir censura en cualquier parte de la distribución, y también por arriba: el ingreso reportado en muchas encuestas está topado en un valor máximo por razones de confidencialidad.

Conviene distinguir dos situaciones que dan lugar a la misma estructura estadística pero que tienen interpretaciones económicas muy distintas:

1. **Censura verdadera.** La variable latente existe y tiene sentido, pero el instrumento de medición no la registra. El ingreso topado en una

encuesta es el ejemplo típico: hay hogares que ganan más que el tope, y ese valor existe aunque no lo observemos.

2. **Solución de esquina.** El valor cero es una decisión económica genuina y no un problema de medición. Cuando un hogar gasta cero en tabaco, ese cero *es* su gasto óptimo, no un valor censurado de un gasto latente negativo. Un gasto negativo no tiene sentido.

La distinción importa porque determina cuál de las esperanzas que derivaremos enseguida es la relevante para responder la pregunta de investigación. Con censura verdadera suele interesarnos la variable latente; con solución de esquina, lo observado. En ambos casos, sin embargo, el tratamiento estadístico es el mismo.

En este tipo de modelos asumiremos un modelo subyacente dado por:

$$\begin{aligned} y_i &= 0 \text{ si } y_i^* \leq b \\ y_i &= y_i^* \text{ si } y_i^* > b \end{aligned}$$

Donde b es una constante a partir de la cual se observa la censura y donde la ecuación del modelo subyacente es de la forma lineal:

$$y_i^* = \mathbf{x}_i\boldsymbol{\beta} + \varepsilon_i$$

En este caso analizamos el problema con el modelo de regresión de Tobin (1958) [Tob58], denominado Tobit, en alusión a Tobin y al uso de la función de densidad normal como función de distribución de la variable dependiente. En este modelo la forma del valor esperado de y_i estará dada por:

$$\mathbb{E}[y_i|\mathbf{x}_i] \neq \mathbf{x}_i\boldsymbol{\beta} \quad (8.15)$$

Lo cierto, es que a diferencia de la ecuación (8.15) el valor esperado de y_i^* sí es de una forma lineal como:

$$\mathbb{E}[y_i^*|\mathbf{x}_i] = \mathbf{x}_i\boldsymbol{\beta} \quad (8.16)$$

De esta manera, el valor esperado de y_i deberá ser ajustado para quedar como:

$$\mathbb{E}[y_i|\mathbf{x}_i] = \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) (\mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda_i) \quad (8.17)$$

Donde σ es la desviación estándar de y_i y:

$$\begin{aligned}\lambda_i &= \frac{\phi\left(\frac{b - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{b - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \\ &= \frac{\phi\left(\frac{0 - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{1 - \Phi\left(\frac{0 - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)} \\ &= \frac{\phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}{\Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)}\end{aligned}$$

Donde $\phi(\cdot)$ y $\Phi(\cdot)$ son las funciones de densidad y acumulada de la normal estándar. Además de que hemos asumido que la constante b es absorbida por la constante contenida en el vector $\boldsymbol{\beta}$

8.3.1. Las tres esperanzas del modelo Tobit

Antes de continuar conviene ordenar las distintas esperanzas que pueden calcularse en este modelo, porque confundirlas es un error muy frecuente. Son tres y responden a preguntas distintas:

1. **La esperanza latente**, $\mathbb{E}[y_i^* \mid \mathbf{x}_i] = \mathbf{x}_i\boldsymbol{\beta}$, dada por la ecuación (8.16). Responde: ¿cuál sería el valor esperado si no hubiera censura? Es la relevante en casos de censura verdadera.
2. **La esperanza truncada**, $\mathbb{E}[y_i \mid \mathbf{x}_i, y_i > 0] = \mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda_i$. Responde: entre quienes tienen un valor positivo, ¿cuál es el valor esperado? Es la relevante si nos interesa la magnitud condicional a participar.
3. **La esperanza observada**, $\mathbb{E}[y_i \mid \mathbf{x}_i]$, dada por la ecuación (8.17). Responde: ¿cuál es el valor esperado en la población completa, incluyendo los ceros? Es la relevante en casos de solución de esquina.

Nótese que la ecuación (8.17) es simplemente el producto de la probabilidad de observar un valor positivo, $\Phi(\mathbf{x}_i\boldsymbol{\beta}/\sigma)$, por el valor esperado condicional a que lo sea. Cada una de estas tres esperanzas tiene su propio efecto marginal, y reportar el que no corresponde a la pregunta planteada es un error de interpretación con consecuencias sustantivas.

8.3.2. Efectos marginales

Dicho lo anterior, el efecto marginal sobre la variable latente, ecuación (8.16), es simplemente:

$$\frac{\partial \mathbb{E}[y_i^* | \mathbf{x}_i]}{\partial x_{ik}} = \beta_k \quad (8.18)$$

Mientras que el efecto marginal sobre la variable observada, ecuación (8.17), resulta ser:

$$\frac{\partial \mathbb{E}[y_i | \mathbf{x}_i]}{\partial x_{ik}} = \beta_k \Phi\left(\frac{\mathbf{x}_i \boldsymbol{\beta}}{\sigma}\right) \quad (8.19)$$

La ecuación (8.19) es un resultado notable por su simplicidad: el efecto marginal sobre la variable observada es el coeficiente multiplicado por la probabilidad de estar por encima del punto de censura. Dado que $0 < \Phi(\cdot) < 1$, se cumple que β_k **sobreestima** el efecto marginal sobre lo observado, y la sobreestimación es tanto mayor cuanto mayor sea la proporción de observaciones censuradas.

Existe además una descomposición muy útil, debida a McDonald y Moffitt, que separa el efecto total en dos canales:

$$\frac{\partial \mathbb{E}[y_i | \mathbf{x}_i]}{\partial x_{ik}} = \underbrace{\Phi\left(\frac{\mathbf{x}_i \boldsymbol{\beta}}{\sigma}\right) \frac{\partial \mathbb{E}[y_i | \mathbf{x}_i, y_i > 0]}{\partial x_{ik}}}_{\text{efecto en la magnitud, dado que participa}} + \underbrace{\mathbb{E}[y_i | \mathbf{x}_i, y_i > 0] \frac{\partial \Phi\left(\frac{\mathbf{x}_i \boldsymbol{\beta}}{\sigma}\right)}{\partial x_{ik}}}_{\text{efecto en la probabilidad de participar}} \quad (8.20)$$

La ecuación (8.20) tiene una lectura económica valiosa: un aumento en x_{ik} modifica el gasto esperado tanto porque hace que quienes ya gastaban gasten más, como porque induce a nuevos individuos a empezar a gastar. En muchas aplicaciones interesa saber cuál de los dos canales domina.

8.3.3. Por qué MCO es inconsistente

Vale la pena hacer explícito el punto, porque es la justificación de todo lo anterior. Ante datos censurados existen dos estrategias ingenuas y ambas fallan:

1. **Estimar por MCO usando toda la muestra**, tratando los ceros como observaciones legítimas. Esto es inconsistente porque, como muestra la ecuación (8.17), la esperanza de lo observado no es lineal en $\mathbf{x}_i$. Por la ecuación (8.19), el estimador resultante está atenuado hacia cero.




Figura 8.4: Inconsistencia de MCO ante datos censurados, con datos simulados

2. **Estimar por MCO descartando los ceros**, es decir, usando sólo las observaciones con $y_i > 0$. Esto convierte el problema de censura en uno de truncamiento y es inconsistente por la omisión del término $\sigma\lambda_i$, exactamente como vimos en la sección de regresión truncada.

Es importante notar que ambos sesgos operan en la misma dirección — atenúan — pero no se cancelan ni se compensan.

La Figura 8.4 ilustra ambos casos con datos simulados en los que conocemos la respuesta correcta. Los círculos vacíos representan los valores latentes que la censura nos impide observar y que, en una aplicación real, no aparecerían en el gráfico. Puede apreciarse cómo las dos rectas estimadas por MCO tienen una pendiente visiblemente menor que la verdadera: en la simulación, un coeficiente real de 1.00 se estima en torno a 0.7 con la muestra completa y algo por debajo de eso descartando los ceros.

8.3.4. Estimación por máxima verosimilitud

Finalmente, en el caso de la estimación, este es un caso más que se resuelve por máxima verosimilitud. La clave está en que cada observación contribuye a la verosimilitud de manera distinta según esté o no censurada, tal como

ocurría en el modelo de duración con censura por la derecha. Las observaciones no censuradas aportan la densidad evaluada en el valor observado; las censuradas aportan la probabilidad de estar en la región de censura. Partamos de establecer la función de verosimilitud como:

$$\begin{aligned}
L(\boldsymbol{\beta}, \sigma) &= \prod_{y_i > 0} f(y_i \mid \mathbf{x}_i) \prod_{y_i = 0} P(y_i^* \leq 0 \mid \mathbf{x}_i) \\
&= \prod_{y_i > 0} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)^2} \prod_{y_i = 0} \Phi\left(-\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) \\
&= \prod_{y_i > 0} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)^2} \prod_{y_i = 0} \left[1 - \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right)\right] \quad (8.21)
\end{aligned}$$

Donde la última igualdad usa la simetría de la normal, $\Phi(-u) = 1 - \Phi(u)$. En su versión logarítmica, la ecuación de verosimilitud queda como:

$$\begin{aligned}
\ell(\boldsymbol{\beta}, \sigma) &= \sum_{y_i > 0} \left[-\frac{1}{2} \ln(2\pi\sigma^2) - \frac{1}{2} \left(\frac{y_i - \mathbf{x}_i\boldsymbol{\beta}}{\sigma} \right)^2 \right] \\
&\quad + \sum_{y_i = 0} \ln \left[1 - \Phi\left(\frac{\mathbf{x}_i\boldsymbol{\beta}}{\sigma}\right) \right] \quad (8.22)
\end{aligned}$$

Obsérvese la estructura de la ecuación (8.22): el primer sumando es exactamente la log-verosimilitud del modelo lineal normal, restringida a las observaciones no censuradas, y el segundo es exactamente la contribución de un modelo probit para las censuradas. El modelo Tobit es, en este sentido preciso, una combinación de ambos, y ese es el origen de su nombre.

De esta expresión podemos obtener las condiciones de primer orden para determinar un estimador de $\boldsymbol{\theta}' = (\boldsymbol{\beta}', \sigma)$, así como la matriz hessiana $\mathbf{H}$ para determinar la varianza de estos estimadores, siguiendo exactamente el procedimiento general del capítulo de métodos de estimación basados en verosimilitud:

$$\left. \frac{\partial \ell(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\hat{\boldsymbol{\theta}}} = \mathbf{0}, \quad \mathbf{H}(\boldsymbol{\theta}) = \frac{\partial^2 \ell(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}'}, \quad \widehat{Var}(\hat{\boldsymbol{\theta}}) = [-\mathbb{E}[\mathbf{H}(\boldsymbol{\theta})]]^{-1}$$

Puede demostrarse que la ecuación (8.22) es globalmente cóncava en una reparametrización adecuada, de modo que el óptimo es único.

8.3.5. Una limitación importante: el modelo de dos partes

El modelo Tobit impone una restricción que con frecuencia resulta difícil de justificar: **el mismo vector β gobierna simultáneamente la decisión de participar y la magnitud del resultado**, y además lo hace con el mismo signo. Si una variable aumenta la probabilidad de que un hogar gaste en un bien, el modelo obliga a que también aumente el monto gastado por quienes ya gastan.

Este supuesto es con frecuencia inverosímil. Puede ocurrir que la edad aumente la probabilidad de fumar pero reduzca la cantidad consumida entre quienes fuman; el Tobit no puede acomodar ese patrón. La alternativa natural es el **modelo de dos partes** o de obstáculo (*hurdle model*), que separa el problema en dos ecuaciones con parámetros distintos: un modelo binario — probit o logit — para la decisión de participar, y un modelo para la magnitud condicional a participar, típicamente una regresión truncada. Nótese que el Tobit es el caso particular que resulta de imponer que los coeficientes de ambas ecuaciones sean proporcionales, lo cual sugiere de inmediato una prueba de razón de verosimilitudes para contrastar la restricción.

La diferencia entre el modelo de dos partes y el modelo de selección de Heckman de la sección anterior es sutil pero importante: el primero supone que, una vez que se participa, no hay problema de selección adicional — es decir, $\rho = 0$ —, mientras que el segundo permite que los no observables de ambas ecuaciones estén correlacionados.

8.4. Aplicación y consideraciones prácticas

8.4.1. Implementación en Python

Para la implementación de estos modelos en Python, el modelo Tobit puede estimarse programando directamente la log-verosimilitud de la ecuación (8.22) y maximizándola con `scipy.optimize`, que es el enfoque que sigue el archivo `tobit.py` del repositorio del curso. El modelo de selección de Heckman se implementa en `heckman.py`, y los cuadernos correspondientes son `Datos_Censurados.ipynb` y `Heckman_Regression.ipynb`. Es una práctica recomendable programar al menos una vez la verosimilitud por cuenta propia antes de recurrir a rutinas preexistentes, ya que es la mejor forma de

entender qué supuestos se están imponiendo.

8.4.2. Aplicación: la oferta laboral de mujeres casadas

La aplicación canónica del modelo de selección es la de la oferta laboral de mujeres casadas, basada en los datos de Mroz (1987) [Mro87] que ya utilizamos en otros capítulos. El problema es el siguiente: queremos estimar los determinantes del salario de mercado, pero el salario sólo se observa para las mujeres que efectivamente trabajan. La decisión de trabajar no es aleatoria: depende de la comparación entre el salario de mercado ofrecido y el salario de reserva, de modo que quienes trabajan son precisamente aquellas para las que el salario ofrecido resulta atractivo.

En este caso, la correlación ρ entre los no observables de ambas ecuaciones tiene una interpretación económica directa: recoge factores no medidos — habilidad, motivación, actitudes hacia el trabajo — que afectan simultáneamente la probabilidad de participar y el salario que se puede obtener. Si esos factores elevan ambas cosas, entonces $\rho > 0$ y la muestra de trabajadoras está compuesta desproporcionadamente por mujeres de alta capacidad no observada, con lo que MCO sobre esa submuestra sobreestimaría el salario que obtendrían las no participantes.

Para la restricción de exclusión, las variables que tradicionalmente se emplean son el número de hijos pequeños en el hogar y el ingreso no laboral del hogar: ambas afectan claramente la decisión de participar — vía el salario de reserva — y puede argumentarse que no afectan directamente la productividad ni, por lo tanto, el salario de mercado ofrecido. Como en toda restricción de exclusión, el argumento es discutible y debe defenderse explícitamente; es perfectamente posible sostener, por ejemplo, que tener hijos pequeños afecta también la productividad o las horas efectivamente disponibles.

8.5. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a) Truncamiento y censura son el mismo problema con nombres distintos.

- b) Si seleccionamos una muestra con base en una variable que no está correlacionada con el término de error de la ecuación de interés, se genera sesgo de selección.
 - c) En un modelo Tobit, β_k es el efecto marginal de x_{ik} sobre la variable observada.
 - d) En una regresión truncada, estimar por MCO produce coeficientes sesgados hacia cero.
 - e) Si en la segunda etapa del procedimiento de Heckman el coeficiente de la razón inversa de Mills no resulta significativo, es preferible estimar por MCO sobre la submuestra.
 - f) Los errores estándar que reporta MCO en la segunda etapa del procedimiento de Heckman son válidos.
 - g) La varianza de una distribución truncada es mayor que la de la distribución original, porque el truncamiento genera heterocedasticidad.
2. Sea $x \sim \text{Normal}(\mu, \sigma^2)$ truncada por la izquierda en a . Se le solicita:
- a) Verificar que la densidad de la ecuación (8.2) integra a uno sobre el intervalo (a, ∞) .
 - b) Demostrar la ecuación (8.3), es decir, que $\mathbb{E}[x \mid x > a] = \mu + \sigma \lambda(\alpha)$.
 - c) Demostrar que $\lambda'(\alpha) = \lambda(\alpha)[\lambda(\alpha) - \alpha]$.
 - d) Evaluar numéricamente $\lambda(\alpha)$ y $\delta(\alpha)$ para $\alpha = -2, -1, 0, 1$, y verificar que $0 < \delta(\alpha) < 1$ en todos los casos. Interpretar la magnitud del desplazamiento de la media en cada caso.
3. Considere una población en la que $y_i = 2 + 0.5x_i + \varepsilon_i$, con $\varepsilon_i \sim \text{Normal}(0, 1)$ y $x_i \sim \text{Normal}(0, 1)$. Se le solicita, mediante simulación en Python:
- a) Generar una muestra de $N = 5,000$ observaciones y verificar que MCO recupera los parámetros.
 - b) Truncar la muestra conservando únicamente las observaciones con $y_i > 2$, reestimar por MCO y comparar. ¿En qué dirección se sesga la pendiente? ¿Es consistente con la ecuación (8.8)?

- c) Censurar la muestra, fijando $y_i = 2$ para todas las observaciones con $y_i^* \leq 2$, reestimar por MCO sobre la muestra completa y comparar.
 - d) Estimar el modelo Tobit correspondiente por máxima verosimilitud y verificar que recupera los parámetros de la población.
 - e) Repetir el ejercicio variando la proporción de observaciones censuradas y graficar el sesgo de MCO en función de esa proporción.
4. Demuestre la ecuación (8.17), es decir, que $\mathbb{E}[y_i | \mathbf{x}_i] = \Phi(\mathbf{x}_i\boldsymbol{\beta}/\sigma)(\mathbf{x}_i\boldsymbol{\beta} + \sigma\lambda_i)$. Sugerencia: aplique la ley de esperanzas iteradas condicionando en si la observación está o no censurada, y note que la contribución de las observaciones censuradas es cero.
 5. Obtenga la descomposición de McDonald y Moffitt de la ecuación (8.20) derivando el producto de la ecuación (8.17). Interprete económicamente cada uno de los dos términos en el contexto del gasto de los hogares en un bien de consumo no universal, y discuta en qué tipo de aplicación cada canal sería el de mayor interés para la política pública.
 6. A partir de la ecuación (8.22), se le solicita:
 - a) Identificar qué parte corresponde a un modelo lineal normal y cuál a un probit, y explicar por qué esta estructura es la que da su nombre al modelo.
 - b) Obtener las condiciones de primer orden respecto de $\boldsymbol{\beta}$ y de σ .
 - c) Explicar por qué el modelo Tobit no puede estimarse en dos etapas separadas — primero un probit y luego una regresión — de forma análoga al procedimiento de Heckman.
 7. **Sobre la restricción de exclusión.** Explique por qué el modelo de Heckman está formalmente identificado aun cuando $\mathbf{w}_i = \mathbf{x}_i$, y por qué a pesar de ello esa identificación se considera frágil en el trabajo aplicado. Ilustre el argumento graficando la razón inversa de Mills $\lambda(u) = \phi(u)/\Phi(u)$ en el rango $u \in [-1, 2]$ y observando qué tan cerca está de ser una función lineal en esa región.
 8. **Aplicación empírica en Python.** Utilizando los datos de Mroz sobre oferta laboral femenina disponibles en el repositorio del curso, se le solicita:

- a) Reportar qué proporción de la muestra tiene salario observado y discutir la magnitud potencial del problema de selección.
- b) Estimar por MCO la ecuación de salarios sobre la submuestra de mujeres que trabajan.
- c) Estimar la primera etapa: un probit de la decisión de participar, incluyendo como restricción de exclusión el número de hijos pequeños y el ingreso no laboral. Reportar y discutir los coeficientes.
- d) Construir $\hat{\lambda}_i$ y estimar la segunda etapa según la ecuación (8.14). Contrastar $H_0 : \beta_\lambda = 0$ e interpretar el signo de $\hat{\beta}_\lambda$ en términos del tipo de selección presente.
- e) Estimar el modelo por máxima verosimilitud completa y comparar con el procedimiento en dos etapas, tanto en coeficientes como en errores estándar.
- f) Repetir el ejercicio *sin* restricción de exclusión, es decir con $\mathbf{w}_i = \mathbf{x}_i$, y comparar los errores estándar con los del inciso (d). Documentar la magnitud del problema de colinealidad.

9. **Aplicación empírica en Python.** Con los datos de consumo censurados del cuaderno `Datos_Censurados.ipynb` del repositorio, estime un modelo Tobit y se le solicita:

- a) Reportar la proporción de observaciones en el punto de censura.
- b) Estimar por MCO sobre la muestra completa, por MCO descartando las observaciones censuradas, y por Tobit. Comparar los tres conjuntos de coeficientes y verificar la dirección de los sesgos anticipada en el texto.
- c) Calcular y reportar los tres efectos marginales correspondientes a las tres esperanzas de la sección anterior, y explicar cuál de ellos respondería a la pregunta “¿cuánto aumentaría el gasto promedio del conjunto de la población si esta variable aumentara en una unidad?”.
- d) Discutir si el caso analizado corresponde a censura verdadera o a una solución de esquina, y qué implica esa distinción para la elección del efecto marginal que debe reportarse.

9

Introducción a inferencia causal

9.1. El marco de resultados potenciales

9.1.1. Motivación

A lo largo del curso hemos utilizado repetidamente la palabra “causalidad” sin haberle dado un contenido formal. En el primer capítulo dijimos que la causalidad derivaba de la construcción teórica que hiciéramos del fenómeno, y en el capítulo de gráficos acíclicos dirigidos introdujimos una representación gráfica de las cadenas causales. Ahora necesitamos un lenguaje matemático preciso que nos permita decir exactamente *qué* estamos estimando cuando afirmamos haber medido un efecto causal, y *bajo qué condiciones* nuestro estimador lo recupera. Ese lenguaje es el marco de resultados potenciales, desarrollado por Rubin (1974) [Rub74] a partir del trabajo previo de Neyman, y conocido por ello como modelo causal de Neyman-Rubin.

La utilidad de este marco es que separa dos cosas que suelen confundirse: el **parámetro** que queremos conocer, que se define sin referencia alguna a datos o a estimadores, y la **estrategia de identificación**, es decir, el conjunto de supuestos que permiten expresar ese parámetro en términos de cantidades observables. Casi todas las discusiones sustantivas en econometría aplicada son discusiones sobre lo segundo.

9.1.2. Resultados potenciales y el problema fundamental

Consideremos un tratamiento binario y denotemos por $D_i \in \{0, 1\}$ el indicador que vale 1 si el individuo i recibe el tratamiento y 0 en caso contrario.

Definición 9.1 *Los **resultados potenciales** del individuo i son:*

- $Y_i(1)$: el valor que tomaría la variable de interés si el individuo recibiera el tratamiento.
- $Y_i(0)$: el valor que tomaría si no lo recibiera.

Es fundamental entender que ambos resultados potenciales están definidos **para todos los individuos**, con independencia de lo que efectivamente les ocurra. Una persona que no participó en un programa de capacitación tiene, de todos modos, un valor $Y_i(1)$ bien definido: el salario que habría obtenido de haber participado. Ese valor simplemente no se observa.

Definición 9.2 *El **efecto causal individual** del tratamiento sobre el individuo i es:*

$$\delta_i = Y_i(1) - Y_i(0) \quad (9.1)$$

Lo que efectivamente observamos es una sola de las dos cantidades, según el valor que tome D_i . Esta relación entre lo observado y lo potencial se expresa mediante la llamada **ecuación de conmutación**:

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0) \quad (9.2)$$

La ecuación (9.2) hace explícito el obstáculo central de toda la disciplina.

Teorema 9.1 ***Problema fundamental de la inferencia causal.** Para ningún individuo es posible observar simultáneamente $Y_i(1)$ y $Y_i(0)$. En consecuencia, el efecto causal individual δ_i de la ecuación (9.1) **nunca es observable**.*

La consecuencia es que la inferencia causal es, inevitablemente, un **problema de datos faltantes**: para cada individuo nos falta exactamente la mitad de la información que necesitaríamos. Dado que los efectos individuales son inalcanzables, renunciamos a ellos y dirigimos la atención a promedios poblacionales, que sí resultan identificables bajo ciertos supuestos.

9.1.3. Los parámetros de interés

Definición 9.3 Definimos los siguientes parámetros:

$$ATE = \mathbb{E}[\delta_i] = \mathbb{E}[Y_i(1) - Y_i(0)] \quad (9.3)$$

$$ATT = \mathbb{E}[\delta_i \mid D_i = 1] = \mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 1] \quad (9.4)$$

$$ATU = \mathbb{E}[\delta_i \mid D_i = 0] = \mathbb{E}[Y_i(1) - Y_i(0) \mid D_i = 0] \quad (9.5)$$

El **Efecto Promedio del Tratamiento** (ATE, *Average Treatment Effect*) responde a la pregunta de qué ocurriría si tratáramos a toda la población. El **Efecto Promedio del Tratamiento sobre los Tratados** (ATT) responde a qué le ocurrió a quienes efectivamente lo recibieron. El **Efecto Promedio sobre los No Tratados** (ATU) responde a qué habría ocurrido si hubiéramos tratado a quienes no lo fueron.

Estos tres parámetros son distintos y la elección entre ellos no es un tecnicismo, sino una decisión sustantiva sobre la pregunta de política que se quiere responder. Si evaluamos un programa social voluntario, el ATT nos dice si el programa funcionó para quienes se inscribieron, mientras que el ATE nos diría qué pasaría si lo volviéramos obligatorio para toda la población. Si quienes se inscriben son precisamente los que más se benefician, ambos números serán muy distintos y confundirlos conduce a recomendaciones equivocadas. Denotando por $\pi = P(D_i = 1)$ la proporción de tratados, los tres parámetros se relacionan por:

$$ATE = \pi \cdot ATT + (1 - \pi) \cdot ATU \quad (9.6)$$

9.1.4. Por qué la comparación simple de medias falla

El estimador ingenuo consiste en comparar la media de la variable de interés entre tratados y no tratados. Llamemos a esta cantidad la **diferencia simple de medias** (SDO, por *Simple Difference in Outcomes*):

$$SDO = \mathbb{E}[Y_i \mid D_i = 1] - \mathbb{E}[Y_i \mid D_i = 0] \quad (9.7)$$

Esta cantidad sí es estimable con datos. La pregunta es qué relación guarda con los parámetros que nos interesan. El siguiente resultado, central en Cunningham (2021) [Cun21], responde exactamente eso.

Teorema 9.2 Descomposición de la diferencia simple de medias.

La diferencia simple de medias de la ecuación (9.7) admite la descomposición:

$$SDO = \underbrace{ATE}_{\text{parámetro de interés}} + \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{sesgo de selección}} + \underbrace{(1 - \pi)(ATT - ATU)}_{\text{sesgo por efectos heterogéneos}} \quad (9.8)$$

Demostración. Por la ecuación de conmutación (9.2), para los tratados observamos $Y_i = Y_i(1)$ y para los no tratados $Y_i = Y_i(0)$, de donde:

$$SDO = \mathbb{E}[Y_i(1) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0]$$

Sumemos y restemos la cantidad contrafactual $\mathbb{E}[Y_i(0) \mid D_i = 1]$, es decir, el resultado que habrían tenido los tratados de no haber sido tratados:

$$SDO = \underbrace{\mathbb{E}[Y_i(1) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 1]}_{= ATT} + \underbrace{\mathbb{E}[Y_i(0) \mid D_i = 1] - \mathbb{E}[Y_i(0) \mid D_i = 0]}_{\text{sesgo de selección}}$$

Es decir, $SDO = ATT + \text{sesgo de selección}$. Ahora expresemos el ATT en términos del ATE . Despejando de la ecuación (9.6):

$$ATE = \pi \cdot ATT + (1 - \pi)ATU = ATT - (1 - \pi)ATT + (1 - \pi)ATU = ATT - (1 - \pi)(ATT - ATU)$$

De donde $ATT = ATE + (1 - \pi)(ATT - ATU)$. Sustituyendo en la expresión anterior obtenemos la ecuación (9.8). ■

La descomposición (9.8) es, en cierto sentido, el resultado más importante de este capítulo, porque organiza todo lo que sigue. Nos dice que la comparación ingenua entre tratados y no tratados contiene el parámetro de interés, pero contaminado por dos términos:

1. El **sesgo de selección** es la diferencia que existiría entre ambos grupos *aun en ausencia del tratamiento*. Si quienes se inscriben a un programa de capacitación son los más motivados, habrían ganado más que los no inscritos incluso sin el programa, y ese diferencial se atribuye erróneamente al tratamiento. Nótese que el primer término, $\mathbb{E}[Y_i(0) \mid D_i = 1]$, es contrafactual y por lo tanto **no observable**: el sesgo de selección no puede calcularse ni restarse directamente.
2. El **sesgo por efectos heterogéneos** aparece cuando el tratamiento no afecta por igual a tratados y no tratados. Desaparece si suponemos efectos constantes, $\delta_i = \delta$ para todo i , pues en ese caso $ATT = ATU$. Obsérvese que este término no aparece si el parámetro de interés es el ATT en lugar del ATE .

Como observa Cunningham, se puede afirmar que toda la empresa de la inferencia causal consiste en desarrollar estrategias creíbles para anular el papel del sesgo de selección.

9.1.5. Supuestos de identificación

Definición 9.4 Independencia. Decimos que la asignación del tratamiento es independiente de los resultados potenciales si:

$$(Y_i(1), Y_i(0)) \perp D_i \quad (9.9)$$

Este supuesto se cumple por construcción en un **experimento aleatorizado**, y es la razón por la cual la aleatorización es el punto de referencia contra el cual se juzgan todas las demás estrategias. Bajo la ecuación (9.9) tenemos $\mathbb{E}[Y_i(0) \mid D_i = 1] = \mathbb{E}[Y_i(0) \mid D_i = 0]$, con lo que el sesgo de selección se anula; y además $ATT = ATU = ATE$, con lo que también se anula el sesgo por efectos heterogéneos. La ecuación (9.8) colapsa entonces a $SDO = ATE$ y la comparación simple de medias es válida.

Es importante subrayar que la independencia **no** exige que los grupos sean idénticos en la muestra observada, sino que la asignación no dependa de los resultados potenciales. Tampoco debe confundirse con la independencia entre D_i y Y_i : si el tratamiento tiene algún efecto, D_i e Y_i están necesariamente relacionados.

En datos observacionales la ecuación (9.9) es insostenible, y se recurre a una versión más débil:

Definición 9.5 Independencia condicional (CIA, o supuesto de selección en observables). Existe un vector de covariables $\mathbf{X}_i$ tal que:

$$(Y_i(1), Y_i(0)) \perp D_i \mid \mathbf{X}_i \quad (9.10)$$

Y además se cumple el supuesto de **soporte común**, $0 < P(D_i = 1 \mid \mathbf{X}_i) < 1$.

Es decir, dentro de cada celda definida por las covariables, el tratamiento es “como si” fuera aleatorio. Este es el supuesto que subyace a la estrategia de estimación por regresión múltiple con controles y a los métodos de emparejamiento basados en el puntaje de propensión de Rosenbaum y Rubin (1983) [RR83]. El supuesto de soporte común exige que existan tanto tratados como

no tratados para cada configuración de covariables; sin él, el contrafactual tendría que obtenerse por extrapolación y no por comparación. Debe advertirse que la ecuación (9.10) es un supuesto fuerte y no contrastable: agregar controles no garantiza que se cumpla, y como discutimos en el capítulo de gráficos acíclicos dirigidos, controlar por las variables equivocadas — en particular por colisionadores o por variables que son a su vez consecuencia del tratamiento — puede *introducir* sesgo donde no lo había.

Definición 9.6 SUTVA (*Stable Unit Treatment Value Assumption*). Se compone de dos condiciones:

1. **Ausencia de interferencia:** los resultados potenciales de un individuo no dependen del tratamiento asignado a los demás.
2. **Ausencia de versiones ocultas del tratamiento:** el tratamiento es el mismo para todos los que lo reciben.

El supuesto SUTVA es tan básico que suele darse por sentado, y sin embargo se viola con frecuencia en aplicaciones económicas. Un programa de capacitación laboral que mejora las perspectivas de los participantes puede desplazar a los no participantes en la búsqueda de empleo, en cuyo caso $Y_i(0)$ del grupo de control depende de cuántos fueron tratados. Estos **efectos de equilibrio general** son precisamente lo que la econometría de efectos de tratamiento tiene más dificultad para capturar, y constituyen una de las críticas más serias que se le dirigen.

9.1.6. Estrategias de identificación y el resto del capítulo

Con este marco podemos reinterpretar lo que ya hemos estudiado y anticipar lo que sigue. Cada estrategia de identificación es, en el fondo, una forma distinta de construir el contrafactual $\mathbb{E}[Y_i(0) \mid D_i = 1]$:

1. El **experimento aleatorizado** lo obtiene por diseño, gracias a la ecuación (9.9).
2. La **regresión con controles** y el emparejamiento lo obtienen suponiendo la ecuación (9.10).

3. Las **variables instrumentales** que estudiamos en su capítulo lo obtienen a partir de una fuente de variación exógena; como vimos al discutir el LATE, el precio de admitir efectos heterogéneos es que el parámetro identificado se restringe al subgrupo de cumplidores.
4. La **diferencia en diferencias** lo obtiene suponiendo que la trayectoria del grupo de control aproxima la trayectoria contrafactual del grupo tratado.
5. El **control sintético** lo construye como una combinación convexa ponderada de unidades no tratadas.

Las dos últimas son el objeto del resto de este capítulo.

9.2. Estimación de modelos para determinar efectos de tratamiento

9.2.1. Motivación del procedimiento Difference - in - Differences (DiD)

La técnica de Differences-in-Differences (DiD) es una de las más populares en ciencias sociales para estimar efectos causales en conjuntos no experimentales. Los diseños de DiD son una estrategia cuasi-experimental para estimar, entre otras cosas, efectos causales. DiD es la técnica más popular en la investigación en ciencias sociales cuantitativas. En general, todos los buenos diseños DiD están basados en algún tipo de experimento natural. La aplicación moderna que popularizó el método en economía es la de Card y Krueger (1994) [CK94], quienes estudiaron el efecto de un aumento del salario mínimo en Nueva Jersey sobre el empleo en la industria de comida rápida, utilizando a Pensilvania como grupo de control. Ese es el caso que se replica en el cuaderno `Increase_Minimum_Wage_On_Employment.ipynb` del repositorio del curso.

La historia es famosa y atribuida a John Snow (1855) [Sno55]—a continuación retomamos la narración del caso en el libro de Cunningham (2021) [Cun21]. Snow analizó las causas de una serie de olas de la pandemia de cólera en Londres en el siglo XIX. El cólera es una enfermedad que ataca a sus víctimas de forma repentina con síntomas como vómito y diarrea. En el siglo

XIX el cólera en Londres era una enfermedad mortal y que, inicialmente, se creía que se transmitía de forma aeróbica.

Snow era un médico en la época en que Londres enfrentó 3 olas de pandemia de cólera que enfermó y mató a decenas de miles de personas y que, en su momento, se consideró como una enfermedad misteriosa.

En aquel momento en el siglo XIX, los doctores no podían ayudar a las víctimas de la enfermedad, ya que estaban equivocados sobre el mecanismo que causaba la cólera y que facilitaba el esparcimiento de la enfermedad. Los médicos creían que la cólera se esparcía mediante el aire por causa de partículas microscópicas. De esta forma, la forma en que los médicos abordaron el problema fue poner en cuarentena a las personas infectadas o potencialmente infectadas con el objeto de disminuir la plaga. Algo que hoy día sabemos era ineficiente.

Snow, inicialmente, creía en la teoría de que la enfermedad se esparcía o transmitía de forma aeróbica. No obstante, con el paso del tiempo, Snow desarrolló una nueva teoría sobre la forma en que se transmitía el cólera, desechando la teoría de la transmisión aeróbica. Snow concluyó que la causa de la enfermedad era un microorganismo que ingresaba al cuerpo humano mediante el consumo de agua y alimentos.

Snow encontró que el principal medio de transmisión del cólera era el agua consumida por la población y que se multiplicaba por el hecho de que los desechos sanitarios se depositaban en la principal fuente de agua de la época, el río Támesis.

La forma en que Snow detectó la fuente principal y mediante la cual construyó su teoría fue una serie de anécdotas similares a las siguientes. Por ejemplo, notó que la transmisión del cólera solía seguir los patrones de comercio. En un caso de la llegada de un barco mercante a un puerto que tenía reportes de infecciones notó que la tripulación enfermaba sólo después de desembarcar, ya que la que no lo hacía no solía enfermarse. En otro caso notó que dos construcciones que tenían fuentes de agua distintas (origen del líquido distinto) tenían patrones de enfermedad distinta, en una había notablemente menos infecciones que en la otra.

Estas observaciones no eran consistentes con la teoría de la transmisión aeróbica. Así, Snow continuó recabando información. Un experimento natural ocurrió cuando notó que había el caso en dos proveedores de agua que tomaban agua de puntos distintos del Támesis, uno después del punto de desagüe del drenaje y otro más desde un punto anterior. Con esta información, Snow recabó información de los lugares que eran atendidos por las empresas

y encontró que el número de casos de cólera por cada 10,000 habitantes era como se muestra en el Cuadro 9.1 y la Figura 9.1.

Cuadro 9.1: Tabla XII de Snow (1854)–Casos de cólera en Londres por cada 10,000 habitantes según proveedor de agua, retomado de Cunningham(2021, p. 472) [Cun21]

Nombre de la compañía	1849	1854
Southwark and Vauxhall	135	147
Lambert	85	19




Figura 9.1: Comparación de los casos de cólera según proveedor de agua en Londres.

9.2.2. Estrategia de estimación

En la literatura se ha discutido algunos principios básicos que se deben cumplir en el caso de data sets en los que se puede implementar el

DiD.[Rot+23] A estos principios se les puede denominar como el modelo canónico del DiD, donde sólo existen dos periodos de tiempo disponibles, existe una población tratada por única vez a partir de que inicia el segundo periodo.

Otra forma de verlo es responder a estas preguntas:

1. ¿Todas las observaciones son tratadas al mismo tiempo?
2. ¿Está seguro de que se puede suponer que las tendencias entre todos los individuos son paralelas?
3. ¿Son suficientemente grandes los conjuntos de datos tratados y no tratados?

En esta sección describimos la forma en que estimaremos el modelo de DiD. La metodología DiD es una técnica utilizada en Econometría para medir el efecto sobre una variable dependiente o de respuesta cuantitativa y debido a un tratamiento o cambio, en un determinado período en el tiempo. Para tal efecto estimamos una ecuación como la siguiente:

$$y_{it} = \beta_1 + \beta_2 T_t + \beta_3 D_i + \theta (T_t \times D_i) + \gamma \mathbf{X}_{it} + \varepsilon_{it} \quad (9.11)$$

Donde y_{it} es la variable sobre la cual queremos evaluar el efecto de un tratamiento, $\mathbf{X}_{it}$ es un conjunto de variables de control, que incluye a las variables de efectos fijos (temporales, de individuos o del tipo que se decida) y, en su caso, una tendencia, entre otras. Finalmente, las variables T_t y D_i son variables dicotómicas que identifican con el valor de 1 el momento a partir del cual se observa el tratamiento y con 0 en cualquier otro caso, y con 1 los individuos que fueron tratados y con 0 en cualquier otro caso, respectivamente.

De esta forma, el producto $T_t \times D_i$ sería una variable dicotómica que indicaría con un 1 a aquellos individuos que fueron tratados a partir del momento en que se implementó el tratamiento y con 0 en cualquier otro caso. Bajo este escenario, θ es un coeficiente que captura el efecto del tratamiento, condicional a que se ha controlado por una serie de factores.

Otra forma de ver lo que se indica en la ecuación (9.11) es como la comparación de la diferencia en diferencia descrita por:

$$\begin{aligned} E = & [(\bar{y}_{exit}|treatment) - (\bar{y}_{baseline}|treatment)] \\ & - [(\bar{y}_{exit}|placebo) - (\bar{y}_{baseline}|placebo)] \end{aligned} \quad (9.12)$$

La expresión (9.12) cuantifica el efecto que tiene el tratamiento como la diferencia de medias de dos grupos: un grupo tratado y otro no tratado. Dentro de los cuales se ha comparado las medias de respecto de una línea base. Podemos plantear esto desde esta otra perspectiva. Pensemos que sólo tenemos dos periodos $t = 1, 2$, en el cual en 1 no ha ocurrido el tratamiento y en 2 ya ha ocurrido. Así, el cambio en la variable de respuesta para los individuos tratados será (suponiendo que omitimos la matriz $\mathbf{X}_{it}$ en la ecuación (9.11)):

$$\begin{aligned}\mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1] &= (\beta_1 + \beta_2 + \beta_3 + \theta) - (\beta_1 + \beta_3) \\ &= \beta_2 + \theta\end{aligned}\tag{9.13}$$

Ahora, sobre los no tratados:

$$\begin{aligned}\mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0] &= (\beta_1 + \beta_2) - (\beta_1) \\ &= \beta_2\end{aligned}\tag{9.14}$$

Así, la diferencia en diferencia resulta de restar la ecuación (9.14) a la ecuación (9.13):

$$\begin{aligned}(\mathbb{E}[y_{i2}|D_i = 1] - \mathbb{E}[y_{i1}|D_i = 1]) - (\mathbb{E}[y_{i2}|D_i = 0] - \mathbb{E}[y_{i1}|D_i = 0]) \\ = \theta\end{aligned}\tag{9.15}$$

Nótese lo que acabamos de hacer: la primera diferencia elimina todo aquello que es fijo en el tiempo dentro de cada grupo, y la segunda diferencia elimina todo aquello que es común a ambos grupos en el tiempo. Lo que sobrevive a las dos diferencias es el efecto del tratamiento. Esta es la intuición esencial del método y explica por qué es tan robusto a la presencia de diferencias permanentes entre los grupos: no exige en absoluto que los grupos sean comparables en *niveles*, sino únicamente en *tendencias*.

La Figura 9.2 representa gráficamente el procedimiento. Los dos grupos parten de niveles distintos, lo cual no representa problema alguno. La trayectoria contrafactual del grupo tratado — lo que le habría ocurrido de no mediar la intervención — se construye trasladando la pendiente observada del grupo de control a partir del punto inicial de los tratados. El efecto estimado es la distancia vertical entre el valor efectivamente observado y ese contrafactual.

9.2.3. El supuesto de tendencias paralelas

La derivación anterior se hizo enteramente dentro del modelo de regresión de la ecuación (9.11), lo cual oculta el supuesto de identificación que en




Figura 9.2: Representación gráfica del estimador de diferencia en diferencias

realidad estamos haciendo. Repitamos el ejercicio en el lenguaje de resultados potenciales que introdujimos al inicio del capítulo, que es donde el supuesto se vuelve visible.

Sean $t = 1$ el periodo previo y $t = 2$ el posterior a la intervención, y sea D_i el indicador de pertenencia al grupo tratado. Nuestro objetivo es el ATT en el segundo periodo:

$$ATT = \mathbb{E}[Y_{i2}(1) - Y_{i2}(0) \mid D_i = 1] \quad (9.16)$$

Definamos el estimando de diferencia en diferencias, es decir, la cantidad poblacional que el método estima:

$$\delta_{2 \times 2} = (\mathbb{E}[Y_{i2} \mid D_i = 1] - \mathbb{E}[Y_{i1} \mid D_i = 1]) - (\mathbb{E}[Y_{i2} \mid D_i = 0] - \mathbb{E}[Y_{i1} \mid D_i = 0]) \quad (9.17)$$

Apliquemos la ecuación de conmutación (9.2). En el primer periodo nadie ha sido tratado todavía, por lo que $Y_{i1} = Y_{i1}(0)$ para *ambos* grupos; este paso incorpora ya un supuesto que enunciaremos formalmente enseguida. En el segundo periodo, $Y_{i2} = Y_{i2}(1)$ para el grupo tratado y $Y_{i2} = Y_{i2}(0)$ para el de control. Sustituyendo:

$$\delta_{2 \times 2} = (\mathbb{E}[Y_{i2}(1) \mid D_i = 1] - \mathbb{E}[Y_{i1}(0) \mid D_i = 1]) - (\mathbb{E}[Y_{i2}(0) \mid D_i = 0] - \mathbb{E}[Y_{i1}(0) \mid D_i = 0])$$

Sumemos y restemos la cantidad contrafactual $\mathbb{E}[Y_{i2}(0) \mid D_i = 1]$, es decir, lo que le habría ocurrido al grupo tratado en el segundo periodo de no haber sido tratado, y reagrupemos:

$$\begin{aligned} \delta_{2 \times 2} &= \underbrace{\mathbb{E}[Y_{i2}(1) - Y_{i2}(0) \mid D_i = 1]}_{= ATT} \\ &+ \underbrace{(\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 1]) - (\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0])}_{\text{sesgo de tendencias no paralelas}} \end{aligned} \quad (9.18)$$

La ecuación (9.18) es el resultado central del método y merece ser leída con detenimiento. El estimador de diferencia en diferencias recupera el *ATT* **si y sólo si** el segundo término es cero, lo cual constituye el supuesto de identificación.

Definición 9.7 *Supuesto de tendencias paralelas.* *En ausencia del tratamiento, el resultado promedio de los grupos tratado y de control habría evolucionado de la misma manera:*

$$\mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 1] = \mathbb{E}[Y_{i2}(0) - Y_{i1}(0) \mid D_i = 0] \quad (9.19)$$

Definición 9.8 *Supuesto de ausencia de anticipación.* *Los individuos no modifican su comportamiento antes de recibir el tratamiento, de modo que $Y_{i1} = Y_{i1}(0)$ también para el grupo tratado.*

Sobre estos dos supuestos deben hacerse varias observaciones que son decisivas en el trabajo aplicado.

En primer lugar, y esto es lo más importante, el supuesto de la ecuación (9.19) es **intrínsecamente no contrastable**. El término $\mathbb{E}[Y_{i2}(0) \mid D_i = 1]$ es contrafactual: describe lo que le habría ocurrido al grupo tratado en un mundo en el que no fue tratado, mundo que no observamos. Ninguna prueba estadística puede verificar directamente el supuesto; lo más que podremos hacer, como veremos, es reunir evidencia circunstancial a su favor.

En segundo lugar, conviene entender qué hace mecánicamente el estimador de MCO cuando el supuesto falla. La regresión *siempre* proyecta la trayectoria del grupo de control a partir del valor inicial del grupo tratado, y mide la distancia vertical entre esa proyección y el valor observado. Si la trayectoria contrafactual verdadera del grupo tratado no era paralela a la del control, MCO seguirá produciendo un número, pero ese número no será el *ATT*. El sesgo puede ir en cualquier dirección e incluso invertir el signo del efecto.




Figura 9.3: Qué estima MCO cuando el supuesto de tendencias paralelas no se cumple

La Figura 9.3 ilustra esta situación. Ahí la trayectoria contrafactual verdadera del grupo tratado era más inclinada que la del grupo de control, de modo que el grupo tratado habría crecido más que el de control aun sin la intervención. MCO no tiene forma de saberlo: impone la pendiente del control y, en consecuencia, atribuye al tratamiento una parte del crecimiento que habría ocurrido de todos modos, sobreestimando el efecto. El único caso en que el estimador coincide con el *ATT* es aquel en que la pendiente contrafactual resulta ser, por coincidencia, la del grupo de control. Esa coincidencia es precisamente lo que postula el supuesto de tendencias paralelas.

En tercer lugar, y como señala Cunningham (2021) [Cun21], el supuesto de tendencias paralelas es esencialmente una reformulación del supuesto de exogeneidad estricta que ya discutimos en el capítulo de datos panel. Afirmar que las tendencias son paralelas equivale a afirmar que la asignación del tratamiento no es endógena respecto de la evolución de la variable de interés. Si un gobierno estatal aumenta el salario mínimo precisamente porque anticipa un auge en el mercado laboral, las tendencias no eran paralelas y el método falla, por más limpio que parezca el diseño.

En cuarto lugar, el supuesto **no es invariante ante transformaciones de la variable dependiente**. Que las tendencias sean paralelas en niveles

no implica que lo sean en logaritmos, y viceversa. Esto significa que la elección de la forma funcional es, en diferencia en diferencias, una decisión de identificación y no meramente de conveniencia.

Finalmente, el supuesto de ausencia de anticipación se viola con frecuencia cuando la política se anuncia antes de entrar en vigor. Un caso clásico es el llamado *dip* de Ashenfelter (1978) [Ash78], quien observó que los ingresos de los participantes en programas de capacitación caían justo antes de inscribirse — precisamente porque la pérdida de empleo era lo que los llevaba a inscribirse —. Comparar contra ese punto deprimido produce una sobreestimación mecánica del efecto del programa.

9.2.4. Diferencia en diferencias con múltiples periodos y unidades

El planteamiento de dos grupos y dos periodos es útil para la intuición, pero la mayoría de las aplicaciones utiliza paneles con muchas unidades y muchos periodos. La generalización natural es el modelo de **efectos fijos en dos vías** (TWFE, por *two-way fixed effects*):

$$y_{it} = \alpha_i + \lambda_t + \delta D_{it} + \gamma \mathbf{X}_{it} + \varepsilon_{it} \quad (9.20)$$

Donde α_i son efectos fijos de unidad, λ_t son efectos fijos de tiempo y D_{it} es un indicador que vale 1 si la unidad i está bajo tratamiento en el periodo t . Notemos la correspondencia con la ecuación (9.11): los efectos fijos de unidad generalizan el término $\beta_3 D_i$, absorbiendo todas las diferencias permanentes entre unidades, y los efectos fijos de tiempo generalizan $\beta_2 T_t$, absorbiendo todos los choques comunes a todas las unidades en cada periodo. El coeficiente δ ocupa el lugar de θ .

Este modelo se estima exactamente con el instrumental de efectos fijos que desarrollamos en el capítulo de datos panel, típicamente mediante la transformación intragrupos aplicada en las dos dimensiones. Cuando todas las unidades tratadas reciben el tratamiento en el mismo momento, la ecuación (9.20) estima el *ATT* bajo tendencias paralelas, tal como en el caso de dos por dos. Cuando el tratamiento se adopta en momentos distintos, en cambio, ocurre algo mucho menos evidente, y a ello dedicamos una sección más adelante.

9.2.5. Estudios de eventos y tendencias previas

Aunque el supuesto de tendencias paralelas no sea contrastable, sí podemos evaluar una implicación observable: si los dos grupos evolucionaban de manera paralela *antes* del tratamiento, resulta más creíble — aunque no queda demostrado — que hubieran seguido haciéndolo después. La herramienta estándar para ello es el **estudio de eventos**, que consiste en estimar una versión dinámica de la ecuación (9.20) con adelantos y rezagos del tratamiento:

$$y_{it} = \alpha_i + \lambda_t + \sum_{\substack{k=-K \\ k \neq -1}}^L \delta_k \cdot \mathbf{1}\{t - E_i = k\} + \gamma \mathbf{X}_{it} + \varepsilon_{it} \quad (9.21)$$

Donde E_i es el periodo en que la unidad i recibe el tratamiento, de modo que $k = t - E_i$ es el “tiempo relativo al evento”. Los coeficientes δ_k con $k < 0$ son los **adelantos** y los que tienen $k \geq 0$ son los **rezagos**.

Debe notarse la exclusión de $k = -1$ en la suma. Se trata de una **normalización necesaria**, no de una elección sustantiva: sin omitir una categoría, el conjunto de indicadores sería colineal con los efectos fijos. En consecuencia, todos los δ_k deben interpretarse como diferencias *respecto del periodo inmediatamente anterior al tratamiento*, y cambiar el periodo de referencia cambia todos los coeficientes reportados.

La lectura de la ecuación (9.21) es doble, y la Figura 9.4 muestra el tipo de gráfico con el que se presenta. Los coeficientes de los adelantos, δ_k con $k < 0$, deberían ser estadísticamente indistinguibles de cero si las tendencias eran paralelas antes del tratamiento; esta es la “prueba de tendencias previas”. Los coeficientes de los rezagos, δ_k con $k \geq 0$, describen la **trayectoria dinámica** del efecto, permitiendo distinguir si el efecto aparece de inmediato o gradualmente, y si persiste o se desvanece. Esta segunda lectura es con frecuencia tan valiosa como la primera y suele ser la razón principal para presentar el gráfico.

Ahora bien, la prueba de tendencias previas debe interpretarse con considerable cautela, y la literatura reciente ha sido enfática al respecto:

1. **No rechazar no es evidencia de que el supuesto se cumpla.** Los coeficientes de los adelantos suelen estimarse con poca precisión, de modo que la prueba tiene bajo poder. Intervalos de confianza amplios que incluyen el cero son compatibles con violaciones sustanciales del supuesto.




Figura 9.4: Gráfico de estudio de eventos: coeficientes de adelantos y rezagos con sus intervalos de confianza

2. **Tendencias previas paralelas no implican tendencias posteriores paralelas.** Es perfectamente posible que las trayectorias coincidan antes y diverjan después por razones ajenas al tratamiento.

3. **Contrastar tendencias previas y luego condicionar el análisis a haberlas superado introduce un sesgo de preselección.** Roth (2022) [Rot22] muestra que este procedimiento en dos etapas, que es la práctica habitual, puede *agravar* el sesgo del estimador y distorsionar la cobertura de los intervalos de confianza, porque los estudios que superan la prueba son precisamente aquellos en los que el ruido muestral compensó la violación del supuesto.

Por estas razones, la práctica moderna se orienta hacia los análisis de **sensibilidad** en lugar de las pruebas binarias: en vez de preguntar si el supuesto se cumple, se pregunta qué tan grande tendría que ser la violación de tendencias paralelas para revertir la conclusión del estudio.

9.2.6. Adopción escalonada y los problemas del estimador TWFE

Llegamos aquí a uno de los desarrollos más importantes de la econometría aplicada de la última década, y a una de las razones por las que conviene revisar con escepticismo la literatura empírica publicada antes de aproximadamente 2019.

Consideremos el caso, muy común, de **adopción escalonada**: distintas unidades reciben el tratamiento en momentos distintos. Por ejemplo, distintos estados aprueban una misma legislación en años diferentes. Durante décadas se estimó la ecuación (9.20) en estos contextos y se interpretó $\hat{\delta}$ como un efecto promedio del tratamiento. Goodman-Bacon (2021) [Goo21] demostró que esa interpretación es, en general, incorrecta.

El resultado, conocido como **descomposición de Goodman-Bacon**, establece que el estimador de TWFE con adopción escalonada es un promedio ponderado de *todas* las comparaciones dos por dos que pueden construirse con los datos. Estas comparaciones son de tres tipos:

1. Unidades tratadas frente a unidades nunca tratadas.
2. Unidades tratadas tempranamente frente a unidades tratadas tardíamente, en el periodo en que estas últimas aún no han sido tratadas.
3. **Unidades tratadas tardíamente frente a unidades tratadas tempranamente, en el periodo en que estas últimas ya han sido tratadas.**

El tercer tipo de comparación es problemático y se le conoce como la “comparación prohibida”. En ella, el grupo que hace las veces de control *ya está bajo tratamiento*. Si el efecto del tratamiento es constante en el tiempo, esto no causa daño, porque el efecto se cancela en la doble diferencia. Pero si el efecto es **dinámico**, es decir, si crece o decrece conforme pasa el tiempo desde la adopción, entonces el resultado del grupo de control está cambiando por causa de su propio tratamiento, y esa variación se atribuye erróneamente — con signo invertido — al grupo tratado tardíamente.

La consecuencia es grave: el estimador de TWFE puede asignar **ponderadores negativos** a algunos de los efectos que promedia. De Chaisemartin y D’Haultfoeulle (2020) [CD20] documentan que, en aplicaciones publicadas, una fracción sustancial de los ponderadores es negativa. En casos extremos

esto produce la situación paradójica de que $\hat{\delta}$ tenga signo *opuesto* al de todos los efectos individuales que agrega. Un estimador que puede reportar un efecto negativo cuando el tratamiento benefició a todas las unidades no es un estimador aceptable.

Adicionalmente, los ponderadores no son los que uno elegiría: son mayores para las unidades tratadas hacia la mitad del periodo muestral, simplemente porque en ellas la varianza del indicador de tratamiento es máxima. No hay ninguna razón sustantiva por la que esas unidades merezcan más peso.

La literatura ha respondido con estimadores robustos a la heterogeneidad de los efectos. Los principales son:

1. **Callaway y Sant’Anna (2021)** [CS21], que estiman efectos desagregados por cohorte de adopción y por periodo, $ATT(g, t)$, utilizando exclusivamente como controles a las unidades nunca tratadas o a las aún no tratadas, y sólo después los agregan con ponderadores explícitos y transparentes.
2. **Sun y Abraham (2021)** [SA21], que muestran que los coeficientes del estudio de eventos de la ecuación (9.21) también están contaminados — de modo que incluso las pruebas de tendencias previas pueden ser engañosas — y proponen un estimador ponderado por interacciones.
3. **De Chaisemartin y D’Haultfœuille (2020)** [CD20], que construyen estimadores basados únicamente en comparaciones válidas y proponen diagnósticos sobre la magnitud de los ponderadores negativos.

Una síntesis muy accesible de toda esta literatura, y de las recomendaciones prácticas que de ella se derivan, se encuentra en Roth, Sant’Anna, Bilinski y Poe (2023) [Rot+23]. La recomendación operativa mínima es la siguiente: si el tratamiento se adopta de forma escalonada, no basta con estimar la ecuación (9.20); debe reportarse además al menos un estimador robusto a la heterogeneidad, y presentarse la descomposición de Goodman-Bacon para documentar de dónde proviene la identificación.

9.2.7. Inferencia

Un aspecto que suele descuidarse es el cálculo de los errores estándar. Bertrand, Duflo y Mullainathan (2004) [BDM04] mostraron que las aplicaciones de diferencia en diferencias con paneles largos padecen un problema serio: las

variables de interés varían típicamente a nivel de grupo — el estado, el municipio — y las variables de resultado están fuertemente autocorrelacionadas en el tiempo. Ignorar ambos hechos produce errores estándar severamente subestimados. En sus simulaciones, pruebas realizadas a un nivel de significancia nominal del 5 % rechazaban la hipótesis nula hasta en un 45 % de los casos cuando el efecto verdadero era cero.

Las soluciones que proponen son tres:

1. **Agrupar los errores estándar** (*clustering*) al nivel al que se asigna el tratamiento, típicamente el grupo. Esto permite correlación serial arbitraria dentro de cada grupo y es, con mucho, la solución más utilizada.
2. **Remuestreo por bloques** (*block bootstrap*), donde el remuestreo se hace sobre grupos completos y no sobre observaciones individuales.
3. **Agregar los datos** a un solo periodo previo y uno posterior, eliminando por completo la dimensión temporal y con ella la autocorrelación.

Es importante subrayar que el agrupamiento debe hacerse al nivel de asignación del tratamiento y no a un nivel más fino. Un error frecuente consiste en agrupar a nivel de individuo cuando la política se asignó a nivel estatal, lo que no resuelve el problema.

Una dificultad adicional aparece cuando el **número de grupos es pequeño**. Las propiedades del estimador agrupado de la varianza son asintóticas en el número de conglomerados, no en el número de observaciones, por lo que con pocos grupos — y en Card y Krueger (1994) [CK94] sólo hay dos — el procedimiento estándar vuelve a sobrerrechazar. Las alternativas en ese caso son el remuestreo salvaje por conglomerados (*wild cluster bootstrap*) y, cuando hay una sola unidad tratada, la inferencia por aleatorización, que es también el principio que subyace a las pruebas de placebo del control sintético que veremos en la siguiente sección.

9.2.8. Pruebas de robustez y diseños relacionados

Además del estudio de eventos, el trabajo aplicado suele acompañarse de las siguientes verificaciones:

1. **Placebo en el tiempo**. Se reasigna artificialmente la fecha del tratamiento a un periodo previo, utilizando únicamente datos anteriores a la intervención real. No debería detectarse ningún efecto.

2. **Placebo en el resultado.** Se estima el mismo modelo sobre una variable que, por razones teóricas, no debería verse afectada por la política. Un efecto significativo sugiere que el diseño está capturando algo distinto del tratamiento.
3. **Sensibilidad al grupo de control.** Se repite el análisis con distintos conjuntos de unidades de control. Si las conclusiones dependen críticamente de esa elección, el resultado es frágil.
4. **Triple diferencia (DDD).** Cuando se dispone de un grupo adicional que, dentro de las mismas unidades tratadas, no debería verse afectado por la política, puede aplicarse una tercera diferencia. Esto permite relajar el supuesto de tendencias paralelas, ya que sólo se requiere que los sesgos de tendencia sean comunes entre los dos subgrupos y no que sean nulos.

Vale la pena recordar, al cerrar esta sección, que ninguna de estas verificaciones *demuestra* el supuesto de identificación. Su función es hacerlo más creíble, y la credibilidad de un diseño de diferencia en diferencias descansa en última instancia sobre el argumento sustantivo de por qué el momento del tratamiento puede considerarse ajeno a la evolución de la variable de interés. Como lo formula Cunningham, el conocimiento institucional del contexto es tan importante como cualquier técnica estadística.

9.3. Control Sintético

9.3.1. Motivación

En esta sección utilizaremos como base el trabajo de Abadie (2021) [Aba21]. Por lo anterior pondremos énfasis en la factibilidad, los requerimientos de los datos, los requerimientos de contexto y algunos problemas metodológicos asociados a la aplicación empírica del control sintético. Particularmente, nos enfocaremos en la importancia que tiene las características que hacen posible la implementación del control sintético.

Susan Athey y Guido Imbens en 2017 describieron al proceso de control sintético como la innovación más importante en la evaluación de políticas públicas en los últimos 15 años (Athey e Imbens (2017) [AI17]). En los últimos años, el control sintético ha sido aplicado a diversos dominios: migración,

conexiones políticas y cumplimiento de leyes, impuestos, crimen organizado y terrorismo, salario mínimo, entre otros. El uso de controles sintéticos no se limita a las ciencias sociales. También ha sido aplicado en ingeniería y ciencias biomédicas, por ejemplo.

Los métodos de control sintético fueron propuestos originalmente por Abadie y Gardeazabal (2003) [AG03] y Abadie, Diamond y Hainmueller (2010) [ADH10] con el propósito de estimar los efectos de intervenciones agregadas –intervenciones que son implementadas a un nivel agregado afectando a un pequeño número de unidades de un conjunto amplio de unidades como ciudades, regiones o países– en algún resultado agregado que sea de interés.

Consideremos una situación en la que una unidad agregada, tal como un estado o municipio, es expuesta a un evento o intervención de interés. En estos casos, los análisis tradicionales de regresión requieren muestras grandes y muchas observaciones dentro de los casos afectados por el evento. En un caso similar, el uso de series de tiempo para la evaluación de una política pública requiere de observaciones por muchos períodos para realizar un análisis adecuadamente.

El método de controles sintéticos está basado en la idea de que, cuando las unidades de observación son un número pequeño de entidades agregadas, una combinación de unidades no afectadas podrían proveer una comparación más apropiada que una simple unidad observada de forma individual.

Esta técnica tiene múltiples aplicaciones que van desde la cuantificación de los efectos económicos de conflictos como el terrorista en el País Vasco (Abadie & Gardeazabal, 2003), la implementación de regulación en el consumo de tabaco en el estado de California, Estados Unidos (Abadie et al., 2010), hasta la cancelación de infraestructura, como en el caso del Nuevo Aeropuerto Internacional de la Ciudad de México (NAIM) (Woo-Mora, 2022) [Woo22].

El primer caso trata de una cuantificación de los efectos económicos del conflicto terrorista en el País Vasco. La observación que motivó el estudio fue que, tras el estallido del terrorismo a finales de la década de 1960, el PIB per cápita en el País Vasco disminuyó unos 10 puntos porcentuales en comparación con las regiones sin terrorismo. Al inicio de la actividad terrorista, a principios de la década de 1970, el País Vasco era una de las regiones más ricas de España, ocupando el tercer puesto en PIB per cápita (de 17 regiones). A finales de la década de 1990, tras 30 años de conflicto terrorista y político, el País Vasco había descendido al sexto puesto en PIB

per cápita. Además, la tregua que ocurrió entre 1998 y 1999, considerada como un experimento natural, mostró que las empresas en el País Vasco durante este período reportaron un desempeño relativamente positivo cuando la tregua se hizo creíble y un rendimiento relativamente negativo al final de la tregua (Abadie & Gardeazabal, 2003).

En este tipo de casos, un análisis puramente basado en series de tiempo es complejo de implementar, dado i) la gravedad del terrorismo y ii) la evolución de la economía que se vio afectada por la recesión económica que sufrió España durante la segunda mitad de la década de 1970 y la primera mitad de la de 1980, en el auge de la actividad terrorista. De esta forma, una simple comparación de la evolución de la economía vasca con la del resto de España no sólo reflejaría el efecto del terrorismo, sino también el efecto de las diferencias pre-terroristas en los determinantes del crecimiento económico (Abadie & Gardeazabal, 2003).

De esta forma, los autores del estudio plantearon que la solución estaba en utilizar una combinación de otras regiones españolas (pool donador) para construir una región de control sintética que refleje las características económicas relevantes del País Vasco antes del inicio del terrorismo político vasco a finales de la década de 1960. De esta forma, se plantea construir un escenario alternativo sintético de la evolución económica posterior de este País Vasco sin terrorismo. Para finalmente, comparar la experiencia real del País Vasco con el contrafactual sintético. Un segundo caso se ubica en el estudio de los efectos de la Proposición 99, un programa a gran escala de control del tabaco implementado en California, Estados Unidos, en 1988. De acuerdo con este estudio, tras la Proposición 99, el consumo de tabaco disminuyó notablemente en California en comparación con una región comparable de control sintético—construida a partir del pool de donadores formado por otros estados en donde no se observó una intervención similar—. Las estimaciones señalan que, para el año 2000, las ventas anuales de cigarrillos per cápita en California eran aproximadamente 26 paquetes inferiores a las que habrían sido en ausencia de la Proposición 99 (Abadie et al., 2010) [ADH10]. Este es el caso que se replica en el cuaderno `California_Tobacco_Tax_and_Health_Protection_Act.ipynb` del repositorio del curso.

Finalmente, el tercer caso es un análisis de las consecuencias derivadas de la cancelación de la construcción del NAIM, elaborado por Woo-Mora (2022) [Woo22] y que tiene el interés adicional de ser una aplicación mexicana y reciente del método. El episodio que estudia es la consulta no oficial,

con una participación menor al 1 % del padrón, mediante la cual se decidió detener la construcción del aeropuerto en Texcoco al inicio de la administración federal de 2018. Utilizando un control sintético construido a partir de un conjunto de países donadores, el autor estima un efecto sobre el PIB de aproximadamente -3% un año después de la cancelación, es decir, antes de la pandemia de Covid-19. Para los periodos posteriores a la pandemia, en los que el contrafactual se vuelve mucho más incierto, reporta límites de predicción en lugar de una estimación puntual, lo cual constituye una buena práctica que conviene destacar. El estudio documenta además que la caída del consumo y de la inversión explica el efecto estimado, que entre 2018 y 2021 el PIB per cápita disminuyó alrededor de 10% , que los efectos son heterogéneos entre regiones, y que — al examinar los datos de ingreso — la mayoría de los hogares resultan afectados mientras que no se detecta efecto sobre los de mayores ingresos.

Este caso ilustra bien varios de los puntos metodológicos que discutiremos a continuación: la elección y justificación del conjunto de donadores, la importancia de fechar la intervención en el momento del anuncio y no en el de la implementación, la necesidad de reportar la incertidumbre cuando un choque global posterior contamina el periodo de análisis, y el uso del método para estimar efectos distributivos y no sólo agregados. El documento se encuentra en la carpeta de bibliografía del curso.

9.3.2. Planteamiento del método de estimación

Supongamos que tenemos datos para $J + 1$ unidades, es decir, observamos $j = 1, 2, \dots, J + 1$. Sin pérdida de generalidad, asumiremos que la primera unidad ($j = 1$) es la unidad que ha sido tratada, esto es, la unidad afectada por la intervención de política pública. El "donor pool." conjunto de donadores que se constituye por el conjunto de potenciales unidades de comparación, $j = 2, \dots, J + 1$, es una colección de unidades no tratadas o no afectadas por la intervención.

Asumiremos que nuestros datos son de una duración de T periodos y que los primeros T_0 periodos son previos a la intervención. Para cada unidad, j , y tiempo, t , observamos el resultado de interés, Y_{jt} . Para cada unidad, j , observamos un conjunto de k predictores del resultado observado, $X_{1j}, \dots, X_{kj}$ el cual podría incluir los valores de la variable analizada, Y_{jt} , pero en periodos previos y los cuales son en sí mismos no afectados por la intervención.

Los $K \times 1$ vectores $\mathbf{X}_1, \dots, \mathbf{X}_{J+1}$ contienen los valores de los predictores

de las unidades $j = 1, \dots, J + 1$, respectivamente. La matriz $k \times J$, $\mathbf{X}_0 = [\mathbf{X}_2, \dots, \mathbf{X}_{J+1}]$ contiene los valores de los predictores de las J unidades no tratadas. Para cada unidad j y periodo de tiempo t definimos Y_{jt}^N como la respuesta potencial que se hubiera observado sin la intervención. Para la unidad afectada por la intervención $j = 1$ y para el periodo postintervención $t > T_0$ definimos Y_{1t}^I como la respuesta potencial bajo la intervención.

De esta forma, el efecto de la intervención de interés para el periodo t afectado ($t > T_0$) estará dado por:

$$\tau_{1t} = Y_{1t}^I - Y_{1t}^N \quad (9.22)$$

De esta forma, el reto de la evaluación de política pública es estimar Y_{1t}^N para $t > T_0$. Esto es, construir el contrafactual.

Un control sintético es definido como el promedio ponderado de las unidades en el conjunto de donadores. Formalmente, un control sintético puede ser representado por un vector $J \times 1$ de pesos $\mathbf{W} = (w_2, \dots, w_{J+1})'$. Dado el conjunto de pesos $\mathbf{W}$ los estimadores del control sintético de Y_{1t}^N y de τ_{1t} son:

$$\hat{Y}_{1t}^N = \sum_{j=2}^{J+1} w_j Y_{jt} \quad (9.23)$$

$$\hat{\tau}_{1t} = Y_{1t} - \hat{Y}_{1t}^N \quad (9.24)$$

Para evitar un escenario en el que la estimación sea explosiva, restringimos los pesos a que no sean negativos y que su suma sea 1. Note que también se debe considerar que el control sintético requiere que las variables en el data set sean rescaladas correctamente para considerar las diferencias por las unidades (por ejemplo, ingreso per cápita) o si la corrección no es necesaria puesto que las variables en los datos no se requieren rescalar por tamaño (por ejemplo, precios).

De esta forma, el control sintético se reduce a la pregunta de cómo deben ser los pesos $w_2, \dots, w_{J+1}$. Dado un conjunto de constantes $v_1, \dots, v_k$, podemos proponer la elección del control sintético $\mathbf{W}^* = (w_2^*, \dots, w_{J+1}^*)'$ que minimiza la distancia entre el vector de predictores de la unidad tratada y el del control sintético:

$$\|\mathbf{X}_1 - \mathbf{X}_0 \mathbf{W}\|_{\mathbf{V}} = \left(\sum_{h=1}^k v_h (X_{h1} - w_2 X_{h2} - \dots - w_{J+1} X_{hJ+1})^2 \right)^{1/2} \quad (9.25)$$

Sujeto a que $w_j \geq 0$ para $j = 2, \dots, J+1$ y que $w_2 + \dots + w_{J+1} = 1$.

De esta forma, la estimación del efecto derivado del tratamiento en la unidad tratada en el momento $t = T_0 + 1, \dots, T$ es:

$$\hat{\tau}_{1t} = Y_{1t} - \sum_{j=2}^{J+1} w_j^* Y_{jt} \quad (9.26)$$

Las dos restricciones sobre los pesos no son un detalle técnico, sino que definen el carácter del método. La restricción de no negatividad y la de que sumen uno obligan a que el control sintético sea una **combinación convexa** de las unidades donadoras, es decir, un promedio ponderado en sentido estricto. Esto tiene dos consecuencias. La primera es que el contrafactual construido nunca puede quedar fuera del rango de valores observados en el conjunto de donadores, lo que evita la extrapolación y descarta los resultados explosivos. La segunda es que la solución tiende a ser **dispersa**: en la práctica sólo unas pocas unidades reciben peso positivo y el resto recibe peso exactamente cero, lo que facilita enormemente la interpretación y la discusión del contrafactual, ya que puede decirse con precisión qué unidades lo componen y en qué proporción.

Las constantes no negativas $\mathbf{V} = v_1, \dots, v_k$ en la ecuación (9.25) reflejan la importancia relativa en el control sintético los valores de los k predictores para la unidad de tratamiento $X_{11}, X_{21}, \dots, X_{k1}$. Así, la pregunta que queda por responder es cómo determinar $\mathbf{V}$. Una forma muy sencilla de determinar ese vector es elegir cada v_h es la inversa de la varianza de $X_{h1}, \dots, X_{hJ+1}$, $h = 1, \dots, k$, lo que resulta en un efecto de rescalamiento de todos los renglones de $[\mathbf{X}_0 : \mathbf{X}_1]$ a una varianza unitaria.

9.3.3. ¿Por qué usar el control sintético?

En principio consideremos que mediante el estimador de una regresión lineal es posible determinar el efecto del tratamiento fácilmente mediante la construcción de un panel. Sea $\mathbf{Y}_0$ la matriz $(T - T_0) \times J$ del resultado post-intervención para las unidades del conjunto de donadores. Sea $\bar{\mathbf{X}}_1$ y $\bar{\mathbf{X}}_0$ el resultado de agregar a las matrices $\mathbf{X}_1$ y $\mathbf{X}_0$, respectivamente, un vector de unos (1's). Para una matriz no singular $\bar{\mathbf{X}}_0 \bar{\mathbf{X}}_0'$, un estimador basado en una regresión del contrafactual Y_{1t}^N para $t > T_0$ es $\hat{\mathbf{B}}' \bar{\mathbf{X}}_1$, donde

$$\hat{\mathbf{B}} = (\bar{\mathbf{X}}_0 \bar{\mathbf{X}}_0')^{-1} \bar{\mathbf{X}}_0 \mathbf{Y}_0'$$

Lo cual es un estimador de regresión de $\bar{\mathbf{X}}_1$ en $\bar{\mathbf{X}}_0$.

También el control sintético evita los resultados explosivos, ya que los pesos en el control sintético son no negativos y suman 1.

Otra ventaja del control sintético es que existe transparencia en el proceso de estimación y en la construcción del contrafactual.

En cuanto a los requerimientos, el control sintético requiere la disponibilidad de datos para las unidades tratadas y para las no tratadas.

Conviene además situar el método respecto de la diferencia en diferencias que acabamos de estudiar. Ambos construyen un contrafactual a partir de unidades no tratadas, pero difieren en cómo lo hacen. La diferencia en diferencias impone *a priori* pesos iguales sobre todas las unidades de control y exige el supuesto de tendencias paralelas. El control sintético, en cambio, **elige los pesos** de manera que la unidad sintética reproduzca la trayectoria previa de la unidad tratada, con lo que el supuesto de tendencias paralelas se sustituye por el requisito, verificable en los datos previos, de un buen ajuste preintervención. En este sentido el control sintético puede verse como una generalización de la diferencia en diferencias en la que los ponderadores dejan de ser uniformes y pasan a ser estimados.

9.3.4. Inferencia mediante pruebas de placebo

Un problema evidente del control sintético es que la inferencia estadística convencional no aplica: típicamente hay una sola unidad tratada, de modo que no existe un tamaño de muestra sobre el cual construir una distribución asintótica. La solución propuesta por Abadie, Diamond y Hainmueller (2010) [ADH10] y (2015) [ADH15] consiste en recurrir a la **inferencia por permutación**, también llamada de placebos en el espacio.

El procedimiento es el siguiente:

1. Aplicar el método de control sintético sucesivamente a *cada una* de las J unidades del conjunto de donadores, tratando a cada una como si hubiera recibido la intervención en el mismo momento T_0 , y utilizando como donadores a las restantes.
2. Obtener así una distribución de $J + 1$ efectos estimados: el de la unidad realmente tratada y J efectos placebo.
3. Comparar la magnitud del efecto estimado para la unidad tratada con la distribución de los efectos placebo. Si el efecto real es atípicamente




Figura 9.5: Control sintético: trayectorias e inferencia mediante placebos en el espacio

grande en relación con esa distribución, tenemos evidencia de que no se trata de un artefacto del método.

La Figura 9.5 muestra las dos piezas del análisis. El panel (a) presenta la comparación básica entre la trayectoria observada de la unidad tratada y la de su control sintético, que por construcción coinciden antes de la intervención y se separan después. El panel (b) presenta la brecha entre ambas, junto con las brechas que resultan de aplicar el mismo procedimiento a cada una de las unidades donadoras. La conclusión inferencial se lee directamente del gráfico: la brecha de la unidad tratada es atípica respecto de la distribución de brechas placebo.

Para hacer la comparación operativa se utiliza el **cociente de errores cuadráticos medios de predicción** (RMSPE). Definamos el RMSPE previo y posterior a la intervención:

$$\begin{aligned}
 RMSPE_j^{pre} &= \left(\frac{1}{T_0} \sum_{t=1}^{T_0} (Y_{jt} - \hat{Y}_{jt}^N)^2 \right)^{1/2} \\
 RMSPE_j^{post} &= \left(\frac{1}{T - T_0} \sum_{t=T_0+1}^T (Y_{jt} - \hat{Y}_{jt}^N)^2 \right)^{1/2}
 \end{aligned} \tag{9.27}$$

Y construyamos para cada unidad el cociente $r_j = RMSPE_j^{post} / RMSPE_j^{pre}$. La normalización por el ajuste previo es esencial: una unidad para la que el control sintético ajusta mal antes de la intervención tendrá necesariamente errores grandes después, sin que ello indique efecto alguno. El cociente r_j aísla el deterioro del ajuste *atribuible* al periodo posterior.

Con estos cocientes puede calcularse un valor p de permutación:

$$p = \frac{\text{número de unidades con } r_j \geq r_1}{J + 1} \quad (9.28)$$

Es decir, la proporción de unidades cuyo cociente es al menos tan extremo como el de la unidad tratada. La interpretación es directa: si la unidad tratada ocupa el primer lugar entre 39 unidades, el valor p es $1/39 \approx 0.026$. Nótese una limitación importante de este enfoque: el valor p más pequeño alcanzable es $1/(J + 1)$, de modo que con un conjunto de donadores pequeño resulta imposible obtener significancia convencional por más grande que sea el efecto.

Una práctica complementaria consiste en graficar todas las trayectorias placebo junto con la de la unidad tratada, descartando previamente aquellas unidades cuyo ajuste preintervención sea muy deficiente — típicamente las que tienen un $RMSPE^{pre}$ varias veces mayor que el de la unidad tratada —, ya que de otro modo el gráfico se vuelve ilegible sin aportar información.

9.3.5. Cuándo no debe usarse el control sintético

Abadie (2021) [Aba21] es explícito en señalar las condiciones bajo las cuales el método no es aplicable, y conviene tenerlas presentes antes de emprender el análisis:

1. **Ajuste preintervención deficiente.** Si ninguna combinación convexa de las unidades donadoras reproduce razonablemente la trayectoria previa de la unidad tratada, el método no debe utilizarse. Esto ocurre típicamente cuando la unidad tratada tiene valores extremos en los predictores, de modo que queda fuera de la envolvente convexa del conjunto de donadores. Forzar el ajuste en ese caso produce un contrafactual sin sentido.
2. **Periodo previo demasiado corto.** Se requieren suficientes periodos anteriores a la intervención para que el ajuste sea informativo y no un

mero producto del sobreajuste. Con pocos periodos, cualquier combinación de donadores puede replicar la trayectoria previa sin que ello garantice nada sobre la posterior.

3. **Contaminación del conjunto de donadores.** Las unidades donadoras no deben haber sido afectadas por la intervención ni por intervenciones similares. Si el tratamiento en la unidad tratada tiene efectos de derrame sobre sus vecinas — lo que constituye una violación de SUTVA — estas deben excluirse del conjunto de donadores.
4. **Anticipación.** Si los agentes modifican su comportamiento antes de la intervención, el periodo previo queda contaminado. La práctica recomendada consiste en retrasar hacia atrás la fecha de tratamiento hasta el momento en que la política fue anunciada.
5. **Volatilidad idiosincrática elevada.** Cuando la variable de interés tiene mucho ruido en relación con la magnitud esperada del efecto, el método carece de poder para detectarlo.

Debe añadirse que la elección del conjunto de donadores es una decisión del investigador que afecta directamente los resultados, y que ampliarlo indiscriminadamente para mejorar el ajuste introduce lo que se conoce como **sesgo de interpolación**: unidades muy distintas a la tratada pueden recibir peso positivo simplemente porque sus valores compensan aritméticamente los de otras. Por esta razón el conjunto de donadores debe restringirse, con criterios sustantivos y declarados de antemano, a unidades comparables.

Finalmente, respecto de las extensiones, múltiples estudios han discutido estimaciones e inferencia con controles sintéticos para casos en los que existen múltiples unidades tratadas o adopción escalonada, así como variantes que relajan la restricción de convexidad o que corrigen el sesgo derivado de un ajuste imperfecto. Estas extensiones son un área activa de investigación.

9.4. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.

- a) El efecto causal individual δ_i puede estimarse si se dispone de una muestra suficientemente grande.
 - b) Si el tratamiento se asigna aleatoriamente, la diferencia simple de medias estima el ATE sin sesgo.
 - c) El supuesto de tendencias paralelas puede contrastarse estadísticamente comparando las trayectorias de ambos grupos antes del tratamiento.
 - d) Si los coeficientes de los adelantos en un estudio de eventos no son significativos, el supuesto de tendencias paralelas se cumple.
 - e) El estimador de efectos fijos en dos vías estima siempre un promedio ponderado con ponderadores positivos de los efectos del tratamiento.
 - f) Que las tendencias sean paralelas en niveles implica que también lo son en logaritmos.
 - g) El control sintético requiere el supuesto de tendencias paralelas.
 - h) El ATT y el ATE coinciden cuando los efectos del tratamiento son homogéneos entre individuos.
2. Considere la siguiente población hipotética de seis individuos, para la cual — por tratarse de un ejercicio — conocemos *ambos* resultados potenciales:

Individuo	$Y_i(1)$	$Y_i(0)$	D_i
1	12	10	1
2	14	11	1
3	16	13	1
4	8	7	0
5	9	9	0
6	11	8	0

Se le solicita:

- a) Calcular el efecto causal individual δ_i de cada individuo, así como el ATE , el ATT y el ATU .
- b) Verificar numéricamente la relación de la ecuación (9.6).

- c) Calcular la diferencia simple de medias que un investigador observaría en la práctica, es decir, utilizando únicamente Y_i según la ecuación de conmutación (9.2).
 - d) Descomponer esa diferencia en los tres términos de la ecuación (9.8) y verificar que la identidad se cumple numéricamente.
 - e) Explicar cuál de los dos sesgos es cuantitativamente más importante en este ejemplo y qué implicaría para la interpretación de la comparación ingenua.
3. Demuestre la descomposición de la ecuación (9.8) siguiendo los pasos del texto, e identifique con precisión cuál de los términos involucra una cantidad contrafactual y por qué ello impide corregir el sesgo directamente.
 4. Demuestre la descomposición de la ecuación (9.18). Se le solicita además: (i) indicar en qué paso exacto se utiliza el supuesto de ausencia de anticipación; (ii) mostrar que bajo el supuesto de tendencias paralelas de la ecuación (9.19) el estimando coincide con el ATT ; y (iii) explicar por qué el método identifica el ATT y no el ATE .
 5. Considere el modelo de regresión de la ecuación (9.11) sin variables de control. Se le solicita:
 - a) Obtener las cuatro medias condicionales $\mathbb{E}[y_{it} \mid D_i, T_t]$ para las cuatro combinaciones posibles de los dos indicadores.
 - b) Verificar que la doble diferencia de esas cuatro medias es exactamente θ .
 - c) Interpretar el significado de β_2 y de β_3 , y explicar por qué ninguno de los dos tiene interpretación causal.
 6. Suponga que estima un modelo de diferencia en diferencias con adopción escalonada mediante la ecuación (9.20) y obtiene $\hat{\delta} < 0$, cuando la teoría y toda la evidencia previa sugieren un efecto positivo. Se le solicita explicar, con base en la descomposición de Goodman-Bacon (2021) [Goo21], cómo es posible que esto ocurra aun cuando el efecto sea positivo para todas las unidades; y describir qué diagnósticos y qué estimadores alternativos aplicaría para verificarlo.

7. Explique por qué los errores estándar convencionales subestiman la incertidumbre en un diseño de diferencia en diferencias con paneles largos, siguiendo el argumento de Bertrand, Duflo y Mullainathan (2004) [BDM04]. Discuta además por qué agrupar los errores estándar a nivel de individuo, cuando el tratamiento se asignó a nivel estatal, no resuelve el problema.
8. **Aplicación empírica en Python.** Replique el estudio de Card y Krueger (1994) [CK94] con los datos del cuaderno `Increase_Minimum_Wage_On_Employment.ipynb` del repositorio del curso. Se le solicita:
 - a) Construir la tabla de las cuatro medias condicionales y calcular la doble diferencia a mano.
 - b) Estimar la ecuación (9.11) por MCO y verificar que el coeficiente de la interacción coincide con el cálculo anterior.
 - c) Calcular los errores estándar convencionales y los agrupados a nivel de estado, y comparar. Discutir el problema del número reducido de conglomerados en este caso particular.
 - d) Discutir explícitamente la plausibilidad del supuesto de tendencias paralelas entre Nueva Jersey y Pensilvania, e identificar qué evidencia adicional desearía tener para evaluarlo.
 - e) Interpretar el signo del resultado a la luz de los modelos de competencia perfecta y de monopsonio en el mercado laboral.
9. **Aplicación empírica en Python.** Replique el estudio de la Proposición 99 de California con el cuaderno `California_Tobacco_Tax_and_Health_Protection_Act.ipynb`. Se le solicita:
 - a) Estimar los pesos $\mathbf{W}^*$ resolviendo el problema de la ecuación (9.25) y reportar qué estados reciben peso positivo y en qué proporción.
 - b) Graficar la trayectoria observada de California frente a la de su control sintético, e identificar visualmente el efecto estimado según la ecuación (9.26).
 - c) Evaluar la calidad del ajuste preintervención mediante el $RMSP E^{pre}$ de la ecuación (9.27).
 - d) Realizar la inferencia por permutación: aplicar el método a cada estado donador y construir el valor p de la ecuación (9.28).

- e) Realizar una prueba de placebo en el tiempo, reasignando la intervención a un año anterior a 1988, y verificar que no se detecta efecto.
 - f) Estimar además un modelo de diferencia en diferencias convencional usando el promedio simple de los demás estados como control, y comparar el resultado con el del control sintético. Explicar a qué se debe la diferencia.
10. **Lectura crítica de un caso mexicano.** Lea el trabajo de Woo-Mora (2022) [Woo22] sobre la cancelación del NAIM, disponible en la carpeta de bibliografía del curso, y evalúelo con los criterios metodológicos desarrollados en este capítulo. Se le solicita:
- a) Identificar con precisión cuál es la unidad tratada, cuál el conjunto de donadores y cuál el momento T_0 de la intervención. Discutir si fechar la intervención en el momento de la consulta, y no en el de la cancelación formal, es la decisión correcta a la luz del supuesto de ausencia de anticipación.
 - b) Evaluar la composición del conjunto de donadores. ¿Qué unidades reciben peso positivo? ¿Resultan comparables con la unidad tratada en términos sustantivos, o hay indicios de sesgo de interpolación?
 - c) Evaluar la calidad del ajuste preintervención y discutir si el número de periodos previos disponibles es suficiente.
 - d) Discutir el tratamiento que el autor da al periodo posterior a la pandemia de Covid-19. ¿Por qué un choque global que afecta simultáneamente a la unidad tratada y a todo el conjunto de donadores complica la interpretación del contrafactual? ¿Es adecuada la decisión de reportar límites de predicción en lugar de una estimación puntual?
 - e) Revisar qué inferencia se realiza y si se reportan pruebas de placebo del tipo descrito en la ecuación (9.28). Discutir cuál es el valor p mínimo alcanzable dado el tamaño del conjunto de donadores.
 - f) Discutir si el diseño permite atribuir el efecto estimado específicamente a la cancelación del aeropuerto, o si podría estar capturando otras políticas y choques simultáneos. Formule al menos dos ame-

nazas concretas a la identificación y proponga, para cada una, una verificación empírica que ayudaría a descartarla.

11. Discuta, para cada una de las siguientes situaciones, cuál de las estrategias de identificación estudiadas en el curso — aleatorización, selección en observables, variables instrumentales, diferencia en diferencias o control sintético — resulta más apropiada, y cuál sería el supuesto de identificación crítico en cada caso:
 - a)* Evaluar el efecto sobre el aprendizaje de un programa de tutorías al que las escuelas se inscriben voluntariamente.
 - b)* Evaluar el efecto sobre la recaudación de una reforma fiscal aprobada por un solo estado del país.
 - c)* Evaluar el efecto sobre el empleo de una reforma laboral que distintos estados adoptaron en años distintos.
 - d)* Evaluar el efecto de los años de escolaridad sobre el salario, con datos de una encuesta de hogares.
 - e)* Evaluar el efecto del salario mínimo sobre el empleo del mercado laboral de Miami tras la llegada masiva de migrantes en 1980, situación análoga a la estudiada por Card (1990) [Car90].

10

Estimación de modelos de duración

10.1. Introducción y motivación

Hasta ahora hemos estudiado modelos en los que la variable dependiente es continua, binaria, multinomial, ordinal, de conteo, truncada o censurada. En este capítulo abordamos un último tipo de variable dependiente que aparece con mucha frecuencia en el trabajo aplicado: el **tiempo que transcurre hasta que ocurre un evento**. A los modelos que analizan este tipo de información los llamamos modelos de duración y, en la literatura estadística y biomédica, análisis de supervivencia.

Los ejemplos en economía y en ciencias sociales son abundantes:

1. El tiempo que una persona permanece desempleada antes de encontrar un empleo. Esta es la aplicación clásica en economía laboral y permite evaluar, por ejemplo, el efecto de la duración y generosidad del seguro de desempleo sobre la búsqueda de trabajo.
2. El tiempo que transcurre desde que una persona sale de prisión hasta que es arrestada nuevamente, es decir, la duración hasta la reincidencia delictiva.
3. El tiempo de supervivencia de una empresa desde su fundación hasta su cierre, o el tiempo que una empresa tarda en adoptar una nueva tecnología.

4. El tiempo que transcurre hasta que un acreditado incurre en incumplimiento de pago de un crédito, problema central en la modelación de riesgo crediticio.
5. La duración de una huelga, de un contrato laboral, de un matrimonio, de un gobierno de coalición, o el tiempo hasta que un hogar sale de un programa de transferencias.
6. En su origen biomédico, el tiempo de supervivencia de un paciente tras un tratamiento, de donde proviene buena parte de la terminología que utilizaremos.

Cabe preguntarnos por qué requerimos un instrumental específico si, después de todo, la duración es una variable continua y no negativa que en principio podríamos analizar con una regresión lineal del logaritmo del tiempo. Existen tres razones que hacen inadecuado ese enfoque.

La primera es que la duración es una variable no negativa y típicamente con una distribución fuertemente asimétrica, lo cual viola los supuestos habituales del modelo lineal. La segunda, y más importante, es que los datos de duración casi siempre están **censurados**: cuando el investigador termina de observar la muestra, un número considerable de individuos todavía no ha experimentado el evento. Sabemos que su duración es *al menos* tan larga como el periodo de observación, pero no conocemos su valor. Descartar esas observaciones o tratarlas como si fueran duraciones completas produce estimadores inconsistentes, como ya discutimos en el capítulo de datos truncados y censurados. La tercera razón es de fondo conceptual: en la mayoría de las aplicaciones económicas el objeto de interés no es tanto la duración esperada como la **tasa a la que los individuos abandonan el estado inicial en cada momento del tiempo**, condicional en que han permanecido en él hasta ese momento. Esa tasa, que llamaremos función de riesgo, es el objeto natural de modelación y es el que permite hablar de conceptos como la dependencia de la duración.

En este capítulo desarrollaremos el instrumental necesario siguiendo principalmente a Wooldridge (2010) [Woo10], capítulo 22; Cameron y Trivedi (2005) [CT05], capítulos 17 y 18; Lancaster (1990) [Lan90], que es el tratamiento clásico y más completo desde la perspectiva econométrica; y Kiefer (1988) [Kie88], que constituye una excelente introducción de lectura accesible. Para el tratamiento estadístico y las aplicaciones biomédicas puede consultarse Kleinbaum y Klein (2012) [KK12].

10.2. Conceptos fundamentales: las cuatro representaciones de una duración

Sea $T \geq 0$ una variable aleatoria continua que representa la duración, es decir, el tiempo que transcurre desde que un individuo entra en un estado inicial hasta que sale de él. Denotaremos por t una realización particular de T . En el ejemplo del desempleo, T es el número de semanas que una persona permanece desempleada.

Una característica notable del análisis de duración es que la distribución de T puede describirse de manera equivalente mediante cuatro funciones distintas. Las cuatro contienen exactamente la misma información y de cualquiera de ellas pueden obtenerse las otras tres, pero cada una resulta más conveniente para propósitos distintos.

Definición 10.1 La *función de distribución acumulada* de T es:

$$F(t) = P(T \leq t), \quad t \geq 0 \quad (10.1)$$

Es decir, la probabilidad de que la duración no exceda el valor t .

Definición 10.2 La *función de supervivencia* de T es:

$$S(t) = 1 - F(t) = P(T > t) \quad (10.2)$$

Es decir, la probabilidad de “sobrevivir” más allá del tiempo t , o de permanecer en el estado inicial después de t . Notemos que $S(0) = 1$, que $S(t)$ es no creciente y que $S(t) \rightarrow 0$ cuando $t \rightarrow \infty$.

Definición 10.3 La *función de densidad* de T es la derivada de la función de distribución acumulada:

$$f(t) = \frac{dF(t)}{dt} = -\frac{dS(t)}{dt} \quad (10.3)$$

Las tres funciones anteriores son las que ya conocemos de cualquier curso de probabilidad. La cuarta es específica del análisis de duración y es la que le da su carácter distintivo.

Definición 10.4 La *función de riesgo* (o *hazard function*) de T se define como:

$$\lambda(t) = \lim_{h \downarrow 0} \frac{P(t \leq T < t + h \mid T \geq t)}{h} \quad (10.4)$$

La interpretación de la ecuación (10.4) es fundamental y conviene detenerse en ella. El numerador es la probabilidad de salir del estado inicial durante el intervalo $[t, t + h)$, *condicional* en haber permanecido en dicho estado hasta el momento t . Al dividir entre h y tomar el límite obtenemos una tasa instantánea de salida por unidad de tiempo. Para valores pequeños de h podemos usar la aproximación:

$$P(t \leq T < t + h \mid T \geq t) \approx \lambda(t) \cdot h \quad (10.5)$$

Es importante subrayar que $\lambda(t)$ **no es una probabilidad**: es una tasa y, en consecuencia, puede tomar valores mayores que uno. La relación entre la función de riesgo y una probabilidad es análoga a la que existe entre una función de densidad y una probabilidad.

Ejemplo. Si T es la duración del desempleo medida en semanas, entonces $\lambda(20)$ es aproximadamente la probabilidad de encontrar empleo entre la semana 20 y la 21, condicional en haber permanecido desempleado durante las primeras 20 semanas. Nótese que el condicionamiento es esencial: no estamos preguntando por la probabilidad incondicional de encontrar empleo en la semana 20, sino por la probabilidad de hacerlo dado que la persona sigue desempleada al llegar a esa semana.

10.2.1. Relaciones entre las cuatro funciones

Demostremos ahora que las cuatro funciones son representaciones equivalentes. Partamos de la definición de probabilidad condicional en el numerador de la ecuación (10.4):

$$P(t \leq T < t + h \mid T \geq t) = \frac{P(t \leq T < t + h)}{P(T \geq t)} = \frac{F(t + h) - F(t)}{1 - F(t)}$$

Dividiendo entre h y tomando el límite cuando h tiende a cero por la derecha, reconocemos en el primer factor la definición de la derivada de $F(t)$:

$$\lambda(t) = \lim_{h \downarrow 0} \left[\frac{F(t + h) - F(t)}{h} \right] \frac{1}{1 - F(t)} = \frac{f(t)}{1 - F(t)} = \frac{f(t)}{S(t)} \quad (10.6)$$

La ecuación (10.6) es la relación fundamental del análisis de duración: la función de riesgo es el cociente de la densidad entre la función de supervivencia. Ahora, recordando de la ecuación (10.3) que $f(t) = -dS(t)/dt$, podemos escribir:

$$\lambda(t) = \frac{-dS(t)/dt}{S(t)} = -\frac{d \log S(t)}{dt} \quad (10.7)$$

Este resultado es muy útil porque nos permite invertir la relación. Integrando ambos lados de la ecuación (10.7) entre 0 y t , y usando que $S(0) = 1$, de donde $\log S(0) = 0$:

$$\int_0^t \lambda(s) ds = -[\log S(t) - \log S(0)] = -\log S(t)$$

De donde obtenemos:

$$S(t) = \exp\left(-\int_0^t \lambda(s) ds\right) = \exp(-\Lambda(t)) \quad (10.8)$$

Donde hemos definido la **función de riesgo acumulado** o riesgo integrado:

$$\Lambda(t) = \int_0^t \lambda(s) ds = -\log S(t) \quad (10.9)$$

Finalmente, derivando la ecuación (10.8) y usando la ecuación (10.3) obtenemos la densidad expresada en términos del riesgo:

$$f(t) = \lambda(t) \exp\left(-\int_0^t \lambda(s) ds\right) = \lambda(t) S(t) \quad (10.10)$$

Las ecuaciones (10.6), (10.8) y (10.10) establecen que conocer cualquiera de las cuatro funciones equivale a conocer todas las demás. Esto es lo que nos permitirá, más adelante, especificar directamente la función de riesgo, que es el objeto con interpretación económica, y derivar de ella la verosimilitud que necesitamos para estimar.

Un resultado adicional que utilizaremos es que la duración esperada puede escribirse como el área bajo la función de supervivencia:

$$\mathbb{E}[T] = \int_0^\infty S(t) dt \quad (10.11)$$

Lo cual se obtiene integrando por partes $\mathbb{E}[T] = \int_0^\infty t f(t) dt$ y usando que $tS(t) \rightarrow 0$ cuando $t \rightarrow \infty$, siempre que la media exista.

10.2.2. Dependencia de la duración

El concepto central que hace interesante a la función de riesgo es el siguiente.

Definición 10.5 Decimos que el proceso presenta **dependencia positiva de la duración** en el momento t si $d\lambda(t)/dt > 0$, y **dependencia negativa de la duración** si $d\lambda(t)/dt < 0$. Si $\lambda(t) = \lambda$ es constante para todo t , decimos que el proceso no presenta dependencia de la duración.

La lectura económica de este concepto es directa y es la razón por la que los modelos de duración resultan atractivos. En el caso del desempleo, la dependencia negativa significa que mientras más tiempo lleva una persona desempleada, menor es su probabilidad instantánea de encontrar trabajo. Este es un hallazgo empírico recurrente y admite al menos dos explicaciones muy distintas: puede tratarse de un efecto de *estigma* o de depreciación del capital humano, en el que la propia duración del desempleo deteriora las posibilidades del individuo; o puede tratarse de un problema de **heterogeneidad no observada**, en el que los individuos con mejores características no observables encuentran empleo primero, de modo que la población de desempleados de larga duración está compuesta cada vez más por individuos con peores perspectivas. Distinguir empíricamente entre ambas explicaciones es uno de los problemas centrales de esta literatura y lo retomaremos en la sección de heterogeneidad no observada.

El caso de ausencia de dependencia de la duración tiene una caracterización notable.

Teorema 10.1 Ausencia de memoria de la distribución exponencial. La función de riesgo es constante, $\lambda(t) = \lambda$ para todo $t \geq 0$, si y sólo si T se distribuye exponencial con parámetro λ . En ese caso el proceso carece de memoria, es decir:

$$P(T > t + s \mid T > t) = P(T > s), \forall s, t \geq 0$$

Demostración. Si $\lambda(t) = \lambda$, de la ecuación (10.8) tenemos $\Lambda(t) = \int_0^t \lambda ds = \lambda t$, por lo que $S(t) = \exp(-\lambda t)$ y $F(t) = 1 - \exp(-\lambda t)$, que es la función de distribución acumulada de una exponencial. Recíprocamente, si T es exponencial, $f(t) = \lambda \exp(-\lambda t)$ y $S(t) = \exp(-\lambda t)$, de donde $\lambda(t) = f(t)/S(t) = \lambda$. Para la propiedad de ausencia de memoria:

$$P(T > t+s \mid T > t) = \frac{S(t+s)}{S(t)} = \frac{\exp(-\lambda(t+s))}{\exp(-\lambda t)} = \exp(-\lambda s) = S(s) = P(T > s) \blacksquare$$

La interpretación económica es que, bajo el supuesto exponencial, la probabilidad de salir del estado inicial en el siguiente instante no depende en

absoluto del tiempo que ya se ha permanecido en él. En el ejemplo del desempleo, una persona que lleva dos semanas desempleada y otra que lleva dos años tendrían exactamente la misma probabilidad instantánea de encontrar trabajo. Es un supuesto muy fuerte que casi nunca resulta defendible, y esa es la razón por la que necesitamos distribuciones más flexibles.

10.3. Distribuciones paramétricas para la duración

Presentamos ahora las especificaciones paramétricas que se utilizan con mayor frecuencia. En cada caso podemos partir de la densidad y obtener el riesgo, o bien especificar directamente el riesgo y recuperar la densidad mediante la ecuación (10.10).

10.3.1. Distribución exponencial

Es el caso más simple, con un solo parámetro $\lambda > 0$:

$$\begin{aligned}\lambda(t) &= \lambda \\ S(t) &= \exp(-\lambda t) \\ f(t) &= \lambda \exp(-\lambda t) \\ \mathbb{E}[T] &= \frac{1}{\lambda}\end{aligned}$$

Es útil como punto de partida y como caso particular contra el cual contrastar especificaciones más generales, pero impone la ausencia de dependencia de la duración.

10.3.2. Distribución Weibull

Es la especificación paramétrica más utilizada en econometría. Tiene dos parámetros, $\gamma > 0$ y $\alpha > 0$:

$$\begin{aligned}F(t) &= 1 - \exp(-\gamma t^\alpha) \\ S(t) &= \exp(-\gamma t^\alpha) \\ f(t) &= \gamma \alpha t^{\alpha-1} \exp(-\gamma t^\alpha) \\ \lambda(t) &= \frac{f(t)}{S(t)} = \gamma \alpha t^{\alpha-1}\end{aligned}\tag{10.12}$$

El parámetro α es el que gobierna la dependencia de la duración y su interpretación es inmediata:

1. Si $\alpha = 1$, entonces $\lambda(t) = \gamma$ es constante y recuperamos la distribución exponencial con $\lambda = \gamma$.
2. Si $\alpha > 1$, entonces $\lambda(t)$ es monótonamente creciente: hay dependencia positiva de la duración.
3. Si $\alpha < 1$, entonces $\lambda(t)$ es monótonamente decreciente: hay dependencia negativa de la duración.

Esta parametrización es especialmente conveniente porque convierte la pregunta sustantiva sobre la dependencia de la duración en una prueba de hipótesis sobre un solo parámetro, $H_0 : \alpha = 1$, que puede contrastarse con cualquiera de las pruebas basadas en verosimilitud que estudiamos en el capítulo correspondiente. La media de la distribución Weibull es $\mathbb{E}[T] = \gamma^{-1/\alpha} \Gamma(1 + 1/\alpha)$, donde $\Gamma(\cdot)$ es la función gamma.

La limitación del modelo Weibull es que impone monotonidad: la función de riesgo sólo puede ser creciente, decreciente o constante, pero nunca puede subir y luego bajar.

10.3.3. Distribución log-logística

Cuando queremos permitir una función de riesgo no monótona, una alternativa natural es la log-logística, en la que especificamos directamente el riesgo como:

$$\lambda(t) = \frac{\gamma \alpha t^{\alpha-1}}{1 + \gamma t^\alpha} \quad (10.13)$$

Con $\gamma, \alpha > 0$. Integrando obtenemos $\Lambda(t) = \log(1 + \gamma t^\alpha)$ y, sustituyendo en la ecuación (10.8):

$$S(t) = (1 + \gamma t^\alpha)^{-1}, \quad F(t) = 1 - (1 + \gamma t^\alpha)^{-1}$$

El comportamiento del riesgo depende de α . Si $\alpha \leq 1$, la función de riesgo es monótonamente decreciente. Si $\alpha > 1$, la función de riesgo es creciente hasta el punto $t^* = [(\alpha - 1)/\gamma]^{1/\alpha}$ y decreciente a partir de ahí. Esta forma de “joroba” es empíricamente relevante en varias aplicaciones: en la duración del desempleo, por ejemplo, es plausible que la intensidad de búsqueda aumente




Figura 10.1: Formas de la función de riesgo bajo las especificaciones Weibull y log-logística

durante los primeros meses y luego decaiga por desánimo. El nombre de la distribución proviene de que, bajo esta especificación, $\log(T)$ tiene una distribución logística.

La Figura 10.1 contrasta las formas que pueden tomar ambas familias. El panel (a) muestra que la Weibull sólo admite riesgos monótonos, gobernados por el parámetro α : decreciente, constante o creciente. El panel (b) muestra que la log-logística permite además la forma de joroba, en la que el riesgo crece hasta t^* y decrece a partir de ahí.

10.3.4. Otras especificaciones

Otras distribuciones utilizadas con frecuencia son la log-normal, en la que $\log(T)$ es normal y que también genera un riesgo en forma de joroba; la Gompertz, con $\lambda(t) = \gamma \exp(\alpha t)$, muy usada en demografía y en análisis de mortalidad; y la gamma generalizada, que anida como casos particulares a la exponencial, la Weibull y la log-normal, lo que la hace útil para contrastar especificaciones mediante pruebas de razón de verosimilitudes.

10.4. El problema de la censura y el esquema de muestreo

10.4.1. Tipos de censura

Como anticipamos en la introducción, el rasgo distintivo de los datos de duración es la censura. Los tipos más relevantes son:

1. **Censura por la derecha.** Es la más común y la única que produce el muestreo de flujo. Al terminar el periodo de observación, el individuo todavía no ha experimentado el evento. Sólo sabemos que $T_i > c_i$, donde c_i es el tiempo de censura del individuo i .
2. **Censura por la izquierda.** Sabemos que el evento ocurrió antes de un cierto momento, pero no cuándo exactamente.
3. **Censura por intervalo.** Sabemos que el evento ocurrió entre dos momentos, lo cual sucede de manera natural cuando la información se recolecta en encuestas periódicas. Este caso lo trataremos en la sección de datos agrupados.

Es importante distinguir la censura del **truncamiento**, distinción que ya establecimos en el capítulo de datos truncados y censurados. En la censura por la derecha, el individuo censurado *sí está* en la muestra y aporta información: sabemos que su duración excede c_i . En el truncamiento, en cambio, el individuo simplemente no aparece en la muestra. La censura implica una pérdida parcial de información que podemos incorporar correctamente en la verosimilitud; el truncamiento implica un problema de selección muestral que requiere corregir la distribución de referencia.

10.4.2. Muestreo de flujo y muestreo de acervo

El esquema de muestreo determina qué tipo de sesgo debemos corregir y es una de las fuentes más frecuentes de error en el trabajo aplicado.

En el **muestreo de flujo** (*flow sampling*) tomamos una muestra aleatoria de los individuos que *entran* al estado inicial durante un intervalo de tiempo determinado, y los seguimos a partir de ese momento. Por ejemplo, tomamos una muestra de todas las personas que quedaron desempleadas durante 2026 y observamos cuánto tiempo tardan en encontrar empleo. Este es el esquema

más sencillo y el único problema que genera es la censura por la derecha de quienes siguen desempleados al terminar el periodo de seguimiento.

En el **muestreo de acervo** (*stock sampling*) tomamos una muestra aleatoria de los individuos que se encuentran *en* el estado inicial en un momento dado. Por ejemplo, entrevistamos a las personas que están desempleadas en septiembre de 2026 y les preguntamos cuánto tiempo llevan en esa situación. Este esquema genera un problema serio que suele pasarse por alto: los individuos con duraciones largas tienen mayor probabilidad de aparecer en la muestra que los individuos con duraciones cortas, simplemente porque están en el estado inicial durante más tiempo. A este fenómeno se le conoce como **sesgo de duración** o muestreo sesgado por longitud (*length-biased sampling*), y produce una sobrerrepresentación sistemática de las duraciones largas. Ignorarlo lleva a sobreestimar la duración media y a distorsionar la forma estimada de la función de riesgo. La corrección requiere trabajar con la distribución truncada por la izquierda, condicionando en que la duración sea al menos igual al tiempo ya transcurrido en el estado al momento de la entrevista.

10.5. Estimación por máxima verosimilitud con datos censurados

10.5.1. Construcción de la verosimilitud

Consideremos el caso de muestreo de flujo con censura por la derecha, que es el escenario más común. Para cada individuo $i = 1, 2, \dots, N$ observamos la terna $(t_i, d_i, \mathbf{x}_i)$, donde:

- $t_i = \min(T_i^*, c_i)$ es la duración observada, siendo T_i^* la duración verdadera (posiblemente no observada) y c_i el tiempo de censura.
- d_i es un indicador de censura que toma el valor de 1 si la observación *no* está censurada, es decir, si observamos el evento, y 0 si está censurada.
- $\mathbf{x}_i$ es un vector de variables explicativas medidas al inicio del episodio.

El supuesto clave que permite construir la verosimilitud es el de **censura no informativa**: condicional en las variables explicativas, la duración verdadera es independiente del tiempo de censura,

$$T_i^* \perp c_i \mid \mathbf{x}_i \quad (10.14)$$

Este supuesto se cumple de manera trivial cuando el tiempo de censura es una constante determinada por el diseño del estudio. Se violaría, en cambio, si los individuos abandonaran el estudio precisamente por razones relacionadas con su duración, un problema de atrición que debe tomarse en serio en aplicaciones con datos de encuestas de panel.

Bajo el supuesto (10.14), la contribución de cada individuo a la verosimilitud depende de si su observación está censurada o no:

1. Si $d_i = 1$, observamos exactamente el momento del evento, por lo que la contribución es la densidad evaluada en ese punto, $f(t_i | \mathbf{x}_i, \boldsymbol{\theta})$.
2. Si $d_i = 0$, lo único que sabemos es que la duración excedió $t_i = c_i$, por lo que la contribución es la probabilidad de ese evento, $P(T_i^* > t_i | \mathbf{x}_i) = S(t_i | \mathbf{x}_i, \boldsymbol{\theta})$.

Combinando ambos casos en una sola expresión, la contribución del individuo i es:

$$L_i(\boldsymbol{\theta}) = [f(t_i | \mathbf{x}_i, \boldsymbol{\theta})]^{d_i} [S(t_i | \mathbf{x}_i, \boldsymbol{\theta})]^{1-d_i} \quad (10.15)$$

De donde la función de log-verosimilitud de la muestra es:

$$\ell(\boldsymbol{\theta}) = \sum_{i=1}^N \{d_i \log f(t_i | \mathbf{x}_i, \boldsymbol{\theta}) + (1 - d_i) \log S(t_i | \mathbf{x}_i, \boldsymbol{\theta})\} \quad (10.16)$$

La ecuación (10.16) admite una reescritura muy elegante en términos de la función de riesgo. Usando la relación $f(t) = \lambda(t)S(t)$ de la ecuación (10.10) y la definición del riesgo acumulado de la ecuación (10.9), que implica $\log S(t) = -\Lambda(t)$, obtenemos:

$$\begin{aligned} \ell(\boldsymbol{\theta}) &= \sum_{i=1}^N \{d_i [\log \lambda(t_i | \mathbf{x}_i) + \log S(t_i | \mathbf{x}_i)] + (1 - d_i) \log S(t_i | \mathbf{x}_i)\} \\ &= \sum_{i=1}^N \{d_i \log \lambda(t_i | \mathbf{x}_i, \boldsymbol{\theta}) - \Lambda(t_i | \mathbf{x}_i, \boldsymbol{\theta})\} \end{aligned} \quad (10.17)$$

La ecuación (10.17) es sumamente útil porque muestra que basta con especificar la función de riesgo para poder estimar: el primer término sólo aparece para las observaciones no censuradas y recoge la información sobre *cuándo* ocurrió el evento, mientras que el segundo aparece para todas las

observaciones y recoge la información sobre el *tiempo de exposición al riesgo*. Notemos además que las observaciones censuradas sí contribuyen a la verosimilitud, lo cual formaliza la afirmación que hicimos antes de que no deben descartarse.

Bajo las condiciones de regularidad que enunciamos en el capítulo de métodos de estimación basados en verosimilitud, el estimador $\hat{\boldsymbol{\theta}}$ que maximiza la ecuación (10.17) es consistente, $\sqrt{N}$ - asintóticamente normal y eficiente, y su matriz de varianzas y covarianzas puede estimarse mediante cualquiera de los tres estimadores de la matriz de información que ahí discutimos.

10.5.2. Aplicación al modelo Weibull con covariables

Veamos cómo se concreta lo anterior en el caso paramétrico más usado. Introducimos las covariables reemplazando el parámetro γ de la ecuación (10.12) por $\exp(\mathbf{x}_i\boldsymbol{\beta})$, donde el primer elemento de $\mathbf{x}_i$ es la unidad. La forma exponencial garantiza que el riesgo sea positivo para cualquier valor de los parámetros, exactamente por la misma razón por la que la usamos en el modelo Poisson del capítulo de modelos de conteo. Así:

$$\begin{aligned}\lambda(t \mid \mathbf{x}_i) &= \exp(\mathbf{x}_i\boldsymbol{\beta})\alpha t^{\alpha-1} \\ \Lambda(t \mid \mathbf{x}_i) &= \exp(\mathbf{x}_i\boldsymbol{\beta})t^\alpha\end{aligned}\tag{10.18}$$

Sustituyendo en la ecuación (10.17), la log-verosimilitud del modelo Weibull es:

$$\ell(\boldsymbol{\beta}, \alpha) = \sum_{i=1}^N \{d_i [\mathbf{x}_i\boldsymbol{\beta} + \log \alpha + (\alpha - 1) \log t_i] - \exp(\mathbf{x}_i\boldsymbol{\beta})t_i^\alpha\} \tag{10.19}$$

La cual se maximiza numéricamente respecto de $(\boldsymbol{\beta}, \alpha)$. Notemos que si imponemos $\alpha = 1$ obtenemos el modelo exponencial, cuya log-verosimilitud es $\sum_i \{d_i \mathbf{x}_i\boldsymbol{\beta} - \exp(\mathbf{x}_i\boldsymbol{\beta})t_i\}$; la comparación entre ambas mediante una prueba de razón de verosimilitudes con un grado de libertad es la forma estándar de contrastar la presencia de dependencia de la duración.

10.6. Modelos de riesgos proporcionales

10.6.1. Planteamiento

La clase de modelos más importante en el análisis de duración con covariables es la de **riesgos proporcionales** (PH, por *proportional hazards*), en la que se postula:

$$\lambda(t, \mathbf{x}) = \kappa(\mathbf{x})\lambda_0(t) \quad (10.20)$$

Donde $\lambda_0(t) > 0$ es la **función de riesgo base** (*baseline hazard*), común a todos los individuos de la población, y $\kappa(\mathbf{x}) > 0$ es un factor de escala que depende de las características observadas. La estructura de la ecuación (10.20) es multiplicativamente separable: las covariables desplazan proporcionalmente la función de riesgo hacia arriba o hacia abajo, pero no alteran su forma en el tiempo. De ahí el nombre.

La parametrización habitual es $\kappa(\mathbf{x}) = \exp(\mathbf{x}\boldsymbol{\beta})$, con lo cual, tomando logaritmos en la ecuación (10.20):

$$\log \lambda(t, \mathbf{x}) = \mathbf{x}\boldsymbol{\beta} + \log \lambda_0(t) \quad (10.21)$$

10.6.2. Interpretación de los coeficientes

La ecuación (10.21) hace transparente la interpretación de los parámetros. Derivando respecto de una variable continua x_j :

$$\beta_j = \frac{\partial \log \lambda(t, \mathbf{x})}{\partial x_j}$$

Es decir, β_j es la **semielasticidad** de la función de riesgo respecto de x_j : un incremento unitario en x_j modifica el riesgo en aproximadamente $100 \cdot \beta_j$ por ciento, y este porcentaje es el mismo en cualquier momento t . Si x_j está expresada en logaritmos, β_j es directamente una elasticidad.

Para variables binarias resulta más conveniente reportar el **cociente de riesgos** (*hazard ratio*), que es el cociente entre la función de riesgo de los individuos con $x_j = 1$ y la de aquellos con $x_j = 0$, manteniendo todo lo demás constante:

$$\frac{\lambda(t, x_j = 1, \mathbf{x}_{-j})}{\lambda(t, x_j = 0, \mathbf{x}_{-j})} = \frac{\exp(\beta_j + \mathbf{x}_{-j}\boldsymbol{\beta}_{-j})\lambda_0(t)}{\exp(\mathbf{x}_{-j}\boldsymbol{\beta}_{-j})\lambda_0(t)} = \exp(\beta_j)$$

Notemos que la función de riesgo base se cancela por completo, de modo que el cociente de riesgos es constante en el tiempo. Un valor de $\exp(\beta_j) = 1.4$, por ejemplo, indica que el riesgo de salida de los individuos con la característica es 40 % mayor en todo momento. Es importante recordar el signo: un coeficiente positivo aumenta el riesgo de salida y, por lo tanto, **reduce** la duración esperada. Esta inversión de signos respecto de lo que estamos acostumbrados en una regresión lineal es una fuente frecuente de errores de interpretación.

Un punto que conviene subrayar es que el modelo Weibull con covariables de la ecuación (10.18) es un caso particular del modelo de riesgos proporcionales, con $\lambda_0(t) = \alpha t^{\alpha-1}$. En cambio, el modelo log-logístico con covariables introducidas en γ *no* pertenece a esta clase.

10.6.3. El modelo de Cox y la verosimilitud parcial

Los modelos paramétricos requieren especificar completamente la forma de $\lambda_0(t)$, y una especificación equivocada produce estimadores inconsistentes de β . Cox (1972) [Cox72] propuso un procedimiento notable que permite estimar β **sin especificar en absoluto la función de riesgo base**, y que constituye uno de los resultados más influyentes de la estadística del siglo XX.

La idea es la siguiente. Ordenemos las duraciones observadas no censuradas de menor a mayor, $t_{(1)} < t_{(2)} < \dots < t_{(D)}$, y supongamos por ahora que no hay empates. Definamos el **conjunto de riesgo** en el momento $t_{(j)}$ como el conjunto de individuos que aún permanecen en el estado inicial justo antes de ese momento:

$$R(t_{(j)}) = \{k : t_k \geq t_{(j)}\}$$

Preguntémonos ahora: dado que sabemos que *alguien* salió del estado inicial en el momento $t_{(j)}$, ¿cuál es la probabilidad de que haya sido precisamente el individuo i y no cualquier otro de los que estaban en riesgo? Esa probabilidad es el cociente entre el riesgo del individuo i y la suma de los riesgos de todos los individuos en el conjunto de riesgo:

$$P(\text{sale } i \mid \text{sale alguien en } t_{(j)}, R(t_{(j)})) = \frac{\lambda(t_{(j)}, \mathbf{x}_i)}{\sum_{k \in R(t_{(j)})} \lambda(t_{(j)}, \mathbf{x}_k)} = \frac{\exp(\mathbf{x}_i \beta) \lambda_0(t_{(j)})}{\sum_{k \in R(t_{(j)})} \exp(\mathbf{x}_k \beta) \lambda_0(t_{(j)})} \quad (10.22)$$

Aquí ocurre el resultado clave: dado que la función de riesgo base $\lambda_0(t_{(j)})$ es común a todos los individuos, aparece como factor tanto en el numerador

como en cada término del denominador, por lo que **se cancela**:

$$P(\text{sale } i \mid \cdot) = \frac{\exp(\mathbf{x}_i \boldsymbol{\beta})}{\sum_{k \in R(t_{(j)})} \exp(\mathbf{x}_k \boldsymbol{\beta})}$$

Multiplicando estas probabilidades sobre todos los momentos en que se observó una salida obtenemos la **verosimilitud parcial** de Cox:

$$L_P(\boldsymbol{\beta}) = \prod_{i: d_i=1} \frac{\exp(\mathbf{x}_i \boldsymbol{\beta})}{\sum_{k \in R(t_i)} \exp(\mathbf{x}_k \boldsymbol{\beta})} \quad (10.23)$$

Cuya versión logarítmica es:

$$\ell_P(\boldsymbol{\beta}) = \sum_{i: d_i=1} \left[\mathbf{x}_i \boldsymbol{\beta} - \log \sum_{k \in R(t_i)} \exp(\mathbf{x}_k \boldsymbol{\beta}) \right] \quad (10.24)$$

Notemos que la ecuación (10.24) tiene exactamente la estructura de la log-verosimilitud de un modelo logit multinomial condicional, donde en cada momento de salida el “conjunto de alternativas” es el conjunto de riesgo. Esta observación no es casual y permite estimar el modelo de Cox reutilizando el instrumental que ya desarrollamos en el capítulo de modelos de respuesta multinomial.

Se le llama verosimilitud *parcial* porque no es una verosimilitud propiamente dicha: descarta la información contenida en los momentos exactos en que ocurrieron las salidas y utiliza únicamente su ordenamiento. A pesar de ello, puede demostrarse que el estimador que la maximiza es consistente y asintóticamente normal, con una pérdida de eficiencia que en la práctica resulta modesta. Las observaciones censuradas contribuyen a la ecuación (10.23) formando parte de los conjuntos de riesgo de los momentos anteriores a su censura, aunque no aportan un factor propio al producto.

La ventaja del modelo de Cox es evidente: obtenemos estimadores de $\boldsymbol{\beta}$ que son robustos a cualquier especificación errónea de $\lambda_0(t)$. Su desventaja es que no estimamos $\lambda_0(t)$, por lo que no podemos calcular duraciones esperadas ni realizar predicciones sobre la duración, y no podemos decir nada sobre la dependencia de la duración, que en muchas aplicaciones económicas es justamente la pregunta de interés. Como señala Wooldridge (2010) [Woo10], esta es la razón por la que en economía los modelos paramétricos y semiparamétricos con riesgo base flexible siguen siendo tan usados como el modelo de Cox, mientras que en aplicaciones biomédicas domina este último.

10.6.4. Modelos de tiempo de falla acelerado

Una clase alternativa a los riesgos proporcionales es la de los modelos de **tiempo de falla acelerado** (AFT, por *accelerated failure time*), en los que se modela directamente el logaritmo de la duración:

$$\log(T_i) = \mathbf{x}_i \boldsymbol{\delta} + \sigma u_i \quad (10.25)$$

Donde u_i tiene una distribución especificada (valor extremo, logística o normal, lo que da lugar respectivamente a los modelos Weibull, log-logístico y log-normal). La interpretación de los coeficientes es distinta y, para muchos lectores, más natural: δ_j mide el cambio porcentual en la duración *esperada* ante un cambio unitario en x_j . Las covariables “aceleran” o “desaceleran” el paso del tiempo para el individuo.

Notemos que la ecuación (10.25) es formalmente una regresión lineal del logaritmo de la duración, y que si no hubiera censura podría estimarse por MCO. La censura es precisamente lo que obliga a estimar por máxima verosimilitud, con la log-verosimilitud de la ecuación (10.16). Esto conecta el modelo AFT con los modelos censurados del tipo Tobit que estudiamos antes.

Un resultado que conviene conocer es que la distribución Weibull es la **única** que pertenece simultáneamente a las clases PH y AFT, y en ese caso los parámetros de ambas representaciones están relacionados por:

$$\boldsymbol{\delta} = -\frac{\boldsymbol{\beta}}{\alpha}$$

Esta relación es la fuente de una confusión muy frecuente en el trabajo aplicado: distintos paquetes estadísticos reportan por omisión una u otra parametrización, con signos opuestos. Antes de interpretar resultados de un modelo Weibull es indispensable verificar cuál de las dos se está reportando.

10.7. Estimación no paramétrica: el estimador de Kaplan-Meier

Antes de imponer cualquier estructura paramétrica es una buena práctica estimar la función de supervivencia de manera no paramétrica. El estimador estándar es el de Kaplan y Meier (1958) [KM58], también llamado estimador de límite de producto.

Sean $t_{(1)} < t_{(2)} < \dots < t_{(J)}$ los momentos distintos en que se observa al menos una salida. Para cada uno definamos:

- n_j : el número de individuos en riesgo justo antes de $t_{(j)}$, es decir, los que no han salido ni han sido censurados.
- e_j : el número de individuos que salen exactamente en $t_{(j)}$.

La probabilidad estimada de sobrevivir al momento $t_{(j)}$, condicional en haber llegado a él, es $1 - e_j/n_j$. Dado que sobrevivir hasta t requiere sobrevivir a cada uno de los momentos anteriores, y aplicando la regla de la probabilidad compuesta, el estimador de la función de supervivencia es:

$$\hat{S}(t) = \prod_{j:t_{(j)} \leq t} \left(1 - \frac{e_j}{n_j}\right) \quad (10.26)$$

El estimador de la ecuación (10.26) es una función escalonada que decrece únicamente en los momentos en que se observan salidas, y que maneja la censura de forma natural: los individuos censurados permanecen en el denominador n_j hasta el momento de su censura y salen del conjunto de riesgo a partir de entonces, sin generar un salto en la curva. La Figura 10.2 muestra la curva que resulta de aplicar el procedimiento a la pequeña muestra que se propone en los ejercicios de este capítulo; las marcas verticales señalan las observaciones censuradas y permiten apreciar que, en efecto, no producen escalón alguno. La mediana de la duración se lee directamente como el valor de t en el que la curva cruza el nivel de 0.5. Su varianza puede estimarse mediante la fórmula de Greenwood, lo que permite construir intervalos de confianza.

En la práctica, el estimador de Kaplan-Meier se utiliza de tres maneras. Primero, como descripción inicial de los datos. Segundo, para comparar visualmente la supervivencia de subgrupos, por ejemplo tratados y no tratados, y contrastar formalmente si las curvas difieren mediante la prueba de rangos logarítmicos (*log-rank test*). Y tercero, como diagnóstico de especificación: dado que de la ecuación (10.9) sabemos que $\Lambda(t) = -\log S(t)$, si graficamos $\log(-\log \hat{S}(t))$ contra $\log(t)$ y el modelo Weibull es correcto, deberíamos observar una línea recta con pendiente α . Análogamente, bajo el modelo de riesgos proporcionales, las curvas de $\log(-\log \hat{S}(t))$ de distintos subgrupos deben ser aproximadamente paralelas; si se cruzan, el supuesto de proporcionalidad es dudoso.




Figura 10.2: Estimador de Kaplan-Meier de la función de supervivencia con observaciones censuradas

10.8. Heterogeneidad no observada

Retomemos ahora el problema que anticipamos al discutir la dependencia de la duración. Supongamos que la función de riesgo individual es constante, $\lambda_i = \lambda(v_i)$, pero que los individuos difieren en una característica no observada $v_i > 0$. El modelo de riesgos proporcionales con heterogeneidad no observada, llamada *frailty* en la literatura de supervivencia, es:

$$\lambda(t \mid \mathbf{x}, v) = v \exp(\mathbf{x}\boldsymbol{\beta}) \lambda_0(t) \quad (10.27)$$

Donde v es independiente de $\mathbf{x}$, con $\mathbb{E}[v] = 1$ como normalización. El problema fundamental es el siguiente: aun cuando la función de riesgo de *cada* individuo sea constante en el tiempo, la función de riesgo de la *población observada* será decreciente. La razón es un puro efecto de composición: los individuos con v alto tienen un riesgo mayor y por lo tanto salen antes del estado inicial, de modo que la población que sobrevive hasta duraciones largas está compuesta cada vez más por individuos con v bajo. El riesgo promedio observado disminuye con el tiempo aunque nada le ocurra a ningún individuo en particular.

La Figura 10.3 ilustra el fenómeno con el caso más simple posible: una población compuesta por dos tipos de individuos en partes iguales, cada uno




Figura 10.3: Dependencia negativa espuria de la duración generada por heterogeneidad no observada

con una función de riesgo perfectamente constante. Aunque ningún individuo experimenta cambio alguno en su riesgo a lo largo del tiempo, el riesgo agregado que observaría el investigador parte de un valor cercano al promedio de ambos tipos y desciende de manera monótona hacia el riesgo del tipo de bajo riesgo. La razón es puramente de composición: los individuos del tipo de riesgo alto abandonan el estado inicial más rápido, de modo que la población sobreviviente se compone cada vez más de individuos del otro tipo.

Este resultado, conocido como **dependencia negativa espuria de la duración**, tiene consecuencias importantes. Formalmente, la función de riesgo observada, obtenida al integrar sobre la distribución de v , es:

$$\lambda(t \mid \mathbf{x}) = \mathbb{E}[v \mid T \geq t, \mathbf{x}] \exp(\mathbf{x}\boldsymbol{\beta})\lambda_0(t)$$

Y puede demostrarse que $\mathbb{E}[v \mid T \geq t, \mathbf{x}]$ es estrictamente decreciente en t . En consecuencia, ignorar la heterogeneidad no observada sesga a la baja la estimación de la dependencia de la duración: en el modelo Weibull, sesga $\hat{\alpha}$ hacia valores menores que la unidad. Adicionalmente, sesga los coeficientes $\hat{\boldsymbol{\beta}}$ hacia cero, de forma análoga al sesgo de atenuación que aparece en los modelos de respuesta binaria cuando se omiten variables relevantes, incluso si la variable omitida es independiente de las incluidas. Esta última propiedad

es una diferencia importante respecto del modelo lineal, donde la omisión de una variable ortogonal a las incluidas no genera sesgo.

La solución habitual consiste en especificar una distribución para v e integrarla analíticamente de la verosimilitud. Las elecciones más comunes son la distribución gamma, que produce expresiones cerradas convenientes, y la inversa gaussiana. Alternativamente, Heckman y Singer propusieron un enfoque no paramétrico que aproxima la distribución de v mediante un número finito de puntos de masa. Debe advertirse, sin embargo, que la identificación de la distribución de la heterogeneidad descansa fuertemente en la forma funcional supuesta y que los resultados suelen ser sensibles a esa elección. Para la discusión detallada véase Lancaster (1990) [Lan90] y Wooldridge (2010) [Woo10], sección 22.3.4.

10.9. Datos agrupados y modelos en tiempo discreto

En la práctica raramente observamos duraciones en tiempo continuo. Las encuestas registran la información en semanas, meses o trimestres, de modo que lo que efectivamente sabemos es en qué *intervalo* ocurrió la salida. Formalmente estamos ante un caso de censura por intervalo. Adicionalmente, este es el marco natural para incorporar covariables que varían en el tiempo.

Dividamos el eje del tiempo en M intervalos $[a_{m-1}, a_m)$, para $m = 1, 2, \dots, M$. Definamos el riesgo en tiempo discreto como la probabilidad de salir durante el intervalo m condicional en haber sobrevivido hasta su inicio:

$$h_m(\mathbf{x}_m) = P(a_{m-1} \leq T < a_m \mid T \geq a_{m-1}, \mathbf{x}_m) \quad (10.28)$$

A diferencia de $\lambda(t)$, la cantidad h_m sí es una probabilidad y está acotada entre cero y uno. Utilizando la ecuación (10.8) para calcular esta probabilidad bajo un modelo de riesgos proporcionales en tiempo continuo con riesgo constante dentro de cada intervalo, obtenemos:

$$h_m(\mathbf{x}_m) = 1 - \exp[-\exp(\mathbf{x}_m\boldsymbol{\beta} + \gamma_m)] \quad (10.29)$$

Donde $\gamma_m = \log \int_{a_{m-1}}^{a_m} \lambda_0(s) ds$ recoge el riesgo base del intervalo. La ecuación (10.29) es exactamente un modelo de respuesta binaria con función de enlace **log-log complementario** (*cloglog*), que es una de las alternativas

al logit y al probit que mencionamos en el capítulo de modelos de elección discreta.

Este resultado tiene una consecuencia práctica muy conveniente. Si reorganizamos los datos en formato de “episodio-periodo”, creando una observación por cada individuo y por cada intervalo en que estuvo en riesgo, y definiendo una variable binaria y_{im} que vale 1 si el individuo i salió durante el intervalo m y 0 en caso contrario, entonces podemos estimar el modelo de duración **utilizando cualquier programa de regresión de respuesta binaria**, incluyendo un conjunto de variables dicotómicas de intervalo que capturan los γ_m . El riesgo base queda estimado de manera completamente flexible, sin imponer forma funcional alguna, y las covariables pueden variar entre intervalos. La censura se maneja de forma automática: un individuo censurado simplemente aporta observaciones con $y_{im} = 0$ hasta el momento de su censura y desaparece después.

Debe notarse que las observaciones así construidas no son independientes entre sí, por lo que la verosimilitud resultante no es la de un modelo binario con muestreo aleatorio. Sin embargo, puede demostrarse que la factorización secuencial de la verosimilitud coincide exactamente con la del modelo binario, de modo que los estimadores puntuales son correctos; lo que se requiere es agrupar los errores estándar al nivel del individuo. Si se emplea el enlace logístico en lugar del cloglog obtenemos el modelo de riesgo proporcional en momios, que es una aproximación razonable cuando los riesgos por intervalo son pequeños.

10.10. Riesgos en competencia

Hasta aquí hemos supuesto que sólo existe una forma de salir del estado inicial. En muchas aplicaciones económicas esto es insatisfactorio. Una persona desempleada puede salir de ese estado por haber encontrado empleo, por haber emigrado o por haber abandonado la fuerza de trabajo; y no tiene sentido tratar esas tres salidas como si fueran el mismo evento, ya que sus determinantes y sus implicaciones de política son completamente distintos.

El marco de **riesgos en competencia** (*competing risks*) considera K causas de salida mutuamente excluyentes. Para cada una definimos una fun-

ción de riesgo específica por causa:

$$\lambda_k(t, \mathbf{x}) = \lim_{h \downarrow 0} \frac{P(t \leq T < t + h, \text{ causa} = k \mid T \geq t, \mathbf{x})}{h}, \quad k = 1, 2, \dots, K \quad (10.30)$$

El riesgo total de salir por cualquier causa es la suma de los riesgos específicos, $\lambda(t, \mathbf{x}) = \sum_{k=1}^K \lambda_k(t, \mathbf{x})$. Bajo el supuesto de independencia condicional entre las causas, la log-verosimilitud se factoriza en K componentes separables:

$$\ell(\boldsymbol{\theta}) = \sum_{k=1}^K \sum_{i=1}^N \{d_{ik} \log \lambda_k(t_i, \mathbf{x}_i) - \Lambda_k(t_i, \mathbf{x}_i)\} \quad (10.31)$$

Donde $d_{ik} = 1$ si el individuo i salió por la causa k . La implicación práctica es notable: bajo el supuesto de independencia, podemos estimar el modelo de cada causa por separado tratando las salidas por las demás causas como si fueran observaciones censuradas. El supuesto de independencia entre riesgos es, sin embargo, fuerte y no contrastable con datos de un solo episodio, un resultado conocido como la imposibilidad de Cox-Tsiatis. En la práctica conviene reportar los resultados como riesgos específicos por causa, sin pretender interpretarlos como los riesgos que se observarían si las demás causas fueran eliminadas.

10.11. Consideraciones prácticas y aplicación

10.11.1. Estrategia de trabajo empírico

A modo de síntesis, una estrategia razonable para el análisis de datos de duración es la siguiente:

1. Documentar con precisión el esquema de muestreo y el mecanismo de censura, y verificar si estamos ante muestreo de flujo o de acervo.
2. Estimar y graficar la función de supervivencia de Kaplan-Meier de la ecuación (10.26), globalmente y por subgrupos de interés, aplicando la prueba de rangos logarítmicos.
3. Examinar el gráfico de $\log(-\log \hat{S}(t))$ contra $\log(t)$ para evaluar la plausibilidad del supuesto Weibull y del supuesto de riesgos proporcionales.

4. Estimar un modelo paramétrico, típicamente Weibull, y contrastar $H_0 : \alpha = 1$ mediante una prueba de razón de verosimilitudes.
5. Estimar un modelo de Cox como verificación de robustez de los coeficientes ante una especificación errónea del riesgo base.
6. Si la información está agrupada o hay covariables que varían en el tiempo, reorganizar los datos en formato episodio-periodo y estimar el modelo cloglog de la ecuación (10.29) con variables dicotómicas de intervalo.
7. Evaluar la sensibilidad de las conclusiones ante la inclusión de heterogeneidad no observada, en particular si el interés recae sobre la dependencia de la duración.

10.11.2. Implementación en Python

Para la implementación de estos modelos en Python contamos con dos bibliotecas principales. El módulo `statsmodels.duration` incluye `SurvfuncRight` para el estimador de Kaplan-Meier, `survdif` para la prueba de rangos logarítmicos y `PHReg` para el modelo de riesgos proporcionales de Cox. La biblioteca `lifelines` ofrece una cobertura más amplia, con implementaciones de los modelos Weibull, log-logístico y log-normal en sus formas PH y AFT, así como herramientas de diagnóstico del supuesto de proporcionalidad. Los modelos en tiempo discreto pueden estimarse directamente con `statsmodels` utilizando un modelo lineal generalizado con familia binomial y enlace `cloglog`, una vez reorganizados los datos en formato episodio-periodo.

10.11.3. Aplicación sugerida: duración hasta la reincidencia delictiva

Una aplicación que ilustra bien todos los elementos del capítulo es el análisis de la reincidencia delictiva a partir de los datos de Chung, Schmidt y Witte, utilizados por Wooldridge (2010) [Woo10] y disponibles en el conjunto `RECID`. Se trata de una muestra de reclusos liberados entre julio de 1977 y junio de 1978, a quienes se dio seguimiento hasta abril de 1984. La variable de duración es el número de meses transcurridos hasta un nuevo arresto, y las observaciones de quienes no fueron arrestados antes de la fecha de corte

están censuradas por la derecha, con tiempos de censura que varían entre 70 y 81 meses por las distintas fechas de liberación.

Las covariables de interés incluyen la participación en un programa de trabajo penitenciario, los años de educación, el tiempo efectivamente cumplido en prisión, el número de condenas previas, el estado civil, la edad y la condición de consumo de drogas o alcohol. La pregunta de política es si el programa de trabajo penitenciario reduce el riesgo de reincidencia, y la pregunta econométrica de interés es si existe dependencia de la duración una vez controladas las características observables. Este ejemplo es además valioso desde el punto de vista de la inferencia causal, ya que la participación en el programa no fue aleatoria y es plausible que exista autoselección de los reclusos, lo cual conecta directamente con la discusión del capítulo de inferencia causal y con el problema de selección de muestra.

10.12. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta en todos los casos.
 - a) La función de riesgo $\lambda(t)$ es una probabilidad y por lo tanto está acotada entre cero y uno.
 - b) Las observaciones censuradas por la derecha no aportan información y deben eliminarse antes de estimar.
 - c) Si en un modelo Weibull estimamos $\hat{\alpha} = 0.7$, entonces mientras más tiempo lleva un individuo en el estado inicial, mayor es su probabilidad instantánea de salir de él.
 - d) En un modelo de riesgos proporcionales, un coeficiente $\hat{\beta}_j$ positivo implica que un incremento en x_j aumenta la duración esperada.
 - e) El estimador de Cox permite contrastar si existe dependencia positiva o negativa de la duración.
 - f) Si tomamos una muestra de las personas que se encuentran desempleadas hoy y les preguntamos cuánto tiempo llevan sin empleo, obtenemos una muestra aleatoria de la distribución de duraciones del desempleo.

2. Demuestre las siguientes relaciones fundamentales:
 - a) $\lambda(t) = -d \log S(t)/dt$, partiendo de la ecuación (10.6).
 - b) $S(t) = \exp(-\Lambda(t))$, es decir la ecuación (10.8).
 - c) $\mathbb{E}[T] = \int_0^\infty S(t)dt$, es decir la ecuación (10.11). Sugerencia: integre por partes.
 - d) Para la distribución Weibull, verifique que $\lambda(t) = \gamma\alpha t^{\alpha-1}$ partiendo de la función de distribución acumulada, y obtenga la condición sobre α que produce dependencia positiva de la duración.
3. Considere la distribución de Gompertz, cuya función de riesgo es $\lambda(t) = \gamma \exp(\alpha t)$ con $\gamma > 0$. Se le solicita: (i) obtener $\Lambda(t)$, $S(t)$ y $f(t)$; (ii) determinar para qué valores de α hay dependencia positiva y negativa de la duración; (iii) mostrar qué caso particular se obtiene cuando $\alpha = 0$; y (iv) escribir la log-verosimilitud con censura por la derecha usando la ecuación (10.17).
4. Partiendo de la ecuación (10.19), obtenga las condiciones de primer orden del modelo Weibull respecto de β y de α . Muestre que, en el caso sin covariables y sin censura, el estimador de máxima verosimilitud del modelo exponencial es $\hat{\lambda} = N / \sum_{i=1}^N t_i$, es decir, el inverso de la duración media muestral, e interprete el resultado.
5. Demuestre que si en la ecuación (10.22) el modelo no fuera de riesgos proporcionales, sino que tuviera la forma $\lambda(t, \mathbf{x}) = \exp(\mathbf{x}\beta(t))\lambda_0(t)$ con coeficientes que varían en el tiempo, la función de riesgo base ya no se cancelaría. Explique qué implica este resultado sobre el papel que juega el supuesto de proporcionalidad en la validez del método de Cox.
6. Considere una muestra pequeña con las siguientes observaciones de duración en meses, donde el asterisco indica censura por la derecha: 3, 5, 5*, 7, 9*, 9, 12, 14*, 14, 18. Se le solicita:
 - a) Construir la tabla del estimador de Kaplan-Meier indicando, para cada momento de salida, el número en riesgo n_j , el número de salidas e_j y el factor $(1 - e_j/n_j)$.
 - b) Calcular $\hat{S}(t)$ en cada punto y graficar la función escalonada resultante.

- c) Estimar la mediana de la duración a partir de la curva obtenida.
 - d) Repetir el ejercicio tratando incorrectamente las observaciones censuradas como si fueran duraciones completas, y comparar. ¿En qué dirección se sesga la estimación de la supervivencia y por qué?
7. **Heterogeneidad no observada.** Suponga una población compuesta por dos tipos de individuos en proporciones iguales. Los del tipo A tienen un riesgo constante $\lambda_A = 0.2$ y los del tipo B un riesgo constante $\lambda_B = 0.05$, y el tipo no es observable por el investigador. Se le solicita:
- a) Obtener la función de supervivencia agregada de la población, $S(t) = 0.5 \exp(-0.2t) + 0.5 \exp(-0.05t)$.
 - b) Obtener la función de riesgo agregada mediante $\lambda(t) = f(t)/S(t)$ y evaluarla en $t = 0$, $t = 5$ y $t = 20$.
 - c) Verificar numéricamente que la función de riesgo agregada es decreciente, a pesar de que la de cada tipo de individuo es constante, y explicar el mecanismo de composición que produce este resultado.
 - d) Discutir qué concluiría erróneamente un investigador que estimara un modelo Weibull sin controlar por el tipo de individuo.
8. **Aplicación empírica en Python.** Utilizando el conjunto de datos de reincidencia delictiva descrito en la sección anterior, o bien un conjunto de datos de duración del desempleo de su elección, se le solicita:
- a) Reportar estadística descriptiva de la duración observada y el porcentaje de observaciones censuradas.
 - b) Estimar y graficar la función de supervivencia de Kaplan-Meier, globalmente y separando por la variable de tratamiento de interés. Aplicar la prueba de rangos logarítmicos.
 - c) Construir el gráfico de $\log(-\log \hat{S}(t))$ contra $\log(t)$ y evaluar la plausibilidad de los supuestos Weibull y de riesgos proporcionales.
 - d) Estimar los modelos exponencial y Weibull por máxima verosimilitud, contrastar $H_0 : \alpha = 1$ mediante una prueba de razón de verosimilitudes e interpretar el resultado en términos de dependencia de la duración.

- e)* Estimar el modelo de Cox y comparar los coeficientes con los del modelo Weibull. Interpretar los cocientes de riesgo de al menos tres variables.
- f)* Reorganizar los datos en formato episodio-periodo y estimar el modelo cloglog de la ecuación (10.29) con variables dicotómicas de intervalo. Comparar el riesgo base estimado de forma flexible con el que impone el modelo Weibull.
- g)* Discutir críticamente si los coeficientes estimados admiten una interpretación causal, identificando las amenazas de identificación presentes.

11

Introducción al Aprendizaje Estadístico

11.1. Motivación, introducción y Notación en el análisis de regresión

Iniciemos con un ejemplo. Pensemos la regresión como un proceso de formalizar un gráfico de dispersión (scatter plot). Como ejemplo, considere la Figura 11.1 en la que se muestra el scatter plot entre los años de educación y el salario. Una hipótesis sensata es pensar que la relación es positiva e, incluso, lineal: a más años de estudio, más salario.

Este planteamiento, como se puede ver, se centra en la creación de una **hipótesis**. Es decir, hacer regresión lineal es asumir la hipótesis de que existe una relación entre las variables que puede ser capturada por un modelo analítico que llamamos ecuación de regresión.

En primer lugar, estableceremos un poco de notación. En el análisis de regresión, siempre partimos de una representación de una ecuación lineal o hipótesis (h) como:

$$y_i = \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \dots + \beta_K x_{iK} + \varepsilon_i = h(x_{i1}, x_{i2}, \dots, x_{iK}) + \varepsilon_i \quad (11.1)$$

Donde cada una de las variables y_i , x_{ik} y ε_i se observan para $i = 1, 2, 3, \dots, N$ y $k = 1, 2, \dots, K$. Al conjunto de las variables x_{ik} se les llama características y a y_i se le suele decir variable objetivo, la cual estamos tratando de predecir. En este curso, al par (y_i, x_{ik}) le llamaremos ejemplo de entrenamiento, del cual tenemos N casos.




Figura 11.1: ¿Qué relación hay entre años de educación y el salario?, retomado de: <https://wol.iza.org/articles/using-linear-regression-to-establish-empirical-relationships/lang/es>

Por lo general, la hipótesis representada por la ecuación de regresión la representaremos para cada i de la forma matricial:

$$\begin{aligned}
 y_i &= \begin{pmatrix} x_{i1} & x_{i2} & \dots & x_{iK} \end{pmatrix} \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_K \end{pmatrix} + \varepsilon_i \\
 &= \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \\
 &= h(\mathbf{x}_i) + \varepsilon_i
 \end{aligned} \tag{11.2}$$

En este sentido, de forma relacionada, podemos definir la función de costos:

$$\begin{aligned}
 J(\boldsymbol{\beta}) &= \frac{1}{2} \sum_{i=1}^N (h(\mathbf{x}_i) - y_i)^2 \\
 &= \frac{1}{2} \sum_{i=1}^N (\mathbf{x}_i \boldsymbol{\beta} - y_i)^2
 \end{aligned} \tag{11.3}$$

11.2. Formas funcionales no lineales: recapitulación

El análisis de regresión no se limita a relaciones lineales. En el capítulo dedicado al concepto de esperanza condicional desarrollamos con detalle tres familias de formas funcionales que permiten describir relaciones no lineales mediante transformaciones que las vuelven lineales en los parámetros, y por lo tanto estimables por MCO. Recuperamos aquí sus resultados, ya que constituyen el punto de partida de todo lo que sigue en este capítulo; las derivaciones a partir de las ecuaciones diferenciales que las generan, así como la discusión gráfica de cada caso, se encuentran en dicho capítulo.

El criterio que distingue a cada familia es **cómo varía la tasa de cambio de y ante cambios en x** . Partiendo de la relación lineal $y = a + bx$, cuya tasa de variación $dy/dx = b$ es constante, obtenemos:

Las tres primeras merecen un comentario. La **regresión exponencial** surge cuando el cambio en y es proporcional al propio nivel de y , es decir $dy/dx = by$, lo que conduce a $y = ae^{bx}$. Al tomar logaritmos obtenemos una relación lineal, de modo que el coeficiente estimado se interpreta directamente

Cuadro 11.1: Formas funcionales y su interpretación

Modelo	Ecuación	Forma estimable	Interpretación de b
Lineal	$y = a + bx$	$y = a + bx$	Cambio en unidades de y
Exponencial	$y = ae^{bx}$	$\ln y = \ln a + bx$	Tasa de crecimiento constante
Logarítmica	$y = a + b \ln x$	$y = a + b \ln x$	Cambio ante variación porcentual
Doble logarítmica	$y = ax^b$	$\ln y = \ln a + b \ln x$	Elasticidad constante
Logística	$y = \frac{L}{1+ae^{-bx}}$	No lineal en parámetros	Crecimiento con saturación

como una tasa de crecimiento. Es la forma funcional detrás de las ecuaciones de salarios en logaritmos que hemos usado a lo largo del curso.

La **regresión logarítmica** corresponde al caso en que el cambio en y es proporcional al inverso de x , esto es $dy/dx = b/x$, y describe situaciones de rendimientos decrecientes. Cuando ambas variables entran en logaritmos, el coeficiente es una **elasticidad**, resultado de uso constante en economía.

Las **funciones logísticas** son de especial relevancia para este capítulo. Modelan procesos de crecimiento que están acotados superiormente por un nivel de saturación L , en los que el crecimiento es lento al inicio, se acelera y finalmente se desacelera al aproximarse al límite. Su ecuación diferencial subyacente es $dy/dx = by(1 - y/L)$. Con $L = 1$ obtenemos exactamente la función que utilizaremos como $G(\cdot)$ en los modelos de clasificación de la sección correspondiente, y que ya aparece en los modelos logit del capítulo de modelos no lineales. Es decir, la función logística cumple aquí un doble papel: describe procesos de difusión y adopción, y sirve como función de enlace que transforma una combinación lineal en una probabilidad.

A diferencia de las anteriores, la función logística **no** puede volverse lineal en los parámetros mediante una transformación simple cuando L es desconocido, por lo que su estimación requiere métodos no lineales o, en el caso de los modelos de respuesta binaria, máxima verosimilitud.

11.2.1. Funciones polinomiales

Otro tipo de ecuaciones o funciones se asocian con una relación entre y y x del tipo no lineal, pero que puede describirse bajo una formulación

de un polinomio de algún grado l . Este tipo de ecuaciones tienen la característica de que permiten modelar crecimientos poblacionales, aceptación de políticas públicas, aceptación de tecnologías, epidemias, etc., mediante una especificación menos compleja en términos matemáticos.

En muchas aplicaciones, una simple transformación logarítmica de la variable x ya no puede ser suficiente para lograr un ajuste satisfactorio. Una forma sencilla de obtener más flexibilidad es utilizar la regresión polinomial. Normalmente, se prefieren polinomios de bajo grado l . En la práctica, rara vez utilizamos polinomios de grado superior a $l = 3$, ya que las estimaciones pueden volverse bastante inestables con una alta variabilidad en los límites del dominio de variables. Además, pueden surgir inestabilidades numéricas en grados muy altos, en cuyo caso se requiere de re-escalar los datos.

En general, partamos de ecuaciones como:

$$y = a + b_1x^1 + b_2x^2 + \dots + b_lx^l \quad (11.4)$$

La figura 11.2 ilustra diferentes escenarios de ecuaciones como 11.4 con diferentes grados l .

11.3. Aprendizaje Estadístico

El aprendizaje estadístico juega un rol esencial en muchas áreas de la ciencia, finanzas y la industria. Las referencias básicas para esta sección son James, Witten, Hastie y Tibshirani (2013) [Jam+13] para el tratamiento introductorio, Hastie, Tibshirani y Friedman (2017) [HTF17] para el tratamiento avanzado, y Géron (2019) [Gér19] para la implementación práctica en Python. Algunos ejemplos son:

1. Predecir si un paciente—que se encuentra hospitalizado debido a un ataque al corazón—tendrá un segundo ataque. La predicción estará basada en métricas demográficas, de la dieta y de registros clínicos.
2. Predecir el precio de una acción en los siguientes 6 meses; considerando la base de las medidas de desempeño de la compañía y de otros datos económicos.
3. Identificar los números en la digitalización de formas escritas a mano.
4. Identificar los factores de riesgo para el cáncer de próstata, basados en datos clínicos y de otras variables demográficas.




Figura 11.2: Funciones polinomiales, retomado de <https://discdn.org/flexregression/smoothreg.html>

El aprendizaje estadístico comprende a un conjunto de herramientas para modelar y entender conjuntos de datos complejos. También se le conoce como *machine learning* (ML), el cual conjuga el desarrollo reciente en el área de la estadística junto con el crecimiento en paralelo de la computación.

El aprendizaje estadístico considera muchos métodos convencionales y de uso amplio como análisis de regresión, clasificación, árboles de decisión, etc. También se refiere a una amplia gama de herramientas para entender o interpretar datos clasificadas como supervisadas y no supervisadas.

- El aprendizaje estadístico supervisado involucra la construcción de un modelo estadístico para predecir o estimar un resultado (o variable que se puede supervisar) basado en uno o más variables explicativas.
- El aprendizaje no supervisado considera variables explicativas, pero los resultados observados no son una variable explicada que sea susceptible de supervisión.

Ahora introduzcamos un poco de notación. Denotaremos a una variable independiente o explicativa con x_{ij} , si dicha variable es un conjunto de variables acomodadas en un vector utilizaremos $\mathbf{X}_i$; en estos casos denotaremos a un elemento o variable del vector $\mathbf{X}_i$ como x_{ik} , donde $i = 1, 2, \dots, N$ denota a los individuos en la muestra y $k = 1, 2, \dots, K$ denota al número de variables. Por convención diremos que $x_{i1} = 1$ para todo $i = 1, 2, \dots, N$, ya que en dicha variable consideraremos al término constante en la regresión.

Por su parte, los resultados, variables dependientes o variables de respuesta se denotarán como:

- y_i denotará una respuesta que es una cantidad continua
- g_i denotará una respuesta cualitativa, discreta o de grupo

Así, con $\mathbf{X}$, y $\mathbf{Y}$ y $\mathbf{G}$ denotaremos a la matriz y vector columna que contiene a todos los valores de las variables dependientes y de respuesta apiladas para cada uno de los elementos en la muestra indexados con i .

Usaremos mayúsculas como X , Y o G para representar a los aspectos genéricos de las variables. De esta forma, debe ser claro que las letras minúsculas serán empleadas para representar a valores observados de las variables, así el valor observado de la variable k -ésima para el elemento de la muestra i -ésimo en $\mathbf{X}$ será representado como x_{ij} . Finalmente, con la notación $\hat{Y}$ o $\hat{G}$ representaremos a los valores estimados o predichos.

El aprendizaje estadístico parte del establecimiento de que una variable dependiente Y es una función de un conjunto de variables explicativas $\mathbf{X} = [X_1, X_2, \dots, X_K]$. De esta forma plantearemos:

$$Y = f(\mathbf{X}) + \varepsilon \quad (11.5)$$

Así, el aprendizaje estadístico se trata de un conjunto de aproximaciones para f . ¿Para qué estimar f ? La respuesta es para hacer predicciones y para hacer inferencia. La más común de ambas razones es la predicción, con una predicción de Y podríamos establecer:

$$\hat{Y} = \hat{f}(\mathbf{X}) \quad (11.6)$$

11.3.1. Ajuste y separación del conjunto de datos

Supongamos la variable objetivo Y , un vector de variables explicativas o variables 'input' X y un modelo predictivo $\hat{f}(X)$ que es estimado a partir de un conjunto de entrenamiento τ .

Definiremos la función de pérdida derivada de la estimación y capturada por los errores entre Y y $\hat{f}(X)$ estará dada por:

$$L(Y, \hat{f}(X)) = \begin{cases} (Y - \hat{f}(X))^2 & \text{error cuadrático} \\ |Y - \hat{f}(X)| & \text{error absoluto} \end{cases} \quad (11.7)$$

De esta forma, podemos establecer el error cuadrático esperado de predicción como:

$$\begin{aligned} \mathbb{E}[(Y - \hat{Y})^2] &= \mathbb{E}[(f(X) + \varepsilon - \hat{f}(X))^2] \\ &= \underbrace{\mathbb{E}[(f(X) - \hat{f}(X))^2]}_{\text{reducible}} + \underbrace{\text{Var}(\varepsilon)}_{\text{irreducible}} \end{aligned} \quad (11.8)$$

Donde el primer término de la ecuación (11.8) es el único componente reducible: por bueno que sea el modelo, nunca podremos predecir mejor que la varianza del error, que es intrínseca al fenómeno.

11.3.2. La disyuntiva entre sesgo y varianza

El componente reducible admite a su vez una descomposición que constituye el resultado central del aprendizaje estadístico y la justificación de

prácticamente todos los métodos que veremos en este capítulo. Evaluando en un punto x_0 y tomando esperanzas sobre las posibles muestras de entrenamiento:

$$\mathbb{E} \left[(f(x_0) - \hat{f}(x_0))^2 \right] = \underbrace{\left(\mathbb{E}[\hat{f}(x_0)] - f(x_0) \right)^2}_{\text{Sesgo}^2} + \underbrace{\text{Var}(\hat{f}(x_0))}_{\text{Varianza}} \quad (11.9)$$

La derivación es la misma que se emplea para descomponer el error cuadrático medio de cualquier estimador: se suma y resta $\mathbb{E}[\hat{f}(x_0)]$ y se verifica que el término cruzado se anula.

La ecuación (11.9) tiene una lectura de fondo. El **sesgo** mide qué tan lejos está, en promedio, el modelo estimado de la verdadera función; proviene de imponer una forma funcional más simple que la realidad. La **varianza** mide cuánto cambiaría el modelo estimado si se hubiera utilizado otra muestra de entrenamiento; proviene de la flexibilidad del modelo. Y aquí está el punto crucial: ambos términos se mueven en direcciones **opuestas** conforme se aumenta la flexibilidad del modelo. Un modelo muy rígido tiene sesgo alto y varianza baja; un modelo muy flexible tiene sesgo bajo y varianza alta. Dado que lo que queremos minimizar es la *suma* de ambos, el modelo óptimo no es el más flexible ni el más simple, sino uno intermedio.

Este resultado explica el fenómeno del **sobreajuste**: un modelo suficientemente flexible puede ajustar los datos de entrenamiento de manera casi perfecta — llevando el error de entrenamiento a cero — y sin embargo predecir muy mal fuera de la muestra, porque lo que ajustó fue en buena medida el ruido de esa muestra particular. De ahí se desprende la consecuencia metodológica que organiza todo el capítulo: **el error de entrenamiento no es un estimador válido del error de predicción**, y por lo tanto necesitamos separar los datos.

La Figura 11.3 muestra el fenómeno con un ejercicio de simulación en el que la función verdadera es conocida y se ajustan polinomios de grado creciente. El panel (a) contiene el resultado central: el error de entrenamiento **decrece de manera monótona** con la flexibilidad — un polinomio de grado alto siempre ajusta mejor los datos con los que se estimó —, mientras que el error de prueba tiene forma de U y alcanza su mínimo en un grado intermedio. Más allá de ese punto, aumentar la flexibilidad empeora la predicción. El panel (b) descompone el componente reducible y hace visible el mecanismo: el sesgo al cuadrado cae rápidamente al principio y luego se estabiliza cerca




Figura 11.3: Disyuntiva entre sesgo y varianza, obtenida por simulación



Figura 11.4: División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]

de cero, mientras que la varianza crece de forma acelerada; la suma de ambos es lo que produce la U.

Vale la pena señalar el contraste con el resto del curso. En los capítulos anteriores buscábamos estimadores insesgados y, entre ellos, el de mínima varianza; el sesgo era algo a evitar. Aquí, en cambio, estaremos dispuestos a **aceptar sesgo deliberadamente** si a cambio obtenemos una reducción mayor de la varianza. Esa es precisamente la lógica de los métodos de regresión restringida que veremos enseguida: introducen sesgo a propósito.

Para hacer predicciones requerimos entonces de un conjunto de datos de entrenamiento y otro de prueba: en el primero estimamos $f(\cdot)$ y en el segundo evaluamos la calidad de las predicciones.

Finalmente, la condición de inferencia nos permite construir pruebas de hipótesis, estimadores que cumplen ciertas propiedades, intervalos de confianza, etc. Así, dividiremos al conjunto de datos conforme se describe en la Figura 11.4.

Para proporcionar una comprensión precisa de la generalización de nuestro modelo óptimo final, se suele dividir nuestros datos sólo en dos conjuntos

de datos: de entrenamiento y de prueba.

- Conjunto de entrenamiento: estos datos se utilizan para desarrollar conjuntos de características, entrenar nuestros algoritmos, ajustar hiperparámetros, comparar modelos y todas las demás actividades necesarias para elegir un modelo final (por ejemplo, el modelo que queremos poner en producción).
- Conjunto de pruebas: una vez elegido un modelo final, estos datos se utilizan para estimar una evaluación insesgada del rendimiento del modelo, a lo que nos referimos como error de generalización.

Acá unos recursos:

<https://mlu-explain.github.io/train-test-validation/>

11.3.3. Método de regresiones restringidas (Shrinkage methods).

Este tipo de métodos permiten:

1. Restringir los posibles valores de las estimaciones del parámetro β a un subconjunto, y
2. Seleccionar variables o regresores dentro de un conjunto de candidatos.

Veamos dos casos particulares: i) una regresión de cresta restringida (ridge regression) y ii) la regresión Lasso (least absolute shrinkage and selection operator).

Regresión Ridge.

La regresión de ridge restringe los coeficientes de la regresión mediante la imposición de una penalización en su magnitud. Los coeficientes estimados por este método resultan de resolver el problema de minimizar los residuales al cuadrado sujeto a que los coeficientes sumen un valor dado. Es decir:

$$\hat{\beta}^{Ridge} = \arg \min_{\beta} \left[\sum_{i=1}^N (y_i - \mathbf{x}_i \beta)^2 + \lambda \sum_{k=2}^K \beta_k^2 \right] \quad (11.10)$$

Donde $\lambda \geq 0$ y suponemos que β_1 es el término constante de la regresión, el cual no se optimiza.

La idea de la penalización de los parámetros se deriva de que la forma equivalente del problema en la ecuación (11.10) es:

$$\hat{\beta}^{Ridge} = \arg \min_{\beta} \left[\sum_{i=1}^N (y_i - \mathbf{X}_i \beta)^2 \right]$$

Sujeto a:

$$\sum_{k=2}^K \beta_k^2 \leq t$$

Note que la penalización no aplica al término constante, ¿por qué?, para garantizar que la estimación del hiperplano asociado pasa por la media de Y y no por el cero (0).

¿Qué implicaciones tiene para la estimación? Es posible estimar el modelo de la ecuación (11.10) pero ajustando las variables incluidas con la resta de la media. Esto, ya que el término constante se puede estimar considerando que este toma el valor de la media de Y dado por:

$$\bar{Y} = \frac{\sum_{i=1}^N y_i}{N}$$

Para los restantes coeficientes los determinaremos mediante un procedimiento dado por:

$$\min_{\beta_R, \lambda} [(\mathbf{Y} - \mathbf{X}\beta_R)'(\mathbf{Y} - \mathbf{X}\beta_R) + \lambda \beta_R' \beta_R] \quad (11.11)$$

Donde β_R contiene sólo las pendientes. Para determinar un valor estimado debemos resolver el problema descrito en la ecuación (11.11):

$$\begin{aligned} \frac{\partial}{\partial \beta_R} S(\beta_R) &= \frac{\partial}{\partial \beta_R} ((\mathbf{Y} - \mathbf{X}\beta_R)'(\mathbf{Y} - \mathbf{X}\beta_R) + \lambda \beta_R' \beta_R) \\ &= \frac{\partial}{\partial \beta_R} (\mathbf{Y}'\mathbf{Y} - 2\mathbf{Y}'\mathbf{X}\beta_R + \beta_R' \mathbf{X}'\mathbf{X}\beta_R + \lambda \beta_R' \beta_R) \\ &= -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\beta_R + 2\lambda \beta_R \end{aligned}$$

Determinando el mínimo:

$$\begin{aligned} -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}\hat{\beta}_R^{Ridge} + 2\lambda \hat{\beta}_R^{Ridge} &= 0 \\ -\mathbf{X}'\mathbf{Y} + (\mathbf{X}'\mathbf{X} + \lambda \mathbb{I}_{K-1})\hat{\beta}_R^{Ridge} &= 0 \end{aligned}$$

Por lo tanto, el estimador estará dado por:

$$\hat{\beta}_R^{Ridge} = (\mathbf{X}'\mathbf{X} + \lambda\mathbb{I}_{K-1})^{-1}\mathbf{X}'\mathbf{Y} \quad (11.12)$$

Del estimador anterior se desprenden dos observaciones importantes. La primera es que, dado que $\lambda > 0$, la matriz $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ es invertible **aun cuando $\mathbf{X}'\mathbf{X}$ no lo sea**. Esto significa que la regresión ridge puede estimarse incluso con más regresores que observaciones, o con colinealidad perfecta, casos en los que MCO simplemente no existe. Es una de las razones principales de su uso. La segunda es que el estimador es **sesgado** — se verifica de inmediato que $\mathbb{E}[\hat{\beta}^{Ridge}] \neq \beta$ para $\lambda > 0$ — y que ese sesgo es introducido deliberadamente a cambio de una reducción de la varianza, exactamente en la lógica de la disyuntiva de la ecuación (11.9).

Queda pendiente la pregunta de cómo elegir λ , que es el único hiperparámetro del procedimiento. Aquí conviene ser preciso, porque es un punto en el que es fácil equivocarse: λ **no** puede elegirse minimizando la función objetivo de la ecuación (11.10), ya que esa función es decreciente en la penalización y el mínimo se alcanzaría trivialmente en $\lambda = 0$, es decir, en MCO. La elección debe hacerse minimizando el **error de predicción fuera de la muestra**, y el procedimiento estándar es la **validación cruzada**:

1. Se divide el conjunto de entrenamiento en V partes o pliegues de tamaño similar, típicamente $V = 5$ o $V = 10$.
2. Para cada valor candidato de λ en una rejilla, y para cada pliegue v , se estima el modelo con las $V - 1$ partes restantes y se calcula el error de predicción sobre el pliegue v , que no participó en la estimación.
3. Se promedian los V errores para obtener el error de validación cruzada de ese λ .
4. Se elige el λ con menor error de validación cruzada.

Una advertencia práctica adicional: la penalización de la ecuación (11.10) **no es invariante a la escala** de los regresores, ya que penaliza la magnitud de los coeficientes y esa magnitud depende de las unidades de medida. Una variable medida en pesos y la misma variable medida en miles de pesos recibirían penalizaciones completamente distintas. Por ello es indispensable **estandarizar los regresores** antes de estimar, dejándolos con media cero y varianza uno. Lo mismo aplica al procedimiento Lasso que veremos a continuación.

Regresión Lasso (Least Absolute Shrinkage and Selection Operator).

La regresión Lasso se define por la solución al problema:

$$\hat{\boldsymbol{\beta}}^{Lasso} = \arg \min_{\boldsymbol{\beta}} \left[\sum_{i=1}^N (y_i - \mathbf{X}_i \boldsymbol{\beta})^2 \right] \quad (11.13)$$

Sujeto a:

$$\sum_{k=2}^K |\beta_k| \leq t$$

Donde $\lambda \geq 0$ y suponemos que β_1 es el término constante de la regresión. El término constante se estima considerando que este toma el valor de la media de Y dado por:

$$\bar{Y} = \frac{\sum_{i=1}^N y_i}{N}$$

La idea de la penalización de los parámetros se deriva de que la forma equivalente del problema en la ecuación (11.13) es:

$$\hat{\boldsymbol{\beta}}^{Lasso} = \arg \min_{\boldsymbol{\beta}} \left[\sum_{i=1}^N (y_i - \mathbf{X}_i \boldsymbol{\beta})^2 + \lambda \sum_{k=2}^K |\beta_k| \right] \quad (11.14)$$

La diferencia esencial entre Ridge y Lasso. A primera vista los dos procedimientos parecen variantes menores uno del otro: ambos añaden una penalización sobre la magnitud de los coeficientes y difieren sólo en si se usa la suma de cuadrados o la suma de valores absolutos. Sin embargo, esa diferencia tiene una consecuencia cualitativa de la mayor importancia:

- La regresión **Ridge** encoge todos los coeficientes hacia cero, pero **nunca los hace exactamente cero**. Todas las variables permanecen en el modelo, con coeficientes pequeños.
- La regresión **Lasso** sí produce coeficientes **exactamente iguales a cero** para un λ suficientemente grande. Por lo tanto, además de encoger, realiza **selección de variables**: el conjunto de regresores con coeficiente distinto de cero constituye el modelo seleccionado.




Figura 11.5: Por qué el Lasso produce coeficientes exactamente iguales a cero y la regresión Ridge no

La razón geométrica de esta diferencia está en la forma de las regiones de restricción. La restricción de Ridge, $\sum_k \beta_k^2 \leq t$, define una esfera, cuya superficie es lisa; la restricción de Lasso, $\sum_k |\beta_k| \leq t$, define un politopo con **vértices sobre los ejes**. Al buscar el punto de esa región que minimiza la suma de residuales al cuadrado, las curvas de nivel elípticas del objetivo tienden a tocar la región en un vértice, y en un vértice algunas coordenadas valen exactamente cero. Con la esfera de Ridge, en cambio, el punto de tangencia se ubica genéricamente fuera de los ejes.

La Figura 11.5 presenta el argumento de dos maneras complementarias. El panel (a) muestra el caso de dos coeficientes: las elipses son las curvas de nivel de la suma de residuales al cuadrado, centradas en la solución de MCO; el círculo y el rombo son las regiones admisibles de Ridge y Lasso para un mismo valor de t . La solución de cada método es el punto de su región en el que una elipse la toca por primera vez. Se observa que la del Lasso cae exactamente sobre un vértice, con $\beta_2 = 0$, mientras que la de Ridge queda fuera de los ejes y conserva ambos coeficientes. El panel (b) muestra el mismo hecho desde otro ángulo, graficando cómo evolucionan los coeficientes estimados al aumentar la penalización: las trayectorias del Lasso alcanzan el cero exacto y se quedan ahí, mientras que las de Ridge se aproximan asintóticamente sin llegar nunca.

Esta propiedad hace del Lasso una herramienta especialmente útil cuando se sospecha que sólo un subconjunto pequeño de los regresores es relevante,

situación que en la literatura se describe como un modelo **disperso**. Su contrapartida es que, a diferencia del caso de Ridge, el problema de la ecuación (11.14) **no tiene solución analítica cerrada**, ya que el valor absoluto no es diferenciable en cero; debe resolverse con métodos numéricos como el descenso por coordenadas.

Una advertencia final sobre la interpretación. Es tentador leer las variables que el Lasso conserva como «las variables que importan» y tratar sus coeficientes como si provinieran de una regresión ordinaria. Esto es incorrecto por dos razones: los coeficientes están encogidos y por lo tanto sesgados hacia cero, y los errores estándar convencionales no son válidos porque no toman en cuenta que la selección misma de las variables fue producto de los datos. La inferencia posterior a la selección es un problema técnico delicado y activo en la literatura. Como regla práctica, el Lasso es una excelente herramienta de *predicción* y de exploración, pero no debe usarse para construir pruebas de hipótesis sobre los coeficientes seleccionados.

11.4. Aplicación de modelos clasificación mediante clustering.

En esta sección abordaremos el caso del clustering, el cual es un problema que podemos enunciar de esta forma. Supongamos que tenemos un conjunto de entrenamiento $\{x_1, x_2, \dots, x_n\}$ de características respecto del cual queremos construir un grupo o grupos de datos cohesivos denominados clústeres. En este caso, para cada una de las x_i características no tenemos una etiqueta y_i . Esta situación de inexistencia de etiquetas es lo que le da el nombre de aprendizaje no supervisado.

Ahora, analicemos diferentes técnicas de aprendizaje no supervisado.

11.4.1. Análisis de Componentes Principales

El análisis de componentes principales (PCA, por sus siglas en inglés) es una herramienta importante y útil de aprendizaje no supervisado para la reducción de dimensiones. También lo podemos ver como un método para identificar un subespacio en el cual los datos se pueden representar, puesto que hay información redundante. El PCA se puede utilizar como una herramienta para el preprocesamiento de datos antes de que se apliquen técnicas

de aprendizaje supervisado. El PCA produce una representación de baja dimensión de un conjunto de datos. Encuentra secuencialmente un conjunto de combinaciones lineales de los predictores que tienen una varianza máxima y son ortogonales entre sí.

El análisis de componentes principales asume que las variables individuales pueden ser descritas por una combinación lineal de factores; es decir, esos factores representan completamente la varianza de las variables. El primer componente principal de un conjunto de características denominadas como $X_1, X_2, \dots, X_K$ es la combinación lineal de las características o predictores X :

$$Z_1 = \phi_{11}X_1 + \phi_{21}X_2 + \dots + \phi_{K1}X_K \quad (11.15)$$

que tiene la mayor varianza, donde ϕ_{j1} satisface:

$$\sum_{j=1}^K \phi_{j1}^2 = 1 \quad (11.16)$$

Los coeficientes ϕ_{ji} se llaman cargas y se pueden encontrar utilizando una descomposición en valores singulares de la matriz X de dimensión $n \times K$. El segundo componente principal es la combinación lineal de $X_1, \dots, X_K$ que tiene máxima varianza entre todas las combinaciones lineales que son ortogonales con Z_1 . Así, el segundo componente sería:

$$Z_2 = \phi_{12}X_1 + \phi_{22}X_2 + \dots + \phi_{K2}X_K \quad (11.17)$$

donde el coeficiente ϕ_2 es el vector de carga del segundo componente principal, satisfaciendo $\phi_1 \cdot \phi_2 = 0$, es decir, $\phi_1 \perp \phi_2$. Este proceso continúa hasta que se encuentren todos los componentes principales $K^* = \min(n - 1, K)$. Aquí, los productos internos $\phi_i \cdot \phi_j = 0$ y $Z_i \cdot Z_j = 0$ para todos $i \neq j$.

El significado de las cargas se puede interpretar de la siguiente manera:

1. El vector de carga ϕ_1 con elementos $\phi_{11}, \phi_{21}, \dots, \phi_{K1}$ define una dirección en el espacio de características a lo largo de la cual los datos varían más.
2. Las direcciones de los componentes principales $\phi_1, \phi_2, \dots, \phi_K$ son la secuencia ordenada de vectores singulares derechos de la matriz X , y las varianzas de los componentes son $1/n$ veces los cuadrados de los valores singulares.

3. El vector de carga ϕ_1 define la línea en el espacio K -dimensional que está más cerca de las n observaciones en términos de distancia euclidiana cuadrada media.

Asumiendo que las variables han sido centradas para tener media cero, la varianza total observada es:

$$\sum_{j=1}^K \text{Var}(X_j) = \sum_{j=1}^K \frac{1}{N} \sum_{i=1}^N x_{ij}^2. \quad (11.18)$$

y la varianza explicada por el m -ésimo componente principal es:

$$\text{Var}(Z_m) = \frac{1}{N} \sum_{i=1}^N z_{im}^2. \quad (11.19)$$

Por lo tanto, la varianza proporcional explicada por el m -ésimo componente principal se da por la cantidad positiva entre 0 y 1.

$$\frac{\sum_{i=1}^N z_{im}^2}{\sum_{j=1}^K \sum_{i=1}^N x_{ij}^2}. \quad (11.20)$$

Una de las desventajas de usar PCA es que las características transformadas Z no son tan intuitivas como las medidas originales X ; reduciendo las posibilidades de interpretación.

11.4.2. Análisis Factorial

El análisis factorial o análisis de factores usa la correlación entre los artículos o elementos individuales para reducirlos a un número pequeño de dimensiones independientes o factores, sin suponer la unidimensionalidad de la escala. La matriz de correlación de los elementos indica cuales exhiben patrones similares de respuesta. Esos elementos son agrupados en factores.

En contraste con el análisis de componentes principales, el análisis de factores o factorial asume que la varianza de la variable puede ser separada en dos partes. La primera está determinada por la varianza conjunta de todas las variables incluidas en el análisis, llamada **comunalidad**. La otra parte está determinada por la varianza específica de la variable en cuestión, llamada **unicidad** y que incluye tanto la variación propia de la variable como el error

de medición. Bajo el enfoque de análisis de factores, los factores explican sólo el primer componente de la varianza.

Formalmente, el modelo factorial con m factores comunes postula que cada variable observada, previamente estandarizada, se descompone como:

$$X_j = \ell_{j1}F_1 + \ell_{j2}F_2 + \dots + \ell_{jm}F_m + u_j \quad (11.21)$$

Donde los F_h son los factores comunes no observados, los ℓ_{jh} son las cargas factoriales y u_j es el componente específico de la variable j , no correlacionado con los factores ni con los componentes específicos de las demás variables. Bajo estos supuestos la varianza de cada variable se separa exactamente en las dos partes que describimos.

La distinción respecto del análisis de componentes principales es entonces la siguiente. El PCA es un procedimiento puramente algebraico que construye combinaciones lineales de las variables observadas para maximizar la varianza explicada, sin postular ningún modelo generador de los datos. El análisis factorial, en cambio, **sí postula un modelo** — la ecuación (11.21) — con variables latentes y un término de error, y por lo tanto es estimable, contrastable y sujeto a que sus supuestos se cumplan o no. Una consecuencia de esta diferencia es que las cargas factoriales están identificadas sólo hasta una rotación, lo cual da lugar a los distintos criterios de rotación (varimax, oblimin, entre otros) que se emplean para facilitar la interpretación.

11.4.3. Clúster

El término clúster refiere a un grupo de individuos u objetos que convergen alrededor de cierto punto y son relativamente cercanos en su posición. En astronomía, existen clústeres de estrellas; en química hay clústeres de átomos. En el campo de la economía en ocasiones se refiere a técnicas que consideran grupos dentro del total de la población. Por ejemplo, las empresas que buscan analizar un grupo de potenciales clientes podrían buscar dividir el total de consumidores en segmentos o clústeres.

El propósito del análisis de clúster es identificar clústeres homogéneos dentro de un conjunto de individuos u objetos heterogéneos. No obstante, hay un mal entendido muy común en el análisis de clúster. Este es la creencia de que existe sólo un tipo de técnica de análisis de clúster. En la realidad, existen muchas técnicas de clústering. Esto se deriva de que existen una amplia variedad de métricas de distancia y algoritmos de agrupamiento que pueden ser usados.

En general, se pueden identificar 2 tipos generales de métodos de clúster:

1. Análisis de agrupamiento del tipo k -Means
2. Análisis de clúster jerárquico

El agrupamiento o clustering se refiere a un conjunto muy amplio de técnicas para encontrar subgrupos, o clústeres, en un conjunto de datos. El objetivo del agrupamiento es encontrar una partición de los datos en grupos distintos de modo que las observaciones dentro de cada grupo sean bastante similares entre sí en algún sentido. Tal sentido de similitud a menudo es una consideración específica del dominio que debe realizarse con base en el conocimiento de los datos que se estudian. La similitud debe estar relacionada con algún resultado vago o posibles múltiples resultados/propósitos.

En las bibliotecas, organizamos los libros por diferentes categorías y subcategorías, mientras que tales selecciones de categorías y subcategorías se basan en las necesidades de los clientes que a menudo no están claramente definidas. En casa, organizamos nuestras cosas en ropa, zapatos, utensilios de cocina y otros para conveniencia cuando los usamos. Por lo tanto, el agrupamiento debe tener algunos propósitos que son difíciles de caracterizar usando una medida de resultado simple. Por esta razón, el aprendizaje supervisado no es aplicable al problema.

Un buen ejemplo de agrupamiento en el comercio sería el agrupamiento para la segmentación del mercado. Supongamos que tenemos acceso a grandes datos (por ejemplo, ingreso medio del hogar, ocupación, distancia desde el área urbana más cercana) de un gran número de personas que pueden o no ser nuestros clientes existentes. Nuestro objetivo es identificar subgrupos de personas que podrían ser más receptivas a una forma particular de publicidad, o agruparlos (en términos de datos) de acuerdo con la probabilidad de comprar un producto en particular.

A diferencia del PCA, que busca una representación de baja dimensión de las observaciones que explica una buena fracción de la varianza, el agrupamiento busca subgrupos homogéneos entre las observaciones.

Hay dos métodos de agrupamiento comúnmente utilizados: el agrupamiento K-medias y el agrupamiento jerárquico. En el agrupamiento K-medias, buscamos particionar las observaciones en un número preespecificado de clústeres, mientras que en el agrupamiento jerárquico no sabemos de antemano cuántos clústeres queremos. En cambio, el agrupamiento jerárquico




Figura 11.6: US Arrest Hierarchical Clustering, retomado de Chang (2020, p 216) [Cha20]

terminará con una representación visual en forma de árbol de las observaciones, llamada dendrograma, que nos permite ver de una vez el agrupamiento obtenido para cada número posible de clústeres (Figura 11.6).

K-Means Clustering

Algoritmo K-Means

El clústering K-Means es un método de análisis que agrupa observaciones en clústeres. Las principales diferencias entre k-means y el clústering jerárquico es que los usuarios de k-means deciden el número de clústeres desde el inicio. Es decir, desde un inicio, determinamos una partición inicial que asumimos.

El algoritmo de k-means tiene los siguientes requerimientos:

1. Conocimiento sobre el mejor número de clústeres.
2. Las variables deberían estar transformadas como con la transformación

z .

El algoritmo K-medias es uno de los métodos de agrupamiento más simples y populares. Sea $X = \{x_i; i = 1, \dots, N\}$ el conjunto de observaciones y sean $C = \{c_1, c_2, \dots, c_k\}$ los centroides de los k clústeres. Denotemos por S_j el conjunto de observaciones asignadas al clúster j . Para un k dado, el objetivo del agrupamiento es encontrar la partición $\{S_1, \dots, S_k\}$ y los centroides que minimizan la suma de distancias euclidianas al cuadrado dentro de los clústeres:

$$\min_{\{S_j\}, \{c_j\}} \sum_{j=1}^k \sum_{x_i \in S_j} \|x_i - c_j\|^2 \quad (11.22)$$

Es importante notar que la distancia entra **al cuadrado**: es esa elección la que hace que el centroide óptimo de cada clúster sea precisamente su media aritmética, y de ahí el nombre del método. Si en la ecuación (11.22) se utilizara la distancia sin elevar al cuadrado, el óptimo sería la mediana y obtendríamos un algoritmo distinto.

El algoritmo K-medias se describe de la siguiente manera:

1. Escoger aleatoriamente k puntos de datos de X como el clúster inicial C .
2. Reasignar todos $x_i \in X$ al promedio de clúster más cercano c_j .
3. Actualizar todos $c_j \in C$ con la media de sus clústeres correspondientes.
4. Repetir los pasos 2 y 3 hasta que las asignaciones de clúster no cambien.

La convergencia del algoritmo está garantizada en un número finito de iteraciones, ya que cada paso reduce el valor de la función objetivo de la ecuación (11.22) y el número de particiones posibles es finito. Sin embargo, la convergencia es sólo a un **óptimo local**: aunque la función objetivo es convexa en los centroides para una asignación dada, el problema conjunto de elegir simultáneamente la partición y los centroides no lo es. La consecuencia práctica es que el resultado depende de los valores iniciales, por lo que la recomendación estándar es ejecutar el algoritmo varias veces con distintos puntos de partida y conservar la solución con menor valor objetivo. El algoritmo también es sensible a los valores atípicos y puede producir clústeres vacíos. Aquí hemos asumido que k es fijo; el problema de agrupamiento con k variable es muy desafiante desde el punto de vista computacional.




Figura 11.7: K-Means algorithm, retomado de Ng (2023, p 146) [Ng23]

Conviene no confundir este método con el de **k-medoides**, que es un algoritmo distinto: en él los centros deben ser observaciones efectivamente presentes en los datos — llamadas medoides — y no promedios, y suele minimizarse la distancia sin elevar al cuadrado. Esto lo hace considerablemente más robusto a valores atípicos, a costa de un mayor esfuerzo de cálculo. La Figura 11.7 ilustra el proceso de determinación de centroides del algoritmo K-medias.

Clustering Jerárquico

El agrupamiento jerárquico busca construir una jerarquía de clústeres. Las estrategias para el agrupamiento jerárquico pueden ser aglomerativas o divisivas. Una estrategia aglomerativa es un enfoque de abajo hacia arriba, es decir, cada observación comienza en su propio clúster, y pares de clústeres se fusionan a medida que se asciende en la jerarquía. Una estrategia divisiva es un enfoque de arriba hacia abajo, es decir, todas las observaciones comienzan en un clúster, y se realizan divisiones de forma recursiva a medida que se desciende en la jerarquía. Por su parte, el agrupamiento divisivo con una búsqueda exhaustiva tiene una complejidad de $O(2^n)$, pero es común utilizar heurísticas más rápidas para elegir las divisiones, como K-Medias.




Figura 11.8: Agglomerative Clustering Algorithm and Dendrogram, retomado de Chang (2020, p 219) [Cha20]

Los resultados del agrupamiento jerárquico generalmente se presentan en un dendrograma.

Para decidir qué clústeres se deben combinar (estrategia aglomerativa) o dónde se debe dividir un clúster (estrategia divisiva), se requiere una medida de disimilitud o similitud entre conjuntos de observaciones, como distancia o enlace entre pares de observaciones. La distancia puede ser Euclidiana, Euclidiana al cuadrado, Manhattan, máxima, Mahalanobis, entre otras. El criterio de enlace puede ser agrupamiento de enlace completo, $\max\{d(a, b); a \in A, b \in B\}$, agrupamiento de enlace simple, $\min\{d(a, b); a \in A, b \in B\}$, o agrupamiento de enlace promedio, $\frac{1}{|A| \cdot |B|} \sum_{a \in A} \sum_{b \in B} d(a, b)$. El enlace simple sufre de encadenamiento porque para fusionar dos grupos, sólo se necesita que un par de puntos esté cerca, independientemente de todos los demás. Por lo tanto, los clústeres pueden estar demasiado dispersos. En contraste, el enlace completo evita el encadenamiento, pero sufre de hacinamiento. El enlace promedio intenta, utilizando la disimilitud promedio por pares, establecer un equilibrio.

Una lección importante que la experiencia ha mostrado es que las medidas de distancia en el análisis de clúster deben basarse en unidades comparables de medida. Si las características consideradas en el análisis de clúster están en unidades distintas, las variables podrían pasarse por una de las posibles técnicas de unificación de medida. Usualmente, esto se logra mediante la

aplicación de la transformación z de todas las variables con el objetivo de estandarizarlas.

Existen 5 métodos de vinculación para clústering jerárquico aglomerativo:

1. Método simple de vinculación que usa la cercanía de 2 observaciones de 2 clústeres como la base de la medida de distancia.
2. Método de vinculación completa que, en contraste, usa las 2 observaciones de 2 clústeres más lejanos como la base de la distancia.
3. Método de vinculación del centroide que calcula el punto medio para cada clúster de sus observaciones.
4. Método de vinculación promedio que determina la media de la distancia entre las observaciones de 2 clústeres.
5. Método de Ward (propuesto por Joe H. Ward en 1963) que vincula clústeres que optimizan un criterio específico: la suma de los errores al cuadrado. Este criterio minimiza la varianza total dentro del clúster. Al igual que otros métodos jerárquicos, este inicia considerando cada observación como si fuera en sí misma un clúster. En este caso, la suma de errores al cuadrado asume el valor de cero, como la media de cada observación. Para calcular la suma de errores para todas las posibles combinaciones de siguientes vínculos se eligen los clústeres que producen el menor incremento en la suma de errores.

11.4.4. Agrupamiento de datos de series temporales

Las observaciones reales de series temporales se pueden agrupar, así como las características extraídas de las mismas, en clusters. Las características se extraen en los dominios de tiempo, frecuencia y ondículas.

La agrupación mediante características del dominio temporal son autocorrelaciones, autocorrelaciones parciales y correlaciones cruzadas. Mientras que, en el dominio de la frecuencia, se extraen características como el periodograma y las ordenadas espectrales y cepstrales. Por último, las características extraídas en el dominio de wavelets son las transformadas discretas de ondículas, las varianzas de ondículas y las correlaciones de ondículas.

Medidas de Distancia

En muchos casos, se utiliza el análisis de clustering tradicional, es decir, el clustering jerárquico, para agrupar series temporales. En este caso, primero se define una medida de distancia adecuada que hereda las características dinámicas de la serie temporal para comparar series temporales, y luego se aplica un análisis de clustering jerárquico estándar utilizando la distancia definida.

Sea $\mathbf{X} = \{x_{ij} : i = 1, \dots, I; j = 1, \dots, J\} = \{\mathbf{x}_i = (x_{i1}, \dots, x_{ij}, \dots, x_{iJ})' : i = 1, \dots, I\}$ la matriz de datos dónde x_{ij} representa la j -ésima variable observada en el i -ésimo elemento y $\mathbf{x}_i$ representa el vector de la i -ésima observación. La clase más común de medida de distancia utilizada en el análisis de clusters es la clase de distancia de Minkowski.

$${}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \quad r \geq 1. \quad (11.23)$$

Para $r = 1$, tenemos la distancia Manhattan:

$${}_1 d_{il} = \sum_{j=1}^J |x_{ij} - x_{lj}| \quad (11.24)$$

y para $r = 2$, tenemos la distancia Euclidiana:

$${}_2 d_{il} = \left[\sum_{j=1}^J (x_{ij} - x_{lj})^2 \right]^{\frac{1}{2}} \quad (11.25)$$

Las versiones ponderadas de las anteriores distancias de clase Minkowski son:

$${}_r \tilde{d}_{il} = \left[\sum_{j=1}^J w_j^r |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, \quad r \geq 1 \quad (11.26)$$

y entonces,

$$\begin{aligned}
{}_1\tilde{d}_{il} &= \sum_{j=1}^J w_j^1 |x_{jl} - x_{lj}| \quad (r = 1) \quad (\text{distancia Manhattan ponderada}) \\
{}_2\tilde{d}_{il} &= \left[\sum_{j=1}^J w_j^2 (x_{jl} - x_{lj})^2 \right]^{\frac{1}{2}} \quad (r = 2) \quad (\text{distancia Euclidiana ponderada})
\end{aligned} \tag{11.27}$$

dónde w_j ($j = 1, \dots, J$) representa una ponderación adecuada para la j -ésima variable.

Para utilizar las medidas de distancia en clustering jerárquico es útil obtener las distancias para cada par de unidades en forma de una matriz cuadrada. La matriz de distancia Minkowski puede ser representada de la siguiente manera:

$${}_r\mathbf{D} = \left\{ {}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}} : i, l = 1, \dots, I \right\}, \quad r \geq 1 \tag{11.28}$$

Clustering Jerárquico Aglomerativo

Los métodos aglomerativos producen una serie de particiones de los datos: el primero consiste en un cluster I de un solo miembro; el último consiste en un solo cluster que contiene todas las unidades I . El clustering aglomerativo comienza con I clusters, donde cada uno incluye exactamente un punto de los datos. Posteriormente, sucede una serie de operaciones de unión que eventualmente fuerza a todos los objetos en un mismo grupo. El clustering aglomerativo general puede ser resumido por el siguiente procedimiento:

1. Empieza con I clusters únicos (singleton). Calcula la matriz de distancias para los I clusters;
2. En la matriz de distancia, busca la mínima distancia $d(C_p, C_q) = \min_{\substack{1 \leq p, q \leq I \\ p \neq q}} d(C_p, C_q)$, dónde $d(\cdot, \cdot)$ es la función de distancia, y por último combina los cluster C_c y $C_{c'}$ para formar el nuevo cluster $C_{cc'}$;

3. Actualiza la matriz de distancia calculando las distancias entre el cluster $C_{cc'}$ y los demás clusters;
4. Repite los pasos 2 y 3 hasta que sólo quede un cluster.

La unión de un par de clusters, o la formación de un nuevo cluster depende de como esté definida la función de distancia entre dos clusters. A continuación se presentan de forma breve algunas formas de definir la función de distancia.

- *Método de enlace simple*: La distancia entre un par de clusters está determinada por las dos unidades más cercanas a los diferentes clusters. El clustering por enlace simple tiende a generar clusters alargados, lo que causa el efecto de encadenamiento. Como resultado, dos clusters con propiedades muy diferentes pueden estar conectados debido a la existencia de perturbaciones. Sin embargo, si los cluster están muy separados, el método de enlace simple funciona bien.
- *Método de enlace completo*: A diferencia del enlace simple, el método de enlace completo utiliza la distancia más lejana de un par de objetos para definir la distancia entre grupos.
- *Método de enlace de promedios grupales*: La distancia entre dos clusters se define como el promedio de las distancias entre todos los pares de puntos de datos, cada uno de los cuales proviene de un cluster diferente.
- *Método de enlace de promedios ponderados*: Similar a los promedios grupales, el enlace promedio también se utiliza para calcular la distancia entre dos clusters. La diferencia radica en que las distancias entre el cluster recién formado y el resto se ponderan en función del número de puntos de datos en cada cluster.
- *Método de enlace de centroides*: Dos clusters se unen según la distancia de sus centroides (media).
- *Método de Ward o de la mínima varianza*: El objetivo del método de Ward es minimizar el aumento de la suma intraclase de los errores cuadrados.

Clustering No Jerárquico

A diferencia del clustering jerárquico, que genera un nivel sucesivo de clusters mediante fusiones o divisiones iterativas, el clustering no jerárquico o por particiones asigna un conjunto de puntos de datos en c clusters sin ninguna estructura jerárquica. Este proceso suele acompañar la optimización de una función criterio, normalmente la minimización de una función objetivo que representa la variabilidad interna de los clusters.

Método de clustering por c-Medias

También conocido como k-Medias, el método c-Medias busca una partición óptima de los datos minimizando el criterio de suma de errores al cuadrado con un procedimiento de optimización iterativo, que pertenece a la categoría de algoritmos hill-climbing. El procedimiento básico de clustering de c-Medias se resume de la siguiente manera:

1. Inicie con c particiones aleatorias o basadas en algún conocimiento previo. Calcule los prototipos de clusters (centroides o medias), es decir, calcule la media de cada cluster considerando sólo las observaciones que pertenecen a cada cluster.
2. Asigne cada unidad del conjunto de datos al grupo más cercano utilizando una medida de distancia adecuada entre cada par de unidades y centroides.
3. Recalcular los prototipos de clusters (centroides o medias) en función de la partición actual.
4. Repita los pasos 2 y 3 hasta que no haya cambios para cada cluster.

El método de c-Medias formalizado matemáticamente es de la siguiente forma:

$$\min : \sum_{i=1}^I \sum_{c=1}^C u_{ic} d_{ic}^2 = \sum_{i=1}^I \sum_{c=1}^C u_{ic} \|\mathbf{x}_i - \mathbf{h}_c\|^2, \quad (11.29)$$

$$\sum_{c=1}^C u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \quad (11.30)$$

donde u_{ic} indica el grado de pertenencia de la unidad i -ésima al clúster c -ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i -ésima pertenece al clúster c -ésimo; $u_{ic} = 0$ en caso contrario; $d_{ic}^2 = \|\mathbf{x}_i - \mathbf{h}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i -ésimo y el centroide del clúster c -ésimo.

Método de clustering por c-Medoides.

Las unidades se clasifican en clusters representados por uno de los puntos de datos del cluster. Estos puntos de datos son los prototipos, los llamados medoides. Cada medoide sintetiza la información del cluster y representa las características prototípicas de los clusters, y luego sintetiza las características de las unidades pertenecientes a cada cluster. Siguiendo el método de agrupamiento de c-medoides, minimizamos la función objetivo representada por la suma de la disimilitud de las unidades con sus unidades representativas más cercanas. El método de clustering por c-medoides primero calcula un conjunto de unidades representativas, los medoides. Tras encontrar el conjunto de medoides, cada unidad del conjunto de datos se asigna a las unidades medoides más cercanas. El algoritmo sugerido por Kaufman y Rousseeuw (1990) para el método de clustering por c-medoides se desarrolla en dos fases:

Fase 1 (*CONSTRUCCIÓN*): Esta fase selecciona secuencialmente c unidades “centralmente localizadas” para ser utilizadas como medoides iniciales.

Fase 2 (*INTERCAMBIO*): Si la función objetivo puede reducirse intercambiando una unidad seleccionada con una no seleccionada, entonces se realiza el intercambio. Esto se repite hasta que la función objetivo ya no pueda ser disminuida. Luego, considerando un conjunto de I unidades representado por $\mathbf{X}$ (conjunto de las observaciones) y un subconjunto de $\mathbf{X}$ con C unidades representado por $\tilde{\mathbf{X}}$ (conjunto de los medoides), donde $C \ll I$, podemos formalizar el modelo de la siguiente manera:

$$\text{mín : } \sum_{i=1}^I \sum_{c=1}^C u_{ic} \tilde{d}_{ic}^2 = \sum_{i=1}^I \sum_{c=1}^C u_{ic} \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2, \quad (11.31)$$

$$\sum_{c=1}^C u_{ic} = 1, \quad u_{ic} \geq 0, \quad u_{ic} \in \{0, 1\} \quad (11.32)$$

donde u_{ic} indica el grado de pertenencia de la unidad i -ésima al cluster c -ésimo; $u_{ic} \in \{0, 1\}$, es decir, $u_{ic} = 1$ cuando la unidad i -ésima pertenece al

cluster c -ésimo; $u_{ic} = 0$ en caso contrario; $\tilde{d}_{ic}^2 = \|\mathbf{x}_i - \tilde{\mathbf{x}}_c\|^2$ indica la distancia euclidiana al cuadrado entre el objeto i -ésimo y el medoide del clúster c -ésimo.

Algunos criterios útiles de validez para determinar el número de clusters son los siguientes:

Criterio de Calinski y Harabasz

Calinski y Harabasz (1974) sugieren tomar el valor de g , el número de clústeres, el cual corresponde al valor máximo de CH_C :

$$CH_C = \frac{\text{trace}(\mathbf{B})}{(C - 1)} : \frac{\text{trace}(\mathbf{W})}{(I - C)}.$$

donde $\mathbf{B}$ es la matriz de dispersión entre grupos y $\mathbf{W}$ es la matriz de dispersión dentro de los grupos. La evaluación de este criterio en un número dado de grupos, C , requiere conocer la pertenencia a los grupos para determinar las matrices $\mathbf{B}$ y $\mathbf{W}$. En general, el número de grupos elegido depende del método de clúster utilizado.

Criterio de la silueta

Este criterio fue propuesto por Rousseeuw (1987). Considere una unidad $i \in (1, \dots, I)$ perteneciente al cluster $p \in (1, \dots, C)$. Por ejemplo, mediante un algoritmo de clustering *c-Medias*, esto significa que la unidad i -ésima está más cerca del centroide del cluster p -ésimo que de cualquier otro centroide.

Sea la distancia promedio (euclidiana al cuadrado) de la unidad i -ésima a todas las demás unidades que pertenecen al clúster p denotada por a_{ip} . Asimismo, sea la distancia promedio de esta unidad a todas las unidades que pertenecen a otro clúster q , $q \neq p$, llamada d_{iq} .

Finalmente, sea b_{ip} el mínimo d_{iq} calculado sobre $q = 1, \dots, C$, $q \neq p$, lo cual representa la disimilitud de la unidad i -ésima con respecto a su cluster vecino más cercano.

Entonces, la silueta del objeto i -ésimo se define de la siguiente manera:

$$S_i = \frac{b_{ip} - a_{ip}}{\max\{a_{ip}, b_{ip}\}} \quad (11.33)$$

donde el denominador es un término de normalización. Mientras mayor sea el valor de S_i , mejor es la asignación de la unidad i -ésima al cluster c -ésimo. La silueta, definida como el promedio de S_i para $i = 1, \dots, I$, es:

$$SIL = \frac{1}{I} \sum_{i=1}^I S_i \quad (11.34)$$

La mejor partición se logra cuando la silueta se maximiza, lo cual implica minimizar la distancia intra-cluster (a_{ip}) mientras se maximiza la distancia inter-cluster (b_{ip}).

11.5. Aplicación de modelos de regresión de respuesta binaria

11.5.1. Modelos de respuesta binaria y ordenada: resumen operativo

Los modelos de elección discreta que desarrollamos con detalle en el capítulo de Estimación de modelos no lineales son, vistos desde la perspectiva del aprendizaje estadístico, **modelos de clasificación**. En esta sección los recuperamos en la forma que necesitamos para aplicarlos, con el énfasis puesto en la predicción y no en la inferencia sobre los parámetros. Presentamos aquí los resultados operativos completos, de modo que la sección pueda leerse de forma autónoma, y remitimos al capítulo referido únicamente para las derivaciones a partir de la variable latente y las demostraciones de las propiedades de los estimadores.

Conviene explicitar el cambio de énfasis, porque es la diferencia central entre ambos capítulos y no un mero cambio de vocabulario:

Modelos de respuesta binaria

Sea y_i una variable que toma únicamente los valores 0 y 1, y sea $\mathbf{x}_i = (x_{i1}, x_{i2}, \dots, x_{iK})$ un vector de variables explicativas. El objeto que modelamos es la probabilidad de respuesta:

$$P(y_i = 1 \mid \mathbf{x}_i) = G(\mathbf{x}_i \boldsymbol{\beta}) \quad (11.35)$$

Donde $G(\cdot)$ es una función que toma valores en el intervalo $(0, 1)$. La razón por la que no utilizamos un modelo lineal de probabilidad, es decir $G(\mathbf{x}_i \boldsymbol{\beta}) = \mathbf{x}_i \boldsymbol{\beta}$, es que este puede producir probabilidades ajustadas fuera

Cuadro 11.2: Dos lecturas del mismo modelo

	Enfoque econométrico	Enfoque de aprendizaje estadístico
Objeto de interés	β y los efectos marginales	$\hat{y}$ fuera de la muestra
Criterio de éxito	Inssegamiento, consistencia, eficiencia	Error de predicción en datos nuevos
Uso de la muestra	Se usa toda para estimar	Se separa en entrenamiento y prueba
Riesgo principal	Sesgo por endogeneidad	Sobreajuste
Diagnóstico típico	Errores estándar, pruebas de hipótesis	Matriz de confusión, validación cruzada

del intervalo $[0, 1]$ y genera errores necesariamente heterocedásticos. Las dos elecciones habituales de $G(\cdot)$ son:

$$\text{Logit: } G(z) = \Lambda(z) = \frac{\exp(z)}{1 + \exp(z)} \quad (11.36)$$

$$\text{Probit: } G(z) = \Phi(z) = \int_{-\infty}^z \phi(v)dv \quad (11.37)$$

Donde $\Lambda(\cdot)$ es la función de distribución acumulada logística y $\Phi(\cdot)$ la de la normal estándar. Ambas producen resultados muy similares en la práctica, ya que difieren esencialmente en la escala: los coeficientes del logit suelen ser aproximadamente 1.6 veces los del probit, pero los efectos marginales y las probabilidades ajustadas resultan casi idénticos.

Un punto que debe subrayarse, porque es la fuente de error de interpretación más frecuente en estos modelos, es que β_k **no es** el efecto marginal de x_{ik} . Derivando la ecuación (11.35) respecto de una variable continua:

$$\frac{\partial P(y_i = 1 \mid \mathbf{x}_i)}{\partial x_{ik}} = g(\mathbf{x}_i \boldsymbol{\beta}) \beta_k \quad (11.38)$$

Donde $g(z) = \partial G(z)/\partial z$ es la función de densidad correspondiente. El efecto marginal depende entonces del punto $\mathbf{x}_i$ en el que se evalúe, por lo que en la práctica se reporta el efecto marginal en la media de las variables o bien el promedio de los efectos marginales individuales. Lo único que β_k determina de manera inequívoca es el *signo* del efecto, ya que $g(\cdot) > 0$ siempre.

La estimación se realiza por máxima verosimilitud, con la log-verosimilitud:

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^N \{y_i \ln G(\mathbf{x}_i \boldsymbol{\beta}) + (1 - y_i) \ln [1 - G(\mathbf{x}_i \boldsymbol{\beta})]\} \quad (11.39)$$

Que se maximiza numéricamente. Puede demostrarse que la ecuación (11.39) es globalmente cóncava tanto para el logit como para el probit, lo que garantiza que el óptimo encontrado es único.

Para efectos de *clasificación* necesitamos además una regla de decisión que convierta la probabilidad estimada en una predicción. La regla habitual es $\hat{y}_i = 1$ si $\hat{P}(y_i = 1 \mid \mathbf{x}_i) > c$, con un umbral $c = 0.5$ por omisión. La elección del umbral no es inocua y debe responder al costo relativo de los dos tipos de error, punto que retomamos al discutir la matriz de confusión.

Modelos de respuesta multinomial

Cuando la variable dependiente toma $J+1$ valores sin orden natural entre ellos, por ejemplo el medio de transporte elegido o la carrera universitaria cursada, utilizamos el modelo logit multinomial. Fijando la categoría 0 como base o de referencia, las probabilidades son:

$$P(y_i = j \mid \mathbf{x}_i) = \frac{\exp(\mathbf{x}_i \boldsymbol{\beta}_j)}{1 + \sum_{h=1}^J \exp(\mathbf{x}_i \boldsymbol{\beta}_h)}, \quad j = 1, 2, \dots, J \quad (11.40)$$

Y para la categoría base:

$$P(y_i = 0 \mid \mathbf{x}_i) = \frac{1}{1 + \sum_{h=1}^J \exp(\mathbf{x}_i \boldsymbol{\beta}_h)}$$

La normalización $\boldsymbol{\beta}_0 = \mathbf{0}$ es necesaria para la identificación: sin ella podríamos sumar un mismo vector a todos los $\boldsymbol{\beta}_j$ sin alterar ninguna probabilidad. En consecuencia, todos los coeficientes se interpretan siempre *en relación con la categoría base*, y cambiar la categoría de referencia cambia los coeficientes reportados aunque no las probabilidades ajustadas.

Este modelo impone una restricción importante conocida como **independencia de alternativas irrelevantes**: el cociente de probabilidades entre dos alternativas cualesquiera no depende de qué otras alternativas estén disponibles. Se trata de un supuesto con frecuencia poco realista, y la discusión detallada de sus implicaciones se encuentra en el capítulo de modelos no lineales.

Modelos de respuesta ordenada

Cuando las categorías sí guardan un orden natural — niveles de calificación, grados de satisfacción, categorías de ingreso — utilizamos el logit o el probit ordenado. Sea $y_i \in \{0, 1, \dots, J\}$ y sea y_i^* una variable latente no observable:

$$y_i^* = \mathbf{x}_i \boldsymbol{\beta} + \varepsilon_i \quad (11.41)$$

Donde $\mathbf{x}_i$ **no incluye término constante**, ya que su papel lo cumplen los umbrales. Sean $\mu_1 < \mu_2 < \dots < \mu_J$ un conjunto de parámetros de corte, de modo que observamos:

$$y_i = j \quad \text{si} \quad \mu_j < y_i^* \leq \mu_{j+1} \quad (11.42)$$

Con $\mu_0 = -\infty$ y $\mu_{J+1} = +\infty$. De aquí se obtienen directamente las probabilidades de cada categoría:

$$P(y_i = j \mid \mathbf{x}_i) = F(\mu_{j+1} - \mathbf{x}_i \boldsymbol{\beta}) - F(\mu_j - \mathbf{x}_i \boldsymbol{\beta}) \quad (11.43)$$

Donde $F(\cdot)$ es la función de distribución acumulada de ε_i , logística o normal estándar según el modelo elegido. La derivación de la ecuación (11.43) a partir de la variable latente, así como la discusión de por qué $\mathbf{X}$ no puede contener un término constante, se encuentran desarrolladas en el capítulo de modelos no lineales.

Los efectos marginales en este modelo requieren cuidado adicional, ya que un incremento en x_{ik} aumenta la probabilidad de unas categorías y la reduce de otras. Para la categoría j :

$$\frac{\partial P(y_i = j \mid \mathbf{x}_i)}{\partial x_{ik}} = \beta_k [f(\mu_j - \mathbf{x}_i \boldsymbol{\beta}) - f(\mu_{j+1} - \mathbf{x}_i \boldsymbol{\beta})] \quad (11.44)$$

Notemos que el signo del efecto marginal sobre una categoría intermedia **no** coincide necesariamente con el signo de β_k . Lo único que puede afirmarse en general es que un β_k positivo reduce la probabilidad de la categoría más baja y aumenta la de la más alta. Este es un punto en el que se cometen errores de interpretación con mucha frecuencia.

La estimación de los tres modelos se realiza por máxima verosimilitud, siguiendo exactamente el procedimiento general del capítulo de métodos de estimación basados en verosimilitud; los detalles de la construcción de cada función de verosimilitud y las propiedades asintóticas de los estimadores se encuentran en el capítulo de modelos no lineales.



Figura 11.9: División del conjunto de datos, retomado de Hastie, Tibshirani, y Friedman (2017, p. 222) [HTF17]

Ajuste y separación del conjunto de datos

De forma similar al caso de regresión, dividiremos al conjunto de datos conforme se describe en la Figura 11.9.

Evaluando los modelos de aprendizaje supervisado

Matriz de confusión

Una vez que se entrena un problema de aprendizaje automatizado supervisado en un conjunto de datos históricos, se prueba el modelo obtenido mediante el uso de datos del conjunto de entrenamiento. De esta forma, es posible comparar las predicciones del modelo entrenado con los valores reales de la variable sujeta de análisis. La matriz de confusión proporciona un medio para evaluar el éxito de un problema de clasificación y dónde se cometen errores (es decir, dónde se vuelve 'confuso').

En el Cuadro 11.3 se muestra un ejemplo de la forma en que se suele mostrar una matriz de confusión.

		Predicciones	
		Positivas (1)	Negativas (0)
Real	Positivas (1)	True Positive (TP)	False Negative (FN)
	Negativas (0)	False Positive (FP)	True Negative (TN)

Cuadro 11.3: Matriz de Confusión

Con base en la matriz de confusión en el Cuadro 11.3, se pueden construir métricas que se calculan de la siguiente manera:

$$Precision = \frac{TP}{TP + FP} \quad (11.45)$$

$$Recuperacion = \frac{TP}{TP + FN} \quad (11.46)$$

$$F1 = 2 \times \frac{Precision \times Recuperacion}{Precision + Recuperacion} \quad (11.47)$$

La medida $F1$ o $F1 - score$ combina precisión y recuperación mediante la media armónica de los dos valores. De esta forma, siempre se ubicará entre ambos indicadores.

11.5.2. Regresión logística con información de videojuegos.

Planteamiento del caso

Supuestos y necesidades del caso:

1. Determinar cuáles son las features/características/steam tags que se asocian con videojuegos para PC exitosos.
2. Hay varias tiendas de videojuegos (Steam, itch, etc.) que utilizan estas tags para clasificar los video juegos.

Propuesta: Usar un modelo de respuesta ordenada

Sea y una variable que representa una respuesta ordenada que toma valores $\{0, 1, 2, \dots, J\} \in \mathbb{Z}$. El modelo de respuesta ordenada (conocido como Probit o Logit ordenado) para y (condicional en un vector de variables explicativas $\mathbf{X}$ -features, características, tags, etc.-) es derivado a partir de un modelo de variable latente y^* , el cual se puede escribir como:

$$y^* = \mathbf{X}\boldsymbol{\beta} + \varepsilon, \varepsilon | \mathbf{X} \sim f(\varepsilon) \quad (11.48)$$

Donde $f(\cdot)$ es una función de densidad de probabilidad simétrica cuya función de densidad acumulada será denotada por $F(\cdot)$, $\boldsymbol{\beta}$ es un vector de dimensión $K \times 1$ y, por razones que más adelante explicamos, $\mathbf{X}$ no tiene término constante. Por otro lado, sean $\mu_1 < \mu_2 < \dots < \mu_J$ puntos de corte o parámetros umbrales que definen lo siguiente:

$$\begin{aligned} y = 0 & \quad \text{si} \quad y^* \leq \mu_1 \\ y = 1 & \quad \text{si} \quad \mu_1 < y^* \leq \mu_2 \\ & \quad \vdots \\ y = J & \quad \text{si} \quad y^* > \mu_J \end{aligned} \quad (11.49)$$

De esta forma, y considerando el conjunto de desigualdades en la ecuación (11.49) y la ecuación (11.48), podemos determinar las siguientes probabilidades a partir de una partición de una función de distribución dada:

$$\begin{aligned}
\mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_1|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_2|\mathbf{X}) \\
&= \mathbf{P}(\mu_1 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_2 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_2 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$\vdots$

$$\begin{aligned}
\mathbf{P}(y = J - 1|\mathbf{X}) &= \mathbf{P}(\mu_{J-1} < y^* \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_J - \mathbf{X}\boldsymbol{\beta}) - F(\mu_{J-1} - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = J|\mathbf{X}) &= \mathbf{P}(y^* > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_J|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_J - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_J - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

Note que en este caso asumimos que $\mathbf{X}$ no tiene término constante, ya que la incorporamos mediante los umbrales μ_j , $j = 1, 2, \dots, J$. Un caso particular de esta modelación son los modelos de clasificación binarios en los que $J = 1$. En la figura 11.10 ilustramos la partición de la función de densidad $f(\cdot)$ que resultaría de las ecuaciones anteriores.




Figura 11.10: Probabilidades en un modelo de respuesta ordenada, considerando $J = 4$ (retomado de Greene (2012, 788) [Gre12])

De esta manera, los resultados de la estimación se pueden interpretar a través de sus efectos marginales dados por:

$$\frac{\partial \mathbf{P}(y = j|\mathbf{X})}{\partial x_k} = -\beta_k(f(\mu_j - \mathbf{X}\boldsymbol{\beta}) - f(\mu_{j-1} - \mathbf{X}\boldsymbol{\beta})) \text{ para } 0 < j < J \quad (11.50)$$

Así, este efecto se interpreta como la contribución que tiene la variable x_k a la probabilidad de que la variable y tome el valor de j

Aplicación al caso de videojuegos

En el caso de los videojuegos, podemos aplicar el modelo de respuesta ordenada asumiendo algunas cosas. Primero, F tendrá una forma de función logística, para facilitar el proceso computacional. Segundo, la variable y será particionada en rangos de ingresos obtenidos por los videojuegos en su primer año (y^*)—año de lanzamiento—, por ejemplo:

$$y^* = \mathbf{X}\boldsymbol{\beta} + \varepsilon, \varepsilon|\mathbf{X} \sim f(\varepsilon)$$

Where y^* is the revenue per year, $\mathbf{X}$ are the characteristics and other variables of video games, $\boldsymbol{\beta}$ are the coefficients and ε is the error term.

$$\begin{aligned} y = 0 & \quad \text{if} \quad y^* \leq 1\text{M USD} \\ y = 1 & \quad \text{if} \quad 1 \text{ MM USD} < y^* \leq 5 \text{ MM USD} \\ y = 2 & \quad \text{if} \quad 5 \text{ MM USD} < y^* \leq 20 \text{ MM USD} \\ y = 3 & \quad \text{if} \quad y^* > 20 \text{ MM USD} \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 0|\mathbf{X}) &= \mathbf{P}(y^* \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_1|\mathbf{X}) \\ &= \mathbf{P}(\varepsilon \leq \mu_1 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\ &= F(\mu_1 - \mathbf{X}\boldsymbol{\beta}) \end{aligned}$$

$$\begin{aligned} \mathbf{P}(y = 1|\mathbf{X}) &= \mathbf{P}(\mu_1 < y^* \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_2|\mathbf{X}) \\ &= \mathbf{P}(\mu_1 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_2 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\ &= F(\mu_2 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}\boldsymbol{\beta}) \end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 2|\mathbf{X}) &= \mathbf{P}(\mu_2 < y^* \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 < \mathbf{X}\boldsymbol{\beta} + \varepsilon \leq \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mu_2 - \mathbf{X}\boldsymbol{\beta} < \varepsilon \leq \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= F(\mu_3 - \mathbf{X}\boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(y = 3|\mathbf{X}) &= \mathbf{P}(y^* > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\mathbf{X}\boldsymbol{\beta} + \varepsilon > \mu_3|\mathbf{X}) \\
&= \mathbf{P}(\varepsilon > \mu_3 - \mathbf{X}\boldsymbol{\beta}|\mathbf{X}) \\
&= 1 - F(\mu_3 - \mathbf{X}\boldsymbol{\beta})
\end{aligned}$$

$$\mathbf{P}(y = 0|\mathbf{X}) = \mu_1 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 1|\mathbf{X}) = \mu_2 - \mathbf{X}\boldsymbol{\beta}$$

$$\mathbf{P}(y = 2|\mathbf{X}) = \mu_3 - \mathbf{X}\boldsymbol{\beta}$$

Supongamos que tenemos n observaciones o, en este caso, videojuegos, los cuales son indexados con $i = 1, 2, 3, \dots, N$. Así, indexaremos a la variable de respuesta y como y_i , por lo que diremos que buscamos estimar las siguientes probabilidades:

$$\begin{aligned}
\mathbf{P}(\text{Revenue}_i \leq 1\text{M USD}|\mathbf{X}_i) &= \mathbf{P}(\varepsilon_i \leq \mu_1 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}
\mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD}|\mathbf{X}_i) &= \mathbf{P}(\mu_1 - \mathbf{X}_i\boldsymbol{\beta} < \varepsilon_i \leq \mu_2 - \mathbf{X}_i\boldsymbol{\beta}|\mathbf{X}_i) \\
&= F(\mu_2 - \mathbf{X}_i\boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i\boldsymbol{\beta})
\end{aligned}$$

$$\begin{aligned}\mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\mu_2 - \mathbf{X}_i \boldsymbol{\beta} < \varepsilon_i \leq \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\ &= F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})\end{aligned}$$

$$\begin{aligned}\mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) &= \mathbf{P}(\varepsilon_i > \mu_3 - \mathbf{X}_i \boldsymbol{\beta} | \mathbf{X}_i) \\ &= 1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta})\end{aligned}$$

Donde, particularmente, F es una función logística. Nuestro objetivo es maximizar la función de verosimilitud (función que maximiza el valor de los parámetros μ_1 , μ_2 , μ_3 y $\boldsymbol{\beta}$ dada la información disponible):

$$\begin{aligned}\mathbf{L}(\boldsymbol{\theta} | \text{Data}) &= \prod_{y_i=0} \mathbf{P}(\text{Revenue}_i \leq 1 \text{M USD} | \mathbf{X}_i) \\ &\quad \times \prod_{y_i=1} \mathbf{P}(1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i) \\ &\quad \times \prod_{y_i=2} \mathbf{P}(5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD} | \mathbf{X}_i) \\ &\quad \times \prod_{y_i=3} \mathbf{P}(\text{Revenue}_i > 20 \text{ MM USD} | \mathbf{X}_i) \\ &= \prod_{y_i=0} (F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=1} (F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\ &\quad \times \prod_{y_i=2} (F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})) \times \prod_{y_i=3} (1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}))\end{aligned}$$

Donde:

$$\boldsymbol{\theta} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \mu_3 \\ \boldsymbol{\beta} \end{bmatrix}$$

Así, el problema consiste en resolver:

$$\begin{aligned}
\max_{\theta} \mathbf{L}(\theta | \text{Data}) = & \prod_{\text{Revenue}_i \leq 1 \text{M USD}} (F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{1 \text{ MM USD} < \text{Revenue}_i \leq 5 \text{ MM USD} | \mathbf{X}_i} (F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_1 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{5 \text{ MM USD} < \text{Revenue}_i \leq 20 \text{ MM USD}} (F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}) - F(\mu_2 - \mathbf{X}_i \boldsymbol{\beta})) \\
& \times \prod_{\text{Revenue}_i > 20 \text{ MM USD}} (1 - F(\mu_3 - \mathbf{X}_i \boldsymbol{\beta}))
\end{aligned}$$

Datos

Usamos como fuente: <https://games-stats.com/>, una descarga de datos de 2021. La tabla de datos originalmente descargada contenía información de 53,650 videojuegos para computadora de los últimos 40 años, acumulando 18.5 billones de dólares.

La tabla de datos de games-stats.com se utilizó como base de datos central debido a su tamaño y variables disponibles. Fue validado con otros datos encontrados en línea, y tenían un tamaño similar entre ellos. Se agregaron más variables con el propósito de enriquecer el análisis.

Hay una gran cantidad de etiquetas (tags) encontradas en la tabla de datos, por lo que resulta complicado clasificar un juego en una sola categoría. Sin embargo, el valor de la etiqueta radica en el hecho de que son los usuarios quienes etiquetan un juego. Esto nos dice cómo un usuario percibe un juego. En total ubicamos 417 tags distintas.

En este caso, requerimos una reducción de dimensionalidad. El modelo debía evaluar más de 450 etiquetas diferentes, algo inviable. Tener 450 etiquetas para evaluar reduce la simplicidad e interpretabilidad del modelo. Así, aplicamos un par de metodologías:

- Extreme Random Decision Tree method: Que es una metodología de *machine learning* que ayudará a considerar menos variables dada la relevancia para los ingresos.
- Spearman Correlation: que muestra la correlación con los ingresos de determinadas variables y muestra también la significación estadística basada en una prueba t. Así, la etiqueta de un jugador tiene la correlación significativa más alta con los ingresos.

Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos	Tags	Juegos
Indie	36,782	Combat	3,866	Multiple Endings	2,065	Historical	1,313	Music	910	Demons	626
Action	25,650	Female Protagonist	3,857	Roguelike	2,054	Walking Simulator	1,312	Competitive	882	Destruction	616
Adventure	23,865	Violent	3,796	Puzzle Platformer	2,047	Resource Management	1,293	Dark Humor	881	Tactical RPG	616
Casual	23,618		3,677	War	1,994	Interactive Fiction	1,292	Aliens	880	Party-Based RPG	594
Singleplayer	23,597	Open World	3,604	Shoot 'Em Up	1,993	Memes	1,252	Clicker	872	Real-Time	589
2D	12,837	Sexual Content	3,598	Linear	1,849	Dungeon Crawler	1,240	Nature	866	2D Fighter	583
Strategy	11,854	Visual Novel	3,502	Character Customization	1,813	Score Attack	1,229	Driving	862	Automobile Sim	582
Simulation	11,569	Comedy	3,398	Hand-drawn	1,804	Dating Sim	1,225	Emotional	862	Match 3	581
RPG	11,097	Turn-Based	3,359	Old School	1,794	Survival	1,212	Flight	857	Rhythm	571
Puzzle	9,354	Action-Adventure	3,342	Massively Multiplayer	1,738	Top-Down Shooter	1,212	Arena Shooter	846	Moddable	565
Multiplayer	8,185	Co-op	3,295	Procedural Generation	1,738	Experimental	1,204	Detective	846	Nonlinear	553
Atmospheric	8,117	Top-Down	3,289	Action RPG	1,735	Post-apocalyptic	1,201	Party	845	Modern	551
Early Access	7,604	Management	3,287	Turn-Based Strategy	1,734	Mod	1,181	1980s	837	Tutorial	543
Platformer	7,103	Third Person	3,240	Replay Value	1,706	RTS	1,167	Perma Death	836	Dystopian	541
Story Rich	6,711	Cartoon	3,210	Classic	1,672	Isometric	1,151	Immersive Sim	824	Parkour	539
3D	6,584	Gore	3,205	Local Co-Op	1,651	Stealth	1,146	Investigation	820	Comic Book	534
Shooter	6,181	FPS	3,100	Online Co-Op	1,641	Dark Fantasy	1,127	Economy	815	Thriller	534
Pixel Graphics	6,174	Sports	2,943	Survival Horror	1,598	Education	1,127	Artificial Intelligence	809	Alternate History	515
Fantasy	5,910	Mystery	2,704	Hidden Object	1,597	Narration	1,125	Best 'em up	805	Artificial Intelligence	496
Colorful	5,629	Point & Click	2,671	Logic	1,586	1990s	1,112	NSFW	781	CRPG	490
Arcade	5,564	Psychological	2,660	Mature	1,582	Drama	1,104	Time Management	782	Grand Strategy	489
Horror	5,504	Stylized	2,659	Magic	1,575	Text-Based	1,095	Beautiful	767	Crime	487
Anime	5,424	Space	2,611	Roguelite	1,558	Base Building	1,089	Cinematic	728	Grid-Based Movement	484
Cute	5,417	Minimalist	2,591	3D Platformer	1,519	Card Game	1,077	Metroidvania	727	Space Sim	483
First-Person	5,351	Physics	2,573	Futuristic	1,518	Abstract	1,072	Team-Based	726	Lore-Rich	471
Funny	5,180	PVP	2,494	Fast-Paced	1,480	Hentai	1,051	City Builder	718	Mouse only	468
Soundtrack	4,886	Choices Matter	2,464	Turn-Based Combat	1,467	Fighting	1,033	Real Time Tactics	702	Supernatural	465
VR	4,862	Building	2,456	PVE	1,466	Third-Person Shooter	1,029	Strategy RPG	696	MMORPG	454
Exploration	4,806	Sandbox	2,415	Crafting	1,451	4 Player Local	1,005	Loot	677	Addictive	451
Retro	4,734	Cartoony	2,389	Bullet Hell	1,447	Tower Defense	997	Psychodelic	672	Souls-like	448
Sci-Fi	4,601	2D Platformer	2,378	Short	1,428	2.5D	992	Character Action Game	669	Trading	448
Great Soundtrack	4,580	Psychological Horror	2,323	Medieval	1,424	Cyberpunk	986	Twin Stick Shooter	662	Split Screen	436
Free to Play	4,473	Tactical	2,317	JRPG	1,423	Military	979	Conversation	657	Dark Comedy	431
Difficult	4,445	Side Scroller	2,243	Romance	1,373	Robots	963	Tabletop	653	Open World Survival Craft	429
Survival	4,410	Realistic	2,220	Hack and Slash	1,365	Action Roguelike	942	Level Editor	651	Science	426
Family Friendly	4,231	Racing	2,198	Choose Your Own Adventure	1,325	Board Game	934	Runner	647	Mythology	425
Dark	3,940	Controller	2,148	Turn-Based Tactics	1,325	Life Sim	916	Inventory Management	645	Inventory Management	413
Relaxing	3,924	Local Multiplayer	2,136	RPGMaker	1,317	LGRTQ+	913	Wargame	636	Philosophical	413

There is a large quantity of tags found in the database, thus it makes complicated to classify a game into a single category. However, tag's value lies in the fact that users are the ones who tag a game. It tells us how a user perceives a game.

There are 417 tags in the database with a particular category for each one in which a game can be.

Figura 11.11: En la tabla de datos ubicamos 417 tags distintas

11.6. Modelos de árboles de decisión y bosques aleatorios.

11.6.1. Métodos basados en árboles

En esta sección discutiremos los métodos basados en árboles para regresión y clasificación. Estos métodos implican estratificar o segmentar el espacio de los predictores en un número J de regiones. Podemos ver el ejemplo de la Figura 11.12.

En esta sección introduciremos las técnicas de bagging, random forest y boosting. Cada uno de ellos involucra múltiples árboles, los cuales son combinados para alcanzar un consenso en la predicción.

Bases de los árboles de decisión. Estos pueden aplicar a casos de regresión y clasificación. La Figura 11.13 muestra el proceso de segmentación visto como un árbol.

En estos ejemplos, esas R_1 , R_2 y R_3 son conocidas como nodos terminales u hojas del árbol. El proceso de delimitación de esos nodos terminales se lleva a cabo en 2 etapas:

1. Dividimos los predictores $(X_1, X_2, \dots, X_K)$ en J regiones distinguibles, que denominamos $R_1, R_2, \dots, R_J$.
2. Para cada observación i que se ubique dentro de cada región R_j hacemos




FIGURE 8.2. The three-region partition for the **Hitters** data set from the regression tree illustrated in Figure 8.1.

Figura 11.12: Ejemplo de regiones. Retomado de Hastie et al (2017, 305)

la misma predicción, la cual puede ser simplemente la media de los valores de la variable explicada en el conjunto de entrenamiento.

Pero ¿cómo construimos las regiones? La respuesta consiste en minimizar la suma de errores al cuadrado (RSS, por sus siglas en inglés) dadas las $R_1, R_2, \dots, R_J$:

$$RSS = \sum_{j=1}^J \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2 \quad (11.51)$$

Donde $\hat{y}_{R_j}$ es la media de las observaciones de la variable explicada de entrenamiento dentro de cada región j -ésima. La implementación se puede ver como el siguiente proceso de **división binaria recursiva**:

- Seleccionamos el predictor X_j y el punto de corte s que parten el espacio en las regiones $\{X \mid X_j < s\}$ y $\{X \mid X_j \geq s\}$.
- Evaluamos este criterio para todos los predictores $X_1, X_2, \dots, X_K$ y para cada punto de corte s posible, y elegimos la combinación que produce la mayor reducción del RSS de la ecuación (11.51).



Figura 11.13: Ejemplo de árbol. Retomado de Hastie et al (2017, 304)

- Repetimos el procedimiento dentro de cada una de las regiones resultantes, y así sucesivamente, hasta alcanzar un criterio de paro.

Debe subrayarse que este procedimiento es **ávido** (*greedy*): en cada paso elige la mejor división inmediata sin considerar si una división peor en este momento permitiría un mejor resultado global más adelante. Buscar el árbol óptimo global es computacionalmente inviable.

El criterio en problemas de clasificación. La ecuación (11.51) sirve cuando la variable explicada es continua. Si la respuesta es categórica, la predicción de cada región es la clase más frecuente en ella y el criterio de división debe medir la *impureza* de los nodos. Los dos criterios habituales son el índice de Gini y la entropía:

$$Gini_j = \sum_{c=1}^C \hat{p}_{jc}(1 - \hat{p}_{jc}) \quad (11.52)$$

$$Entropia_j = - \sum_{c=1}^C \hat{p}_{jc} \ln(\hat{p}_{jc}) \quad (11.53)$$

Donde $\hat{p}_{jc}$ es la proporción de observaciones de la región j que pertenecen a la clase c . Ambas medidas valen cero cuando la región contiene una sola clase — pureza total — y alcanzan su máximo cuando las clases están repartidas por igual. Notemos que la tasa de error de clasificación también podría usarse, pero es menos sensible a cambios en las proporciones y por ello se prefieren las dos anteriores para hacer crecer el árbol.

Poda del árbol. Un árbol al que se le permite crecer sin restricción termina con una hoja por observación y ajusta perfectamente los datos de entrenamiento, es decir, es el caso extremo de sobreajuste que anticipamos al discutir la ecuación (11.9): sesgo nulo y varianza enorme. La solución estándar consiste en hacer crecer un árbol grande y luego **podarlo**, penalizando el número de hojas:

$$\sum_{j=1}^{|T|} \sum_{i \in R_j} (y_i - \hat{y}_{R_j})^2 + \alpha |T| \quad (11.54)$$

Donde $|T|$ es el número de nodos terminales y $\alpha \geq 0$ es un parámetro de penalización que se elige por validación cruzada. La estructura de la ecuación (11.54) es exactamente la de los métodos de regresión restringida que vimos antes: un término de ajuste más una penalización por complejidad.

11.6.2. Métodos de conjunto: bagging, bosques aleatorios y boosting

Los árboles individuales tienen una virtud y un defecto. La virtud es que son muy interpretables y capturan interacciones y no linealidades sin necesidad de especificarlas. El defecto es que tienen **varianza muy alta**: un cambio pequeño en la muestra de entrenamiento puede alterar por completo la estructura del árbol. Los métodos de conjunto atacan precisamente ese defecto combinando muchos árboles.

Bagging (*bootstrap aggregating*). La idea explota un hecho elemental: si promediamos B estimadores independientes con varianza σ^2 cada uno, la varianza del promedio es σ^2/B . Dado que no disponemos de B muestras independientes, se generan B muestras por remuestreo con reemplazo (bootstrap) del conjunto de entrenamiento, se ajusta un árbol sin podar a cada una y se promedian las predicciones:

$$\hat{f}_{bag}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}^{*b}(x) \quad (11.55)$$

En problemas de clasificación se toma el voto mayoritario en lugar del promedio. Un subproducto útil del procedimiento es que cada árbol deja fuera aproximadamente un tercio de las observaciones — las llamadas observaciones *fuera de bolsa* u *out-of-bag* — que pueden usarse para estimar el error de predicción sin necesidad de validación cruzada.

Bosques aleatorios (*random forests*). El problema del bagging es que los B árboles no son independientes: si un predictor es muy dominante, aparecerá en la primera división de casi todos los árboles y las predicciones estarán fuertemente correlacionadas, lo que limita la reducción de varianza. Los bosques aleatorios introducen una modificación sencilla y muy eficaz: en cada división se considera únicamente un subconjunto aleatorio de $m < p$ predictores, elegido de nuevo en cada nodo. Habitualmente $m \approx \sqrt{p}$ en clasificación y $m \approx p/3$ en regresión. Al forzar que los árboles no puedan recurrir siempre a los mismos predictores, se **decorrelacionan** entre sí y el promedio de la ecuación (11.55) reduce la varianza mucho más. Nótese que con $m = p$ el bosque aleatorio coincide con el bagging.

Boosting. La lógica aquí es distinta y en cierto sentido opuesta. En lugar de ajustar muchos árboles en paralelo sobre remuestreos y promediarlos, el boosting los ajusta de manera **secuencial**, donde cada árbol se entrena sobre

los *residuales* que dejó el conjunto de los anteriores:

$$\hat{f}(x) \leftarrow \hat{f}(x) + \nu \hat{f}^b(x) \quad (11.56)$$

Donde $\hat{f}^b$ es un árbol pequeño — con frecuencia de una o dos divisiones únicamente — y ν es un parámetro de encogimiento pequeño que controla la velocidad del aprendizaje. Cada árbol corrige lentamente lo que los anteriores no lograron explicar. La diferencia conceptual con el bagging es importante: el bagging combina modelos de bajo sesgo y alta varianza para reducir la varianza, mientras que el boosting combina modelos de alto sesgo y baja varianza — árboles muy pequeños — para reducir el sesgo. Por esta razón el boosting sí puede sobreajustar si se le permiten demasiadas iteraciones, a diferencia del bagging, y el número de iteraciones debe elegirse por validación cruzada.

El costo de los métodos de conjunto. Los tres procedimientos mejoran de manera notable la capacidad predictiva respecto de un árbol individual, pero sacrifican por completo la interpretabilidad: ya no existe un árbol que pueda dibujarse y leerse. Lo que sí puede obtenerse son medidas de **importancia de las variables**, calculadas como la reducción total del RSS o del índice de Gini atribuible a cada predictor, promediada sobre todos los árboles. Conviene advertir que esas medidas describen la contribución de cada variable a la predicción y **no** constituyen efectos causales ni efectos marginales en el sentido de los capítulos anteriores.

11.7. Modelos de redes neuronales.

11.7.1. Introducción y Motivación

El procedimiento de estimación mediante redes neuronales es un método que puede ser usado tanto para clasificación como para predicción. En ocasiones, este es considerado como una caja negra en términos de la interpretación de los parámetros estimados.

Quizá la principal ventaja de este método es que tiene una amplia exactitud o capacidad predictiva. Por esta razón se suele considerar que las redes neuronales son una herramienta computacional fundamental.

Las redes neuronales (también denominadas redes neuronales artificiales) están basadas en el funcionamiento biológico del cerebro, donde las neuronas están interconectadas y aprenden de la experiencia.

El origen de la técnica se ubica en el trabajo de McCulloch - Pitts (1943), en el cual se propone un modelo simplificado de una neurona basada en el funcionamiento biológico de las neuronas con el objetivo de establecer un resultado en términos de una proposición lógica.

Su estructura soporta/captura relaciones altamente complejas entre las variables usadas como predictores y la variable objetivo o explicada. Situación que no siempre es posible con otros métodos.

El uso moderno de las redes neuronales es llamado aprendizaje profundo (*deep learning*), ya que las redes modernas son profundas (deep), es decir, que tienen múltiples capas ocultas.

11.7.2. Algunos conceptos relevantes

En comparación con un proceso de regresión, las redes neuronales no requieren que los usuarios/analistas determinen una forma funcional o forma específica de la relación entre los predictores y la variable objetivo. En cambio, las redes neuronales tratan de aproximar/inferir/determinar la relación a partir de los datos.

De hecho, la regresión lineal y logística son un caso particular de las redes neuronales en la que sólo hay una capa que conjunta a los inputs y los outputs, y no hay capas ocultas. Las capas ocultas son aquellas que se ubican entre la capa de input y la capa de output. La Figura 11.14 ilustra esta estructura de capas.

Otros conceptos relevantes son los nodos input y output. Si tenemos K predictores, la capa de input usualmente incluirá K nodos. Así, las capas ocultas tienen como su input al output de la capa input, y así sucesivamente. **Unidades neuronales - neurona.** En su corazón, una unidad neuronal (neurona) toma la suma ponderada de sus inputs con un término adicional (término de sesgo), θ_j .

Dado un conjunto de inputs $\{x_1, x_2, \dots, x_K\}$, una unidad toma un conjunto de pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{Kj}$. Para computar el output de una capa de nodos oculta calculamos la suma ponderada de los input y aplicamos una función de activación a ellos. Es decir, dado un conjunto de valores input $\{x_1, x_2, \dots, x_K\}$ calculamos el output del nodo $j = 1, 2, \dots, J$:

$$Z_j = \theta_j + \sum_{i=1}^K w_{ij}x_i = \theta_j + \mathbf{W}_j \cdot \mathbf{X} \quad (11.57)$$




Figura 11.14: Ejemplo de redes neuronales. Retomado de Shmueli et al (2019, 285) [Shm+19]

Donde los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{Kj}$ se obtienen mediante el aprendizaje. Adicionalmente, θ_j también es conocido como el sesgo del nodo j , es una constante que controla el nivel de la contribución del nodo j .

Finalmente, aplicamos una función que denominaremos función de activación para una unidad a . Así, podemos implementar una función de activación para el nodo j del cual obtenemos el output:

$$Output_j = a = f(Z_j) \quad (11.58)$$

Función que puede ser, por ejemplo, una función logística:

$$Output_j = f(\theta_j + \mathbf{W}_j \cdot \mathbf{X}) = \frac{1}{1 + e^{-(\theta_j + \sum_{i=1}^K w_{ij}x_i)}} = \frac{1}{1 + e^{-(\theta_j + \mathbf{W}_j \cdot \mathbf{X})}} \quad (11.59)$$

En este punto debemos observar que el proceso de determinación de los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{Kj}$ es iterativo y suele considerar como valores iniciales a valores pequeños aleatorios. Para simplificar asumiremos que el término de sesgo, θ_j , está contenido como uno de los predictores $\mathbf{X}$ y se determina como parte de los pesos $\mathbf{W}_j$, de esta forma:

$$Z_j = \sum_{i=0}^K w_{ij}x_i = \mathbf{W}_j \cdot \mathbf{X} \quad (11.60)$$




Figure 7.1 The sigmoid function takes a real value and maps it to the range $(0, 1)$. It is nearly linear around 0 but outlier values get squashed toward 0 or 1.

Figura 11.15: Ejemplo de la función de activación Sigmoide. Retomado de Jurafsky, et al (2024, Cap. 7, p.2) [JM23]

Donde, el predictor ubicado en la posición $i = 0$ será un uno 1.

En relación a la función de activación, en la práctica se suele hacer uso de 3:

1. Sigmoide, la cual se ilustra en la Figura 11.15.

$$y = \sigma(Z) = \frac{1}{1 + e^{-Z}} \quad (11.61)$$

2. tanh, la cual se ilustra en la Figura 11.16.

$$y = \tanh(Z) = \frac{e^Z - e^{-Z}}{e^Z + e^{-Z}} \quad (11.62)$$

3. ReLU (*Rectified Linear Unit*), que es la función de activación de uso más extendido en las capas ocultas de las redes profundas.

$$y = \text{ReLU}(Z) = \max\{Z, 0\} \quad (11.63)$$

La Figura 11.17 presenta las tres funciones junto con sus derivadas, que es lo que verdaderamente importa para el entrenamiento. En el panel (a) se aprecia que la sigmoide y la tangente hiperbólica están acotadas mientras que ReLU no lo está. El panel (b) muestra el punto crítico: las derivadas de las dos primeras se desvanecen rápidamente al alejarse del origen — la de la




Figure 7.3 The tanh and ReLU activation functions.

Figura 11.16: Ejemplo de la función de activación $\tanh$. Retomado de Jurafsky, et al (2024, Cap. 7, p.4) [JM23]




Figura 11.17: Funciones de activación y sus derivadas

sigmoide no supera nunca el valor de 0.25 —, mientras que la de ReLU vale exactamente uno en toda la región positiva.

La elección entre estas funciones no es indiferente. La sigmoide y la tangente hiperbólica son diferenciables y acotadas, pero su derivada se aproxima a cero cuando el argumento es grande en valor absoluto. En redes con muchas capas esto genera el problema conocido como **desvanecimiento del gradiente**: al propagar los errores hacia atrás, las derivadas se multiplican entre sí y el gradiente que llega a las primeras capas es tan pequeño que esas capas prácticamente no aprenden. La función ReLU no padece este problema en la región positiva, ya que su derivada es exactamente uno, y es además muy económica de calcular. Esa es la razón por la que desplazó a las otras dos en el uso práctico, aunque introduce su propia dificultad: las unidades cuyo argumento se vuelve permanentemente negativo dejan de contribuir por completo.

Tomemos el siguiente ejemplo. Supongamos los valores para un nodo j :

$$\mathbf{W}_j = [0.5 \quad 0.2 \quad 0.3 \quad 0.9]$$

$$\mathbf{X} = \begin{bmatrix} 1 \\ 0.5 \\ 0.6 \\ 0.1 \end{bmatrix}$$

$$\begin{aligned} y &= \sigma(\mathbf{W}_j \cdot \mathbf{X}) \\ &= \frac{1}{1 + e^{-(\mathbf{W}_j \cdot \mathbf{X})}} \\ &= \frac{1}{1 + e^{-(0.5+0.2 \times 0.5+0.3 \times 0.6+0.9 \times 0.1)}} \\ &= \frac{1}{1 + e^{-(0.87)}} \\ &= 0.7 \end{aligned}$$

En términos simples, este proceso aplica para cada uno de los casos en las Figuras 11.18 y 11.19.

Una unidad neuronal muy simple es conocida como el perceptron, el cual tiene como salida una respuesta binaria:

$$y = \begin{cases} 0 & \text{si } \mathbf{W}_j \cdot \mathbf{X} \leq 0 \\ 1 & \text{si } \mathbf{W}_j \cdot \mathbf{X} > 0 \end{cases} \quad (11.64)$$




Figure 7.2 A neural unit, taking 3 inputs x_1 , x_2 , and x_3 (and a bias b that we represent as a weight for an input clamped at $+1$) and producing an output y . We include some convenient intermediate variables: the output of the summation, z , and the output of the sigmoid, a . In this case the output of the unit y is the same as a , but in deeper networks we'll reserve y to mean the final output of the entire network, leaving a as the activation of an individual node.

Figura 11.18: Ilustración de una unidad neuronal. Retomado de Jurafsky, et al (2024, Cap. 7, p.3) [JM23]




Figure 7.9 Replacing the bias node (shown in a) with x_0 (b).

Figura 11.19: Ilustración de una red neuronal con 1 capa oculta. Retomado de Jurafsky, et al (2024, Cap. 7, p.11) [JM23]

11.7.3. Preprocesamiento de datos

Cuando usamos una función de activación logística las redes neuronales se desempeñan mejor cuando los predictores y la variable objetivo están en el intervalo $[0, 1]$; considerando:

$$X_{normalizada} = \frac{X - a}{b - a} \quad (11.65)$$

Donde $a = \min(X)$ y $b = \max(X)$.

Adicionalmente, existe una función de normalización de los valores contenidos en los vectores que se forman en cada nodo $Z_1, Z_2, \dots, Z_d$. Esta función es conocida como función Softmax:

$$Softmax(Z_j) = \frac{e^{z_j}}{\sum_{i=1}^d e^{z_i}}, \quad 1 \leq j \leq d \quad (11.66)$$

La función Softmax de la ecuación (11.66) transforma un vector de d valores reales cualesquiera en un vector de d cantidades positivas que suman uno, es decir, en una distribución de probabilidad sobre d categorías. Por esta razón se utiliza en la capa de salida de los problemas de clasificación con más de dos clases.

Notemos que la ecuación (11.66) no es una construcción nueva para nosotros: es exactamente la misma forma funcional del modelo logit multinomial del capítulo de modelos no lineales, con la diferencia de que allí se normalizaba fijando $\beta_0 = \mathbf{0}$ para la categoría base — por razones de identificación de los parámetros — mientras que aquí, al no interesarnos la interpretación de los pesos, se conservan todas las categorías de forma simétrica. Análogamente, la función sigmoide de una sola salida corresponde al modelo logit binario. En este sentido preciso, una red neuronal sin capas ocultas *es* un modelo logit.

11.7.4. Entrenamiento del modelo

Entrenar un modelo significa estimar los pesos $\theta_j, w_{1j}, w_{2j}, \dots, w_{Kj}$ que llevan al mejor resultado de predicción posible.

El mecanismo seguido para este proceso se le conoce como **back propagation**. Es el método más popular usado para determinar los pesos (aprender). Como su nombre lo indica, los errores son calculados en forma recursiva;

iniciando en la última capa (la capa de output) y continuando con la previa hasta llegar a la capa de input.

El proceso de entrenamiento se puede pensar como los siguientes pasos:

1. Establecemos una función de pérdida que mida la distancia entre el output obtenido y el objetivo. En problemas de clasificación esa función es la **entropía cruzada**, que para el caso binario se define como:

$$L(\boldsymbol{\theta}) = - \sum_{i=1}^N [y_i \ln \hat{y}_i + (1 - y_i) \ln(1 - \hat{y}_i)] \quad (11.67)$$

Donde $\hat{y}_i$ es la probabilidad predicha por la red. Conviene detenerse en la ecuación (11.67): es exactamente el **negativo de la log-verosimilitud** del modelo de respuesta binaria que obtuvimos en el capítulo de modelos no lineales. Minimizar la entropía cruzada y maximizar la verosimilitud son, literalmente, el mismo problema. Lo que la literatura de aprendizaje automático llama «función de pérdida» es en muchos casos un objeto que ya conocemos con otro nombre.

2. Para encontrar los parámetros que minimicen la función de pérdida usamos el algoritmo de **descenso de gradiente**, que actualiza los pesos de forma iterativa moviéndose en la dirección opuesta al gradiente:

$$\boldsymbol{\theta}^{(s+1)} = \boldsymbol{\theta}^{(s)} - \eta \left. \frac{\partial L(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right|_{\boldsymbol{\theta}=\boldsymbol{\theta}^{(s)}} \quad (11.68)$$

Donde $\eta > 0$ es la **tasa de aprendizaje**, un hiperparámetro que controla el tamaño del paso. Nótese el parentesco con los métodos numéricos de Newton-Raphson que describimos en el capítulo de máxima verosimilitud: la diferencia es que aquí no se utiliza el hessiano, lo cual abarata enormemente cada iteración a costa de requerir muchas más. En la práctica se emplea la variante de **descenso de gradiente estocástico**, que en cada paso evalúa el gradiente sobre un subconjunto pequeño de observaciones en lugar de sobre la muestra completa.

3. Finalmente, implementamos un algoritmo de **retropropagación** (*back-propagation*) para calcular el gradiente que requiere la ecuación (11.68). No se trata de un método de optimización distinto, sino de una forma eficiente de aplicar la regla de la cadena: el gradiente respecto de los

pesos de una capa se obtiene reutilizando el que ya se calculó para la capa siguiente, lo que evita recalcular derivadas repetidas.

Debe advertirse, para cerrar, que a diferencia de los modelos de este curso la función de pérdida de una red neuronal con capas ocultas **no es globalmente cóncava**, por lo que el procedimiento puede converger a óptimos locales y el resultado depende de los valores iniciales de los pesos. Esta es una diferencia de fondo respecto de los modelos logit, probit y Poisson que estudiamos antes, cuya log-verosimilitud sí es globalmente cóncava y cuyo óptimo es por lo tanto único.

11.8. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.
 - a)* Un modelo con menor error de entrenamiento predice mejor fuera de la muestra.
 - b)* Aumentar la flexibilidad de un modelo siempre reduce el sesgo y siempre aumenta la varianza.
 - c)* El parámetro de penalización λ de la regresión Ridge debe elegirse minimizando la función objetivo penalizada.
 - d)* La regresión Ridge puede estimarse aun cuando existan más regresores que observaciones.
 - e)* La regresión Lasso y la regresión Ridge encogen los coeficientes, y ambas pueden dejar algunos exactamente en cero.
 - f)* Los resultados de Ridge y Lasso no cambian si se multiplica un regresor por mil.
 - g)* El algoritmo K-medias converge siempre al óptimo global.
 - h)* El análisis de componentes principales y el análisis factorial son dos nombres del mismo procedimiento.
 - i)* Una red neuronal sin capas ocultas y con función de activación logística es equivalente a un modelo logit.

- j) En un bosque aleatorio con $m = p$ obtenemos exactamente el procedimiento de bagging.
2. Demuestre la descomposición de sesgo y varianza de la ecuación (11.9). Sugerencia: sume y reste $\mathbb{E}[\hat{f}(x_0)]$ dentro del cuadrado y verifique que el término cruzado se anula. Explique además por qué la esperanza se toma sobre las posibles muestras de entrenamiento y no sobre las observaciones.
 3. A partir de la ecuación (11.11) se le solicita:
 - a) Reproducir la obtención del estimador $\hat{\beta}_R^{Ridge} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I})^{-1}\mathbf{X}'\mathbf{Y}$.
 - b) Demostrar que $\mathbb{E}[\hat{\beta}_R^{Ridge}] \neq \beta$ para $\lambda > 0$, es decir, que el estimador es sesgado, y obtener una expresión para el sesgo.
 - c) Verificar que cuando $\lambda \rightarrow 0$ se recupera el estimador de MCO, y que cuando $\lambda \rightarrow \infty$ todos los coeficientes tienden a cero.
 - d) Explicar por qué la matriz $\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}$ es invertible aun cuando $\mathbf{X}'\mathbf{X}$ no lo sea, y qué implica esto para el caso en que $K > n$.
 4. Considere el caso de un único regresor estandarizado y ortogonal, de modo que $\mathbf{X}'\mathbf{X} = 1$. Se le solicita:
 - a) Obtener explícitamente el estimador Ridge y verificar que es $\hat{\beta}^{MCO}/(1+\lambda)$, es decir, un encogimiento proporcional que nunca llega a cero.
 - b) Obtener el estimador Lasso y verificar que toma la forma de umbral suave: $\hat{\beta}^{Lasso} = \text{sign}(\hat{\beta}^{MCO}) \max\{|\hat{\beta}^{MCO}| - \lambda/2, 0\}$.
 - c) Explicar, a partir de las dos expresiones anteriores, por qué el Lasso produce ceros exactos y Ridge no.
 5. Explique la diferencia conceptual entre bagging y boosting en términos de la descomposición de la ecuación (11.9): ¿cuál de los dos componentes ataca cada uno? Explique además por qué el boosting puede sobreajustar si se le permiten demasiadas iteraciones y el bagging esencialmente no.
 6. Verifique que la función Softmax de la ecuación (11.66) produce en efecto una distribución de probabilidad, es decir, que todos sus valores son positivos y suman uno. Muestre además que en el caso de $d = 2$

categorías se reduce a la función sigmoide, y explique cuál es la relación de este resultado con el modelo logit multinomial del capítulo de modelos no lineales.

7. Considere una neurona con función de activación logística y los valores $\mathbf{W}_j = [0.5, 0.2, 0.3, 0.9]$ y $\mathbf{X} = [1, 0.5, 0.6, 0.1]'$ del ejemplo del texto. Se le solicita: (i) verificar el cálculo del texto; (ii) recalcular la salida usando ReLU y usando tangente hiperbólica, comparando los tres resultados; y (iii) calcular la derivada de la sigmoide en ese punto y explicar qué relación tiene con el problema del desvanecimiento del gradiente.
8. **Aplicación en Python.** Con un conjunto de datos de su elección que tenga un número considerable de regresores, se le solicita:
 - a) Separar los datos en conjuntos de entrenamiento y de prueba.
 - b) Estimar por MCO, por Ridge y por Lasso, estandarizando previamente los regresores.
 - c) Elegir λ por validación cruzada de 10 pliegues en ambos casos y graficar el error de validación cruzada contra λ .
 - d) Reportar cuántos coeficientes deja exactamente en cero el Lasso y cuántos el Ridge.
 - e) Comparar el error de predicción de los tres métodos en el conjunto de prueba, y contrastarlo con el error de entrenamiento. Documentar la magnitud del sobreajuste de MCO.
 - f) Graficar las trayectorias de los coeficientes en función de λ para ambos métodos y describir la diferencia cualitativa entre ambos gráficos.
9. **Aplicación en Python.** Con un conjunto de datos apropiado para clasificación, se le solicita estimar y comparar: un modelo logit, un árbol de decisión individual, un bosque aleatorio y una red neuronal con una capa oculta. Para cada uno reporte la matriz de confusión sobre el conjunto de prueba y discuta la disyuntiva entre capacidad predictiva e interpretabilidad. Discuta en particular qué preguntas puede responder el logit que los otros tres no, y viceversa.
10. **Discusión.** A lo largo del curso hemos estudiado dos tradiciones con objetivos distintos: la econometría, orientada a la estimación e interpre-

tación de parámetros estructurales, y el aprendizaje estadístico, orientado a la predicción. Se le solicita elaborar, con base en el Cuadro 11.2 y en el material del curso, una discusión de al menos dos cuartillas sobre los siguientes puntos: ¿por qué un modelo con excelente capacidad predictiva puede ser inútil para evaluar una política pública? ¿Por qué un modelo con interpretación causal válida puede predecir mal? ¿Y en qué situaciones concretas las herramientas de aprendizaje estadístico sí resultan útiles para la inferencia causal?

Bibliografía

- [Aba21] Alberto Abadie. «Using Synthetic Controls: Feasibility, Data Requirements, and Methodological Aspects». En: *Journal of Economic Literature* 59.2 (2021), págs. 391-425.
- [ADH10] Alberto Abadie, Alexis Diamond y Jens Hainmueller. «Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California’s Tobacco Control Program». En: *Journal of the American Statistical Association* 105.490 (2010), págs. 493-505.
- [ADH15] Alberto Abadie, Alexis Diamond y Jens Hainmueller. «Comparative Politics and the Synthetic Control Method». En: *American Journal of Political Science* 59.2 (2015), págs. 495-510.
- [AG03] Alberto Abadie y Javier Gardeazabal. «The Economic Costs of Conflict: A Case Study of the Basque Country». En: *American Economic Review* 93.1 (2003), págs. 113-132.
- [AJR01] Daron Acemoglu, Simon Johnson y James A. Robinson. «The Colonial Origins of Comparative Development: An Empirical Investigation». En: *American Economic Review* 91.5 (2001), págs. 1369-1401.
- [Ada20] Christopher P. Adams. *Learning Microeconometrics with R*. Estados Unidos: CRC Press, 2020.
- [AP09] Joshua D. Angrist y Jörn-Steffen Pischke. *Mostly Harmless Econometrics: An Empiricist’s Companion*. Princeton: Princeton University Press, 2009.
- [AB91] Manuel Arellano y Stephen Bond. «Some Tests of Specification for Panel Data: Monte Carlo Evidence and an Application to Employment Equations». En: *The Review of Economic Studies* 58.2 (1991), págs. 277-297.

- [Ash78] Orley Ashenfelter. «Estimating the Effect of Training Programs on Earnings». En: *The Review of Economics and Statistics* 60.1 (1978), págs. 47-57.
- [AI17] Susan Athey y Guido W. Imbens. «The State of Applied Econometrics: Causality and Policy Evaluation». En: *Journal of Economic Perspectives* 31.2 (2017), págs. 3-32.
- [BB85] Jonathan B. Baker y Timothy F. Bresnahan. «The Gains from Merger or Collusion in Product-Differentiated Industries». En: *The Journal of Industrial Economics* 33.4 (1985), págs. 427-444.
- [BDM04] Marianne Bertrand, Esther Duflo y Sendhil Mullainathan. «How Much Should We Trust Differences-in-Differences Estimates?». En: *The Quarterly Journal of Economics* 119.1 (2004), págs. 249-275.
- [BP80] Trevor S. Breusch y Adrian R. Pagan. «The Lagrange Multiplier Test and its Applications to Model Specification in Econometrics». En: *The Review of Economic Studies* 47.1 (1980), págs. 239-253.
- [CS21] Brantly Callaway y Pedro H. C. Sant’Anna. «Difference-in-Differences with Multiple Time Periods». En: *Journal of Econometrics* 225.2 (2021), págs. 200-230.
- [CT05] Colin Cameron y Pravin K. Trivedi. *Microeconometrics: Methods and Applications*. Estados Unidos: Cambridge University Press, 2005.
- [Car90] David Card. «The Impact of the Mariel Boatlift on the Miami Labor Market». En: *Industrial and Labor Relations Review* 43.2 (1990), págs. 245-257.
- [CK94] David Card y Alan B. Krueger. «Minimum Wages and Employment: A Case Study of the Fast-Food Industry in New Jersey and Pennsylvania». En: *American Economic Review* 84.4 (1994), págs. 772-793.
- [CD20] Clément de Chaisemartin y Xavier D’Haultfoeulle. «Two-Way Fixed Effects Estimators with Heterogeneous Treatment Effects». En: *American Economic Review* 110.9 (2020), págs. 2964-2996.
- [Cha20] Mark Chang. *Artificial Intelligence for Drug Development, Precision Medicine, and Healthcare*. Estados Unidos: CRC Press Taylor & Francis Group, 2020.

- [CG76] Laurits R. Christensen y William H. Greene. «Economies of Scale in U.S. Electric Power Generation». En: *Journal of Political Economy* 84.4, Part 1 (1976), págs. 655-676.
- [Cox72] David R. Cox. «Regression Models and Life-Tables». En: *Journal of the Royal Statistical Society, Series B* 34.2 (1972), págs. 187-220.
- [Cun21] Scott Cunningham. *Causal inference: The mixtape*. Estados Unidos: Yale University Press, 2021.
- [Gér19] Aurélien Geron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 2nd. Estados Unidos: O'Reilly Media, 2019.
- [Goo21] Andrew Goodman-Bacon. «Difference-in-Differences with Variation in Treatment Timing». En: *Journal of Econometrics* 225.2 (2021), págs. 254-277.
- [Gre12] William Greene. *Econometric Analysis*. Estados Unidos: Prentice Hall, 2012.
- [GG60] Yehuda Grunfeld y Zvi Griliches. «Is Aggregation Necessarily Bad?». En: *The Review of Economics and Statistics* 42.1 (1960), págs. 1-13.
- [Han82] Lars Peter Hansen. «Large Sample Properties of Generalized Method of Moments Estimators». En: *Econometrica* 50.4 (1982), págs. 1029-1054.
- [HTF17] Trevor Hastie, Robert Tibshirani y Jerome Friedman. *The Elements of Statistical Learning. Data Mining, Inference, and Prediction*. LLC: Springer, 2017.
- [Hau78] Jerry A. Hausman. «Specification Tests in Econometrics». En: *Econometrica* 46.6 (1978), págs. 1251-1271.
- [Hay00] Fumio Hayashi. *Econometrics*. Princeton: Princeton University Press, 2000.
- [Hec79] James J. Heckman. «Sample Selection Bias as a Specification Error». En: *Econometrica* 47.1 (1979), págs. 153-161.
- [Hun22] Nick Huntington-Klein. *The Effect: An Introduction to Research Design and Causality*. Boca Raton: Chapman y Hall/CRC, 2022.

- [IA94] Guido W. Imbens y Joshua D. Angrist. «Identification and Estimation of Local Average Treatment Effects». En: *Econometrica* 62.2 (1994), págs. 467-475.
- [Jam+13] Gareth James et al. *An Introduction to Statistical Learning with Applications in R*. New York: Springer, 2013.
- [JM23] Dan Jurafsky y James H. Martin. *Speech and Language Processing*. New York: Stanford, 2023.
- [KM58] Edward L. Kaplan y Paul Meier. «Nonparametric Estimation from Incomplete Observations». En: *Journal of the American Statistical Association* 53.282 (1958), págs. 457-481.
- [KW97] Michael P. Keane y Kenneth I. Wolpin. «The Career Decisions of Young Men». En: *Journal of Political Economy* 105.3 (1997), págs. 473-522.
- [Kie88] Nicholas M. Kiefer. «Economic Duration Data and Hazard Functions». En: *Journal of Economic Literature* 26.2 (1988), págs. 646-679.
- [KK12] David G. Kleinbaum y Mitchel Klein. *Survival Analysis: A Self-Learning Text*. 3rd. New York: Springer, 2012.
- [Lan90] Tony Lancaster. *The Econometric Analysis of Transition Data*. Cambridge: Cambridge University Press, 1990.
- [LM12] Richard J. Larsen y Morris L. Marx. *An Introduction to Mathematical Statistics and Its Applications*. Estados Unidos: Pearson, 2012.
- [Mro87] Thomas A. Mroz. «The Sensitivity of an Empirical Model of Married Women's Hours of Work to Economic and Statistical Assumptions». En: *Econometrica* 55.4 (1987), págs. 765-799.
- [Mun78] Yair Mundlak. «On the Pooling of Time Series and Cross Section Data». En: *Econometrica* 46.1 (1978), págs. 69-85.
- [Ner63] Marc Nerlove. «Returns to Scale in Electricity Supply». En: *Measurement in Economics: Studies in Mathematical Economics and Econometrics in Memory of Yehuda Grunfeld*. Ed. por Carl F. Christ. Stanford: Stanford University Press, 1963, págs. 167-198.
- [Ng23] Andrew Ng. *Machine Learning Specialization*. 2023.
- [Nic81] Stephen Nickell. «Biases in Dynamic Models with Fixed Effects». En: *Econometrica* 49.6 (1981), págs. 1417-1426.

- [PGJ16] Judea Pearl, Madelyn Glymour y Nicholas P. Jewell. *Causal Inference in Statistics: A Primer*. Chichester: John Wiley & Sons, 2016.
- [RR83] Paul R. Rosenbaum y Donald B. Rubin. «The Central Role of the Propensity Score in Observational Studies for Causal Effects». En: *Biometrika* 70.1 (1983), págs. 41-55.
- [Rot22] Jonathan Roth. «Pretest with Caution: Event-Study Estimates after Testing for Parallel Trends». En: *American Economic Review: Insights* 4.3 (2022), págs. 305-322.
- [Rot+23] Jonathan Roth et al. «What’s trending in difference-in-differences? A synthesis of the recent econometrics literature». En: *Journal of Econometrics* (2023).
- [Rub74] Donald B. Rubin. «Estimating Causal Effects of Treatments in Randomized and Nonrandomized Studies». En: *Journal of Educational Psychology* 66.5 (1974), págs. 688-701.
- [Sar58] John D. Sargan. «The Estimation of Economic Relationships Using Instrumental Variables». En: *Econometrica* 26.3 (1958), págs. 393-415.
- [Shm+19] Galit Shmueli et al. *Data Mining for Business Analytics: Concepts, Techniques and Applications in Python*. Estados Unidos: Wiley, 2019.
- [Sno55] John Snow. *On the Mode of Communication of Cholera*. 2nd. Londres: John Churchill, 1855.
- [SS97] Douglas Staiger y James H. Stock. «Instrumental Variables Regression with Weak Instruments». En: *Econometrica* 65.3 (1997), págs. 557-586.
- [SY05] James H. Stock y Motohiro Yogo. «Testing for Weak Instruments in Linear IV Regression». En: *Identification and Inference for Econometric Models: Essays in Honor of Thomas Rothenberg*. Ed. por Donald W. K. Andrews y James H. Stock. Cambridge: Cambridge University Press, 2005, págs. 80-108.
- [SA21] Liyang Sun y Sarah Abraham. «Estimating Dynamic Treatment Effects in Event Studies with Heterogeneous Treatment Effects». En: *Journal of Econometrics* 225.2 (2021), págs. 175-199.

- [Tob58] James Tobin. «Estimation of Relationships for Limited Dependent Variables». En: *Econometrica* 26.1 (1958), págs. 24-36.
- [Ver17] Marno Verbeek. *A Guide to Modern Econometrics*. 5th. Chichester: John Wiley & Sons, 2017.
- [Woo22] L. Guillermo Woo-Mora. «Las consecuencias del pecado original: costos económicos y distributivos de la política populista en México». En: *Los abusos del poder público*. Primer lugar del Premio MEY 2022, categoría de artículo de investigación. Ciudad de México: Centro de Estudios Espinosa Yglesias (CEEY), 2022.
- [Woo10] Jeffrey M. Wooldridge. *Econometric Analysis of Cross Section and Panel Data*. Estados Unidos: The MIT Press, 2010.
- [Zel62] Arnold Zellner. «An Efficient Method of Estimating Seemingly Unrelated Regressions and Tests for Aggregation Bias». En: *Journal of the American Statistical Association* 57.298 (1962), págs. 348-368.

Apéndice A

Teoría de convergencia asintótica

A continuación listamos y enunciamos una serie de definiciones relevantes para la teoría de grandes muestras. En su caso, en la medida de lo posible no haremos demostraciones de algunos de los resultados enunciados puesto que ello en sí mismo podría ser una parte significativa de un curso de probabilidad y estadística, lo que además implica tiempo de nuestro curso que podríamos requerir para otros temas.

A.1. Convergencia de sucesiones

Definición A.1 *Sea una sucesión de números no aleatorios $\{a_N : N = 1, 2, \dots\}$, decimos que a_N converge a un número a (es decir, tiene su límite en a) si $\forall \varepsilon > 0$, $\exists N_\varepsilon$ tal que si $N > N_\varepsilon$, entonces:*

$$|a_N - a| < \varepsilon$$

Es decir, $a_N \longrightarrow a$ cuando $N \longrightarrow \infty$.

Definición A.2 *Sea una sucesión de números no aleatorios $\{a_N : N = 1, 2, \dots\}$, decimos que la sucesión está acotada si y sólo si existe $b < \infty$ tal que $|a_N| \leq b$, $\forall N = 1, 2, \dots$.*

Estas definiciones aplican de forma similar a vectores y a matrices cuando las analizamos y aplicamos elemento a elemento.

A.2. Convergencia en probabilidad y acotamientos en probabilidad

Definición A.3 Sea una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ decimos que una sucesión de variables aleatorias es convergente en probabilidad a una constante a si $\forall \varepsilon > 0$ tenemos que:

$$\lim_{N \rightarrow \infty} P[|x_N - a| > \varepsilon] = 0$$

Alternativamente, una sucesión de variables aleatorias tiene un límite en probabilidad en una constante a si cumple la condición anterior, lo cual escribiremos como:

$$p \lim x_N = a$$

Definición A.4 Sea una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ decimos que la sucesión está acotada en probabilidad si y sólo si para cada $\varepsilon > 0$, existe un $b_\varepsilon < \infty$ y un entero N_ε tal que $\forall N \geq N_\varepsilon$ sucede que:

$$P[|x_N| \geq b_\varepsilon] < \varepsilon$$

Todas las definiciones de esta sección aplican elemento a elemento a sucesiones de vectores o matrices de variables aleatorias. Por ejemplo, si $\{\mathbf{X}_N : N = 1, 2, \dots\}$ es una sucesión de un vector de variables aleatorias o vector aleatorio de dimensión $K \times 1$, entonces decimos que $\mathbf{X}_N$ converge en probabilidad a $\mathbf{a}$ o $p \lim \mathbf{X}_N = \mathbf{a}$, donde $\mathbf{a}$ es un vector aleatorio de dimensión $K \times 1$, si y sólo si cada una de las entradas de la sucesión de vectores aleatorios cumple que:

$$p \lim x_{Nj} = a_j$$

Para todo $j = 1, 2, \dots, K$. Una forma equivalente de escribir este resultado es:

$$p \lim \|\mathbf{X}_N - \mathbf{a}\| = 0$$

Donde $\|b\| \equiv (b'b)^{1/2}$, es decir, el símbolo denota la norma euclidiana de un vector de dimensión $K \times 1$.

De forma similar, supongamos que analizamos una sucesión de matrices de variables aleatorias o matrices aleatorias $\{\mathbf{Z}_N : N = 1, 2, \dots\}$, cuya dimensión es de $M \times K$. Supongamos que existe una matriz de la misma dimensión $\mathbf{B}$, entonces podemos decir en forma equivalente que:

$$p \lim \|\mathbf{Z}_N - \mathbf{B}\| = 0$$

Donde $\|\mathbf{A}\| \equiv [\text{tr}(\mathbf{A}'\mathbf{A})]^{1/2}$ y $\text{tr}(\mathbf{C})$ denota la traza de una matriz cuadrada.

Teorema A.1 Teorema de mapeo continuo. Sea $g : \mathbb{R}^K \longrightarrow \mathbb{R}^J$ una función continua en algún punto $c \in \mathbb{R}^K$. Sea $\{\mathbf{X}_N : N = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ tal que $p\text{ lím } \mathbf{X}_N = c$. Entonces:

$$p\text{ lím } g(\mathbf{X}_N) = g(c)$$

En otras palabras:

$$p\text{ lím } g(\mathbf{X}_N) = g(p\text{ lím } \mathbf{X}_N)$$

Este resultado es de uso constante y conviene tener presente lo que autoriza y lo que no: permite intercambiar el límite en probabilidad con funciones continuas, de modo que si $\hat{\boldsymbol{\theta}} \xrightarrow{p} \boldsymbol{\theta}$ entonces $g(\hat{\boldsymbol{\theta}}) \xrightarrow{p} g(\boldsymbol{\theta})$. Notemos que **no** vale el resultado análogo para esperanzas: en general $\mathbb{E}[g(\hat{\boldsymbol{\theta}})] \neq g(\mathbb{E}[\hat{\boldsymbol{\theta}}])$, razón por la cual una función continua de un estimador insesgado no es, en general, insesgada, aunque sí sea consistente si el estimador original lo es. Esta asimetría entre consistencia e insesgamiento aparece repetidamente a lo largo del curso.

A.3. Convergencia en distribución

Definición A.5 Una sucesión de variables aleatorias $\{x_N : N = 1, 2, \dots\}$ converge en distribución a una variable aleatoria continua si y sólo si $\forall \xi \in \mathbb{R}$:

$$\lim_{N \rightarrow \infty} F_N(\xi) = F(\xi)$$

Donde F_N es la función de distribución acumulada (c.d.f.) de x_N y F es la función de distribución acumulada continua de x . En otras palabras, la expresión anterior se puede escribir como:

$$x_N \xrightarrow{d} x$$

Definición A.6 Una sucesión de vectores aleatorios $\{\mathbf{X}_N : N = 1, 2, \dots\}$ de dimensión $K \times 1$ converge en distribución a un vector aleatorio $\mathbf{X}$ de dimensión $K \times 1$ si y sólo si para cualquier vector **no aleatorio** $\mathbf{C}$ de dimensión $K \times 1$ tal que $\mathbf{C}'\mathbf{C} = 1$, sucede que:

$$\mathbf{C}'\mathbf{X}_N \xrightarrow{d} \mathbf{C}'\mathbf{X}$$

o simplemente:

$$\mathbf{X}_N \xrightarrow{d} \mathbf{X}$$

Por ejemplo, cuando $\mathbf{X} \sim \text{Normal}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, podemos decir que si:

$$\mathbf{C}'\mathbf{X}_N \xrightarrow{d} \text{Normal}(\mathbf{C}'\boldsymbol{\mu}, \mathbf{C}'\boldsymbol{\Sigma}\mathbf{C})$$

Para cada $\mathbf{C} \in \mathbb{R}^K$ tal que $\mathbf{C}'\mathbf{C} = 1$, en este caso escribiremos que:

$$\mathbf{X}_N \xrightarrow{d} \text{Normal}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

A.4. Teoremas límite para muestras aleatorias

Teorema A.2 Ley Débil de los Grandes Números. Sea $\{\mathbf{W}_i : i = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ independientes e idénticamente distribuidos tal que $\mathbb{E}[|w_{ik}|] < \infty$, con $k = 1, 2, \dots, K$. Entonces la sucesión satisface:

$$N^{-1} \sum_{i=1}^N \mathbf{W}_i \xrightarrow{p} \boldsymbol{\mu}_w$$

Donde $\boldsymbol{\mu}_w \equiv \mathbb{E}[\mathbf{W}_i]$.

Teorema A.3 Teorema del Límite Central. Sea $\{\mathbf{W}_i : i = 1, 2, \dots\}$ una sucesión de vectores aleatorios de dimensión $K \times 1$ independientes e idénticamente distribuidos tal que $\mathbb{E}[w_{ik}^2] < \infty$, con $k = 1, 2, \dots, K$, y $\mathbb{E}[\mathbf{W}_i] = \mathbf{0}$. Entonces la sucesión satisface:

$$N^{-1/2} \sum_{i=1}^N \mathbf{W}_i \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{B})$$

Donde $\mathbf{B} = \text{Var}(\mathbf{W}_i) = \mathbb{E}[\mathbf{W}_i \mathbf{W}_i']$ es una matriz definida positiva.

Estos dos resultados son los que hacen funcionar toda la teoría asintótica del curso, y conviene notar el papel distinto de cada uno. La Ley de los Grandes Números se aplica a los promedios que aparecen en el *denominador*

de los estimadores — expresiones del tipo $N^{-1}\mathbf{X}'\mathbf{X}$ — y garantiza que converjan a una matriz de constantes. El Teorema del Límite Central se aplica al *numerador* — expresiones del tipo $N^{-1/2}\mathbf{X}'\boldsymbol{\varepsilon}$ — y le confiere una distribución normal. El factor de escalamiento es distinto en cada caso, N^{-1} frente a $N^{-1/2}$, y esa diferencia es la que produce la tasa de convergencia $\sqrt{N}$ que aparece en todos los resultados de normalidad asintótica.

A.5. Teorema de Slutsky y método delta

Los dos resultados anteriores describen por separado el comportamiento de promedios y de sumas escaladas. Para combinarlos — que es lo que se necesita en la práctica, ya que los estimadores son cocientes de ambas cosas — requerimos el siguiente teorema, que utilizamos repetidamente en los capítulos de variables instrumentales y de máxima verosimilitud.

Teorema A.4 Teorema de Slutsky. *Sea $\{\mathbf{X}_N\}$ una sucesión de vectores aleatorios tal que $\mathbf{X}_N \xrightarrow{d} \mathbf{X}$, y sea $\{\mathbf{A}_N\}$ una sucesión de matrices aleatorias tal que $\mathbf{A}_N \xrightarrow{p} \mathbf{A}$, donde $\mathbf{A}$ es una matriz de constantes. Entonces:*

$$\mathbf{A}_N \mathbf{X}_N \xrightarrow{d} \mathbf{A} \mathbf{X}$$

En particular, si $\mathbf{X} \sim \text{Normal}(\mathbf{0}, \mathbf{B})$, entonces:

$$\mathbf{A}_N \mathbf{X}_N \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{A} \mathbf{B} \mathbf{A}')$$

El teorema de Slutsky es el que autoriza el paso que damos en todas las demostraciones de normalidad asintótica del curso. El patrón es siempre el mismo: se escribe el error de estimación escalado como el producto de un factor que converge en probabilidad a una matriz de constantes y otro que converge en distribución a una normal,

$$\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) = \underbrace{\mathbf{A}_N}_{\xrightarrow{p} \mathbf{A}} \cdot \underbrace{\left(N^{-1/2} \sum_{i=1}^N \mathbf{s}_i \right)}_{\xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{B})}$$

y se concluye que el producto converge en distribución a una $\text{Normal}(\mathbf{0}, \mathbf{A} \mathbf{B} \mathbf{A}')$. El lector puede verificar que exactamente esta estructura aparece en la demostración de la normalidad asintótica del estimador de 2SLS y en la del estimador de máxima verosimilitud.

Es importante subrayar que el teorema exige que el límite $\mathbf{A}$ sea **no aleatorio**. Si ambos factores fueran aleatorios en el límite, el producto no tendría en general una distribución tratable, y de hecho no podría escribirse simplemente como el producto de los límites.

El segundo resultado que necesitamos responde a la siguiente pregunta: si conocemos la distribución asintótica de un estimador, ¿cuál es la de una función no lineal de él?

Teorema A.5 Método delta. Sea $\hat{\boldsymbol{\theta}}$ un estimador de dimensión $P \times 1$ tal que:

$$\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{V})$$

Y sea $\mathbf{c} : \mathbb{R}^P \rightarrow \mathbb{R}^Q$ una función continuamente diferenciable en $\boldsymbol{\theta}$, con jacobiano $\mathbf{C}(\boldsymbol{\theta}) = \partial \mathbf{c}(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}'$ de dimensión $Q \times P$ y rango Q . Entonces:

$$\sqrt{N}(\mathbf{c}(\hat{\boldsymbol{\theta}}) - \mathbf{c}(\boldsymbol{\theta})) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{C}(\boldsymbol{\theta})\mathbf{V}\mathbf{C}(\boldsymbol{\theta})')$$

La idea de la demostración es una expansión de Taylor de primer orden alrededor de $\boldsymbol{\theta}$:

$$\mathbf{c}(\hat{\boldsymbol{\theta}}) \approx \mathbf{c}(\boldsymbol{\theta}) + \mathbf{C}(\boldsymbol{\theta})(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})$$

De donde $\sqrt{N}(\mathbf{c}(\hat{\boldsymbol{\theta}}) - \mathbf{c}(\boldsymbol{\theta})) \approx \mathbf{C}(\boldsymbol{\theta})\sqrt{N}(\hat{\boldsymbol{\theta}} - \boldsymbol{\theta})$, y se aplica el teorema de Slutsky con $\mathbf{A} = \mathbf{C}(\boldsymbol{\theta})$. El resto del argumento consiste en verificar que el residuo de la expansión de Taylor es de orden despreciable.

El método delta es el que justifica la forma de la varianza en la prueba de Wald del capítulo de métodos de estimación basados en verosimilitud, y es también el que permite obtener errores estándar de cantidades derivadas: efectos marginales, elasticidades, cocientes de coeficientes o el punto de inflexión de una relación cuadrática. En el trabajo aplicado esto es de uso cotidiano: cada vez que un programa estadístico reporta el error estándar de un efecto marginal en un modelo logit, lo está calculando por este método.

Ejemplo. Supongamos que estimamos $\hat{\beta}_1$ y $\hat{\beta}_2$ y nos interesa el cociente $\theta = \beta_1/\beta_2$, que es la forma que toma, por ejemplo, la medida de rendimientos a escala o el punto donde una relación cuadrática alcanza su máximo. Aquí $Q = 1$, $P = 2$ y el jacobiano es:

$$\mathbf{C} = \begin{bmatrix} \frac{1}{\beta_2} & -\frac{\beta_1}{\beta_2^2} \end{bmatrix}$$

De donde la varianza asintótica del cociente resulta:

$$AVar(\hat{\theta}) = \frac{1}{\beta_2^2} V_{11} - 2 \frac{\beta_1}{\beta_2^3} V_{12} + \frac{\beta_1^2}{\beta_2^4} V_{22}$$

Nótese que esta expresión se vuelve inestable cuando β_2 es cercano a cero, lo que anticipa el problema de los instrumentos débiles que discutimos en el capítulo de variables instrumentales: ahí el estimador es precisamente un cociente cuyo denominador puede ser pequeño.

A.6. Relación entre los modos de convergencia

Para cerrar conviene ordenar los conceptos introducidos. Entre los modos de convergencia que hemos definido existen las siguientes implicaciones, y ninguna de las recíprocas es cierta en general:

convergencia casi segura $\implies$ convergencia en probabilidad $\implies$ convergencia en distribución

La distinción práctica más relevante para nuestros propósitos es la primera implicación de derecha a izquierda que *no* se cumple: una sucesión puede converger en distribución sin converger en probabilidad a nada. El caso típico es $\sqrt{N}(\hat{\theta} - \theta)$, que converge en distribución a una normal pero no converge en probabilidad a ninguna constante — su dispersión no desaparece, precisamente porque el escalamiento por $\sqrt{N}$ está diseñado para que no lo haga. Es $\hat{\theta}$ sin escalar el que converge en probabilidad a θ .

Vale la pena señalar también que estos resultados son **asintóticos** y no dicen nada sobre el comportamiento en muestras finitas. Que un estimador sea consistente y asintóticamente normal no garantiza que con $N = 40$ su distribución se parezca a una normal ni que su sesgo sea pequeño. Determinar qué tan grande debe ser la muestra para que la aproximación sea razonable es una pregunta empírica que se responde, cuando es posible, mediante simulación.

A.7. Estimadores y estadísticas de prueba

Definición A.7 Sea $\{\hat{\theta}_N : N = 1, 2, \dots\}$ una sucesión de estimadores dados y acomodados en un vector $P \times 1$. Sea $\theta \in \Theta$, donde N indexa el tamaño de

la muestra. Si $\hat{\boldsymbol{\theta}} \xrightarrow{P} \boldsymbol{\theta}$ para cualquier valor de $\boldsymbol{\theta}$, entonces decimos que $\hat{\boldsymbol{\theta}}_N$ es un estimador consistente de $\boldsymbol{\theta}$.

Definición A.8 Sea $\{\hat{\boldsymbol{\theta}}_N : N = 1, 2, \dots\}$ una sucesión de estimadores dados y acomodados en un vector $P \times 1$. Sea $\boldsymbol{\theta} \in \boldsymbol{\Theta}$, donde N indexa el tamaño de la muestra. Asumamos que:

$$\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{V})$$

Donde $\mathbf{V}$ es una matriz semidefinida positiva de dimensión $P \times P$. Entonces, decimos que $\hat{\boldsymbol{\theta}}_N$ es $\sqrt{N}$ - asintóticamente distribuida de forma normal y $\mathbf{V}$ es la varianza asintótica de $\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})$ denotada como $\text{AVar}\sqrt{N}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) = \mathbf{V}$.

Teorema A.6 Supongamos que $\mathbf{V}$ es una matriz definida positiva. Entonces, para cualquier matriz no estocástica $\mathbf{R}$ de dimensión $Q \times P$, con $Q \leq P$ y $\text{Rango}(\mathbf{R}) = Q$, sucede que:

$$\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta}) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{RVR}')$$

y que:

$$[\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})]'[\mathbf{RVR}']^{-1}[\sqrt{N}\mathbf{R}(\hat{\boldsymbol{\theta}}_N - \boldsymbol{\theta})] \xrightarrow{d} \chi_Q^2$$

Este último teorema es el que sostiene todas las pruebas de hipótesis del curso: es el resultado que convierte la normalidad asintótica de un estimador en una estadística con distribución Chi cuadrada, y por lo tanto en una prueba con valores críticos tabulados. La matriz $\mathbf{R}$ recoge las restricciones que se quieren contrastar, y Q — su número de renglones — son los grados de libertad. El lector puede verificar que la prueba de Wald del capítulo de máxima verosimilitud, la prueba de Hausman del capítulo de datos panel y la prueba de sobreidentificación de Sargan-Hansen del capítulo de variables instrumentales son todas casos particulares de esta construcción.

A.8. Ejercicios

A continuación proponemos los siguientes ejercicios:

1. Determine si las siguientes afirmaciones son FALSAS o VERDADERAS, justificando su respuesta.

- a) Si una sucesión converge en distribución, entonces converge en probabilidad.
 - b) Si $\hat{\theta}$ es un estimador consistente de θ , entonces $g(\hat{\theta})$ es consistente para $g(\theta)$ para cualquier función continua g .
 - c) Si $\hat{\theta}$ es un estimador insesgado de θ , entonces $g(\hat{\theta})$ es insesgado para $g(\theta)$ para cualquier función continua g .
 - d) La sucesión $\sqrt{N}(\hat{\theta} - \theta)$ converge en probabilidad a cero.
 - e) El teorema de Slutsky se aplica igualmente si el límite de la sucesión $\mathbf{A}_N$ es una matriz aleatoria.
 - f) Que un estimador sea consistente y asintóticamente normal garantiza que en una muestra de 50 observaciones su distribución sea aproximadamente normal.
2. Sea $\{x_N\}$ una sucesión de variables aleatorias con $x_N \sim \text{Normal}(0, 1/N)$. Se le solicita:
- a) Demostrar que $x_N \xrightarrow{p} 0$ aplicando directamente la definición de convergencia en probabilidad.
 - b) Determinar a qué converge en distribución la sucesión $\sqrt{N} x_N$.
 - c) Explicar por qué el inciso anterior no contradice el primero, y relacionarlo con la discusión sobre los modos de convergencia.
3. Considere el estimador de MCO $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$. Se le solicita:
- a) Escribir $\sqrt{N}(\hat{\beta} - \beta)$ como el producto de un factor que converge en probabilidad y otro que converge en distribución, identificando explícitamente cada uno.
 - b) Indicar qué teorema del apéndice se aplica a cada factor y qué supuesto requiere.
 - c) Aplicar el teorema de Slutsky para obtener la varianza asintótica, y verificar que coincide con la que se deriva en el capítulo de MCO.
4. **Método delta.** Sea $\hat{\beta} = (\hat{\beta}_1, \hat{\beta}_2)'$ con $\sqrt{N}(\hat{\beta} - \beta) \xrightarrow{d} \text{Normal}(\mathbf{0}, \mathbf{V})$. Obtenga la varianza asintótica de las siguientes funciones, indicando en cada caso el jacobiano:

- a) $\theta = \exp(\beta_1)$, que es la forma que toma un cociente de riesgos en el modelo de duración.
- b) $\theta = \beta_1/\beta_2$, y explique en qué situación esta expresión se vuelve numéricamente inestable.
- c) $\theta = -\beta_1/(2\beta_2)$, que es el punto donde una relación cuadrática $\beta_1x + \beta_2x^2$ alcanza su máximo o mínimo.

5. **Simulación en Python.** Se le solicita verificar numéricamente el Teorema del Límite Central y la calidad de la aproximación asintótica:

- a) Genere $R = 10,000$ muestras de tamaño N de una distribución fuertemente asimétrica, por ejemplo una exponencial, y grafique el histograma de $\sqrt{N}(\bar{x} - \mu)$ para $N = 5, 25, 100, 500$.
- b) Superponga en cada caso la densidad normal correspondiente y evalúe visualmente a partir de qué tamaño de muestra la aproximación resulta aceptable.
- c) Repita el ejercicio con una distribución de Cauchy y explique por qué el resultado es distinto. ¿Cuál de los supuestos del teorema falla?
- d) Estime por simulación el sesgo de $\hat{\sigma}^2 = \sum_i (y_i - \hat{y}_i)^2/n$ del capítulo primero para distintos valores de n , y verifique que desaparece conforme n crece aun cuando el estimador sea sesgado en muestras finitas.